Modelo Híbrido de clasificación Multimodal de la Salud Mental basado en Deep Learning tabular y Machine Learning (clasificador ensemble)

2 Related Works

2.1 Métodos de Ensemble (Machine Learning) para la clasificación en salud mental

Los clasificadores de conjunto basados en **árboles** (**Machine Learning**) han sido objeto de numerosas investigaciones para la predicción de trastornos de **salud mental** a partir de datos estructurados de carácter clínico, demográfico y de encuestas. Liu et al. [8] compararon **RF, XGBoost y LightGBM** en una cohorte de 15,173 personas mayores para predecir **ansiedad, depresión y demencia**, y el modelo **LightGBM** alcanzó el AUC más alto (0,85) y demostró una precisión superior a la de los otros dos clasificadores. Del mismo modo, Ahammed et al. [18] aplicaron cinco algoritmos de **Machine Learning —entre ellos RF y XGBoost**— a datos de encuestas longitudinales del estudio australiano LSAC, y **RF** logró de forma consistente el mayor rendimiento en dos oleadas (precisión: 0,82; AUC: 0,89), identificando el aislamiento social, el acoso escolar y la adicción a las redes sociales como predictores claves. Asimismo, centrándose en una dimensión diferente de la **salud mental**, Niu et al. [19] emplearon **RF, XGBoost y LightGBM** para predecir el **riesgo de suicidio** en adolescentes a partir de 169 variables multimodales recopiladas en tríadas familiares (N = 21 858), logrando un AUROC constante de 0,875–0,877 y confirmando que la dificultad emocional era el predictor dominante. Por otra parte, Tariq et al. [20] ampliaron esta línea de trabajo al ámbito de la educación superior, utilizando **RF y XGBoost** (**Machine Learning**) para la clasificación del **estrés de los estudiantes** basada en encuestas y obteniendo una precisión de **RF** de 0,89, con un análisis SHAP que identificó la presión arterial, la calidad del sueño y las relaciones profesor-alumno como las características más influyentes.

2.2 Arquitecturas híbridas de Deep Learning para la evaluación psiquiátrica (salud mental)

Conscientes de las limitaciones de los modelos de modalidad única, trabajos recientes han explorado marcos **híbridos** que combinan extractores de características profundas con clasificadores de conjunto. Kanchapogu y Nandan Mohanty [4] propusieron un proceso híbrido que combina una **red neuronal convolucional (CNN)** para las características de series temporales de actigrafía con **XGBoost** para las variables demográficas, y señalaron una mejora en la clasificación de la **depresión bipolar y unipolar**. Del mismo modo, Saylam e İncel [10] desarrollaron un marco de aprendizaje multitarea para la predicción simultánea de **depresión, ansiedad y estrés (DAS)** a partir de biomarcadores digitales recopilados por dispositivos wearables, demostrando que **RF y XGBoost** alcanzaron rendimientos alineados tanto en la línea de base como en tareas múltiples, y que el aumento temporal mejoraba aún más los resultados. Asimismo, para la detección de **ansiedad y angustia** en pacientes cardíacos, Ebrahimi et al. [9] evaluaron nueve algoritmos de **Machine Learning** más dos estrategias de conjunto —apilamiento y votación— en el conjunto de datos ACQUIRE-ICD, con un clasificador de apilamiento que alcanzó un F1-macro de 0,93 para la **ansiedad**. De igual manera, en el ámbito de la evaluación basada en el habla, Zhang et al. [21] introdujeron el **Auto-Masked Audio Spectrogram Transformer (AMAST)** para la detección de la **depresión**, alcanzando puntuaciones F1 de 0,92 y 0,91 en dos conjuntos de datos de referencia. Por otra parte, más allá de los trastornos del estado de ánimo, Zulqarnain et al. [11] demostraron un marco híbrido **CNN-GRU** para la detección de la **esquizofrenia** basada en EEG que alcanzó una precisión del 98,41 %.