Diseño de un Sistema de Visión Computacional para el Pre-diagnóstico de Fenestración y Dehiscencia Ósea Alveolar a partir de Fotografías Intraorales y Tomografías CBCT

José Cabrera-Ticlla[1], Lucero Ayala-Mauricio[1] y Wilfredo Ticona[1,2]

[1] Universidad ESAN, Lima, Perú
22200150@ue.edu.pe, 22200171@ue.edu.pe, wmamani@esan.edu.pe
[2] Universidad Tecnológica del Perú, Lima, Perú
C19404@utp.edu.pe

Resumen La **fenestración** y la **dehiscencia ósea alveolar** son defectos frecuentes en los dientes anteriores que pueden terminar en recesión gingival y pérdida dental, y su diagnóstico depende de la **CBCT**, cuyo uso rutinario está limitado por la radiación y el tiempo que demanda. Este trabajo propone el diseño de un sistema de **visión computacional** para el pre-diagnóstico por diente de ambos defectos a partir de **fotografías intraorales y tomografías CBCT**. Sobre el dataset **FDTooth**, con una cohorte de 217 pacientes y 2604 dientes, se compararon tres metodologías: rasgos diseñados a mano con clasificadores de **Machine Learning**, ajuste fino de **ConvNeXt V2 Tiny** y representaciones del modelo fundacional **DINOv2** con clasificadores de **Machine Learning**. La evaluación usó validación cruzada agrupada por paciente y una prueba retenida de 43 pacientes evaluada una sola vez, con el *Macro-F1* como métrica principal. En la validación cruzada del conjunto de desarrollo, ninguna metodología superó 0.535 de *Macro-F1* con solo la fotografía, mientras que el ensamble de **ConvNeXt V2** y rasgos diseñados de la **CBCT** alcanzó 0.810 (IC 95 %: 0.793–0.826) y un AUC de 0.933. La **CBCT** resultó indispensable para distinguir ambos defectos. **[Resultado en la prueba retenida pendiente.]**

Palabras clave: **Fenestración** · **Dehiscencia** · **CBCT** · **Fotografía intraoral** · **Visión computacional** · **Deep Learning** · **Machine Learning**

Borrador. Problema Solución Dataset Del mismo modo, Asimismo, Por otra parte

1 Introducción

Las enfermedades bucodentales constituyen uno de los problemas de salud pública más extendidos del mundo y, en sus etapas avanzadas, conducen a la pérdida de piezas dentarias [1]. Entre las alteraciones del soporte óseo de los

dientes destacan la **fenestración** y la **dehiscencia ósea alveolar**: la primera es un defecto localizado del hueso alveolar que expone la raíz sin comprometer la cresta, mientras que la segunda es la pérdida del hueso que cubre la raíz y afecta al margen óseo [2]. Estos **defectos óseos alveolares** se asocian con exposición radicular, necrosis pulpar, recesión gingival, bolsas periodontales profundas y, en casos severos, pérdida del diente [2]; además, su presencia antes de un tratamiento ortodóntico puede agravar el daño periodontal, por lo que deben evaluarse antes de mover los dientes [3].

La Organización Mundial de la Salud (OMS) estima que cerca de 3700 millones de personas padecen enfermedades bucodentales y que la periodontopatía grave supera los 1000 millones de casos en el mundo; asimismo, la pérdida total de dientes afecta a cerca del 7 % de las personas de 20 años o más y al 23 % de las de 60 años o más [1]. En el caso específico de la **fenestración** y la **dehiscencia**, su frecuencia es elevada incluso en pacientes sin maloclusiones severas: Sun et al. analizaron mediante **tomografía computarizada de haz cónico (CBCT)** 732 dientes anteriores de 61 individuos Clase I y hallaron dehiscencia en el 27.46 % y fenestración en el 26.91 % de los dientes, con al menos un defecto en el 48.91 % de ellos y en la totalidad de los pacientes [3].

En América Latina y el Caribe, el Estudio de la Carga Global de la Enfermedad 2023 estimó 308.2 millones de casos prevalentes de trastornos bucales, que ocupan el primer lugar en prevalencia entre todas las causas de enfermedad de la región; dentro de ellos, la periodontitis severa fue el segundo trastorno más prevalente, con 87.2 millones de casos, y su discapacidad aumentó en 25 % o más desde 1990 en la mayoría de los países [4]. Del mismo modo, la evidencia epidemiológica de la región se concentra en Brasil, México, Chile y Colombia, mientras que los estudios de otros países son escasos [4].

En el Perú, el mismo estudio ubica al país con la segunda tasa más alta de años vividos con discapacidad por edentulismo en adultos de 60 años o más de la región (1366.9 por cada 100 000 habitantes), solo por debajo de Bolivia [4]. Dado que el edentulismo es el desenlace final de la enfermedad periodontal avanzada [1] y que la **fenestración** y la **dehiscencia** pueden terminar en la pérdida del diente [2], su detección oportuna resulta relevante para el país; sin embargo, la evidencia peruana sobre estos defectos es escasa [4].

La **CBCT** es la modalidad de imagen de elección para diagnosticar estos defectos, pero su uso rutinario en los controles es poco práctico por la exposición a radiación y el tiempo que demanda; por otra parte, la inspección visual de las **fotografías intraorales** es subjetiva, lenta y puede ser poco precisa [2]. Ante ello, la **inteligencia artificial (IA)** ha ganado participación en el diagnóstico odontológico: un metaanálisis reciente reportó, para la detección de periodontitis en radiografías, una sensibilidad agrupada de 0.93 y una especificidad de 0.88 a nivel de paciente [5], y los modelos de **visión computacional** ya permiten el cribado remoto de enfermedades bucales a partir de **imágenes intraorales** [6]. De igual manera, modelos de **Deep Learning** han detectado **fenestración y dehiscencia** directamente en cortes de **CBCT**, con exactitudes de 0.82 a 0.95 a nivel de diente [7]. Asimismo, la publicación del dataset **FDTooth**, que

reúne fotografías intraorales y CBCT de 241 pacientes, incluyó un modelo de referencia que detecta estos defectos solo a partir de fotografías, con un AUC de 0.76 y una especificidad de 0.65, sin distinguir entre fenestración y dehiscencia [2]. Estos resultados muestran el potencial de la IA, pero también la necesidad de aprovechar ambas modalidades de forma conjunta [2,5,7].

En este contexto, el presente trabajo propone el diseño de un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. Para ello, se comparan tres enfoques sobre el dataset **FDTooth**: rasgos diseñados a mano con **Machine Learning**, ajuste fino de una **red convolucional preentrenada** y representaciones de un **modelo fundacional** combinadas con clasificadores de **Machine Learning**.

2 Trabajos Relacionados

2.1 Machine Learning con rasgos diseñados a mano para el diagnóstico de lesiones óseas dentales

Los clasificadores de **Machine Learning** alimentados con rasgos cuantitativos de la imagen, como los radiómicos, de textura y de color, han sido ampliamente estudiados para el diagnóstico de **lesiones de los maxilares** en **CBCT**. Song et al. [8] extrajeron 348 rasgos radiómicos de las **CBCT** de 326 pacientes para diferenciar **ameloblastoma y queratoquiste odontogénico** con seis algoritmos, y **XGBoost** alcanzó una exactitud de 0.843, un F1 de 0.841 y un AUC de 0.872, con un desempeño superior al de los radiólogos. Del mismo modo, Sha et al. [9] integraron seis rasgos radiómicos de las **CBCT** de 300 pacientes en un clasificador por votación suave que combina **Random Forest, SVM y regresión logística**, y obtuvieron en el conjunto de prueba valores de AUC de 0.781 a 0.849 y una exactitud de 0.711 al distinguir tres tipos de **lesiones quísticas**. Asimismo, centrándose en pacientes con **periodontitis**, Zhang et al. [10] emplearon 206 rasgos radiómicos de **CBCT**, y el modelo **Random Forest** logró un AUC de 0.710 para detectar aterosclerosis carotídea concomitante. Por otra parte, Rashid y Dudley [11] transformaron mediciones de color **CIELAB** de 300 dientes extraídos en rasgos diseñados para clasificar la severidad de la **caries oclusal**, y observaron que los modelos basados en árboles (**Random Forest, XGBoost y CatBoost**) rindieron por debajo de las redes neuronales, que alcanzaron una exactitud balanceada de 0.89, y que apenas mejoraban con más datos de entrenamiento. En conjunto, estos trabajos muestran que los rasgos diseñados a mano son interpretables y eficaces con muestras moderadas, pero ninguno los aplicó a la **fenestración y dehiscencia** ni a **fotografías intraorales**.

2.2 Deep Learning para la evaluación del hueso alveolar en CBCT y fotografías intraorales

Conscientes de las limitaciones de los rasgos diseñados a mano, trabajos recientes han aplicado **Deep Learning** a la evaluación del **soporte óseo pe-**

riodontal. Tichy et al. [12] revisaron 29 estudios de Deep Learning para el diagnóstico de periodontitis y reportaron exactitudes de 81 a 99 % en radiografías panorámicas y de 78 % en CBCT, así como un AUROC de 0.93 en el cribado con fotografías, aunque advirtieron que la mayoría utilizó datos de un solo centro. Del mismo modo, Yang et al. [13] entrenaron una 3D-ResNet con 505 CBCT para clasificar la pérdida ósea horizontal de los primeros molares inferiores y alcanzaron una exactitud global de 0.829, comparable a la de los odontólogos (0.820). Asimismo, Palkovics et al. [14] utilizaron una SegResNet para segmentar en CBCT los defectos periodontales infraóseos mandibulares, con mediciones lineales y volumétricas confiables frente a la segmentación semiautomática, mientras que Xu et al. [7] entrenaron un Swin UNETR con 10 752 cortes sagitales de CBCT para medir y detectar la fenestración y dehiscencia. Por otra parte, en el caso de las fotografías intraorales, Mao et al. [15] analizaron 26 estudios de detección de enfermedad periodontal y hallaron exactitudes de clasificación de 0.46 a 1.00, con solo 9 estudios que usaron más de una vista. De igual manera, Li et al. [16] compararon seis redes convolucionales entrenadas con fotografías intraorales frontales de 826 pacientes, usando como referencia mediciones derivadas de CBCT, y ResNet-18 alcanzó una exactitud de 90.62 % en un conjunto de prueba externo para detectar la deficiencia transversal maxilar. Estos resultados confirman que un modelo basado en fotografías puede aprender de etiquetas obtenidas por CBCT, aunque el desempeño varía según la tarea y la vista utilizada.

2.3 Modelos fundacionales y fusión multimodal en el diagnóstico odontológico

Ante la escasez de datos etiquetados, los modelos fundacionales preentrenados de forma autosupervisada y la fusión multimodal se perfilan como alternativas al entrenamiento supervisado desde cero. Hu et al. [17] adaptaron DINOv2 mediante aprendizaje autosupervisado específico del dominio para segmentar radiografías periapicales con pocas anotaciones, y lograron un Dice de 74.77 % frente a 33.53–41.55 % de U-Net y DeepLabV3+, superando también a MAE, MoCo v3 y BEiT v3. Del mismo modo, Li et al. [18] preentrenaron y ajustaron el modelo HC-Net+ con 10 881 ortopantomografías para detectar periodontitis en estadios II a IV, superaron a los periodoncistas (AUROC de 94.2 % frente a 85.6 %) y mantuvieron una exactitud superior a 92.4 % en cuatro centros. Asimismo, Feng et al. [19] revisaron la fusión de datos multimodales en ortodoncia y concluyeron que integrar modalidades compensa las limitaciones de resolución y de especificidad tisular que presenta cada una por separado. Por otra parte, Chen et al. [6] señalaron que los modelos multimodales permiten integrar imágenes y datos clínicos en la vigilancia de la salud bucal. Sin embargo, el único trabajo que aborda la fenestración y dehiscencia con fotografías intraorales pareadas con CBCT, el de Liu et al. [2], empleó un ensamble de redes convolucionales supervisadas solo sobre la fotografía y en una tarea binaria. Hasta donde se conoce, no se ha evaluado un modelo fun-

dacional ni la **fusión** de ambas modalidades para distinguir por diente entre normal, **fenestración** y **dehiscencia**, vacío que aborda el presente trabajo.

3 Metodología

La Fig. 1 resume la metodología propuesta.

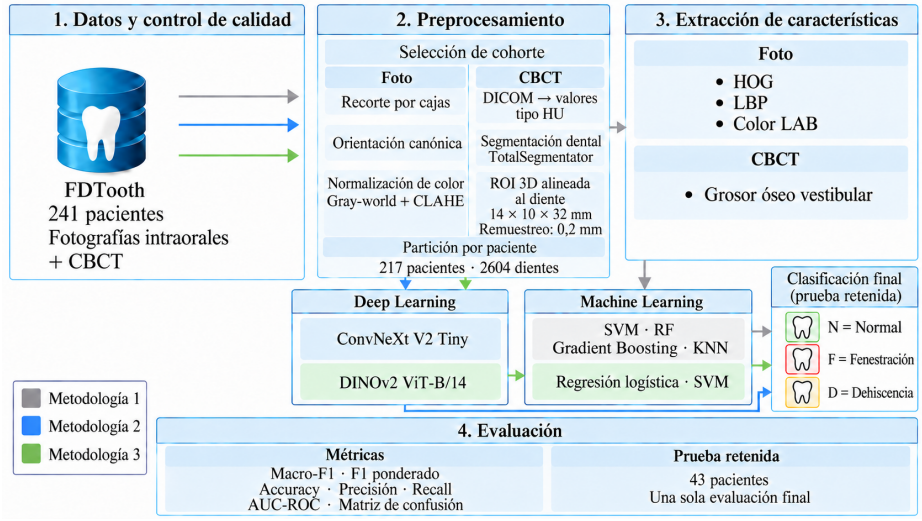


Figura 1. Metodología.

3.1 Datos y control de calidad

Se utilizó el dataset público **FDTooth** [2], recolectado entre enero de 2010 y enero de 2023 en dos centros de la Facultad de Odontología de la Universidad de Hong Kong. Para cada uno de sus 241 pacientes, de 9 a 55 años, el dataset incluye una **fotografía intraoral frontal** en formato JPEG de 5760×3840 píxeles y una **tomografía CBCT** en formato DICOM con un tamaño de vóxel de 0.15 a 0.18 mm. Cada uno de los 12 dientes anteriores tiene una etiqueta de referencia: normal (N), **fenestración** (F) o **dehiscencia** (D). Esta etiqueta proviene de la lectura de la **CBCT** por dos odontólogos experimentados, con una concordancia $\kappa > 0.9$ [2]. Antes del modelado, se verificó la integridad de los 487 archivos mediante sumas SHA256 y se contrastaron las etiquetas del archivo CSV con las del archivo JSON de anotaciones dentales. Se excluyeron 24 pacientes: 23 por discordancia entre ambas fuentes y uno por coordenadas de cajas incompatibles con la imagen. La cohorte apta quedó conformada por 217 pacientes y 2604 dientes.

3.2 Preprocesamiento

En la **fotografía intraoral**, cada diente se recortó a partir de su caja delimitadora, ampliada hacia la encía para incluir el margen gingival. El recorte se llevó a una orientación canónica y se redimensionó a 768 píxeles en su lado largo sin deformar la imagen. Luego se normalizó el color con el método **Gray-world**, que corrige el balance de blancos, y con **CLAHE**, que realza el contraste local. Asimismo, la **CBCT** se convirtió de DICOM a valores tipo unidades Hounsfield y se segmentó con **TotalSegmentator** [20], que identifica cada diente según la numeración FDI y logró segmentar 2600 de los 2604 dientes. A partir de cada segmentación se extrajo una región de interés (ROI) 3D de $14 \times 10 \times 32$ mm, alineada con el eje longitudinal del diente y remuestreada a vóxeles isotrópicos de 0.2 mm. Por último, la cohorte se particionó por paciente, de modo que todos los dientes de una persona pertenecen al mismo conjunto: el conjunto de desarrollo reúne 174 pacientes (2088 dientes) y el de prueba retenida, 43 pacientes (516 dientes).

3.3 Extracción de características

La metodología M1 representa cada diente con un vector de rasgos diseñados a mano. En la **fotografía**, el histograma de gradientes orientados (**HOG**), reducido con análisis de componentes principales, describe la forma del contorno gingival y la prominencia radicular. Del mismo modo, los patrones binarios locales uniformes (**LBP**) describen la textura de la superficie, y las estadísticas de color en el espacio **LAB** se calculan por separado para el diente y la encía. En la **CBCT**, se mide el perfil de **grosor óseo vestibular** a lo largo de la raíz. De este perfil se derivan la altura de la cresta ósea, las zonas sin hueso y el grosor medio, rasgos que reflejan directamente la diferencia entre una **dehiscencia**, que compromete el margen óseo, y una **fenestración**, que deja intacta la cresta. El vector final concatena estos rasgos con la posición del diente en la arcada.

3.4 Modelado y clasificación

Se compararon tres metodologías, todas con la misma salida por diente: N, F o D. En la M1, el vector de rasgos alimenta cuatro clasificadores de **Machine Learning**: **SVM** con kernel RBF, **Random Forest**, **Gradient Boosting** y **KNN**. La imputación y el escalado de los rasgos se ajustan solo con los datos de entrenamiento de cada partición. En la M2, se realiza el ajuste fino de la red convolucional preentrenada **ConvNeXt V2 Tiny** [21] con tres entradas alternativas: la **fotografía**, una representación 2.5D de la ROI de la **CBCT** y la fusión de ambas en una arquitectura de dos ramas. El entrenamiento emplea aumento de datos y parada temprana. Por otra parte, en la M3 el modelo fundacional **DINOv2 ViT-B/14** [22], ya aplicado con éxito a imágenes dentales [17], se usa como extractor congelado. Sus embeddings de la **fotografía** y de la **CBCT** se reducen con análisis de componentes principales y se clasifican con

regresión logística y **SVM** con kernel RBF. Por último, se evaluó un ensamble que combina las predicciones de M2 con **fusión**, M2 con **CBCT** y M1 con **CBCT**.

3.5 Evaluación

En el conjunto de desarrollo se aplicó una validación cruzada de cinco particiones externas agrupadas por paciente. Dentro de cada partición de entrenamiento, una validación interna selecciona los hiperparámetros, y las predicciones fuera de partición (OOF) permiten comparar las configuraciones sin usar el conjunto de prueba. El desempeño se mide con *Macro-F1*, F1 ponderado, exactitud (*accuracy*), precisión, sensibilidad (*recall*), AUC-ROC uno contra el resto y la matriz de confusión. La métrica principal es el *Macro-F1*, porque pondera por igual las tres clases y no premia a un modelo que solo acierta la clase mayoritaria. Los intervalos de confianza del 95 % y las diferencias entre modelos se estimaron mediante *bootstrap* de pacientes con 1000 a 2000 remuestreos. Finalmente, la mejor configuración de cada metodología se reentrena con todo el conjunto de desarrollo y se evalúa una sola vez en la prueba retenida de 43 pacientes (516 dientes).

4 Resultados

Los resultados corresponden a las predicciones fuera de partición del conjunto de desarrollo, que reúne 174 pacientes y 2088 dientes: 938 normales, 663 con **fenestración** y 487 con **dehiscencia**. Los intervalos de confianza (IC) del 95 % se estimaron por remuestreo *bootstrap* de pacientes. **[Resultados en la prueba retenida pendientes.]**

4.1 Comparación por metodología y modalidad

La Tabla 1 resume el mejor modelo de cada metodología según la modalidad de entrada. Con solo la **fotografía intraoral**, ninguna metodología superó un *Macro-F1* de 0.535, valor cercano al del enfoque de referencia basado solo en fotografías (0.55). En cambio, al incorporar la **CBCT** el desempeño subió a un rango de 0.621 a 0.789, y **ConvNeXt V2 Tiny** con ajuste fino (M2) obtuvo los mejores valores en la **CBCT** (0.789) y en la **fusión** (0.796). El ensamble de M2 con **fusión**, M2 con **CBCT** y M1 con **CBCT** alcanzó el mejor resultado global, con un *Macro-F1* de 0.810.

4.2 Desempeño de los modelos principales

La Tabla 2 detalla las métricas de los modelos principales. El ensamble obtuvo un *Macro-F1* de 0.810 (IC 95 %: 0.793–0.826), una exactitud de 0.816 y un AUC de 0.933, con valores de F1 equilibrados entre las tres clases: 0.852 para normal, 0.784 para **fenestración** y 0.793 para **dehiscencia**. Asimismo, su sensibilidad

Tabla 1. *Macro-F1* del mejor modelo de cada metodología por modalidad (conjunto de desarrollo).

Modalidad	Referencia[a]	M1 rasgos	M3 DINOv2	M2 ConvNeXt V2
Fotografía	0.55	0.535	0.510	0.534
CBCT	–	0.741	0.621	0.789
Fusión	–	0.715	0.598	0.796
Ensamble (M2 fusión + M2 CBCT + M1 CBCT)				**0.810**

[a] Enfoque del antecedente [2], basado solo en fotografías, en la tarea de tres clases.

fue de 0.832, 0.805 y 0.801, y su precisión de 0.873, 0.764 y 0.786 para las clases N, F y D, respectivamente. Entre los modelos individuales, M2 con **fusión** (0.796) y M2 con **CBCT** (0.789) superaron a **Random Forest** con rasgos de la **CBCT** (0.741), mientras que **DINOv2** con **regresión logística** no pasó de 0.621.

Tabla 2. Métricas de los modelos principales (conjunto de desarrollo). El AUC es el promedio macro uno contra el resto.

Modelo	Modalidad	Macro-F1 [IC 95 %]	F1 pond.	Exact.	AUC	F1 N	F1 F	F1 D
Ensamble	Fusión	**0.810** [0.793, 0.826]	0.817	0.816	0.933	0.852	0.784	0.793
M2 ConvNeXt V2	Fusión	0.796 [0.778, 0.814]	0.803	0.801	0.921	0.838	0.765	0.786
M2 ConvNeXt V2	CBCT	0.789 [0.770, 0.805]	0.795	0.795	0.909	0.832	0.758	0.776
M2 ConvNeXt V2	Foto	0.534 [0.506, 0.561]	0.542	0.540	0.724	0.590	0.490	0.523
M1 Random Forest	CBCT	0.741 [0.715, 0.763]	0.751	0.750	0.889	0.807	0.699	0.715
M1 Random Forest	Fusión	0.715 [0.691, 0.740]	0.729	0.728	0.878	0.789	0.684	0.673
M1 Random Forest	Foto	0.535 [0.505, 0.562]	0.544	0.541	0.723	0.599	0.479	0.526
M3 DINOv2 + RL	CBCT	0.621 [0.596, 0.645]	0.632	0.630	0.804	0.685	0.583	0.596
M3 DINOv2 + SVM	Fusión	0.598 [0.571, 0.625]	0.612	0.613	0.797	0.675	0.563	0.557
M3 DINOv2 + SVM	Foto	0.510 [0.480, 0.540]	0.528	0.532	0.718	0.622	0.432	0.477

RL: regresión logística. Exact.: exactitud. F1 pond.: F1 ponderado.

4.3 Análisis de errores

La Tabla 3 compara las matrices de confusión del ensamble y de M1 con **CBCT**. En el ensamble, el error más frecuente fue clasificar dientes normales como **fenestración** (111 casos), mientras que la confusión entre **fenestración** y **dehiscencia** se redujo de 107 a 59 dientes en el sentido F→D y de 60 a 54 en el sentido D→F con respecto a M1. Del mismo modo, al agrupar ambos defectos en una sola clase patológica, M2 con **fusión** alcanzó una sensibilidad de 0.927, una especificidad de 0.774, una exactitud de 0.858 y un AUC de 0.925, y entre los dientes patológicos distinguió la **fenestración** de la **dehiscencia** con una exactitud de 0.873.

Tabla 3. Matrices de confusión en el conjunto de desarrollo (filas: clase real; columnas: clase predicha).

	Ensamble			M1 RF (CBCT)		
Real	N	F	D	N	F	D
N (938)	780	111	47	740	142	56
F (663)	70	534	59	91	465	107
D (487)	43	54	390	65	60	362

4.4 Comparaciones estadísticas

La diferencia de *Macro-F1* entre M2 con **fusión** y M1 con **CBCT** fue de +0.056 (IC 95 %: +0.031 a +0.080), por lo que el ajuste fino superó de forma significativa a los rasgos diseñados a mano. En cambio, la ventaja de la **fusión** sobre la **CBCT** sola dentro de M2 fue de +0.008, con un intervalo que incluye el cero, y por tanto no fue significativa. Por último, el ensamble superó a M2 con **fusión** por +0.014 (IC 95 %: +0.002 a +0.025), una mejora pequeña pero significativa.

4.5 Discusión

El principal hallazgo es que la **CBCT** determina el desempeño: con solo la **fotografía** ninguna metodología superó 0.535 de *Macro-F1*, lo que concuerda con el desempeño moderado que reportó el antecedente al usar solo fotografías [2]. Esto sugiere que la fotografía muestra signos indirectos de los defectos, como el contorno gingival, pero no basta para distinguir con fiabilidad entre **fenestración** y **dehiscencia**. Asimismo, el ajuste fino de **ConvNeXt V2** superó a los rasgos diseñados a mano, en línea con la ventaja de las redes neuronales sobre los modelos basados en árboles observada en otros problemas dentales [11]. Por otra parte, **DINOv2** congelado tuvo el peor desempeño con la **CBCT**. A diferencia del trabajo de Hu et al. [17], que adaptó **DINOv2** al dominio dental antes de usarlo, en este estudio sus representaciones, aprendidas con imágenes naturales, se usaron sin ajuste, lo que explicaría su menor rendimiento en cortes tomográficos. De igual manera, la **fusión** aportó una mejora marginal y no significativa sobre la **CBCT** sola, por lo que la complementariedad entre modalidades que describe la literatura [19] no se tradujo aquí en una ganancia clara. La principal limitación es que estos resultados provienen de la validación cruzada del conjunto de desarrollo de un único dataset, recolectado en una sola institución, por lo que falta confirmarlos en la prueba retenida y en datos externos.

5 Conclusiones

Este trabajo diseñó un sistema de **visión computacional** para el pre-diagnóstico por diente de **fenestración y dehiscencia ósea alveolar** a partir

de **fotografías intraorales y tomografías CBCT**, y comparó tres metodologías sobre el dataset **FDTooth**. En la validación cruzada del conjunto de desarrollo, el ensamble basado en el ajuste fino de **ConvNeXt V2** y en rasgos diseñados a mano de la **CBCT** alcanzó un *Macro-F1* de 0.810 y un AUC de 0.933, con un desempeño equilibrado en las tres clases. Los resultados muestran que la **CBCT** es indispensable para separar ambos defectos, que el ajuste fino supera de forma significativa a los rasgos diseñados a mano y que un modelo fundacional congelado no se adapta bien a las imágenes tomográficas. **[Conclusión sobre la prueba retenida pendiente.]**

Como trabajo futuro, se propone evaluar el sistema en datos de otras instituciones, adaptar **DINOv2** al dominio de la **CBCT** mediante aprendizaje autosupervisado y explorar estrategias de fusión que aprovechen mejor la información de la **fotografía intraoral**.

Referencias

1. Organización Mundial de la Salud: Salud bucodental (oral health): nota descriptiva. `https://www.who.int/news-room/fact-sheets/detail/oral-health` (2025), publicada el 17 de marzo de 2025. Accedido: 14 de octubre de 2026
2. Liu, K., Elbatel, M., Chu, G., Shan, Z., Sum, F.H.K.M.H., Hung, K.F., Zhang, C., Li, X., Yang, Y.: FDTooth: Intraoral photographs and CBCT images for fenestration and dehiscence detection. Scientific Data **12**, 1007 (2025). `https://doi.org/10.1038/s41597-025-05348-3`
3. Sun, L., Mu, C., Chen, L., Zhao, B., Pan, J., Liu, Y.: Dehiscence and fenestration of class I individuals with normality patterns in the anterior region: a CBCT study. Clinical Oral Investigations **26**(5), 4137–4145 (2022). `https://doi.org/10.1007/s00784-022-04384-2`
4. GBD 2023 Latin America and Caribbean Oral Disorders Collaborators: The burden of oral disorders in Latin America and Caribbean countries from 1990 to 2023 and projections until 2050: a systematic analysis for the Global Burden of Disease Study 2023. The Lancet Regional Health – Americas **60**, 101517 (2026). `https://doi.org/10.1016/j.lana.2026.101517`
5. Zhang, X., Liu, Z., Zhang, Y., An, X.: Artificial intelligence for detection of periodontitis on radiographic images: a systematic review and diagnostic test accuracy meta-analysis. Journal of Dentistry p. 107054 (2026). `https://doi.org/10.1016/j.jdent.2026.107054`
6. Chen, Z., Liu, P., Han, K., Liao, P., Yang, Y., Wong, M.C.M., Yiu, C.K.Y., Lo, E.C.M.: AI in oral health surveillance: critical review. Journal of Dental Research **105**(7), 840–852 (2026). `https://doi.org/10.1177/00220345261434568`
7. Xu, A., Huang, H., Zhang, B., Dong, S., Che, X.: Using Swin UNETR deep model for automated detection of alveolar bone fenestration/dehiscence in CBCT. Frontiers in Bioengineering and Biotechnology **14**, 1752350 (2026). `https://doi.org/10.3389/fbioe.2026.1752350`
8. Song, Y., Ma, S., Mao, B., Xu, K., Liu, Y., Ma, J., Jia, J.: Application of machine learning in the preoperative radiomic diagnosis of ameloblastoma and odontogenic keratocyst based on cone-beam CT. Dentomaxillofacial Radiology **53**(5), 316–324 (2024). `https://doi.org/10.1093/dmfr/twae016`

9. Sha, X., Wang, C., Sun, J., Qi, S., Yuan, X., Zhang, H., Yang, J.: CBCT radiomics features combine machine learning to diagnose cystic lesions in the jaw. Dentomaxillofacial Radiology **54**(5), 381–388 (2025). https://doi.org/10.1093/dmfr/twaf024
10. Zhang, M., Cai, J., Cao, Q., Chen, Z., Maimaitiaili, S., Yuan, S., Yang, T., Li, Z., Zhang, Z., Yang, Y., et al.: Radiomic features and carotid stenosis in periodontitis a two stage bootstrap and multimodal machine learning study. Scientific Reports **16**(1), 8177 (2026). https://doi.org/10.1038/s41598-026-38463-1
11. Rashid, F., Dudley, J.: Classification of occlusal caries severity using spectrophotometric CIELAB measurements and machine learning algorithms. Clinical Oral Investigations **30**(6), 233 (2026). https://doi.org/10.1007/s00784-026-06911-x
12. Tichy, A., Werner, N., Dujic, H., Wetzel, C., Pitchika, V., Bumm, C.V., Folwaczny, M., Schwendicke, F.: Artificial intelligence in periodontology: a systematic review. Journal of Periodontal Research **61**(6), 639–661 (2026). https://doi.org/10.1111/jre.70107
13. Yang, Y., Jin, E., Bian, Z., Chen, Y., Chen, X., Wu, Y., Tan, J.: The application of deep learning in intelligent assessment of horizontal bone loss in mandibular first molars. Clinical Oral Investigations **30**(10), 470 (2026). https://doi.org/10.1007/s00784-026-07180-4
14. Palkovics, D., Molnar, B., Pinter, C., García-Mato, D., Diaz-Pinto, A., Tanacs, A., Dobos, A., Windisch, P., Ramseier, C.A.: Deep learning cone-beam computed tomography image segmentation for the 3D visualization of mandibular infraosseous periodontal defects. Journal of Periodontology **97**(9), 1847–1859 (2026). https://doi.org/10.1002/jper.70058
15. Mao, K., Thu, K.M., Hung, K.F., Yu, O.Y., Hsung, R.T., Lam, W.Y.: Artificial intelligence in detecting periodontal disease from intraoral photographs: A systematic review. International Dental Journal **75**(5), 100883 (2025). https://doi.org/10.1016/j.identj.2025.100883
16. Li, J., Wang, R., Yi, Z., Ni, J., Zuo, Z., Wang, Y.: Comparing deep learning models for identifying maxillary transverse deficiency from intraoral photographs. International Dental Journal **76**(4), 109689 (2026). https://doi.org/10.1016/j.identj.2026.109689
17. Hu, M., Zhang, Q., Wei, Z., Jia, P., Yuan, M., Yu, H., Yin, X., Peng, J.: Self-supervised learning enhances periapical films segmentation with limited labeled data. Journal of Dentistry **163**, 106150 (2025). https://doi.org/10.1016/j.jdent.2025.106150
18. Li, Y., Cui, Z., Mei, L., Xie, Y., Marini, L., Pelekos, G., Gu, W., Yu, X., Wu, X., Wei, X., et al.: A novel AI-powered radiographic analysis surpasses specialists in stage II–IV periodontitis detection: a multicenter diagnostic study. npj Digital Medicine **8**(1), 691 (2025). https://doi.org/10.1038/s41746-025-02077-0
19. Feng, Y., Jia, Y., Lv, L., Wei, X., Hu, M.: Progress of multimodal imaging: Bridging orthodontics to comprehensive oral multidisciplinary care. International Dental Journal **76**(3), 109510 (2026). https://doi.org/10.1016/j.identj.2026.109510
20. Wasserthal, J., Breit, H.C., Meyer, M.T., Pradella, M., Hinck, D., Sauter, A.W., Heye, T., Boll, D.T., Cyriac, J., Yang, S., Bach, M., Segeroth, M.: TotalSegmentator: Robust segmentation of 104 anatomic structures in CT images. Radiology: Artificial Intelligence **5**(5), e230024 (2023). https://doi.org/10.1148/ryai.230024
21. Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I.S., Xie, S.: ConvNeXt V2: Co-designing and scaling ConvNets with masked autoencoders. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). pp. 16133–16142 (2023). https://doi.org/10.1109/CVPR52729.2023.01548

22. Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., et al.: DINOv2: Learning robust visual features without supervision. arXiv:2304.07193 (2023)