Diseño de un Sistema de Visión Computacional para el Pre-diagnóstico de Fenestración y Dehiscencia Ósea Alveolar a partir de Fotografías Intraorales y Tomografías CBCT

José Cabrera-Ticlla[1], Lucero Ayala-Mauricio[1] y Wilfredo Ticona[1,2]

[1] Universidad ESAN, Lima, Perú
22200150@ue.edu.pe, 22200171@ue.edu.pe, wmamani@esan.edu.pe
[2] Universidad Tecnológica del Perú, Lima, Perú
C19404@utp.edu.pe

Resumen La **fenestración** y la **dehiscencia ósea alveolar** son defectos frecuentes en los dientes anteriores, cuyo diagnóstico depende de la **CBCT**. Este trabajo propone el diseño de un sistema de **visión computacional** para su pre-diagnóstico por diente a partir de **fotografías intraorales y tomografías CBCT**. Sobre el dataset **FDTooth** (217 pacientes y 2604 dientes) se compararon rasgos diseñados a mano con **Machine Learning** (M1), ajuste fino de **ConvNeXt V2 Tiny** (M2) y el modelo fundacional **DINOv2** congelado con clasificadores (M3), elegidos por validación cruzada agrupada por paciente y evaluados una sola vez en una prueba retenida de 43 pacientes. Con solo la fotografía, ningún modelo superó 0.551 de *Macro-F1*, mientras que el ensamble de M2 y M1 con la **CBCT** obtuvo 0.842 (IC 95 %: 0.783–0.891), un AUC de 0.940 y una sensibilidad de 0.979 para detectar dientes con algún defecto. La **CBCT** resultó indispensable, y el ajuste fino superó de forma significativa a los rasgos diseñados y al modelo fundacional congelado.

Palabras clave: **Fenestración** · **Dehiscencia** · **CBCT** · **Fotografía intraoral** · **Visión computacional** · **Deep Learning** · **Machine Learning**

Borrador. Problema Solución Dataset Del mismo modo, Asimismo, Por otra parte

1 Introducción

Las enfermedades bucodentales son uno de los problemas de salud pública más extendidos del mundo: la Organización Mundial de la Salud (OMS) estima que afectan a cerca de 3700 millones de personas y que la periodontopatía grave supera los 1000 millones de casos [1]. Entre las alteraciones del soporte óseo de los dientes destacan la **fenestración**, un defecto localizado del hueso alveolar que expone la raíz sin comprometer la cresta, y la **dehiscencia**, que es la pérdida del hueso que cubre la raíz y afecta al margen óseo. Ambas se asocian con recesión

gingival, bolsas periodontales profundas y, en casos severos, pérdida del diente [2]. Su frecuencia es elevada incluso sin maloclusiones severas: en 732 dientes anteriores evaluados con **tomografía computarizada de haz cónico (CBCT)**, Sun et al. hallaron dehiscencia en el 27.46 % y fenestración en el 26.91 %, con al menos un defecto en todos los pacientes; además, deben evaluarse antes de un tratamiento ortodóntico, porque el movimiento dental puede agravarlas [3].

En América Latina y el Caribe, los trastornos bucales ocupan el primer lugar en prevalencia entre todas las causas de enfermedad, con 308.2 millones de casos en 2023, de los cuales 87.2 millones corresponden a periodontitis severa [4]. Del mismo modo, el Perú presenta la segunda tasa más alta de la región de años vividos con discapacidad por edentulismo en adultos de 60 años o más (1366.9 por cada 100 000 habitantes), desenlace final de la enfermedad periodontal avanzada, mientras que la evidencia peruana sobre estos defectos es escasa [4].

La **CBCT** es la modalidad de elección para diagnosticar estos defectos, pero su uso rutinario es poco práctico por la radiación y el tiempo que demanda, y la inspección visual de las **fotografías intraorales** es subjetiva [2]. Ante ello, la **inteligencia artificial (IA)** ha ganado terreno en el diagnóstico odontológico: un metaanálisis reportó, para la detección de periodontitis en radiografías, una sensibilidad agrupada de 0.93 y una especificidad de 0.88 [5], y la **visión computacional** ya permite el cribado remoto de enfermedades bucales a partir de **imágenes intraorales** [6]. Asimismo, modelos de **Deep Learning** han detectado la **fenestración y dehiscencia** en cortes de **CBCT** con exactitudes de 0.82 a 0.95 [7], y la publicación del dataset **FDTooth**, con fotografías y CBCT de 241 pacientes, incluyó un modelo que detecta estos defectos solo a partir de fotografías, con un AUC de 0.76 y sin distinguir entre ellos [2].

En este contexto, el presente trabajo propone el diseño de un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. Para ello, se comparan sobre **FDTooth** tres metodologías: rasgos diseñados a mano con **Machine Learning**, ajuste fino de una **red convolucional preentrenada** y representaciones de un **modelo fundacional** con clasificadores de **Machine Learning**, con la **fotografía**, la **CBCT** y su **fusión** como entradas, y con una prueba retenida por paciente que se evalúa una sola vez.

2 Trabajos Relacionados

2.1 Machine Learning con rasgos diseñados a mano para el diagnóstico de lesiones óseas dentales

Los clasificadores de **Machine Learning** alimentados con rasgos cuantitativos de la imagen, como los radiómicos, de textura y de color, han sido ampliamente estudiados para el diagnóstico de **lesiones de los maxilares** en **CBCT**. Song et al. [8] extrajeron 348 rasgos radiómicos de las **CBCT** de 326 pacientes para diferenciar **ameloblastoma y queratoquiste odontogénico** con seis

algoritmos, y **XGBoost** alcanzó una exactitud de 0.843, un F1 de 0.841 y un AUC de 0.872, con un desempeño superior al de los radiólogos. Del mismo modo, Sha et al. [9] integraron seis rasgos radiómicos de las **CBCT** de 300 pacientes en un clasificador por votación suave que combina **Random Forest, SVM y regresión logística**, y obtuvieron en el conjunto de prueba valores de AUC de 0.781 a 0.849 y una exactitud de 0.711 al distinguir tres tipos de **lesiones quísticas**. Asimismo, centrándose en pacientes con **periodontitis**, Zhang et al. [10] emplearon 206 rasgos radiómicos de **CBCT**, y el modelo **Random Forest** logró un AUC de 0.710 para detectar aterosclerosis carotídea concomitante. Por otra parte, Rashid y Dudley [11] transformaron mediciones de color **CIELAB** de 300 dientes extraídos en rasgos diseñados para clasificar la severidad de la **caries oclusal**, y observaron que los modelos basados en árboles (**Random Forest, XGBoost y CatBoost**) rindieron por debajo de las redes neuronales, que alcanzaron una exactitud balanceada de 0.89, y que apenas mejoraban con más datos de entrenamiento. En conjunto, estos trabajos muestran que los rasgos diseñados a mano son interpretables y eficaces con muestras moderadas, pero ninguno los aplicó a la **fenestración y dehiscencia** ni a **fotografías intraorales**.

2.2 Deep Learning para la evaluación del hueso alveolar en CBCT y fotografías intraorales

Conscientes de las limitaciones de los rasgos diseñados a mano, trabajos recientes han aplicado **Deep Learning** a la evaluación del **soporte óseo periodontal**. Tichy et al. [12] revisaron 29 estudios de **Deep Learning** para el diagnóstico de **periodontitis** y reportaron exactitudes de 81 a 99 % en radiografías panorámicas y de 78 % en **CBCT**, así como un AUROC de 0.93 en el cribado con **fotografías**, aunque advirtieron que la mayoría utilizó datos de un solo centro. Del mismo modo, Yang et al. [13] entrenaron una **3D-ResNet** con 505 **CBCT** para clasificar la **pérdida ósea horizontal** de los primeros molares inferiores y alcanzaron una exactitud global de 0.829, comparable a la de los odontólogos (0.820). Asimismo, Palkovics et al. [14] utilizaron una **SegResNet** para segmentar en **CBCT** los **defectos periodontales infraóseos** mandibulares, con mediciones lineales y volumétricas confiables frente a la segmentación semiautomática, mientras que Xu et al. [7] entrenaron un **Swin UNETR** con 10 752 cortes sagitales de **CBCT** para medir y detectar la **fenestración y dehiscencia**. Por otra parte, en el caso de las **fotografías intraorales**, Mao et al. [15] analizaron 26 estudios de detección de **enfermedad periodontal** y hallaron exactitudes de clasificación de 0.46 a 1.00, con solo 9 estudios que usaron más de una vista. De igual manera, Li et al. [16] compararon seis **redes convolucionales** entrenadas con **fotografías intraorales frontales** de 826 pacientes, usando como referencia mediciones derivadas de **CBCT**, y **ResNet-18** alcanzó una exactitud de 90.62 % en un conjunto de prueba externo para detectar la **deficiencia transversal maxilar**. Estos resultados confirman que un modelo basado en fotografías puede aprender de etiquetas obtenidas por **CBCT**, aunque el desempeño varía según la tarea y la vista utilizada.

2.3 Modelos fundacionales y fusión multimodal en el diagnóstico odontológico

Ante la escasez de datos etiquetados, los **modelos fundacionales** preentrenados de forma autosupervisada y la **fusión multimodal** se perfilan como alternativas al entrenamiento supervisado desde cero. Hu et al. [17] adaptaron **DINOv2** mediante aprendizaje autosupervisado específico del dominio para segmentar **radiografías periapicales** con pocas anotaciones, y lograron un Dice de 74.77 % frente a 33.53–41.55 % de U-Net y DeepLabV3+, superando también a MAE, MoCo v3 y BEiT v3. Del mismo modo, Li et al. [18] preentrenaron y ajustaron el modelo **HC-Net+** con 10 881 **ortopantomografías** para detectar **periodontitis** en estadios II a IV, superaron a los periodoncistas (AUROC de 94.2 % frente a 85.6 %) y mantuvieron una exactitud superior a 92.4 % en cuatro centros. Asimismo, Feng et al. [19] revisaron la **fusión de datos multimodales** en ortodoncia y concluyeron que integrar modalidades compensa las limitaciones de resolución y de especificidad tisular que presenta cada una por separado. Por otra parte, Chen et al. [6] señalaron que los modelos multimodales permiten integrar imágenes y datos clínicos en la vigilancia de la salud bucal. Sin embargo, el único trabajo que aborda la **fenestración y dehiscencia** con **fotografías intraorales** pareadas con **CBCT**, el de Liu et al. [2], empleó un ensamble de **redes convolucionales** supervisadas solo sobre la fotografía y en una tarea binaria. Hasta donde se conoce, no se ha evaluado un **modelo fundacional** ni la **fusión** de ambas modalidades para distinguir por diente entre normal, **fenestración** y **dehiscencia**, vacío que aborda el presente trabajo.

3 Metodología

La Fig. 1 resume la metodología propuesta.

3.1 Datos y control de calidad

Se utilizó el dataset público **FDTooth** [2], recolectado en la Facultad de Odontología de la Universidad de Hong Kong: 241 pacientes de 9 a 55 años, cada uno con una **fotografía intraoral frontal** de 5760×3840 píxeles y una **CBCT** con vóxeles de 0.15 a 0.18 mm. Cada uno de los 12 dientes anteriores está etiquetado como normal (N), **fenestración** (F) o **dehiscencia** (D) a partir de la lectura de la **CBCT** por dos odontólogos, con una concordancia $\kappa > 0.9$ [2]. Tras verificar la integridad de los 487 archivos con sumas SHA256 y contrastar las etiquetas del archivo CSV con las del archivo JSON, se excluyeron 24 pacientes: 23 por discordancia entre ambas fuentes y uno por coordenadas incompatibles con la imagen. La cohorte quedó conformada por 217 pacientes y 2604 dientes.

3.2 Preprocesamiento

En la **fotografía intraoral**, cada diente se recortó a partir de su caja delimitadora ampliada hacia la encía, se llevó a una orientación canónica, se redimensionó a 768 píxeles en su lado largo y se normalizó su color con **Gray-world** y

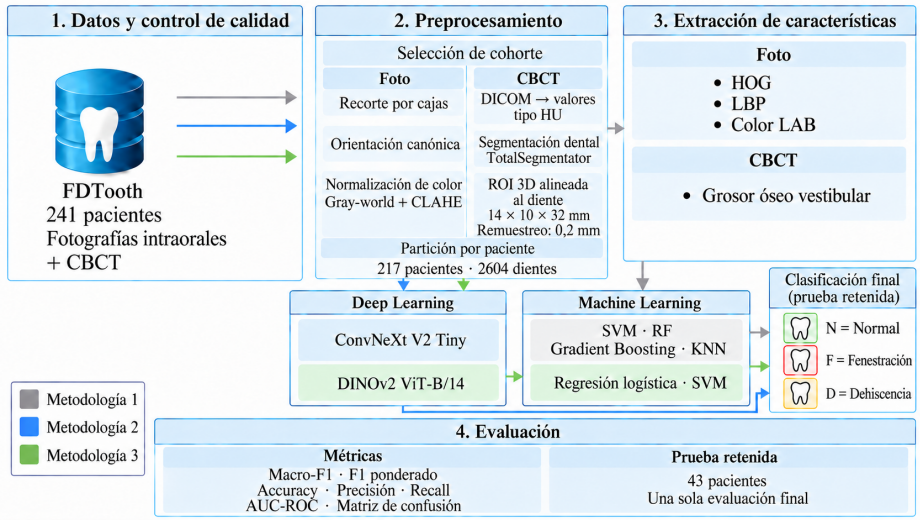


Figura 1. Metodología.

CLAHE. Asimismo, la **CBCT** se convirtió a valores tipo unidades Hounsfield (HU) y se segmentó con **TotalSegmentator** [20], que identificó 2600 de los 2604 dientes; de cada uno se extrajo una región de interés (ROI) 3D de $14 \times 10 \times 32$ mm alineada con su eje longitudinal y remuestreada a vóxeles de 0.2 mm. La cohorte se particionó por paciente en un conjunto de desarrollo de 174 pacientes y 2088 dientes (938 N, 663 F y 487 D) y una prueba retenida de 43 pacientes y 516 dientes (226 N, 169 F y 121 D).

3.3 Extracción de características

En la M1, la **fotografía** se describe con el histograma de gradientes orientados (**HOG**) reducido por análisis de componentes principales, patrones binarios locales (**LBP**) y estadísticas de color **LAB** del diente y de la encía. En la **CBCT**, se mide el perfil de **grosor óseo vestibular** a lo largo de la raíz con umbrales de 400, 700 y 1000 HU, del que se derivan la altura de la cresta, las zonas sin hueso y el grosor medio; estos rasgos reflejan la diferencia entre una **dehiscencia**, que compromete el margen óseo, y una **fenestración**, que deja intacta la cresta. El vector se completa con la longitud y el volumen del diente y su posición en la arcada.

3.4 Modelado y clasificación

Las tres metodologías producen la misma salida por diente: N, F o D. En la M1, los rasgos alimentan **SVM** con kernel RBF, **Random Forest**, **HistGradientBoosting** y **KNN**. En la M2, se ajusta de extremo a extremo **ConvNeXt**

V2 Tiny [21], preentrenada en ImageNet-22k, con la **fotografía**, una representación 2.5D de la ROI de la **CBCT** o la **fusión** de ambas en una arquitectura de dos ramas; el entrenamiento usa pérdida ponderada por clase, aumento de datos y aumento en inferencia (TTA), y en la prueba se promedian las probabilidades de tres semillas. Por otra parte, en la M3 el modelo fundacional **DINOv2 ViT-B/14** [22], ya aplicado a imágenes dentales [17], se usa como extractor congelado, y sus representaciones se reducen por análisis de componentes principales y se clasifican con **regresión logística** o **SVM**. Por último, entre quince variantes de ensamble evaluadas en desarrollo (promedio, *stacking*, contexto del paciente y umbrales), la mejor fue el promedio de probabilidades de M2 con **fusión**, M2 con **CBCT** y M1 con **CBCT**.

3.5 Evaluación

En el conjunto de desarrollo se aplicó una validación cruzada anidada de cinco particiones agrupadas por paciente: una validación interna eligió los hiperparámetros y las predicciones fuera de partición permitieron comparar y elegir los modelos. Como referencia, se replicó en las mismas particiones el enfoque del antecedente basado solo en fotografías [2], cuya mejor variante (**MobileNetV3-Small** con ajuste fino) obtuvo un *Macro-F1* de 0.548. Los modelos elegidos se reentrenaron con todo el conjunto de desarrollo y se evaluaron una sola vez en la prueba retenida. Se reportan *Macro-F1*, que es la métrica principal porque pondera por igual las tres clases, F1 ponderado, exactitud, precisión, sensibilidad, AUC-ROC uno contra el resto y la matriz de confusión. Los intervalos de confianza (IC) del 95 % y las diferencias entre modelos se estimaron por *bootstrap* pareado de pacientes con 2000 remuestreos.

4 Resultados

4.1 Comparación por metodología y modalidad

La Fig. 2 compara el *Macro-F1* de cada metodología según la modalidad de entrada. Con solo la **fotografía intraoral**, ninguna metodología superó 0.535 en desarrollo ni 0.551 en la prueba, valores cercanos al del antecedente replicado (0.548). En cambio, con la **CBCT** el desempeño subió a un rango de 0.584 a 0.836 en la prueba, y **ConvNeXt V2 Tiny** (M2) obtuvo los mejores valores con la **CBCT** y con la **fusión** en ambos conjuntos, seguida por los rasgos diseñados (M1) y por **DINOv2** congelado (M3). Los valores de la prueba fueron algo mayores que los de desarrollo, pero sus intervalos se solapan.

4.2 Desempeño en la prueba retenida

La Tabla 1 detalla el mejor modelo de cada metodología y el ensamble. El ensamble obtuvo en la prueba un *Macro-F1* de 0.842 (IC 95 %: 0.783–0.891), una exactitud de 0.845 y un AUC de 0.940, con valores de F1 equilibrados en las

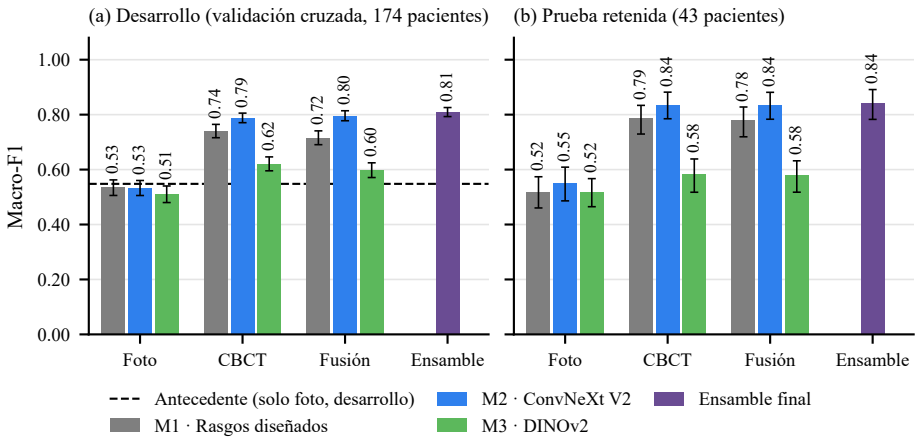


Figura 2. *Macro-F1* por metodología y modalidad: (a) conjunto de desarrollo (validación cruzada agrupada por paciente, 174 pacientes); (b) prueba retenida (43 pacientes). Barras de error: IC 95 % por *bootstrap* de pacientes. Línea discontinua: réplica del enfoque del antecedente con solo fotografías, medida en desarrollo.

tres clases. Asimismo, su sensibilidad fue de 0.805, 0.876 y 0.876, y su precisión de 0.938, 0.796 y 0.779 para N, F y D, respectivamente. M2 con **fusión** y con **CBCT** alcanzaron 0.836, M1 con **CBCT** 0.786 y M3 con **CBCT** solo 0.584.

Tabla 1. Mejor modelo de cada metodología en la prueba retenida (43 pacientes, 516 dientes). El AUC es el promedio macro uno contra el resto.

	Macro-F1				F1 por clase		
Modelo	Desarrollo	Prueba [IC 95 %]	Exact.	AUC	N	F	D
Ensamble	0.810	**0.842** [0.783, 0.891]	0.845	0.940	0.867	0.834	0.825
M2 Fusión	0.796	0.836 [0.783, 0.881]	0.839	0.941	0.870	0.807	0.830
M2 CBCT	0.789	0.836 [0.785, 0.882]	0.837	0.931	0.859	0.812	0.838
M1 RF CBCT	0.741	0.786 [0.729, 0.834]	0.791	0.911	0.813	0.785	0.761
M3 RL CBCT	0.621	0.584 [0.518, 0.639]	0.593	0.781	0.660	0.543	0.547

RF: *Random Forest*. RL: regresión logística. Exact.: exactitud.

4.3 Análisis de errores

La Fig. 3 muestra las matrices de confusión en la prueba retenida. En el ensamble, el error más frecuente fue clasificar dientes normales como **fenestración** (28 de 226), mientras que solo 7 **fenestraciones** y 5 **dehiscencias** se clasificaron como normales. Frente a M1 con **CBCT**, el ensamble redujo los errores

D→N de 15 a 5 y F→D de 18 a 14; en cambio, M3 reconoció solo el 53 % de las **fenestraciones**. Del mismo modo, al agrupar ambos defectos en una sola clase patológica ($P(F) + P(D) > 0.5$), el ensamble alcanzó una sensibilidad de 0.979, una especificidad de 0.765, una exactitud de 0.886 y un AUC de 0.927.

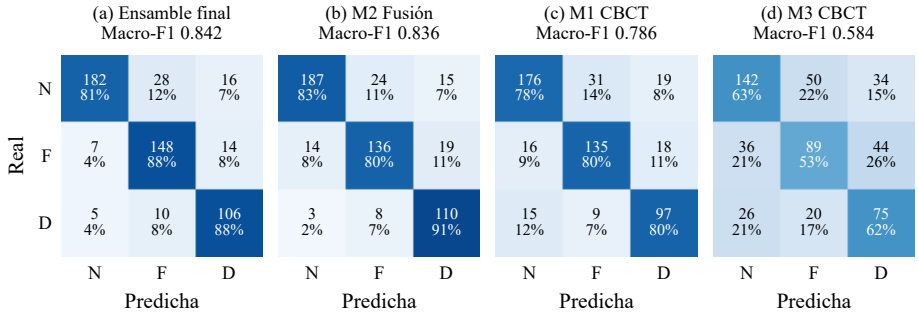


Figura 3. Matrices de confusión en la prueba retenida (filas: clase real; columnas: clase predicha). Cada celda indica el número de dientes y el porcentaje de su clase real.

4.4 Comparaciones estadísticas

Con el *bootstrap* pareado, la **CBCT** superó a la **fotografía** dentro de M2 por +0.285 (IC 95 %: +0.231 a +0.345) en la prueba, y M2 con **fusión** superó a M1 con **CBCT** por +0.049 (+0.013 a +0.090), al igual que M1 con **CBCT** a M3 con **CBCT** por +0.203 (+0.145 a +0.258); las tres diferencias fueron también significativas en desarrollo. En cambio, la **fusión** no mejoró a la **CBCT** sola en M2 (−0.001; −0.022 a +0.020), y la ventaja del ensamble sobre M2 con **fusión**, significativa en desarrollo (+0.014; +0.002 a +0.025), no lo fue en la prueba (+0.006; −0.014 a +0.026).

4.5 Discusión

El principal hallazgo es que la **CBCT** determina el desempeño: con solo la **fotografía**, las tres metodologías quedaron en el nivel del antecedente [2], lo que indica que la fotografía muestra signos indirectos, como el contorno gingival, pero no basta para separar la **fenestración** de la **dehiscencia**; por ello, la **fusión** tampoco superó a la **CBCT** sola, y la complementariedad que describe la literatura [19] no se tradujo en una ganancia. Asimismo, el ajuste fino de **ConvNeXt V2** superó a los rasgos diseñados, en línea con lo observado en otros problemas dentales [11], mientras que **DINOv2** congelado, a diferencia del adaptado al dominio dental [17], no se ajustó a los cortes tomográficos. Por otra parte, la sensibilidad del ensamble (0.979) lo hace útil para el cribado,

pues casi no omite dientes con defectos. Que la prueba supere ligeramente al desarrollo, con intervalos solapados, descarta un sobreajuste en la selección de modelos. Las limitaciones son el uso de un único dataset de una sola institución y el tamaño de la prueba (43 pacientes), que produce intervalos amplios.

5 Conclusiones

Este trabajo diseñó un sistema de **visión computacional** para el pre-diagnóstico por diente de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**, y comparó tres metodologías sobre el dataset **FDTooth**. En la prueba retenida, evaluada una sola vez, el ensamble del ajuste fino de **ConvNeXt V2** y de los rasgos diseñados de la **CBCT** alcanzó un *Macro-F1* de 0.842, un AUC de 0.940 y una sensibilidad de 0.979 para detectar dientes con defectos, frente a un máximo de 0.551 con solo la **fotografía**. Los resultados muestran que la **CBCT** es indispensable para separar ambos defectos, que el ajuste fino supera de forma significativa a los rasgos diseñados a mano y que un modelo fundacional congelado no se adapta bien a las imágenes tomográficas. Como trabajo futuro, se propone validar el sistema en datos de otras instituciones, adaptar **DINOv2** al dominio de la **CBCT** y explorar estrategias de fusión que aprovechen mejor la **fotografía intraoral**.

Referencias

1. Organización Mundial de la Salud: Salud bucodental (oral health): nota descriptiva. `https://www.who.int/news-room/fact-sheets/detail/oral-health` (2025), publicada el 17 de marzo de 2025. Accedido: 14 de octubre de 2026
2. Liu, K., Elbatel, M., Chu, G., Shan, Z., Sum, F.H.K.M.H., Hung, K.F., Zhang, C., Li, X., Yang, Y.: FDTooth: Intraoral photographs and CBCT images for fenestration and dehiscence detection. Scientific Data **12**, 1007 (2025). `https://doi.org/10.1038/s41597-025-05348-3`
3. Sun, L., Mu, C., Chen, L., Zhao, B., Pan, J., Liu, Y.: Dehiscence and fenestration of class I individuals with normality patterns in the anterior region: a CBCT study. Clinical Oral Investigations **26**(5), 4137–4145 (2022). `https://doi.org/10.1007/s00784-022-04384-2`
4. GBD 2023 Latin America and Caribbean Oral Disorders Collaborators: The burden of oral disorders in Latin America and Caribbean countries from 1990 to 2023 and projections until 2050: a systematic analysis for the Global Burden of Disease Study 2023. The Lancet Regional Health – Americas **60**, 101517 (2026). `https://doi.org/10.1016/j.lana.2026.101517`
5. Zhang, X., Liu, Z., Zhang, Y., An, X.: Artificial intelligence for detection of periodontitis on radiographic images: a systematic review and diagnostic test accuracy meta-analysis. Journal of Dentistry p. 107054 (2026). `https://doi.org/10.1016/j.jdent.2026.107054`
6. Chen, Z., Liu, P., Han, K., Liao, P., Yang, Y., Wong, M.C.M., Yiu, C.K.Y., Lo, E.C.M.: AI in oral health surveillance: critical review. Journal of Dental Research **105**(7), 840–852 (2026). `https://doi.org/10.1177/00220345261434568`

7. Xu, A., Huang, H., Zhang, B., Dong, S., Che, X.: Using Swin UNETR deep model for automated detection of alveolar bone fenestration/dehiscence in CBCT. Frontiers in Bioengineering and Biotechnology **14**, 1752350 (2026). https://doi.org/10.3389/fbioe.2026.1752350
8. Song, Y., Ma, S., Mao, B., Xu, K., Liu, Y., Ma, J., Jia, J.: Application of machine learning in the preoperative radiomic diagnosis of ameloblastoma and odontogenic keratocyst based on cone-beam CT. Dentomaxillofacial Radiology **53**(5), 316–324 (2024). https://doi.org/10.1093/dmfr/twae016
9. Sha, X., Wang, C., Sun, J., Qi, S., Yuan, X., Zhang, H., Yang, J.: CBCT radiomics features combine machine learning to diagnose cystic lesions in the jaw. Dentomaxillofacial Radiology **54**(5), 381–388 (2025). https://doi.org/10.1093/dmfr/twaf024
10. Zhang, M., Cai, J., Cao, Q., Chen, Z., Maimaitiaili, S., Yuan, S., Yang, T., Li, Z., Zhang, Z., Yang, Y., et al.: Radiomic features and carotid stenosis in periodontitis a two stage bootstrap and multimodal machine learning study. Scientific Reports **16**(1), 8177 (2026). https://doi.org/10.1038/s41598-026-38463-1
11. Rashid, F., Dudley, J.: Classification of occlusal caries severity using spectrophotometric CIELAB measurements and machine learning algorithms. Clinical Oral Investigations **30**(6), 233 (2026). https://doi.org/10.1007/s00784-026-06911-x
12. Tichy, A., Werner, N., Dujic, H., Wetzel, C., Pitchika, V., Bumm, C.V., Folwaczny, M., Schwendicke, F.: Artificial intelligence in periodontology: a systematic review. Journal of Periodontal Research **61**(6), 639–661 (2026). https://doi.org/10.1111/jre.70107
13. Yang, Y., Jin, E., Bian, Z., Chen, Y., Chen, X., Wu, Y., Tan, J.: The application of deep learning in intelligent assessment of horizontal bone loss in mandibular first molars. Clinical Oral Investigations **30**(10), 470 (2026). https://doi.org/10.1007/s00784-026-07180-4
14. Palkovics, D., Molnar, B., Pinter, C., García-Mato, D., Diaz-Pinto, A., Tanacs, A., Dobos, A., Windisch, P., Ramseier, C.A.: Deep learning cone-beam computed tomography image segmentation for the 3D visualization of mandibular infraosseous periodontal defects. Journal of Periodontology **97**(9), 1847–1859 (2026). https://doi.org/10.1002/jper.70058
15. Mao, K., Thu, K.M., Hung, K.F., Yu, O.Y., Hsung, R.T., Lam, W.Y.: Artificial intelligence in detecting periodontal disease from intraoral photographs: A systematic review. International Dental Journal **75**(5), 100883 (2025). https://doi.org/10.1016/j.identj.2025.100883
16. Li, J., Wang, R., Yi, Z., Ni, J., Zuo, Z., Wang, Y.: Comparing deep learning models for identifying maxillary transverse deficiency from intraoral photographs. International Dental Journal **76**(4), 109689 (2026). https://doi.org/10.1016/j.identj.2026.109689
17. Hu, M., Zhang, Q., Wei, Z., Jia, P., Yuan, M., Yu, H., Yin, X., Peng, J.: Self-supervised learning enhances periapical films segmentation with limited labeled data. Journal of Dentistry **163**, 106150 (2025). https://doi.org/10.1016/j.jdent.2025.106150
18. Li, Y., Cui, Z., Mei, L., Xie, Y., Marini, L., Pelekos, G., Gu, W., Yu, X., Wu, X., Wei, X., et al.: A novel AI-powered radiographic analysis surpasses specialists in stage II–IV periodontitis detection: a multicenter diagnostic study. npj Digital Medicine **8**(1), 691 (2025). https://doi.org/10.1038/s41746-025-02077-0
19. Feng, Y., Jia, Y., Lv, L., Wei, X., Hu, M.: Progress of multimodal imaging: Bridging orthodontics to comprehensive oral multidisciplinary care. International Dental Journal **76**(3), 109510 (2026). https://doi.org/10.1016/j.identj.2026.109510

20. Wasserthal, J., Breit, H.C., Meyer, M.T., Pradella, M., Hinck, D., Sauter, A.W., Heye, T., Boll, D.T., Cyriac, J., Yang, S., Bach, M., Segeroth, M.: TotalSegmentator: Robust segmentation of 104 anatomic structures in CT images. Radiology: Artificial Intelligence **5**(5), e230024 (2023). https://doi.org/10.1148/ryai.230024
21. Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I.S., Xie, S.: ConvNeXt V2: Co-designing and scaling ConvNets with masked autoencoders. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). pp. 16133–16142 (2023). https://doi.org/10.1109/CVPR52729.2023.01548
22. Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., et al.: DINOv2: Learning robust visual features without supervision. arXiv:2304.07193 (2023)