Diseño de un Sistema de Visión Computacional para el Pre-diagnóstico de Fenestración y Dehiscencia Ósea Alveolar a partir de Fotografías Intraorales y Tomografías CBCT

José Cabrera-Ticlla[1], Lucero Ayala-Mauricio[1] y Wilfredo Ticona[1,2]

[1] Universidad ESAN, Lima, Perú
22200150@ue.edu.pe, 22200171@ue.edu.pe, wmamani@esan.edu.pe
[2] Universidad Tecnológica del Perú, Lima, Perú
C19404@utp.edu.pe

Resumen La **fenestración** y la **dehiscencia ósea alveolar** son defectos frecuentes en los dientes anteriores, cuyo diagnóstico depende de la **CBCT**. Este trabajo propone el diseño de un sistema de **visión computacional** para su pre-diagnóstico por diente a partir de **fotografías intraorales y tomografías CBCT**. Sobre el dataset **FDTooth** (217 pacientes y 2604 dientes) se construyeron **ensambles híbridos** que promedian las probabilidades de **ConvNeXt V2 Tiny** ajustada con la fotografía y la **CBCT** (**Deep Learning**) y de clasificadores **SVM**, **Random Forest**, **HistGradientBoosting** y **KNN** entrenados con rasgos de la **CBCT** (**Machine Learning**). La mejor de las doce combinaciones se eligió por validación cruzada agrupada por paciente y se evaluó una sola vez en una prueba retenida de 43 pacientes, donde obtuvo un *Macro-F1* de 0.842 (IC 95 %: 0.783–0.891), un AUC de 0.940 y una sensibilidad de 0.979 para detectar dientes con algún defecto, frente a 0.551 con solo la fotografía. La **CBCT** resultó indispensable, y el ensamble superó a su componente de **Machine Learning** (0.786) y, sin diferencia significativa en la prueba, a su mejor componente de **Deep Learning** (0.836).

Palabras clave: **Fenestración** · **Dehiscencia** · **CBCT** · **Fotografía intraoral** · **Visión computacional** · **Deep Learning** · **Machine Learning**

1 Introducción

Las enfermedades bucodentales son uno de los problemas de salud pública más extendidos del mundo: la Organización Mundial de la Salud (OMS) estima que afectan a cerca de 3700 millones de personas y que la periodontopatía grave supera los 1000 millones de casos [1]. Entre las alteraciones del soporte óseo de los dientes destacan la **fenestración**, un defecto localizado del hueso alveolar que expone la raíz sin comprometer la cresta, y la **dehiscencia**, que es la pérdida del hueso que cubre la raíz y afecta al margen óseo. Ambas se asocian con recesión

gingival, bolsas periodontales profundas y, en casos severos, pérdida del diente [2]. Su frecuencia es elevada incluso sin maloclusiones severas: en 732 dientes anteriores evaluados con **tomografía computarizada de haz cónico (CBCT)**, Sun et al. hallaron dehiscencia en el 27.46 % y fenestración en el 26.91 %, con al menos un defecto en todos los pacientes; además, deben evaluarse antes de un tratamiento ortodóntico, porque el movimiento dental puede agravarlas [3].

En América Latina y el Caribe, los trastornos bucales ocupan el primer lugar en prevalencia entre todas las causas de enfermedad, con 308.2 millones de casos en 2023, de los cuales 87.2 millones corresponden a periodontitis severa [4]. Del mismo modo, el Perú presenta la segunda tasa más alta de la región de años vividos con discapacidad por edentulismo en adultos de 60 años o más (1366.9 por cada 100 000 habitantes), desenlace final de la enfermedad periodontal avanzada, mientras que la evidencia peruana sobre estos defectos es escasa [4].

La **CBCT** es la modalidad de elección para diagnosticar estos defectos, pero su uso rutinario es poco práctico por la radiación y el tiempo que demanda, y la inspección visual de las **fotografías intraorales** es subjetiva [2]. Ante ello, la **inteligencia artificial (IA)** ha ganado terreno en el diagnóstico odontológico: un metaanálisis reportó, para la detección de periodontitis en radiografías, una sensibilidad agrupada de 0.93 y una especificidad de 0.88 [5], y la **visión computacional** ya permite el cribado remoto de enfermedades bucales a partir de **imágenes intraorales** [6]. Asimismo, modelos de **Deep Learning** han detectado la **fenestración y dehiscencia** en cortes de **CBCT** con exactitudes de 0.82 a 0.95 [7], y la publicación del dataset **FDTooth**, con fotografías y CBCT de 241 pacientes, incluyó un modelo que detecta estos defectos solo a partir de fotografías, con un AUC de 0.76 y sin distinguir entre ellos [2].

Este trabajo propone el diseño de un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. Sobre **FDTooth** se construyen **ensambles híbridos** que combinan una **red convolucional preentrenada** ajustada con la **fotografía** y la **CBCT** (**Deep Learning**) con clasificadores de **Machine Learning** alimentados con rasgos diseñados de la **CBCT**, y se evalúan con una prueba retenida por paciente que se usa una sola vez. Hasta donde se conoce, el único trabajo con **fotografías intraorales** pareadas con **CBCT** para estos defectos [2] usó solo la fotografía y en una tarea binaria, y no se ha evaluado la **fusión** de ambas modalidades ni un **ensamble híbrido** de **Deep Learning** y **Machine Learning** para distinguir por diente entre normal, **fenestración** y **dehiscencia**, vacío que aborda el presente trabajo.

2 Trabajos Relacionados

2.1 Machine Learning con rasgos diseñados a mano para el diagnóstico de lesiones óseas dentales

Los clasificadores de **Machine Learning** alimentados con rasgos cuantitativos de la imagen, como los radiómicos, de textura y de color, han sido estudiados para diagnosticar **lesiones de los maxilares** en **CBCT**. Song et al. [8]

extrajeron 348 rasgos radiómicos de las **CBCT** de 326 pacientes para diferenciar **ameloblastoma y queratoquiste odontogénico** con seis algoritmos, y **XGBoost** alcanzó el mejor desempeño (**exactitud: 0.843; F1: 0.841; AUC: 0.872**), superando el diagnóstico de los radiólogos. Del mismo modo, Sha et al. [9] integraron seis rasgos radiómicos de las **CBCT** de 300 pacientes en un clasificador por votación suave que combina **Random Forest, SVM y regresión logística**, y obtuvieron en el conjunto de prueba **valores de AUC de 0.781 a 0.849 y una exactitud de 0.711**, distinguiendo tres tipos de lesiones quísticas con solo seis rasgos. Asimismo, centrándose en pacientes con **periodontitis**, Zhang et al. [10] emplearon 206 rasgos radiómicos de **CBCT**, y el modelo **Random Forest** logró un **AUC de 0.710**, al detectar la aterosclerosis carotídea concomitante a partir de la tomografía. Finalmente, Rashid y Dudley [11] transformaron mediciones de color **CIELAB** de 300 dientes extraídos en rasgos diseñados para clasificar la severidad de la **caries oclusal** con **Random Forest, XGBoost, CatBoost y redes neuronales**, y estas últimas alcanzaron una **exactitud balanceada de 0.89**, mientras que los modelos basados en árboles rindieron por debajo y apenas mejoraban con más datos de entrenamiento.

2.2 Deep Learning para la evaluación del hueso alveolar en CBCT y fotografías intraorales

Ante las limitaciones de los rasgos diseñados a mano, trabajos recientes han aplicado **Deep Learning** a la evaluación del **soporte óseo periodontal**. Tichy et al. [12] revisaron 29 estudios de **Deep Learning** para el diagnóstico de **periodontitis** y reportaron **exactitudes de 81 a 99 % en radiografías panorámicas, de 78 % en CBCT y un AUROC de 0.93 en el cribado con fotografías**, advirtiendo que la mayoría de los estudios utilizó datos de un solo centro. Del mismo modo, Yang et al. [13] entrenaron una **3D-ResNet** con 505 **CBCT** para clasificar la **pérdida ósea horizontal** de los primeros molares inferiores y alcanzaron una **exactitud global de 0.829**, comparable a la de los odontólogos. Asimismo, Palkovics et al. [14] utilizaron una **SegResNet** para segmentar en **CBCT** los **defectos periodontales infraóseos** mandibulares, y obtuvieron mediciones lineales y volumétricas confiables frente a la segmentación semiautomática. De igual manera, Xu et al. [7] entrenaron un **Swin UNETR** con 10 752 cortes sagitales de **CBCT** para medir y detectar la **fenestración y dehiscencia**, con **exactitudes de 0.82 a 0.95 a nivel de diente**, lo que indica que ambos defectos pueden detectarse de forma automática en la tomografía. Por otra parte, en el caso de las **fotografías intraorales**, Mao et al. [15] analizaron 26 estudios de detección de **enfermedad periodontal** con **Deep Learning** y hallaron **exactitudes de clasificación de 0.46 a 1.00**, con solo 9 estudios que usaron más de una vista. Finalmente, Li et al. [16] compararon seis **redes convolucionales** entrenadas con **fotografías intraorales frontales** de 826 pacientes, usando como referencia mediciones derivadas de **CBCT**, y **ResNet-18** alcanzó una **exactitud de 90.62 %** en un conjunto de prueba

externo para detectar la **deficiencia transversal maxilar**, de modo que un modelo basado en fotografías puede aprender de etiquetas obtenidas por tomografía.

2.3 Modelos fundacionales y fusión multimodal en el diagnóstico odontológico

Ante la escasez de datos etiquetados, los **modelos fundacionales** preentrenados de forma autosupervisada y la **fusión multimodal** ofrecen alternativas al entrenamiento supervisado desde cero. Hu et al. [17] adaptaron **DINOv2** mediante aprendizaje autosupervisado específico del dominio para segmentar **radiografías periapicales** con pocas anotaciones, y lograron un **Dice de 74.77 % frente a 33.53–41.55 % de U-Net y DeepLabV3+**, por encima también de MAE, MoCo v3 y BEiT v3. Del mismo modo, Li et al. [18] preentrenaron y ajustaron el modelo **HC-Net+** con 10 881 **ortopantomografías** para detectar **periodontitis** en estadios II a IV y obtuvieron un **AUROC de 94.2 % frente a 85.6 % de los periodoncistas**, y mantuvo una exactitud superior al 92.4 % en cuatro centros. Asimismo, Feng et al. [19] revisaron la **fusión de datos multimodales** en ortodoncia, y concluyeron que integrar modalidades compensa las limitaciones de resolución y de especificidad tisular que presenta cada una por separado. Finalmente, Chen et al. [6] analizaron el uso de **modelos multimodales** en la vigilancia de la **salud bucal**, señalando que permiten integrar imágenes y datos clínicos en un mismo análisis.

3 Metodología

La metodología se basó en los antecedentes revisados: el dataset y la referencia con solo **fotografías** de [2], la región de interés por diente en cortes de la **CBCT** [7,20], los rasgos de la **CBCT** con varios clasificadores y su combinación por votación suave [8,9], y el ajuste fino de redes preentrenadas con **fotografías** y etiquetas obtenidas de la tomografía [16,21]. La unión de ambos tipos de modelo en un **ensamble híbrido** es propia de este trabajo. La Fig. 1 resume la metodología propuesta, organizada en cuatro fases.

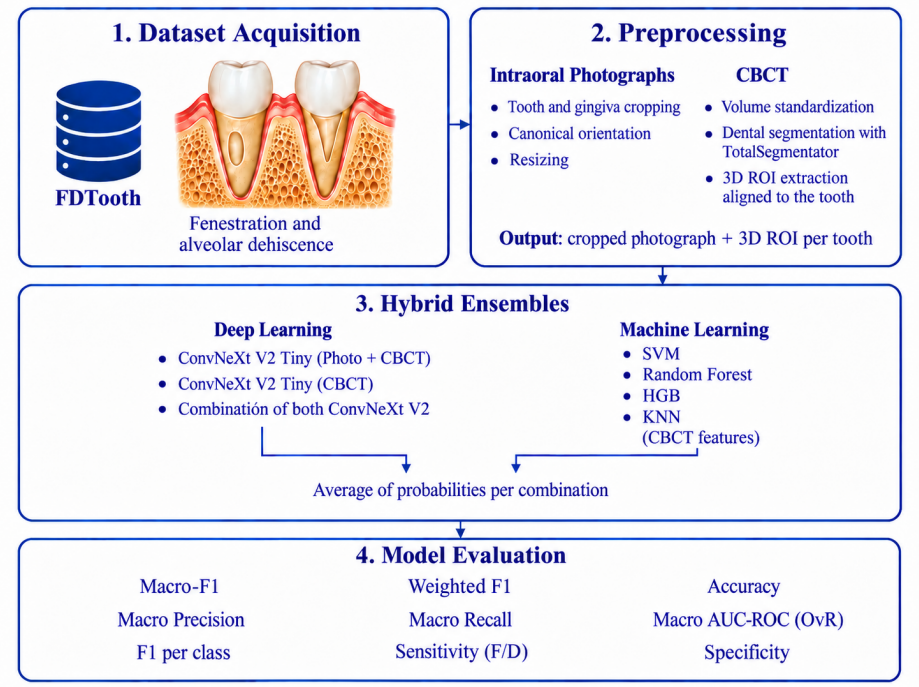


Fig. 1. Metodología.

3.1 Obtención del dataset

Se utilizó el dataset público **FDTooth** [2], recolectado en la Facultad de Odontología de la Universidad de Hong Kong: 241 pacientes de 9 a 55 años, cada uno con una **fotografía intraoral frontal** de alta resolución, en su mayoría de 5760×3840 píxeles, y una **CBCT** con vóxeles de 0.15 a 0.18 mm. Cada uno de los 12 dientes anteriores está etiquetado como normal (N), **fenestración** (F) o **dehiscencia** (D) a partir de la lectura de la **CBCT** por dos odontólogos, con

una concordancia $\kappa > 0.9$ [2]. Tras verificar la integridad de los 487 archivos con sumas SHA256 y contrastar las etiquetas del archivo CSV con las del archivo JSON, se excluyeron 24 pacientes: 23 por discordancia entre ambas fuentes y uno por coordenadas incompatibles con la imagen. La cohorte incluyó 217 pacientes y 2604 dientes.

3.2 Preprocesamiento

La Tabla 1 resume las seis actividades de esta fase, que son las del segundo bloque de la Fig. 1: tres para la **fotografía intraoral** y tres para la **CBCT**. Cada una se explica a continuación.

Tabla 1. Actividades del preprocesamiento.

Actividad	**Descripción**	**Tareas**
Fotografía intraoral		
Recorte por diente y encía	Aísla cada diente junto con la encía que cubre su raíz.	• Asignar cada caja delimitadora a su diente. • Ampliarla 30 % a los lados, 60 % hacia apical y 20 % hacia coronal.
Orientación canónica	Deja todos los dientes con el ápice arriba y la cara mesial a la derecha.	• Voltear en vertical los dientes inferiores. • Voltear en horizontal los del lado izquierdo.
Redimensionamiento	Unifica el tamaño de los recortes sin deformarlos.	• Escalar a 768 píxeles en el lado largo. • Conservar el color original.
CBCT		
Estandarización del volumen	Lleva las tomografías de ambos equipos a la misma escala de intensidad y de vóxel.	• Ordenar los cortes DICOM por su posición. • Convertir a valores tipo HU con la Ec. (1). • Remuestrear a 0.5 mm (volumen completo) y a 0.2 mm (región anterior).
Segmentación dental	Ubica y numera cada diente en la tomografía.	• Aplicar *TotalSegmentator* al volumen de 0.5 mm. • Conservar el mayor componente conectado de cada diente.
Extracción de la ROI 3D	Obtiene una región comparable entre dientes, alineada con su eje largo.	• Calcular el eje largo por componentes principales. • Orientar los otros ejes hacia vestibular y distal. • Muestrear $14 \times 10 \times 32$ mm con vóxeles de 0.2 mm.

Recorte por diente y encía. Las anotaciones de **FDTooth** incluyen la caja delimitadora de los 12 dientes, pero no su número [2]. Por ello, cada caja se asignó a su diente según su posición en la foto: las seis superiores y las seis inferiores se ordenaron de izquierda a derecha. Luego la caja se amplió para incluir la encía; el margen hacia apical es el mayor porque la recesión gingival asociada a estos defectos [2] se observa en la encía que cubre la raíz.

Orientación canónica. Los dientes inferiores se voltearon en vertical y los del lado izquierdo del paciente, en horizontal. Así, todos los recortes quedan con el ápice arriba y la cara mesial a la derecha, y la red no necesita aprender la misma anatomía en cuatro orientaciones. Los volteos, que en otros trabajos con **fotografías intraorales** se usan como aumento de datos [15], aquí se aplican de forma fija para normalizar la orientación.

Redimensionamiento. Cada recorte se redimensionó a 768 píxeles en su lado largo, manteniendo su proporción, para que todos tengan un tamaño similar sin deformar el diente; el redimensionamiento es un paso habitual en los modelos de **Deep Learning** con **fotografías intraorales** [15]. No se normalizó el color: los modelos usan el recorte con su color original.

Estandarización del volumen. Los cortes DICOM de cada **CBCT** se ordenaron por su posición y sus intensidades se convirtieron a valores tipo unidades Hounsfield (HU), que en la **CBCT** son aproximados, con los parámetros de reescalado del archivo:

$$\mathrm{HU} = m \cdot v + b \tag{1}$$

donde v es el valor almacenado del vóxel, m la pendiente (*RescaleSlope*) y b la intersección (*RescaleIntercept*). Como las tomografías provienen de equipos con vóxeles de 0.15 y 0.18 mm [2], se remuestrearon por interpolación lineal a 0.5 mm en el volumen completo, que es la entrada de la segmentación, y a 0.2 mm en la región anterior, de donde se extraen las ROI.

Segmentación dental. **TotalSegmentator** [20], una red basada en nnU-Net, se aplicó al volumen de 0.5 mm para ubicar cada diente con su número FDI. De cada máscara se conservó el mayor componente conectado, para descartar fragmentos sueltos. La segmentación identificó 2600 de los 2604 dientes; los cuatro restantes, todos del conjunto de desarrollo, quedaron sin ROI.

Extracción de la ROI 3D. El eje largo de cada diente se obtuvo por análisis de componentes principales de su máscara; de los otros dos ejes, uno apunta hacia vestibular y el otro hacia distal, de modo que todos los dientes comparten la misma orientación. La región de interés (ROI) mide 14 mm en sentido vestíbulo-lingual, 10 mm en sentido mesio-distal y 32 mm a lo largo del eje, lo que cubre el canino completo, y se muestreó con vóxeles de 0.2 mm. Su corte vestíbulo-lingual central equivale a los cortes sagitales en que Xu et al. detectaron ambos defectos [7].

Finalmente, la cohorte se particionó por paciente, para que los dientes de un mismo paciente no aparecieran en ambos conjuntos, en un conjunto de desarrollo de 174 pacientes y 2088 dientes (938 N, 663 F y 487 D) y una prueba retenida de 43 pacientes y 516 dientes (226 N, 169 F y 121 D). La Fig. 2 muestra el resultado del preprocesamiento para un diente de cada clase.

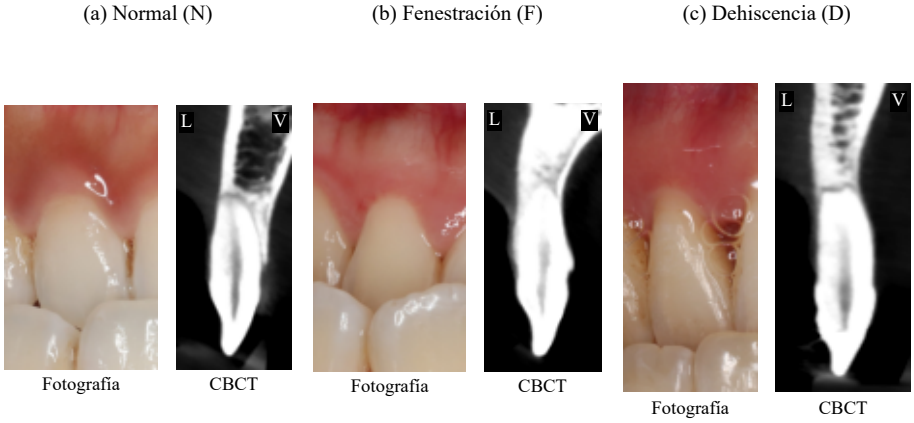


Fig. 2. Resultado del preprocesamiento en un incisivo lateral inferior de cada clase: recorte de la **fotografía intraoral** en orientación canónica y corte vestíbulo-lingual de la ROI de la **CBCT** (V: vestibular; L: lingual). Datos de **FDTooth** [2].

3.3 Ensambles híbridos

El sistema combina, a nivel de decisión, modelos de **Machine Learning** y de **Deep Learning**: cada uno clasifica el diente por separado y luego se promedian sus probabilidades de N, F y D. La Tabla 2 resume las actividades de esta fase, que son las del tercer bloque de la Fig. 1. Cada una se explica a continuación.

Tabla 2. Actividades de los ensambles híbridos.

Actividad	**Descripción**	**Tareas**
Machine Learning		
Rasgos de la CBCT	Mide el hueso vestibular de cada diente.	• Perfil de grosor por mm de raíz. • Cresta, zonas sin hueso y hueco más largo.
Clasificadores	Estiman la probabilidad de N, F y D.	• SVM, RF, HGB y KNN con los rasgos. • Hiperparámetros por búsqueda interna.
Deep Learning		
ConvNeXt V2 (CBCT)	Clasifica el diente con su ROI.	• Entrada 2.5D con tres cortes. • Ajuste fino de la red preentrenada.
ConvNeXt V2 (Foto+CBCT)	Fusiona la foto y la ROI en una red.	• Una rama por modalidad. • Cabeza común para ambas ramas.
Ambas	Las dos redes: Foto+CBCT y CBCT.	• Aporta al ensamble las probabilidades de las dos redes.
Ensamble		
Promedio de probabilidades	Une cada configuración de DL con cada ML.	• Promedio con la Ec. (4). • Doce ensambles en total.

Rasgos de la CBCT. Sobre la ROI se midió, en cada milímetro a lo largo de la raíz, el grosor de la tabla ósea vestibular con tres umbrales de densidad (400, 700 y 1000 HU), ya que los valores de la **CBCT** no están calibrados. De este perfil se derivan la altura de la cresta, la fracción de raíz sin hueso (menos de 0.3 mm) y el hueco óseo más largo con hueso por encima y por debajo, que es el patrón de la **fenestración**; en cambio, la **dehiscencia** compromete el margen óseo y desplaza la cresta hacia apical. El vector se completa con el perfil lingual, la longitud y el volumen del diente y su posición en la arcada. Este enfoque, en el que rasgos medidos en la **CBCT** alimentan a varios clasificadores, sigue a Song et al. [8].

Clasificadores. Los rasgos se imputaron con la mediana, se estandarizaron y alimentaron a cuatro clasificadores; SVM, RF y HGB usaron pesos de clase balanceados. **SVM** [22] separa las clases con un margen máximo en el espacio que define el kernel RBF:

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2\right) \tag{2}$$

donde γ controla el alcance de cada muestra y C penaliza los errores; sus probabilidades se obtienen con el escalado de Platt. **Random Forest** (RF) [23] promedia las probabilidades de T árboles entrenados con muestras y rasgos aleatorios:

$$P_{\mathrm{RF}}(c \mid \mathbf{x}) = \frac{1}{T} \sum_{t=1}^{T} p_t(c \mid \mathbf{x}) \tag{3}$$

donde $p_t(c \mid \mathbf{x})$ es la proporción de la clase c en la hoja del árbol t a la que llega $\mathbf{x}$. **HistGradientBoosting** (HGB) suma árboles pequeños que corrigen los errores de los anteriores [24], y **KNN** [25] asigna la clase de los k vecinos más cercanos, ponderados por la inversa de su distancia. Los hiperparámetros se eligieron por *Macro-F1* en una búsqueda interna agrupada por paciente; la Tabla 4 muestra los valores elegidos en cada ensamble y, en su nota, el espacio de búsqueda.

ConvNeXt V2 (CBCT). **ConvNeXt V2 Tiny** [21], preentrenada con autoencoders enmascarados y ajustada en ImageNet-22k e ImageNet-1k, se ajustó de extremo a extremo con una representación 2.5D de la ROI: tres cortes vestíbulo-linguales, el central y uno a 0.6 mm a cada lado, que ocupan los tres canales de la imagen. Cada corte se llevó a $[0, 1]$ con una ventana de -300 a 2200 HU, se redimensionó a 320×144 píxeles y se normalizó con las estadísticas de ImageNet; los cuatro dientes sin ROI recibieron una entrada vacía.

ConvNeXt V2 (Foto+CBCT). La red de **fusión** tiene dos ramas ConvNeXt V2 Tiny, una para el recorte de la **fotografía**, llevado a 384×224 píxeles, y otra para la ROI de la **CBCT**; sus vectores se concatenan y pasan a una cabeza común con *dropout* de 0.3 y una capa lineal de tres salidas. Como referencia, la misma red se ajustó con solo la **fotografía**. Las dos redes se entrenaron con entropía cruzada ponderada por la inversa de la frecuencia de cada clase y aumento de datos (rotaciones, escalados, traslaciones y cambios de brillo y contraste, sin volteos, para no alterar la orientación canónica); la tasa de aprendizaje y las épocas se eligieron con una validación interna por paciente (Tabla 4). En la prueba,

cada red se reentrenó con todo el desarrollo, con tres semillas, y en la **CBCT** se promediaron tres posiciones del corte central (TTA).

Ambas. Esta configuración no entrena una red nueva: incluye en el ensamble las probabilidades de las dos redes anteriores.

Promedio de probabilidades. Cada ensamble promedia con el mismo peso las probabilidades de los modelos que lo forman:

$$P_{\text{ens}}(c \mid \mathbf{x}) = \frac{1}{|M|} \sum_{m \in M} P_m(c \mid \mathbf{x}), \qquad c \in \{N, F, D\} \tag{4}$$

donde M reúne una red, o las dos en «Ambas», y un clasificador de **Machine Learning**; así, en «Ambas + RF» cada modelo pesa 1/3. El diente se asigna a la clase de mayor probabilidad, como en la votación suave de Sha et al. [9]. Al cruzar las tres configuraciones de **Deep Learning** con los cuatro clasificadores se obtienen doce **ensambles híbridos**. En desarrollo también se probaron combinaciones con parámetros aprendidos (regresión logística sobre las probabilidades, contexto de los dientes del mismo paciente y umbrales por clase), pero ninguna superó al promedio simple.

3.4 Evaluación

En el conjunto de desarrollo se aplicó una validación cruzada anidada de cinco particiones agrupadas por paciente: una validación interna eligió los hiperparámetros y las predicciones fuera de partición permitieron comparar los doce ensambles y elegir el de mayor *Macro-F1*. Como referencia, se replicó en las mismas particiones el enfoque del antecedente basado solo en fotografías [2], cuya mejor variante (**MobileNetV3-Small** con ajuste fino) obtuvo un *Macro-F1* de 0.548. Los modelos se reentrenaron con todo el conjunto de desarrollo y el ensamble elegido se evaluó una sola vez en la prueba retenida; la rejilla completa en la prueba se calculó después y es solo descriptiva. Se reportan *Macro-F1*, que es la métrica principal porque pondera por igual las tres clases, F1 ponderado, exactitud, precisión y sensibilidad macro, AUC-ROC uno contra el resto, F1 por clase y la matriz de confusión; además, al agrupar F y D como clase patológica, se reportan su sensibilidad y la especificidad. Los intervalos de confianza (IC) del 95 % y las diferencias entre modelos se estimaron por *bootstrap* pareado de pacientes con 2000 remuestreos.

4 Resultados

4.1 Comparación de los ensambles híbridos

La Tabla 3 reúne los doce ensambles. En desarrollo, su *Macro-F1* varió entre 0.778 y 0.810, y el mejor fue el que combina ambas configuraciones de **ConvNeXt V2** con **Random Forest**, que se eligió como sistema final. En la prueba retenida, este ensamble obtuvo también el mayor *Macro-F1* (0.842; IC 95 %: 0.783–0.891), con una exactitud de 0.845, un F1 ponderado de 0.846 y un AUC

Tabla 3. Ensambles híbridos de *Deep Learning* (ConvNeXt V2 Tiny) y *Machine Learning* (rasgos de la CBCT). Desarrollo: 174 pacientes; prueba retenida: 43 pacientes. Precisión, sensibilidad y AUC son promedios macro de N, F y D.

		Desarrollo	Prueba retenida						
ConvNeXt V2	ML	*Macro-F1*	Exact.	Prec.	Sens.	*Macro-F1*	AUC	Sens. F/D	Espec.
Foto+CBCT	SVM	0.789	0.810	0.801	0.815	0.806	0.933	0.938	0.779
	RF	0.795	0.841	0.832	0.848	0.838	0.939	0.962	0.779
	HGB	0.778	0.812	0.804	0.821	0.809	0.933	0.934	0.788
	KNN	0.785	0.814	0.804	0.816	0.808	0.929	0.969	0.779
CBCT	SVM	0.784	0.818	0.811	0.822	0.814	0.933	0.972	0.761
	RF	0.793	0.841	0.836	0.849	0.839	0.936	0.976	0.757
	HGB	0.781	0.822	0.814	0.830	0.820	0.932	0.945	0.774
	KNN	0.784	0.828	0.823	0.833	0.825	0.929	0.983	0.752
Ambas	SVM	0.804	0.841	0.833	0.846	0.837	0.939	0.976	0.792
(Foto+CBCT	**RF**	**0.810**	**0.845**	**0.838**	**0.852**	**0.842**	**0.940**	**0.979**	**0.765**
y CBCT)	HGB	0.805	0.831	0.824	0.840	0.830	0.941	0.959	0.783
	KNN	0.804	0.835	0.829	0.840	0.832	0.937	0.983	0.757

Ambas: las dos redes, cuyas probabilidades se promedian junto con las del clasificador de ML (Ec. 4). RF: *Random Forest*. HGB: *HistGradientBoosting*. Exact.: exactitud. Sens. F/D y Espec.: sensibilidad y especificidad al agrupar F y D frente a N. En negrita, el ensamble elegido.

Tabla 4. Hiperparámetros de cada ensamble híbrido, elegidos con la búsqueda interna en desarrollo.

		ConvNeXt V2			
ConvNeXt V2	ML	lr	Épocas	Hiperparámetros del ML	Peso
Foto+CBCT	SVM	10^{-3} / 10^{-4}	7	RBF; $C = 3$; $\gamma = 0.003$	1/2
	RF	10^{-3} / 10^{-4}	7	500 árboles; máx. rasgos 0.2; hoja mín. 1	1/2
	HGB	10^{-3} / 10^{-4}	7	tasa 0.1; máx. hojas 7; L2 1.0	1/2
	KNN	10^{-3} / 10^{-4}	7	$k = 31$; ponderación por distancia	1/2
CBCT	SVM	10^{-3} / 10^{-4}	16	RBF; $C = 3$; $\gamma = 0.003$	1/2
	RF	10^{-3} / 10^{-4}	16	500 árboles; máx. rasgos 0.2; hoja mín. 1	1/2
	HGB	10^{-3} / 10^{-4}	16	tasa 0.1; máx. hojas 7; L2 1.0	1/2
	KNN	10^{-3} / 10^{-4}	16	$k = 31$; ponderación por distancia	1/2
Ambas	SVM	10^{-3} / 10^{-4}	7 / 16	RBF; $C = 3$; $\gamma = 0.003$	1/3
(Foto+CBCT	**RF**	**10^{-3} / 10^{-4}**	**7 / 16**	**500 árboles; máx. rasgos 0.2; hoja mín. 1**	**1/3**
y CBCT)	HGB	10^{-3} / 10^{-4}	7 / 16	tasa 0.1; máx. hojas 7; L2 1.0	1/3
	KNN	10^{-3} / 10^{-4}	7 / 16	$k = 31$; ponderación por distancia	1/3

lr: tasa de aprendizaje de la cabeza / del *backbone*. Épocas: con parada temprana (paciencia de 7); en Ambas, Foto+CBCT / CBCT. Peso: el de cada modelo en el promedio (Ec. 4). Comunes a las redes: AdamW con decaimiento de pesos de 0.05, OneCycle, lote de 32, suavizado de etiquetas de 0.1 y 3 semillas en la prueba. Espacio de búsqueda: lr de la cabeza {0.001, 0.0003} (*backbone*: lr / 10); épocas $\leq$ 30; SVM: C {0.3, 1, 3, 10}, γ {scale, 0.003, 0.01}; RF: max_features $\{\sqrt{p}, 0.2\}$, min_samples_leaf {1, 3, 8}; HGB: learning_rate {0.03, 0.1}, max_leaf_nodes {7, 15}, L2 {0, 1}; KNN: k {7, 15, 31}; p: número de rasgos. Máx. rasgos: max_features; hoja mín.: min_samples_leaf; tasa: learning_rate; máx. hojas: max_leaf_nodes. En negrita, el ensamble elegido.

de 0.940. En ambos conjuntos, **Random Forest** fue el mejor clasificador de **Machine Learning** para cada configuración de **Deep Learning**, y combinar las dos redes superó a usar una sola con cualquiera de los cuatro clasificadores. La sensibilidad para detectar dientes con algún defecto osciló entre 0.934 y 0.983 en los ensambles, y la especificidad, entre 0.752 y 0.792.

La Tabla 4 reúne los hiperparámetros de cada ensamble. Como el ensamble combina decisiones, cada red y cada clasificador se entrenó una sola vez y se re-

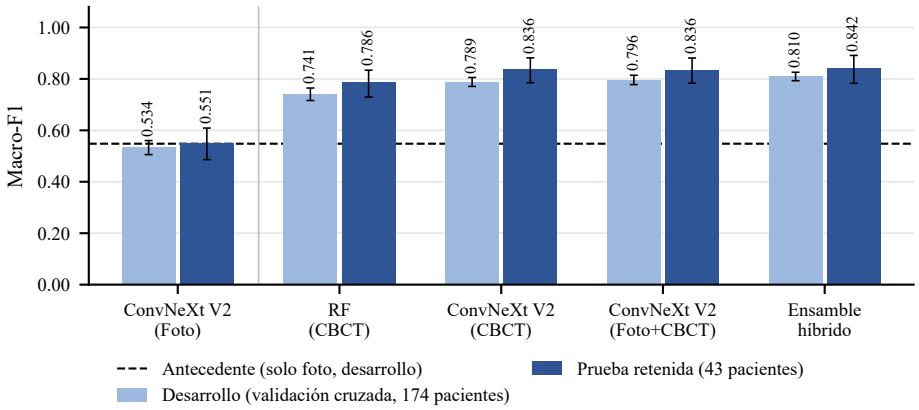


Fig. 3. *Macro-F1* del ensamble híbrido elegido y de sus componentes en desarrollo (validación cruzada agrupada por paciente) y en la prueba retenida. ConvNeXt V2 con solo la fotografía se muestra como referencia. Barras de error: IC 95 % por *bootstrap* de pacientes. Línea discontinua: réplica del enfoque del antecedente con solo fotografías, medida en desarrollo.

utilizó en todas las combinaciones; por eso sus valores se repiten en los ensambles que lo incluyen.

4.2 Aporte de cada componente

La Fig. 3 compara el ensamble elegido con sus componentes. Con solo la **fotografía intraoral**, **ConvNeXt V2** obtuvo un *Macro-F1* de 0.534 en desarrollo y de 0.551 en la prueba, valores cercanos al del antecedente replicado (0.548). En cambio, con la **CBCT** el componente de **Machine Learning** alcanzó 0.786 en la prueba y los de **Deep Learning** 0.836, y el ensamble superó a todos en ambos conjuntos. Sus F1 por clase fueron equilibrados (0.867, 0.834 y 0.825), con una sensibilidad de 0.805, 0.876 y 0.876 y una precisión de 0.938, 0.796 y 0.779 para N, F y D, respectivamente. Los valores de la prueba superaron ligeramente a los de desarrollo, aunque sus intervalos se solapan.

4.3 Análisis de errores

La Fig. 4 muestra la matriz de confusión del ensamble elegido en la prueba retenida. El error más frecuente fue clasificar dientes normales como **fenestración** (28 de 226), mientras que solo 7 **fenestraciones** y 5 **dehiscencias** se clasificaron como normales. En las matrices de sus componentes, que no se muestran, cada uno aportó aciertos distintos: **ConvNeXt V2** con **CBCT** reconoció 149 **fenestraciones**, pero confundió 35 dientes normales con esa clase; con **fusión**, acertó más dientes normales (187) y **dehiscencias** (110); y **Random Forest**

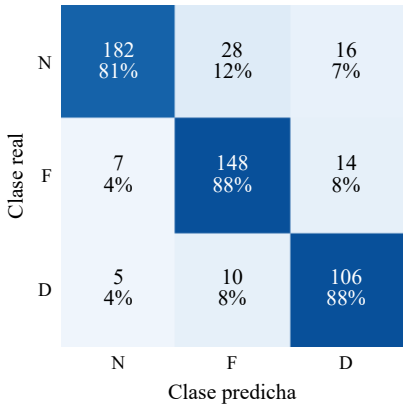


Fig. 4. Matriz de confusión del ensamble híbrido elegido (ConvNeXt V2 Foto+CBCT, ConvNeXt V2 CBCT y Random Forest) en la prueba retenida. Cada celda indica el número de dientes y el porcentaje de su clase real.

cometió 15 errores D→N. Al promediarlos, el ensamble conservó el reconocimiento de las **fenestraciones** (148) y bajó a 28 los errores N→F. Del mismo modo, al agrupar ambos defectos en una sola clase patológica ($P(F) + P(D) > 0.5$), el ensamble alcanzó una sensibilidad de 0.979, una especificidad de 0.765, una exactitud de 0.886 y un AUC de 0.927.

4.4 Comparaciones estadísticas

Con el *bootstrap* pareado, la **CBCT** superó a la **fotografía** en **ConvNeXt V2** por +0.285 (IC 95 %: +0.231 a +0.345) en la prueba, y el componente de **Deep Learning** con **fusión** superó al de **Machine Learning** por +0.049 (+0.013 a +0.090); ambas diferencias fueron también significativas en desarrollo. En cambio, la **fusión** no mejoró a la **CBCT** sola (−0.001; −0.022 a +0.020), y la ventaja del ensamble sobre **ConvNeXt V2** con **fusión**, significativa en desarrollo (+0.014; +0.002 a +0.025), no lo fue en la prueba (+0.006; −0.014 a +0.026).

4.5 Discusión

El principal hallazgo es que la **CBCT** determina el desempeño: con solo la **fotografía**, **ConvNeXt V2** quedó en el nivel del antecedente [2], lo que indica que la fotografía muestra signos indirectos, como el contorno gingival, pero no basta para separar la **fenestración** de la **dehiscencia**; por ello, la **fusión** dentro de la red tampoco superó a la **CBCT** sola, y la complementariedad que describe la literatura [19] no se tradujo en una ganancia. En cambio, la combinación a nivel de decisión sí aportó: en los doce ensambles, promediar ambas configuraciones de **ConvNeXt V2** superó a usar una sola, y **Random Forest**

fue el mejor complemento, en línea con la votación suave de clasificadores que emplearon Sha et al. [9]. Asimismo, el ajuste fino superó a los rasgos diseñados, como en otros problemas dentales [11], pero los rasgos de la **CBCT** corrigieron parte de los errores de la red. Por otra parte, la sensibilidad del ensamble (0.979) lo hace útil para el cribado, pues casi no omite dientes con defectos. La prueba superó ligeramente al desarrollo, con intervalos solapados, de modo que no hay indicios de sobreajuste en la selección del ensamble. Las limitaciones incluyen la ausencia de una validación externa, pues la prueba retenida proviene de la misma institución que el desarrollo y la generalización a otros centros, tomógrafos y poblaciones queda por demostrar; el tamaño de la prueba (43 pacientes), que produce intervalos amplios, y que la ventaja del ensamble sobre su mejor componente no fue significativa en la prueba.

5 Conclusiones

Este trabajo diseñó un sistema de **visión computacional** para el prediagnóstico por diente de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**, basado en **ensambles híbridos** de **Deep Learning** y **Machine Learning** sobre el dataset **FDTooth**. En la prueba retenida, evaluada una sola vez, el ensamble de **ConvNeXt V2** con **fotografía y CBCT**, **ConvNeXt V2** con **CBCT** y **Random Forest** con rasgos de la **CBCT** alcanzó un *Macro-F1* de 0.842, un AUC de 0.940 y una sensibilidad de 0.979 para detectar dientes con defectos, frente a 0.551 con solo la **fotografía**. En esta cohorte, la **CBCT** fue indispensable para separar ambos defectos, el ajuste fino superó de forma significativa a los rasgos diseñados a mano y promediar ambos tipos de modelo dio el mejor desempeño, aunque con una ventaja pequeña sobre la mejor red. Como trabajo futuro, se propone validar el sistema en datos de otras instituciones, incorporar otras arquitecturas de **Deep Learning** al ensamble y explorar estrategias de fusión que aprovechen mejor la **fotografía intraoral**.

Referencias

1. Organización Mundial de la Salud: Salud bucodental (oral health): nota descriptiva. `https://www.who.int/news-room/fact-sheets/detail/oral-health` (2025), publicada el 17 de marzo de 2025. Accedido: 14 de octubre de 2026
2. Liu, K., Elbatel, M., Chu, G., Shan, Z., Sum, F.H.K.M.H., Hung, K.F., Zhang, C., Li, X., Yang, Y.: FDTooth: Intraoral photographs and CBCT images for fenestration and dehiscence detection. Scientific Data **12**, 1007 (2025). `https://doi.org/10.1038/s41597-025-05348-3`
3. Sun, L., Mu, C., Chen, L., Zhao, B., Pan, J., Liu, Y.: Dehiscence and fenestration of class I individuals with normality patterns in the anterior region: a CBCT study. Clinical Oral Investigations **26**(5), 4137–4145 (2022). `https://doi.org/10.1007/s00784-022-04384-2`
4. GBD 2023 Latin America and Caribbean Oral Disorders Collaborators: The burden of oral disorders in Latin America and Caribbean countries from 1990 to 2023 and

projections until 2050: a systematic analysis for the Global Burden of Disease Study 2023. The Lancet Regional Health – Americas **60**, 101517 (2026). https://doi.org/10.1016/j.lana.2026.101517
5. Zhang, X., Liu, Z., Zhang, Y., An, X.: Artificial intelligence for detection of periodontitis on radiographic images: a systematic review and diagnostic test accuracy meta-analysis. Journal of Dentistry p. 107054 (2026). https://doi.org/10.1016/j.jdent.2026.107054
6. Chen, Z., Liu, P., Han, K., Liao, P., Yang, Y., Wong, M.C.M., Yiu, C.K.Y., Lo, E.C.M.: AI in oral health surveillance: critical review. Journal of Dental Research **105**(7), 840–852 (2026). https://doi.org/10.1177/00220345261434568
7. Xu, A., Huang, H., Zhang, B., Dong, S., Che, X.: Using Swin UNETR deep model for automated detection of alveolar bone fenestration/dehiscence in CBCT. Frontiers in Bioengineering and Biotechnology **14**, 1752350 (2026). https://doi.org/10.3389/fbioe.2026.1752350
8. Song, Y., Ma, S., Mao, B., Xu, K., Liu, Y., Ma, J., Jia, J.: Application of machine learning in the preoperative radiomic diagnosis of ameloblastoma and odontogenic keratocyst based on cone-beam CT. Dentomaxillofacial Radiology **53**(5), 316–324 (2024). https://doi.org/10.1093/dmfr/twae016
9. Sha, X., Wang, C., Sun, J., Qi, S., Yuan, X., Zhang, H., Yang, J.: CBCT radiomics features combine machine learning to diagnose cystic lesions in the jaw. Dentomaxillofacial Radiology **54**(5), 381–388 (2025). https://doi.org/10.1093/dmfr/twaf024
10. Zhang, M., Cai, J., Cao, Q., Chen, Z., Maimaitiaili, S., Yuan, S., Yang, T., Li, Z., Zhang, Z., Yang, Y., et al.: Radiomic features and carotid stenosis in periodontitis a two stage bootstrap and multimodal machine learning study. Scientific Reports **16**(1), 8177 (2026). https://doi.org/10.1038/s41598-026-38463-1
11. Rashid, F., Dudley, J.: Classification of occlusal caries severity using spectrophotometric CIELAB measurements and machine learning algorithms. Clinical Oral Investigations **30**(6), 233 (2026). https://doi.org/10.1007/s00784-026-06911-x
12. Tichy, A., Werner, N., Dujic, H., Wetzel, C., Pitchika, V., Bumm, C.V., Folwaczny, M., Schwendicke, F.: Artificial intelligence in periodontology: a systematic review. Journal of Periodontal Research **61**(6), 639–661 (2026). https://doi.org/10.1111/jre.70107
13. Yang, Y., Jin, E., Bian, Z., Chen, Y., Chen, X., Wu, Y., Tan, J.: The application of deep learning in intelligent assessment of horizontal bone loss in mandibular first molars. Clinical Oral Investigations **30**(10), 470 (2026). https://doi.org/10.1007/s00784-026-07180-4
14. Palkovics, D., Molnar, B., Pinter, C., García-Mato, D., Diaz-Pinto, A., Tanacs, A., Dobos, A., Windisch, P., Ramseier, C.A.: Deep learning cone-beam computed tomography image segmentation for the 3D visualization of mandibular infraosseous periodontal defects. Journal of Periodontology **97**(9), 1847–1859 (2026). https://doi.org/10.1002/jper.70058
15. Mao, K., Thu, K.M., Hung, K.F., Yu, O.Y., Hsung, R.T., Lam, W.Y.: Artificial intelligence in detecting periodontal disease from intraoral photographs: A systematic review. International Dental Journal **75**(5), 100883 (2025). https://doi.org/10.1016/j.identj.2025.100883
16. Li, J., Wang, R., Yi, Z., Ni, J., Zuo, Z., Wang, Y.: Comparing deep learning models for identifying maxillary transverse deficiency from intraoral photographs. International Dental Journal **76**(4), 109689 (2026). https://doi.org/10.1016/j.identj.2026.109689

17. Hu, M., Zhang, Q., Wei, Z., Jia, P., Yuan, M., Yu, H., Yin, X., Peng, J.: Self-supervised learning enhances periapical films segmentation with limited labeled data. Journal of Dentistry **163**, 106150 (2025). https://doi.org/10.1016/j.jdent.2025.106150
18. Li, Y., Cui, Z., Mei, L., Xie, Y., Marini, L., Pelekos, G., Gu, W., Yu, X., Wu, X., Wei, X., et al.: A novel AI-powered radiographic analysis surpasses specialists in stage II–IV periodontitis detection: a multicenter diagnostic study. npj Digital Medicine **8**(1), 691 (2025). https://doi.org/10.1038/s41746-025-02077-0
19. Feng, Y., Jia, Y., Lv, L., Wei, X., Hu, M.: Progress of multimodal imaging: Bridging orthodontics to comprehensive oral multidisciplinary care. International Dental Journal **76**(3), 109510 (2026). https://doi.org/10.1016/j.identj.2026.109510
20. Wasserthal, J., Breit, H.C., Meyer, M.T., Pradella, M., Hinck, D., Sauter, A.W., Heye, T., Boll, D.T., Cyriac, J., Yang, S., Bach, M., Segeroth, M.: TotalSegmentator: Robust segmentation of 104 anatomic structures in CT images. Radiology: Artificial Intelligence **5**(5), e230024 (2023). https://doi.org/10.1148/ryai.230024
21. Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I.S., Xie, S.: ConvNeXt V2: Co-designing and scaling ConvNets with masked autoencoders. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). pp. 16133–16142 (2023). https://doi.org/10.1109/CVPR52729.2023.01548
22. Cortes, C., Vapnik, V.: Support-vector networks. Machine Learning **20**(3), 273–297 (1995). https://doi.org/10.1007/BF00994018
23. Breiman, L.: Random forests. Machine Learning **45**(1), 5–32 (2001). https://doi.org/10.1023/A:1010933404324
24. Friedman, J.H.: Greedy function approximation: A gradient boosting machine. The Annals of Statistics **29**(5), 1189–1232 (2001). https://doi.org/10.1214/aos/1013203451
25. Cover, T.M., Hart, P.E.: Nearest neighbor pattern classification. IEEE Transactions on Information Theory **13**(1), 21–27 (1967). https://doi.org/10.1109/TIT.1967.1053964