

UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Diseño de un Sistema de Visión Computacional para el Pre-diagnóstico de Fenestración y Dehiscencia Ósea Alveolar a partir de Fotografías Intraorales y Tomografías CBCT

Plan de tesis

José Cabrera Ticlla
Lucero Ayala Mauricio

Asesor: Wilfredo Mamani Ticona

Lima, diciembre de 2026

DEDICATORIA

[Dedicatoria pendiente.]

Índice

Introducción **1**

I Planteamiento del Problema **2**

1.1. Descripción de la Realidad Problemática 2
1.2. Formulación del Problema 3
1.2.1. Problema general 3
1.2.2. Problemas específicos 3
1.3. Objetivos de la Investigación 4
1.3.1. Objetivo general 4
1.3.2. Objetivos específicos 4
1.4. Justificación de la Investigación 4
1.4.1. Teórica 4
1.4.2. Práctica 5
1.4.3. Metodológica 5
1.5. Delimitación del Estudio 5
1.5.1. Espacial 5
1.5.2. Temporal 5
1.5.3. Conceptual 6

II Marco Teórico **6**

2.1. Antecedentes de la Investigación 6
2.1.1. Machine Learning con rasgos diseñados a mano 6
2.1.2. Deep Learning para la evaluación del hueso alveolar 7
2.1.3. Modelos fundacionales y fusión multimodal 8
2.2. Bases Teóricas 8
2.2.1. Variable independiente: sistema de visión computacional 8
2.2.2. Variable dependiente: pre-diagnóstico de fenestración y dehiscencia . . 10
2.2.3. Otros temas: métricas de evaluación 11
2.3. Marco Conceptual o Contexto de la Investigación 12
2.3.1. Fenestración ósea alveolar 12
2.3.2. Dehiscencia ósea alveolar 13
2.3.3. Tomografía computarizada de haz cónico (CBCT) 13
2.3.4. Fotografía intraoral 13
2.3.5. Visión computacional 13
2.3.6. Ensamble híbrido 13
2.3.7. Rasgos diseñados 13
2.3.8. Ajuste fino 13

2.4. Hipótesis 14
2.4.1. Hipótesis general 14
2.4.2. Hipótesis específicas 14

III Metodología **14**
3.1. Diseño de la investigación 15
3.1.1. Diseño 15
3.1.2. Tipo 15
3.1.3. Enfoque 15
3.2. Población y Muestra 15
3.2.1. Población 15
3.2.2. Muestra 16
3.3. Operacionalización de Variables 16
3.4. Técnicas de Recolección de Datos 16
3.5. Metodología de la implementación de la solución 18
3.5.1. Selección de la metodología 18
3.5.2. Desarrollo de la metodología 19
3.5.3. Metodología para la medición de resultados 21

Referencias **22**

Anexos **25**

Índice de Figuras

1 Ejemplos de diente normal, con fenestración y con dehiscencia 10
2 Selección de la cohorte y partición por paciente 17
3 Metodología propuesta 19

Índice de Tablas

1 Población, muestra y unidad de análisis 16
2 Operacionalización de variables 17
3 Clases del estudio y distribución por conjunto 18

Resumen

La **fenestración** y la **dehiscencia ósea alveolar** son defectos frecuentes en los dientes anteriores que se asocian con recesión gingival, exposición radicular y, en casos severos, pérdida del diente. Su diagnóstico depende de la **tomografía computarizada de haz cónico (CBCT)**, cuyo uso rutinario está limitado por la radiación y el tiempo que demanda, mientras que la inspección visual de las **fotografías intraorales** es subjetiva. Por ello, esta investigación busca diseñar un sistema de **visión computacional** para el pre-diagnóstico por diente de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. El trabajo sigue cuatro fases: obtención del dataset **FDTooth** con su control de calidad, preprocesamiento de ambas modalidades, **ensambles híbridos** y evaluación. Cada ensamble promedia las probabilidades de una red **ConvNeXt V2 Tiny** ajustada con la fotografía y la **CBCT** (**Deep Learning**) y de un clasificador **SVM**, **Random Forest**, **HistGradientBoosting** o **KNN** entrenado con rasgos de la **CBCT** (**Machine Learning**). Con 217 pacientes y 2604 dientes, la mejor de las doce combinaciones se eligió por validación cruzada agrupada por paciente y se midió una única vez sobre 43 pacientes reservados. Usando solo la fotografía, la red no pasó de 0.551 de *Macro-F1*; el ensamble elegido, que une las dos configuraciones de **ConvNeXt V2** con **Random Forest**, llegó a 0.842 (IC 95 %: 0.783–0.891), con un AUC de 0.940 y una sensibilidad de 0.979 para los dientes con algún defecto. La **CBCT** resulta, entonces, imprescindible: la fotografía apenas deja ver signos indirectos en la encía y combinarla con la tomografía dentro de la red no aporta. El ensamble superó a su componente de **Machine Learning** (0.786) y, por un margen pequeño que no fue significativo en la prueba, a la mejor red (0.836). Gracias a su sensibilidad, el sistema podría ayudar al odontólogo a decidir qué dientes revisar primero, aunque antes de llevarlo a la clínica habrá que probarlo con datos de otros centros.

Palabras clave: **fenestración**, **dehiscencia**, **CBCT**, **fotografía intraoral**, **visión computacional**, **Deep Learning**, **Machine Learning**.

Abstract

[Traducción del Resumen pendiente.]

Keywords: **fenestration**, **dehiscence**, **CBCT**, **intraoral photography**, **computer vision**, **Deep Learning**, **Machine Learning**.

Introducción

Perder un diente suele ser el final de un proceso largo en el que el hueso que lo sostiene se va deteriorando sin dar síntomas (Organización Mundial de la Salud, 2025). Dos de esos deterioros, la **fenestración** y la **dehiscencia ósea alveolar**, afectan precisamente la delgada lámina de hueso que recubre la raíz. Rara vez se notan en la consulta: lo habitual es descubrirlos cuando ya obligan a cambiar un plan de tratamiento, por ejemplo antes de mover los dientes en ortodoncia (Guo et al., 2026).

El diagnóstico de ambos defectos se apoya en la **tomografía computarizada de haz cónico (CBCT)**, que muestra el hueso alveolar en tres dimensiones. Sin embargo, la CBCT expone al paciente a radiación y demanda tiempo, por lo que no se usa en cada control, y la fotografía intraoral, que sí se toma de rutina, solo muestra signos indirectos como la recesión de la encía (Liu et al., 2025). Por ello, el odontólogo suele decidir con información incompleta cuándo solicitar una tomografía.

La odontología ya usa modelos de **visión computacional** para leer radiografías, tomografías y fotografías clínicas (Yuan et al., 2026). Lo que faltaba para este problema era un conjunto de datos que uniera ambas fuentes, y eso cambió con **FDTooth**: por primera vez se publicaron fotografías intraorales y tomografías CBCT de los mismos pacientes, con la etiqueta de cada diente (Liu et al., 2025).

Aprovechando ese dataset, aquí se plantea el diseño de un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. El sistema asigna a cada diente anterior una de tres clases (normal, fenestración o dehiscencia) mediante **ensambles híbridos** que juntan dos tipos de modelo: una red convolucional ajustada al problema, que aprende directamente de las imágenes, y clasificadores de **Machine Learning** que trabajan con rasgos del hueso medidos en la tomografía.

El Capítulo I expone el problema, los objetivos, la justificación y los límites del estudio. En el Capítulo II se revisan los trabajos previos y los conceptos que sustentan ambas variables, y se plantean las hipótesis. El Capítulo III explica cómo se llevará a cabo el estudio, desde la

muestra y las variables hasta cada fase del sistema.

CAPÍTULO I: Planteamiento del Problema

Este capítulo parte de la magnitud del problema y de las limitaciones del diagnóstico actual, y de ahí deriva las preguntas, los objetivos, las razones del estudio y su alcance.

1.1. Descripción de la Realidad Problemática

Según la Organización Mundial de la Salud, unos 3700 millones de personas tienen alguna enfermedad bucodental y los casos de periodontopatía grave pasan de 1000 millones; a ello se suma que el 7 % de los mayores de 20 años y el 23 % de los mayores de 60 ya perdieron todos sus dientes (Organización Mundial de la Salud, 2025). Parte de ese deterioro empieza en el hueso alveolar. En la **fenestración**, el hueso se abre en una ventana y deja ver la raíz, aunque la cresta sigue intacta; en la **dehiscencia**, el hueso falta desde el borde y la raíz queda descubierta hacia arriba. Ambos defectos pueden derivar en exposición radicular, necrosis pulpar, recesión de la encía, bolsas periodontales profundas y, en el peor de los casos, la pérdida del diente (Liu et al., 2025).

No se trata de hallazgos raros. Al revisar con **CBCT** 732 dientes anteriores de 61 personas con oclusión Clase I, Sun et al. (2022) hallaron dehiscencia en el 27.46 % y fenestración en el 26.91 %; casi la mitad de los dientes (48.91 %) tenía al menos uno de los dos defectos y ningún paciente estaba libre de ellos. Un consenso de expertos advierte, además, que son comunes en los adultos que llegan a ortodoncia y que el movimiento de los dientes puede empeorarlos (Guo et al., 2026).

La situación regional no es mejor. En América Latina y el Caribe, los trastornos bucales sumaron 308.2 millones de casos en 2023 y fueron el grupo de enfermedades más frecuente; la periodontitis severa ocupó el segundo lugar, con 87.2 millones, y la discapacidad que causa creció 25 % o más desde 1990 en casi todos los países (GBD 2023 Latin America and Caribbean Oral Disorders Collaborators, 2026). El Perú aparece con la segunda tasa más alta de la región de años vividos con discapacidad por edentulismo en mayores de 60 años, 1366.9 por cada 100 000 habitantes, detrás solo de Bolivia (GBD 2023 Latin America and Caribbean Oral

Disorders Collaborators, 2026). Aun así, los estudios peruanos sobre estos defectos son escasos, y la evidencia regional proviene sobre todo de Brasil, México, Chile y Colombia.

A esto se suma un problema práctico. La **CBCT** es el examen que mejor muestra estos defectos, pero irradia al paciente y toma tiempo, así que no se pide en cada control; las radiografías convencionales no alcanzan a mostrar el hueso vestibular, y mirar las **fotografías intraorales** a simple vista es lento, subjetivo y poco preciso (Liu et al., 2025). El único modelo publicado que intenta detectarlos desde las fotografías de **FDTooth** logró un AUC de 0.76 con una especificidad de 0.65, y ni siquiera separa la fenestración de la dehiscencia (Liu et al., 2025). Hoy no hay, por tanto, un sistema que combine ambas imágenes para indicar, diente por diente, cuál de los dos defectos está presente.

1.2. Formulación del Problema

Las preguntas de investigación salen de la situación descrita y siguen las fases del sistema: hay una pregunta general y una pregunta específica por cada fase.

1.2.1. Problema general

¿En qué medida el diseño de un sistema de **visión computacional** permite el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**?

1.2.2. Problemas específicos

PE1: ¿Cómo asegurar la integridad y la consistencia de las **fotografías intraorales y tomografías CBCT** del dataset **FDTooth** para el pre-diagnóstico de **fenestración y dehiscencia**?

PE2: ¿Qué técnicas de preprocesamiento permiten obtener regiones de interés comparables por diente a partir de las **fotografías intraorales y tomografías CBCT**?

PE3: ¿Qué combinación de modelos de **Deep Learning** y **Machine Learning** en un **ensamble híbrido** obtiene el mejor desempeño en la clasificación de **fenestración y dehiscencia**?

PE4: ¿Qué desempeño alcanza el sistema de **visión computacional** en el pre-diagnóstico por diente de **fenestración y dehiscencia** en una prueba retenida?

1.3. Objetivos de la Investigación

Cada objetivo responde a una de las preguntas anteriores, en el mismo orden.

1.3.1. Objetivo general

Diseñar un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**.

1.3.2. Objetivos específicos

OE1: Construir una cohorte verificada de **fotografías intraorales y tomografías CBCT** a partir del dataset **FDTooth**.

OE2: Implementar el preprocesamiento de las **fotografías intraorales y tomografías CBCT** para obtener una región de interés por diente.

OE3: Implementar **ensambles híbridos** que combinen el ajuste fino de **ConvNeXt V2 Tiny** (**Deep Learning**) con clasificadores de **Machine Learning** entrenados con rasgos de la **CBCT** para la clasificación de **fenestración y dehiscencia**.

OE4: Evaluar el desempeño del sistema de **visión computacional** en el pre-diagnóstico por diente de **fenestración y dehiscencia** mediante el *Macro-F1* y métricas complementarias en una prueba retenida.

1.4. Justificación de la Investigación

1.4.1. Teórica

El estudio responde a una pregunta que la literatura aún no ha resuelto: si juntar una red convolucional ajustada con clasificadores que usan rasgos medidos a mano separa mejor la **fenestración** de la **dehiscencia** que cada modelo por separado. También permite saber cuánto

aporta cada fuente por sí sola y juntas, la **fotografía intraoral** y la **CBCT**, algo que los trabajos previos no midieron con tres clases (Liu et al., 2025; Xu et al., 2026).

1.4.2. Práctica

El resultado será un sistema que marca cada diente anterior como normal, con fenestración o con dehiscencia. Con esa información, el odontólogo puede decidir con más fundamento cuándo pedir una tomografía o en qué dientes fijarse al leerla. En ortodoncia esto pesa especialmente, porque los defectos que ya existen deben conocerse antes de empezar a mover los dientes (Guo et al., 2026).

1.4.3. Metodológica

Para que los resultados no se inflen, ningún paciente aparece a la vez en entrenamiento y en evaluación, los modelos se eligen con validación cruzada anidada y los 43 pacientes de prueba se usan una única vez. Los doce ensambles y sus componentes se comparan con los mismos datos y con intervalos de confianza por *bootstrap*, de modo que el procedimiento puede repetirse en otros problemas de imagen dental.

1.5. Delimitación del Estudio

1.5.1. Espacial

El estudio se realiza en la Universidad ESAN, en Lima. Las imágenes, sin embargo, vienen de Hong Kong: **FDTooth** se recolectó en dos centros de la Facultad de Odontología de esa universidad (Liu et al., 2025).

1.5.2. Temporal

El trabajo se ejecuta en el semestre 2026-2, de agosto a diciembre de 2026, con datos tomados entre enero de 2010 y enero de 2023 (Liu et al., 2025).

1.5.3. Conceptual

Solo se clasifican los 12 dientes anteriores de cada paciente, en tres clases: normal, **fenestración** y **dehiscencia**. El sistema da un pre-diagnóstico de apoyo; no sustituye el criterio clínico ni la lectura de la tomografía por un especialista. Quedan fuera el tratamiento de los defectos y la puesta en marcha del sistema en una clínica.

CAPÍTULO II: Marco Teórico

Aquí se reúne lo que ya se sabe sobre el tema: los estudios previos más cercanos, los conceptos detrás de cada variable, las definiciones clave y, al final, las hipótesis que se pondrán a prueba.

2.1. Antecedentes de la Investigación

Los estudios revisados se agrupan en tres líneas. Las dos primeras, el **Machine Learning** con rasgos diseñados y el **Deep Learning**, son los componentes del ensamble híbrido que propone este trabajo; la tercera reúne alternativas recientes, como los modelos fundacionales y la fusión de modalidades. En cada una se revisa qué ha funcionado y qué queda por hacer.

2.1.1. Machine Learning con rasgos diseñados a mano

Medir propiedades concretas de la imagen (textura, color, rasgos radiómicos) y entregárselas a un clasificador de **Machine Learning** es una vía bastante explorada para las **lesiones de los maxilares** en **CBCT**. Con 348 rasgos radiómicos extraídos de las tomografías de 326 pacientes, Song et al. (2024) probaron seis algoritmos para separar el **ameloblastoma** del **queratoquiste odontogénico**; el mejor, **XGBoost**, llegó a una exactitud de 0.843, un F1 de 0.841 y un AUC de 0.872, por encima de los radiólogos. Sha et al. (2025) trabajaron con apenas seis rasgos de las **CBCT** de 300 pacientes, pero los combinaron en una votación suave entre **Random Forest, SVM y regresión logística**; en su conjunto de prueba distinguieron tres tipos de **lesiones quísticas** con AUC de 0.781 a 0.849 y una exactitud de 0.711. En pacientes con **periodontitis**, Zhang et al. (2026) usaron 206 rasgos de **CBCT** y un **Random Forest**

para detectar aterosclerosis carotídea asociada, con un AUC de 0.710. Fuera de la tomografía, Rashid y Dudley (2026) convirtieron mediciones de color **CIELAB** de 300 dientes extraídos en rasgos para graduar la **caries oclusal**: los modelos de árboles quedaron por debajo de las redes neuronales, que alcanzaron una exactitud balanceada de 0.89. Estos rasgos tienen la ventaja de ser interpretables y de rendir bien con muestras medianas, pero nadie los ha llevado todavía a la **fenestración y dehiscencia** ni a las **fotografías intraorales**.

2.1.2. Deep Learning para la evaluación del hueso alveolar

El paso siguiente ha sido dejar que la red aprenda por sí misma qué mirar en el **soporte óseo periodontal**. En una revisión de 29 estudios de **Deep Learning** sobre **periodontitis**, Tichy et al. (2026) encontraron exactitudes de 81 a 99 % en radiografías panorámicas, de 78 % en **CBCT** y un AUROC de 0.93 cuando el cribado se hacía con **fotografías**; eso sí, casi todos los trabajos usaban datos de un único centro. Yang et al. (2026) entrenaron una **3D-ResNet** con 505 **CBCT** para clasificar la **pérdida ósea horizontal** en primeros molares inferiores y lograron una exactitud de 0.829, prácticamente igual a la de los odontólogos (0.820). Otros equipos se han concentrado en medir el defecto: Palkovics et al. (2026) segmentaron con una **SegResNet** los **defectos infraóseos** mandibulares y obtuvieron mediciones fiables, y Xu et al. (2026) entrenaron un **Swin UNETR** con 10 752 cortes sagitales de **CBCT** que detectó la **fenestración y dehiscencia** con exactitudes de 0.82 a 0.95 por diente.

Con **fotografías intraorales** el panorama es más irregular. Mao et al. (2025) reunieron 26 estudios sobre **enfermedad periodontal** y vieron exactitudes que iban de 0.46 a 1.00; solo 9 de ellos usaban más de una vista. J. Li et al. (2026), por su parte, compararon seis **redes convolucionales** entrenadas con **fotografías frontales** de 826 pacientes y etiquetadas a partir de mediciones en **CBCT**; **ResNet-18** detectó la **deficiencia transversal maxilar** con 90.62 % de exactitud en una prueba externa. Este último caso muestra que una red que solo ve fotografías puede aprender de etiquetas tomadas de la tomografía, aunque cuánto logra depende mucho de la tarea y de la vista.

2.1.3. Modelos fundacionales y fusión multimodal

Cuando hay pocas imágenes etiquetadas, dos alternativas ganan interés: partir de un **modelo fundacional** preentrenado sin etiquetas y combinar varias fuentes de imagen. Hu et al. (2025) siguieron la primera: adaptaron **DINOv2** al dominio dental con aprendizaje autosupervisado y, con pocas anotaciones, segmentaron **radiografías periapicales** con un Dice de 74.77 %, mientras que U-Net y DeepLabV3+ se quedaron entre 33.53 y 41.55 %. En la misma línea, Y. Li et al. (2025) preentrenaron **HC-Net+** con 10 881 **ortopantomografías** y, al detectar **periodontitis** en estadios II a IV, superaron a periodoncistas con experiencia (AUROC de 94.2 % frente a 85.6 %). Sobre la segunda alternativa, Feng et al. (2026) revisaron la **fusión multimodal** en ortodoncia y concluyeron que juntar modalidades compensa lo que a cada una le falta en resolución o en detalle del tejido.

Para la **fenestración y dehiscencia**, en cambio, el único estudio con **fotografías intraorales** y **CBCT** de los mismos pacientes es el de Liu et al. (2025), y su modelo usó solo la fotografía para responder si había defecto o no. No se encontró ningún trabajo que junte **Deep Learning** y **Machine Learning** en un **ensamble híbrido**, ni que fusione ambas imágenes, para decir, diente por diente, si es normal, tiene **fenestración** o tiene **dehiscencia**.

2.2. Bases Teóricas

2.2.1. Variable independiente: sistema de visión computacional

2.2.1.1. Definición

En el **Machine Learning** o aprendizaje automático, en lugar de escribir reglas a mano, se le muestran ejemplos a un algoritmo para que encuentre por su cuenta los patrones que le permitan predecir casos nuevos. El **Deep Learning** es la rama que hace esto con redes neuronales de muchas capas, y es la que ha permitido analizar imágenes médicas con buenos resultados (Yuan et al., 2026). Reconocer lo que hay en una imagen es la tarea central de la **visión computacional**, y en odontología tiene un peso especial: buena parte del cribado, el diagnóstico y la planificación se decide mirando fotografías, radiografías o cortes histológicos (Yuan et al., 2026). Para este trabajo, el sistema de visión computacional es la cadena de fases

que recibe la **fotografía intraoral y la tomografía CBCT** de un paciente y devuelve una clase para cada diente.

2.2.1.2. Clasificación

Según cómo obtienen la representación de la imagen y cómo toman la decisión final, los métodos que usa este trabajo se clasifican en tres grupos:

- **Rasgos diseñados a mano con Machine Learning.** Un experto define qué medir en la imagen, como la textura, el color o el grosor del hueso, y un clasificador como **SVM**, **Random Forest**, **Gradient Boosting** o **KNN** aprende a separar las clases a partir de esos valores (Sha et al., 2025; Song et al., 2024).

- **Ajuste fino de redes convolucionales.** Una red convolucional preentrenada aprende directamente de la imagen sus propias representaciones, y sus pesos se reajustan con los datos del problema. Las redes convolucionales son el marco predominante de Deep Learning para el análisis de imágenes dentales (Yuan et al., 2026), y **ConvNeXt V2** es una arquitectura reciente de este tipo (Woo et al., 2023).

- **Ensambles híbridos.** Juntan las decisiones de modelos de distinto tipo, por ejemplo una red convolucional y un clasificador de rasgos: cada modelo clasifica por separado y la decisión final sale de promediar o votar sus probabilidades. La votación suave entre **Random Forest**, **SVM** y regresión logística ya se ha usado con rasgos de **CBCT** (Sha et al., 2025). Este trabajo combina así una red **ConvNeXt V2** con clasificadores de **Machine Learning**.

2.2.1.3. Primeras referencias

Aplicar visión computacional a estos defectos es algo muy reciente. En 2025, Liu et al. (2025) publicaron **FDTooth**, el primer dataset abierto con fotografías intraorales y tomografías CBCT pensado para detectarlos, y lo acompañaron de un modelo de referencia que solo usaba las fotografías. Un año después, Xu et al. (2026) presentaron una red de Deep Learning que mide y detecta ambos defectos sobre los cortes de CBCT. De esos dos trabajos parte el presente estudio.

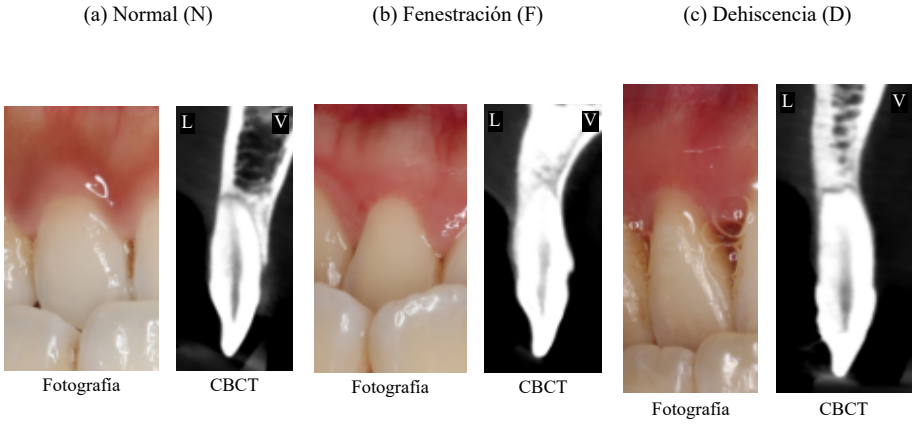
2.2.2. Variable dependiente: pre-diagnóstico de fenestración y dehiscencia

2.2.2.1. Definición

La **fenestración** es un defecto localizado del hueso alveolar que expone la raíz del diente sin comprometer la cresta alveolar, mientras que la **dehiscencia** es la pérdida del hueso que cubre la superficie de la raíz y suele afectar al margen óseo (Liu et al., 2025). En esta investigación, el pre-diagnóstico es la clasificación automática de cada diente anterior como normal, con fenestración o con dehiscencia, que orienta pero no sustituye la evaluación del especialista. La Figura 1 muestra un incisivo lateral inferior de cada clase, tomado del conjunto de desarrollo entre los clasificados correctamente con alta confianza. En cada par, a la izquierda se ve el recorte de la **fotografía intraoral**, donde solo se observan la encía y la corona, y a la derecha el corte vestíbulo-lingual de la **CBCT** (V: vestibular; L: lingual), que permite ver la cortical ósea que cubre la raíz.

Figura 1

Ejemplos de diente normal, con fenestración y con dehiscencia



Fuente: Elaboración propia con datos de **FDTooth** (Liu et al., 2025).

2.2.2.2. Factores

Los defectos óseos alveolares tienen una etiología multifactorial que incluye anomalías craneofaciales congénitas, periodontitis crónica y alteraciones funcionales de la oclusión (Guo et al., 2026). Su frecuencia varía según el tipo de maloclusión: la dehiscencia es común en los dientes anteriores inferiores de pacientes con maloclusión esquelética Clase III de ángulo alto y en pacientes con biprotrusión, mientras que la fenestración predomina en los dientes anteriores

superiores de pacientes con maloclusión esquelética Clase II (Guo et al., 2026). El riesgo de que aparezcan o empeoren durante la ortodoncia sube, además, cuando la encía es delgada, ya hay recesión o el reborde alveolar es estrecho (Guo et al., 2026).

2.2.2.3. Etapas

Hay defectos que el paciente ya trae a la primera consulta y otros que se producen durante la ortodoncia, sobre todo cuando se mueve el diente más allá de lo que permite el hueso alveolar (Guo et al., 2026). Si pasan inadvertidos, la raíz descubierta retiene placa, la encía se inflama y la enfermedad periodontal puede avanzar hasta que el diente se pierde (Liu et al., 2025).

2.2.2.4. Características

En las fotografías intraorales, los dientes con estos defectos suelen mostrar signos indirectos como recesión gingival, alteraciones del contorno de la encía y raíces prominentes, aunque su identificación visual es subjetiva (Liu et al., 2025). En la tomografía, la lámina ósea vestibular de los dientes anterosuperiores presenta patrones morfológicos distintos, y su grosor y el grosor gingival son predictores clave de esa morfología (Domic et al., 2026).

2.2.2.5. Técnicas

Una radiografía periapical proyecta el diente en dos dimensiones y deja ocultas las paredes vestibular y lingual, justo donde están estos defectos; por eso el diagnóstico se hace con **CBCT** (Liu et al., 2025). La fotografía intraoral se ha propuesto como filtro previo, sin radiación, para señalar qué dientes conviene revisar en la tomografía (Liu et al., 2025), y en los cortes de CBCT ya hay modelos de Deep Learning que los detectan de forma automática (Xu et al., 2026).

2.2.3. Otros temas: métricas de evaluación

Con tres clases, cada una se evalúa por separado contando, para la clase c, los aciertos (VP), los dientes asignados a ella por error (FP) y los que le pertenecían pero se asignaron a otra (FN). Con esos conteos se obtienen la precisión (Ecuación (1)), la sensibilidad o *recall*

(Ecuación (2)) y el F1 que combina ambas (Ecuación (3)):

$$\text{Precisión}_c = \frac{VP_c}{VP_c + FP_c} \tag{1}$$

$$\text{Recall}_c = \frac{VP_c}{VP_c + FN_c} \tag{2}$$

$$F1_c = \frac{2 \cdot \text{Precisión}_c \cdot \text{Recall}_c}{\text{Precisión}_c + \text{Recall}_c} \tag{3}$$

El *Macro-F1* es el promedio simple del F1 de las tres clases (Ecuación 4), por lo que cada clase pesa lo mismo sin importar cuántos dientes tenga. En cambio, el F1 ponderado pondera cada clase por su número de casos n_c sobre el total N (Ecuación 5), y la exactitud (*accuracy*) es la proporción de dientes bien clasificados (Ecuación 6):

$$\textit{Macro-F1} = \frac{1}{3} \sum_{c=1}^{3} F1_c \tag{4}$$

$$F1_{\text{pond}} = \sum_{c=1}^{3} \frac{n_c}{N} F1_c \tag{5}$$

$$\text{Exactitud} = \frac{\sum_{c=1}^{3} VP_c}{N} \tag{6}$$

El AUC-ROC mide la capacidad del modelo para ordenar los casos de una clase por encima de los demás a cualquier umbral, y se promedia entre las tres clases mediante el esquema uno contra el resto. Por último, si la fenestración y la dehiscencia se agrupan como clase patológica frente a los dientes normales, la sensibilidad indica qué proporción de dientes con algún defecto detecta el sistema, y la especificidad, qué proporción de dientes normales reconoce como tales.

2.3. Marco Conceptual o Contexto de la Investigación

2.3.1. Fenestración ósea alveolar

Defecto localizado del hueso alveolar que deja expuesta la raíz sin comprometer la cresta alveolar (Liu et al., 2025).

2.3.2. Dehiscencia ósea alveolar

Pérdida del hueso que cubre la superficie de la raíz y que compromete el margen óseo (Liu et al., 2025).

2.3.3. Tomografía computarizada de haz cónico (CBCT)

Técnica de imagen tridimensional de alta resolución considerada la modalidad de elección para diagnosticar la fenestración y la dehiscencia (Liu et al., 2025).

2.3.4. Fotografía intraoral

Imagen clínica de los dientes y la encía que se toma de rutina en ortodoncia y que muestra signos indirectos de los defectos óseos, como la recesión gingival (Liu et al., 2025).

2.3.5. Visión computacional

Campo de la inteligencia artificial cuya tarea fundamental es el reconocimiento de imágenes, que en odontología apoya el cribado y el diagnóstico a partir de fotografías y radiografías (Yuan et al., 2026).

2.3.6. Ensamble híbrido

Combinación de modelos de **Deep Learning** y de **Machine Learning** que clasifican por separado y cuya decisión final es el promedio de las probabilidades que cada uno asigna a las clases.

2.3.7. Rasgos diseñados

Medidas que un experto define de antemano sobre la imagen, como el grosor del hueso vestibular en la tomografía, y que se entregan a un clasificador de **Machine Learning**.

2.3.8. Ajuste fino

Reentrenamiento de los pesos de una red preentrenada con los datos de un problema específico para adaptar sus representaciones a ese problema.

2.4. Hipótesis

Las hipótesis son las respuestas tentativas a las preguntas del Capítulo I y siguen su misma numeración.

2.4.1. Hipótesis general

Mediante el diseño de un sistema de **visión computacional** es posible pre-diagnosticar la **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT** con un *Macro-F1* superior al obtenido usando solo la fotografía intraoral.

2.4.2. Hipótesis específicas

HE1: La verificación de integridad y de concordancia de las anotaciones permite construir a partir de **FDTooth** una cohorte sin archivos corruptos ni etiquetas discordantes.

HE2: El preprocesamiento de las **fotografías intraorales y tomografías CBCT** permite obtener una región de interés para al menos el 99 % de los dientes de la cohorte.

HE3: El **ensamble híbrido** de **Deep Learning** y **Machine Learning** obtiene un *Macro-F1* mayor que el de cada uno de sus componentes por separado en la clasificación de **fenestración y dehiscencia**.

HE4: El sistema de **visión computacional** que incorpora la **CBCT** obtiene en la prueba retenida un *Macro-F1* mayor que el de los modelos que usan solo la **fotografía intraoral**.

CAPÍTULO III: Metodología

Este capítulo explica cómo se responderán las preguntas planteadas: qué tipo de estudio es, con qué datos se trabaja, cómo se miden las variables y qué fases sigue el sistema.

3.1. Diseño de la investigación

3.1.1. Diseño

Un estudio es experimental cuando el investigador cambia a propósito una o más condiciones y observa qué efecto tiene ese cambio sobre el resultado, manteniendo lo demás bajo control (Hernández-Sampieri & Mendoza Torres, 2018). Eso es lo que se hace aquí: se varían los componentes del ensamble híbrido (tres configuraciones de la red y cuatro clasificadores) y el tipo de entrada, y se mide cómo cambia el desempeño del pre-diagnóstico, siempre sobre las mismas particiones de pacientes.

3.1.2. Tipo

La investigación es aplicada, ya que su fin no es solo ampliar el conocimiento sino resolver un problema concreto (Hernández-Sampieri & Mendoza Torres, 2018): dar al odontólogo una herramienta que le ayude a reconocer los dientes con fenestración o dehiscencia sin fiarse solo de lo que ve.

3.1.3. Enfoque

El enfoque es cuantitativo, porque las hipótesis se contrastan con datos numéricos y análisis estadístico, siguiendo pasos ordenados (Hernández-Sampieri & Mendoza Torres, 2018). Cada imagen se convierte en números y cada modelo se juzga por métricas con sus intervalos de confianza.

3.2. Población y Muestra

3.2.1. Población

La población está conformada por los 241 pacientes del dataset público **FDTooth**, de 9 a 55 años, atendidos en dos centros de la Facultad de Odontología de la Universidad de Hong Kong entre 2010 y 2023. Cada paciente cuenta con una **fotografía intraoral** frontal, una **tomografía CBCT** y la etiqueta de sus 12 dientes anteriores como normal, con **fenestración** o con **dehiscencia** (Liu et al., 2025).

3.2.2. Muestra

No se sortea a los pacientes: entran todos los que tienen datos confiables, lo que corresponde a un muestreo no probabilístico por conveniencia (Hernández-Sampieri & Mendoza Torres, 2018). Se descartan 24 pacientes, 23 porque las etiquetas del CSV y del JSON no coinciden y uno porque las cajas no encajan con su fotografía. Quedan 217 pacientes y 2604 dientes, y cada diente anterior es una unidad de análisis. La Tabla 1 reúne estos datos.

Tabla 1
Población, muestra y unidad de análisis

Dimensión	Estudio
Población	241 pacientes del dataset **FDTooth**, de 9 a 55 años, con una fotografía intraoral frontal y una tomografía CBCT cada uno, y 12 dientes anteriores etiquetados por paciente (Liu et al., 2025).
Muestra	Muestreo no probabilístico por conveniencia (Hernández-Sampieri & Mendoza Torres, 2018): 217 pacientes y 2604 dientes que cumplen los criterios de calidad. Se excluyeron 24 pacientes, 23 por discordancia entre las etiquetas del archivo CSV y del archivo JSON y uno por coordenadas de cajas incompatibles con la imagen.
Unidad de análisis	Un diente anterior, representado por su recorte de la fotografía intraoral y su región de interés de la tomografía CBCT.

Fuente: Elaboración propia.

La Figura 2 detalla la selección de la cohorte y su partición por paciente en un conjunto de desarrollo y una prueba retenida, de modo que los dientes de un mismo paciente nunca aparecen en ambos conjuntos.

3.3. Operacionalización de Variables

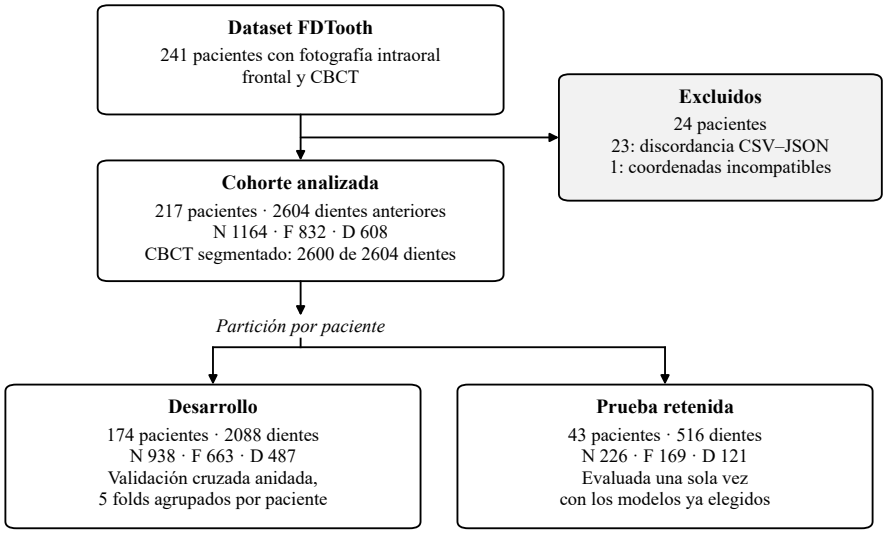
En la Tabla 2 se indica, para cada variable, qué aspectos se observan y con qué indicador se miden.

3.4. Técnicas de Recolección de Datos

No se toman datos nuevos de pacientes: se descarga **FDTooth** desde PhysioNet, que solo lo entrega a investigadores acreditados. Este dataset, publicado por Liu et al. (2025), trae por cada paciente una fotografía intraoral JPEG de 5760×3840 píxeles, una tomografía CBCT en DICOM con vóxeles de 0.15 a 0.18 mm, un archivo CSV con la etiqueta de los 12

Figura 2

Selección de la cohorte y partición por paciente



Fuente: Elaboración propia. N: normal; F: fenestración; D: dehiscencia.

Tabla 2

Operacionalización de variables

Variable	Dimensión	Indicador	Medición
VI: Sistema de visión computacional	Componente de Deep Learning	ConvNeXt V2 Tiny con Foto+CBCT, con CBCT o el promedio de ambas	Nominal
	Componente de Machine Learning	SVM, Random Forest, HistGradientBoosting o KNN con rasgos de la CBCT	Nominal
	Modalidad de entrada	Fotografía, CBCT o fusión	Nominal
VD: Pre-diagnóstico de fenestración y dehiscencia	Desempeño global	*Macro-F1*, F1 ponderado, exactitud	Ecuaciones 4–6
	Desempeño por clase	Precisión, sensibilidad y F1 de N, F y D	Ecuaciones 1–3
	Discriminación	AUC-ROC uno contra el resto	Área bajo la curva
	Detección de patología	Sensibilidad F/D y especificidad	Proporción
	Errores	Matriz de confusión	Conteo por clase

Fuente: Elaboración propia.

dientes anteriores y la caja que ubica cada diente en la fotografía. Las etiquetas las pusieron dos odontólogos con experiencia leyendo la CBCT, y coincidieron casi siempre ($\kappa > 0.9$) (Liu et al., 2025). La Tabla 3 muestra cuántos dientes de cada clase hay en desarrollo y en prueba.

Tabla 3
Clases del estudio y distribución por conjunto

Clase	Descripción	Desarrollo	Prueba
N	Normal: hueso vestibular íntegro	938	226
F	**Fenestración**: raíz expuesta sin compromiso de la cresta	663	169
D	**Dehiscencia**: pérdida de hueso que compromete el margen óseo	487	121
Total	Dientes (pacientes: 174 y 43)	2088	516

Fuente: Elaboración propia con base en Liu et al. (2025).

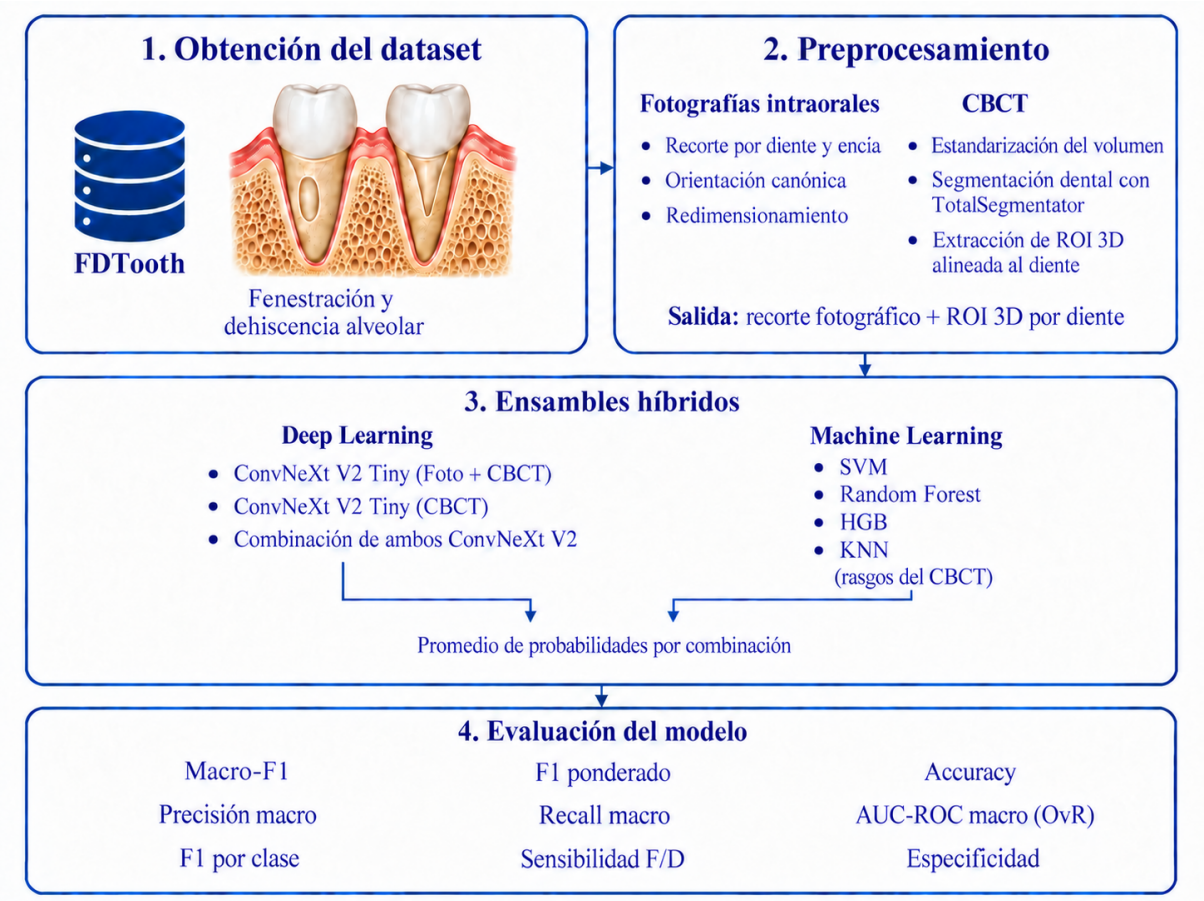
3.5. Metodología de la implementación de la solución

3.5.1. Selección de la metodología

Casi todos los sistemas de visión computacional en odontología hacen lo mismo en dos pasos: primero convierten la imagen en una descripción numérica y después la clasifican (Yuan et al., 2026). Este trabajo usa dos maneras de hacerlo: una red convolucional que aprende por sí misma qué mirar y unos rasgos del hueso medidos a mano que se entregan a clasificadores de **Machine Learning**. En lugar de quedarse con una, las combina en **ensambles híbridos** que promedian sus decisiones.

La metodología se construyó a partir de los antecedentes revisados en el Capítulo II. La obtención del dataset sigue a Liu et al. (2025), cuyo enfoque con solo **fotografías** se replica como referencia. La región de interés de cada diente en la **CBCT** se obtiene con **TotalSegmentator** (Wasserthal et al., 2023) y se analiza mediante cortes de la tomografía, como en Xu et al. (2026). Asimismo, los rasgos diseñados de la **CBCT** evaluados con varios clasificadores retoman a Song et al. (2024), y la combinación de clasificadores mediante el promedio de sus probabilidades sigue la votación suave de Sha et al. (2025). Del mismo modo, el ajuste fino de una red preentrenada se basa en Woo et al. (2023), y el uso de **fotografías** con etiquetas obtenidas de la tomografía, en J. Li et al. (2026). Lo propio de este trabajo es unir ambos tipos de modelo en un **ensamble híbrido** para distinguir por diente entre normal,

Figura 3
Metodología propuesta



Fuente: Elaboración propia.

fenestración y **dehiscencia**. El proceso se divide en cuatro fases, que resume la Figura 3.

3.5.2. Desarrollo de la metodología

3.5.2.1. Fase 1: Obtención del dataset

Se descarga **FDTooth** y, antes de usarlo, se comprueba con sumas SHA256 que ninguno de sus 487 archivos esté dañado, y se compara la etiqueta de cada diente en el CSV con la del JSON de anotaciones. Quedan fuera los pacientes cuyas etiquetas no coinciden o cuyas cajas no encajan con la imagen; al final se conservan 217 pacientes y 2604 dientes. Con esta fase se cumple el OE1.

3.5.2.2. Fase 2: Preprocesamiento

De la **fotografía intraoral** se recorta cada diente con su caja, agrandada hacia arriba para no perder el borde de la encía; el recorte se gira a una orientación común y se lleva a 768

píxeles en su lado mayor sin deformarlo. La **CBCT**, por su parte, se pasa de DICOM a valores tipo unidades Hounsfield y se segmenta con **TotalSegmentator** (Wasserthal et al., 2023), que reconoce cada diente por su número FDI. Alrededor de cada diente se recorta un bloque 3D de $14 \times 10 \times 32$ mm, orientado según su eje y remuestreado a vóxeles de 0.2 mm. Por último, los pacientes se reparten en dos grupos que no se mezclan: 174 (2088 dientes) para desarrollo y 43 (516 dientes) para la prueba final. Con esta fase se cumple el OE2.

3.5.2.3. Fase 3: Ensambles híbridos

Cada ensamble junta, a nivel de decisión, un modelo de **Deep Learning** y uno de **Machine Learning**: los dos clasifican el diente por separado y se promedian sus probabilidades de N, F y D. En la rama de **Deep Learning** se realiza el ajuste fino de **ConvNeXt V2 Tiny** (Woo et al., 2023), preentrenada en ImageNet-22k, en dos configuraciones: con una representación 2.5D de la CBCT y con la fusión de esta y de la fotografía en una arquitectura de dos ramas. Una tercera configuración promedia las dos redes. El entrenamiento usa una pérdida ponderada por clase, aumento de datos y aumento en inferencia (TTA), con la tasa de aprendizaje y el número de épocas elegidos en desarrollo, y en la prueba se promedian las probabilidades de tres semillas. Como referencia, la misma red se ajusta también con solo la fotografía. En la rama de **Machine Learning**, cada diente se describe con rasgos diseñados a partir de la CBCT: el perfil de **grosor óseo vestibular**, medido con umbrales de 400, 700 y 1000 unidades Hounsfield, del que se derivan la altura de la cresta ósea, las zonas sin hueso y el hueco óseo más largo, junto con el grosor lingual, la longitud y el volumen del diente y su posición en la arcada. Estos rasgos alimentan a **SVM**, **Random Forest**, **HistGradientBoosting** y **KNN**. Al cruzar las tres configuraciones de la red con los cuatro clasificadores se obtienen doce ensambles, y se elige el de mejor *Macro-F1* en desarrollo. La salida es la clase de cada diente: N, F o D. Esta fase responde al OE3.

3.5.2.4. Fase 4: Evaluación

En el conjunto de desarrollo se aplica una validación cruzada de cinco particiones externas agrupadas por paciente, con una validación interna para seleccionar los hiperparámetros y predicciones fuera de partición para comparar los doce ensambles. Como referencia, en las mismas particiones se replica el enfoque del antecedente basado solo en fotografías (Liu et al.,

2025) con redes convolucionales (MobileNetV3-Small, DenseNet121, ResNet50 y EfficientNet-B0) y con HOG más SVM o Random Forest. Los componentes se reentrenan con todo el conjunto de desarrollo y el ensamble elegido se evalúa una sola vez en la prueba retenida. Esta fase responde al OE4.

3.5.3. Metodología para la medición de resultados

Cada modelo se juzga con las métricas de las Ecuaciones 1 a 6, el AUC-ROC, la matriz de confusión y, al agrupar los dos defectos, la sensibilidad y la especificidad. Manda el *Macro-F1*: como da el mismo peso a las tres clases, un modelo que acierte solo los dientes normales, que son mayoría, no puede obtener un buen puntaje. Para saber cuánto confiar en cada cifra se remuestrean los pacientes 2000 veces (*bootstrap* pareado) y se obtienen intervalos de confianza del 95 %; dos modelos se consideran distintos solo si el intervalo de su diferencia no contiene el cero. Así se contrastan las hipótesis: la HE3 compara el ensamble elegido con cada uno de sus componentes, y la HE4 y la hipótesis general enfrentan los modelos con CBCT a los que solo ven la fotografía.

Referencias

Domic, D., Rodrigues, D. M., Couso-Queiruga, E., Barboza, E. P., Sanz, M., Ulm, C., & Avila-Ortiz, G. (2026). Morphological patterns of buccal bone plate in the maxillary esthetic zone: A cross-sectional study. *Journal of Periodontology*, *97*(7), 1503-1515. https://doi.org/10.1002/jper.70071

Feng, Y., Jia, Y., Lv, L., Wei, X., & Hu, M. (2026). Progress of Multimodal Imaging: Bridging Orthodontics to Comprehensive Oral Multidisciplinary Care. *International Dental Journal*, *76*(3), 109510. https://doi.org/10.1016/j.identj.2026.109510

GBD 2023 Latin America and Caribbean Oral Disorders Collaborators. (2026). The burden of oral disorders in Latin America and Caribbean countries from 1990 to 2023 and projections until 2050: a systematic analysis for the Global Burden of Disease Study 2023. *The Lancet Regional Health – Americas*, *60*, 101517. https://doi.org/10.1016/j.lana.2026.101517

Guo, R., Li, X., Hou, J., Huang, Y., Fang, B., He, H., Jin, Z., Yan, F., Wang, L., Bai, Y., Hu, W., Chen, L., Song, J., Han, X., Jin, F., Wang, J., & Hu, M. (2026). Expert consensus on orthodontic-associated alveolar ridge augmentation for adult patients. *International Journal of Oral Science*, *18*(1), 29. https://doi.org/10.1038/s41368-026-00430-x

Hernández-Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill Interamericana Editores.

Hu, M., Zhang, Q., Wei, Z., Jia, P., Yuan, M., Yu, H., Yin, X., & Peng, J. (2025). Self-supervised learning enhances periapical films segmentation with limited labeled data. *Journal of Dentistry*, *163*, 106150. https://doi.org/10.1016/j.jdent.2025.106150

Li, J., Wang, R., Yi, Z., Ni, J., Zuo, Z., & Wang, Y. (2026). Comparing Deep Learning Models for Identifying Maxillary Transverse Deficiency from Intraoral Photographs. *International Dental Journal*, *76*(4), 109689. https://doi.org/10.1016/j.identj.2026.109689

Li, Y., Cui, Z., Mei, L., Xie, Y., Marini, L., Pelekos, G., Gu, W., Yu, X., Wu, X., Wei, X., et al. (2025). A novel AI-powered radiographic analysis surpasses specialists in stage II–IV periodontitis detection: a multicenter diagnostic study. *npj Digital Medicine*, *8*(1), 691. https://doi.org/10.1038/s41746-025-02077-0

Liu, K., Elbatel, M., Chu, G., Shan, Z., Sum, F. H. K. M. H., Hung, K. F., Zhang, C., Li, X., & Yang, Y. (2025). FDTooth: Intraoral photographs and CBCT images for fenestration and dehiscence detection. *Scientific Data*, *12*, 1007. https://doi.org/10.1038/s41597-025-05348-3

Mao, K., Thu, K. M., Hung, K. F., Yu, O. Y., Hsung, R. T., & Lam, W. Y. (2025). Artificial Intelligence in Detecting Periodontal Disease From Intraoral Photographs: A Systematic Review. *International Dental Journal*, *75*(5), 100883. https://doi.org/10.1016/j.identj.2025.100883

Organización Mundial de la Salud. (2025, marzo). *Salud bucodental*. Consultado el 14 de octubre de 2026, desde https://www.who.int/news-room/fact-sheets/detail/oral-health

Palkovics, D., Molnar, B., Pinter, C., García-Mato, D., Diaz-Pinto, A., Tanacs, A., Dobos, A., Windisch, P., & Ramseier, C. A. (2026). Deep learning cone-beam computed tomography image segmentation for the 3D visualization of mandibular infraosseous periodontal defects. *Journal of Periodontology*, *97*(9), 1847-1859. https://doi.org/10.1002/jper.70058

Rashid, F., & Dudley, J. (2026). Classification of occlusal caries severity using spectrophotometric CIELAB measurements and machine learning algorithms. *Clinical Oral Investigations*, *30*(6), 233. https://doi.org/10.1007/s00784-026-06911-x

Sha, X., Wang, C., Sun, J., Qi, S., Yuan, X., Zhang, H., & Yang, J. (2025). CBCT radiomics features combine machine learning to diagnose cystic lesions in the jaw. *Dentomaxillofacial Radiology*, *54*(5), 381-388. https://doi.org/10.1093/dmfr/twaf024

Song, Y., Ma, S., Mao, B., Xu, K., Liu, Y., Ma, J., & Jia, J. (2024). Application of machine learning in the preoperative radiomic diagnosis of ameloblastoma and odontogenic keratocyst based on cone-beam CT. *Dentomaxillofacial Radiology*, *53*(5), 316-324. https://doi.org/10.1093/dmfr/twae016

Sun, L., Mu, C., Chen, L., Zhao, B., Pan, J., & Liu, Y. (2022). Dehiscence and fenestration of Class I individuals with normality patterns in the anterior region: a CBCT study. *Clinical Oral Investigations*, *26*(5), 4137-4145. https://doi.org/10.1007/s00784-022-04384-2

Tichy, A., Werner, N., Dujic, H., Wetzel, C., Pitchika, V., Bumm, C. V., Folwaczny, M., & Schwendicke, F. (2026). Artificial Intelligence in Periodontology: A Systematic Review. *Journal of Periodontal Research*, *61*(6), 639-661. https://doi.org/10.1111/jre.70107

Wasserthal, J., Breit, H.-C., Meyer, M. T., Pradella, M., Hinck, D., Sauter, A. W., Heye, T., Boll, D. T., Cyriac, J., Yang, S., Bach, M., & Segeroth, M. (2023). TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images. *Radiology: Artificial Intelligence*, *5*(5), e230024. https://doi.org/10.1148/ryai.230024

Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I. S., & Xie, S. (2023). ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 16133-16142. https://doi.org/10.1109/CVPR52729.2023.01548

Xu, A., Huang, H., Zhang, B., Dong, S., & Che, X. (2026). Using Swin UNETR deep model for automated detection of alveolar bone fenestration/dehiscence in CBCT. *Frontiers in Bioengineering and Biotechnology*, *14*, 1752350. https://doi.org/10.3389/fbioe.2026.1752350

Yang, Y., Jin, E., Bian, Z., Chen, Y., Chen, X., Wu, Y., & Tan, J. (2026). The application of deep learning in intelligent assessment of horizontal bone loss in mandibular first molars. *Clinical Oral Investigations*, *30*(10), 470. https://doi.org/10.1007/s00784-026-07180-4

Yuan, Y., Zhou, H., Wang, B., Li, C., Gong, B., & Li, Z. (2026). Integrating AI into Dentistry: Technical Pathways and Clinical Applications in Oral Diseases-A Comprehensive Overview. *International Dental Journal*, *76*(2), 109336. https://doi.org/10.1016/j.identj.2025.109336

Zhang, M., Cai, J., Cao, Q., Chen, Z., Maimaitiaili, S., Yuan, S., Yang, T., Li, Z., Zhang, Z., Yang, Y., et al. (2026). Radiomic features and carotid stenosis in periodontitis a two stage bootstrap and multimodal machine learning study. *Scientific Reports*, *16*(1), 8177. https://doi.org/10.1038/s41598-026-38463-1

Anexos

Anexo 1: Matriz de Consistencia

Problemas	**Objetivos**	**Hipótesis**	**Variables e indicadores**	**Metodología**
PG: ¿En qué medida el diseño de un sistema de visión computacional permite el pre-diagnóstico de fenestración y dehiscencia ósea alveolar a partir de fotografías intraorales y tomografías CBCT?	**OG:** Diseñar un sistema de visión computacional para el pre-diagnóstico de fenestración y dehiscencia ósea alveolar a partir de fotografías intraorales y tomografías CBCT.	**HG:** El sistema de visión computacional permite el pre-diagnóstico con un Macro-F1 superior al obtenido usando solo la fotografía intraoral.	**VI:** Sistema de visión computacional. Dimensiones: componente de Deep Learning (ConvNeXt V2 Tiny), componente de Machine Learning (SVM, RF, HGB, KNN) y modalidad (foto, CBCT, fusión).	**Diseño:** experimental.
PE1: ¿Cómo asegurar la integridad y la consistencia de las imágenes de FDTooth?	**OE1:** Construir una cohorte verificada a partir de FDTooth.	**HE1:** La verificación permite una cohorte sin archivos corruptos ni etiquetas discordantes.	**VD:** Pre-diagnóstico de fenestración y dehiscencia.	**Tipo:** aplicada.
PE2: ¿Qué técnicas de preprocesamiento permiten obtener regiones de interés comparables por diente?	**OE2:** Implementar el preprocesamiento de las fotografías y tomografías.	**HE2:** El preprocesamiento obtiene una región de interés para al menos el 99 % de los dientes.	**Indicadores:** Macro-F1, F1 ponderado, exactitud, precisión, sensibilidad, AUC-ROC, sensibilidad F/D, especificidad y matriz de confusión.	**Enfoque:** cuantitativo.
PE3: ¿Qué combinación de Deep Learning y Machine Learning en un ensamble híbrido obtiene el mejor desempeño?	**OE3:** Implementar ensambles híbridos de Deep Learning y Machine Learning.	**HE3:** El ensamble híbrido obtiene un Macro-F1 mayor que el de cada uno de sus componentes por separado.		**Población:** 241 pacientes de FDTooth.
PE4: ¿Qué desempeño alcanza el sistema en una prueba retenida?	**OE4:** Evaluar el desempeño del sistema en una prueba retenida.	**HE4:** El sistema con CBCT obtiene un Macro-F1 mayor que los modelos con solo fotografía.		**Muestra:** 217 pacientes y 2604 dientes.