

UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Diseño de un Sistema de Visión Computacional para el Pre-diagnóstico de Fenestración y Dehiscencia Ósea Alveolar a partir de Fotografías Intraorales y Tomografías CBCT

Plan de tesis

José Cabrera Ticlla
Lucero Ayala Mauricio

Asesor: Wilfredo Mamani Ticona

Lima, diciembre de 2026

DEDICATORIA

[Dedicatoria pendiente.]

Índice

Introducción **1**

I. Planteamiento del Problema **2**

1.1.. Descripción de la Realidad Problemática 2
1.2.. Formulación del Problema 3
1.2.1.. Problema general 3
1.2.2.. Problemas específicos 4
1.3.. Objetivos de la Investigación 4
1.3.1.. Objetivo general 4
1.3.2.. Objetivos específicos 4
1.4.. Justificación de la Investigación 5
1.4.1.. Teórica 5
1.4.2.. Práctica 5
1.4.3.. Metodológica 5
1.5.. Delimitación del Estudio 6
1.5.1.. Espacial 6
1.5.2.. Temporal 6
1.5.3.. Conceptual 6

II. Marco Teórico **6**

2.1.. Antecedentes de la Investigación 6
2.1.1.. Machine Learning con rasgos diseñados a mano 7
2.1.2.. Deep Learning para la evaluación del hueso alveolar 7
2.1.3.. Modelos fundacionales y fusión multimodal 8
2.2.. Bases Teóricas 9
2.2.1.. Variable independiente: sistema de visión computacional 9
2.2.2.. Variable dependiente: pre-diagnóstico de fenestración y dehiscencia . . 10
2.2.3.. Otros temas: métricas de evaluación 11
2.3.. Marco Conceptual o Contexto de la Investigación 12
2.3.1.. Fenestración ósea alveolar 12
2.3.2.. Dehiscencia ósea alveolar 12
2.3.3.. Tomografía computarizada de haz cónico (CBCT) 13
2.3.4.. Fotografía intraoral 13
2.3.5.. Visión computacional 13
2.3.6.. Modelo fundacional 13
2.3.7.. Ajuste fino 13
2.4.. Hipótesis 13

2.4.1.. Hipótesis general 13
2.4.2.. Hipótesis específicas 14

III. Metodología **14**
3.1.. Diseño de la investigación 14
3.1.1.. Diseño 14
3.1.2.. Tipo 15
3.1.3.. Enfoque 15
3.2.. Población y Muestra 15
3.3.. Operacionalización de Variables 15
3.4.. Técnicas de Recolección de Datos 16
3.5.. Metodología de la implementación de la solución 17
3.5.1.. Selección de la metodología 17
3.5.2.. Desarrollo de la metodología 17
3.5.3.. Metodología para la medición de resultados 19

Referencias **20**

Anexos **23**

Índice de Figuras

1. Metodología propuesta 17

Índice de Tablas

1. Población, muestra y unidad de análisis 15
2. Operacionalización de variables 16
3. Clases del estudio y distribución en el conjunto de desarrollo 16

Resumen

La **fenestración** y la **dehiscencia ósea alveolar** son defectos frecuentes en los dientes anteriores que se asocian con recesión gingival, exposición radicular y, en casos severos, pérdida del diente. Su diagnóstico depende de la **tomografía computarizada de haz cónico (CBCT)**, cuyo uso rutinario está limitado por la radiación y el tiempo que demanda, mientras que la inspección visual de las **fotografías intraorales** es subjetiva. El objetivo de la presente investigación es diseñar un sistema de **visión computacional** para el pre-diagnóstico por diente de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. La metodología se organiza en cuatro fases: control de calidad del dataset **FDTooth**, preprocesamiento de ambas modalidades, extracción de características y modelado, y evaluación. Se comparan tres metodologías: rasgos diseñados a mano con clasificadores de **Machine Learning**, ajuste fino de **ConvNeXt V2 Tiny** y representaciones del modelo fundacional **DINOv2** con clasificadores de **Machine Learning**, sobre una cohorte de 217 pacientes y 2604 dientes. En la validación cruzada preliminar del conjunto de desarrollo, ninguna metodología superó un *Macro-F1* de 0.535 con solo la fotografía, mientras que un ensamble basado en el ajuste fino y en rasgos de la **CBCT** alcanzó 0.810 y un AUC de 0.933. Estos resultados indican que la **CBCT** es indispensable para distinguir ambos defectos y que el ajuste fino supera a los rasgos diseñados a mano y al modelo fundacional congelado. La evaluación final se realizará una sola vez en una prueba retenida de 43 pacientes.

Palabras clave: **fenestración**, **dehiscencia**, **CBCT**, **fotografía intraoral**, **visión computacional**, **Deep Learning**, **Machine Learning**.

Abstract

[Traducción del Resumen pendiente.]

Keywords: **fenestration**, **dehiscence**, **CBCT**, **intraoral photography**, **computer vision**, **Deep Learning**, **Machine Learning**.

Borrador. Problema Solución Dataset Del mismo modo, Asimismo, Por otra parte

Introducción

La salud bucal es parte de la salud general, y las enfermedades que afectan al soporte de los dientes terminan, en sus etapas avanzadas, en la pérdida de piezas dentarias (Organización Mundial de la Salud, 2025). Entre estas alteraciones se encuentran la **fenestración** y la **dehiscencia ósea alveolar**, dos defectos del hueso que cubre la raíz de los dientes. Estos defectos suelen pasar inadvertidos en el examen clínico y se descubren cuando ya condicionan un tratamiento, por ejemplo al planificar el movimiento de los dientes en ortodoncia (Guo et al., 2026).

El diagnóstico de ambos defectos se apoya en la **tomografía computarizada de haz cónico (CBCT)**, que muestra el hueso alveolar en tres dimensiones. Sin embargo, la CBCT expone al paciente a radiación y demanda tiempo, por lo que no se usa en cada control, y la fotografía intraoral, que sí se toma de rutina, solo muestra signos indirectos como la recesión de la encía (Liu et al., 2025). Por ello, el odontólogo suele decidir con información incompleta cuándo solicitar una tomografía.

En los últimos años, la **inteligencia artificial** y en particular la **visión computacional** se han incorporado al diagnóstico odontológico, con modelos que analizan radiografías, tomografías y fotografías clínicas (Yuan et al., 2026). La publicación del dataset **FDTooth**, que reúne por primera vez fotografías intraorales y tomografías CBCT de los mismos pacientes con etiquetas por diente (Liu et al., 2025), hace posible estudiar de forma conjunta ambas modalidades.

En este contexto, la presente investigación propone el diseño de un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**. El sistema compara tres metodologías: rasgos diseñados a mano con clasificadores de **Machine Learning**, ajuste fino de una red convolucional y representaciones de un modelo fundacional, y clasifica cada diente anterior como normal, con fenestración o con dehiscencia.

El documento se organiza en tres capítulos. El Capítulo I presenta el planteamiento del

problema, los objetivos, la justificación y la delimitación del estudio. El Capítulo II desarrolla el marco teórico, que incluye los antecedentes, las bases teóricas de ambas variables, el marco conceptual y las hipótesis. Por último, el Capítulo III describe la metodología: el diseño de la investigación, la población y la muestra, la operacionalización de variables, la recolección de datos y las fases de implementación del sistema.

CAPÍTULO I: Planteamiento del Problema

En el presente capítulo se describe la realidad problemática, se formulan el problema general y los problemas específicos, se plantean los objetivos y se presentan la justificación y la delimitación del estudio.

1.1. Descripción de la Realidad Problemática

La Organización Mundial de la Salud estima que cerca de 3700 millones de personas padecen enfermedades bucodentales y que la periodontopatía grave supera los 1000 millones de casos en el mundo; asimismo, la pérdida total de dientes afecta a cerca del 7 % de las personas de 20 años o más y al 23 % de las de 60 años o más (Organización Mundial de la Salud, 2025). Dentro de este panorama, la **fenestración** es un defecto localizado del hueso alveolar que expone la raíz sin comprometer la cresta, mientras que la **dehiscencia** es la pérdida del hueso que cubre la raíz y afecta al margen óseo. Ambas se asocian con exposición radicular, necrosis pulpar, recesión gingival, bolsas periodontales profundas y, en casos severos, pérdida del diente (Liu et al., 2025).

Estos defectos son frecuentes incluso en personas sin maloclusiones severas. Sun et al. (2022) analizaron mediante **CBCT** 732 dientes anteriores de 61 individuos Clase I y encontraron dehiscencia en el 27.46 % y fenestración en el 26.91 % de los dientes, con al menos un defecto en el 48.91 % de ellos y en la totalidad de los pacientes. Del mismo modo, un consenso de expertos señala que estos defectos son comunes en los adultos que buscan tratamiento ortodóntico y que pueden agravarse durante el movimiento de los dientes (Guo et al., 2026).

En América Latina y el Caribe, el Estudio de la Carga Global de la Enfermedad 2023 estimó 308.2 millones de casos prevalentes de trastornos bucales, que ocupan el primer lugar en

prevalencia entre todas las causas de enfermedad de la región. Dentro de ellos, la periodontitis severa fue el segundo trastorno más prevalente, con 87.2 millones de casos, y su discapacidad aumentó en 25 % o más desde 1990 en la mayoría de los países (GBD 2023 Latin America and Caribbean Oral Disorders Collaborators, 2026). En el Perú, el mismo estudio ubica al país con la segunda tasa más alta de años vividos con discapacidad por edentulismo en adultos de 60 años o más de la región, con 1366.9 por cada 100 000 habitantes, solo por debajo de Bolivia (GBD 2023 Latin America and Caribbean Oral Disorders Collaborators, 2026). Además, la evidencia epidemiológica bucal de la región se concentra en Brasil, México, Chile y Colombia, y los estudios peruanos sobre estos defectos son escasos.

El problema se agrava porque el diagnóstico depende de un examen que no puede repetirse en cada control. La **CBCT** es la modalidad de imagen de elección para diagnosticar estos defectos, pero su uso rutinario es poco práctico por la exposición a radiación y el tiempo que demanda; por otra parte, las radiografías bidimensionales no muestran con suficiente detalle el hueso vestibular, y la inspección visual de las **fotografías intraorales** es subjetiva, lenta y puede ser poco precisa (Liu et al., 2025). El único modelo publicado que detecta estos defectos a partir de fotografías del dataset **FDTooth** alcanzó un AUC de 0.76 y una especificidad de 0.65, y no distingue entre fenestración y dehiscencia (Liu et al., 2025). En consecuencia, no existe aún un sistema que aproveche ambas modalidades para pre-diagnosticar por diente cuál de los dos defectos está presente.

1.2. Formulación del Problema

Para la identificación del problema general y de los problemas específicos se tomó como base la realidad problemática descrita y las fases de la metodología propuesta, de modo que cada problema específico corresponde a una fase del sistema.

1.2.1. Problema general

¿En qué medida el diseño de un sistema de **visión computacional** permite el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**?

1.2.2. Problemas específicos

PE1: ¿Cómo asegurar la integridad y la consistencia de las **fotografías intraorales y tomografías CBCT** del dataset **FDTooth** para el pre-diagnóstico de **fenestración y dehiscencia**?

PE2: ¿Qué técnicas de preprocesamiento permiten obtener regiones de interés comparables por diente a partir de las **fotografías intraorales y tomografías CBCT**?

PE3: ¿Qué metodología de extracción de características y modelado de **Machine Learning** y **Deep Learning** obtiene el mejor desempeño en la clasificación de **fenestración y dehiscencia**?

PE4: ¿Qué desempeño alcanza el sistema de **visión computacional** en el pre-diagnóstico por diente de **fenestración y dehiscencia** en una prueba retenida?

1.3. Objetivos de la Investigación

Para la identificación del objetivo general y de los objetivos específicos se tomaron como base el problema general y los problemas específicos, de modo que cada objetivo responde a uno de ellos.

1.3.1. Objetivo general

Diseñar un sistema de **visión computacional** para el pre-diagnóstico de **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT**.

1.3.2. Objetivos específicos

OE1: Construir una cohorte verificada de **fotografías intraorales y tomografías CBCT** a partir del dataset **FDTooth**.

OE2: Implementar el preprocesamiento de las **fotografías intraorales y tomografías CBCT** para obtener una región de interés por diente.

OE3: Implementar y comparar tres metodologías de extracción de características y modelado basadas en **Machine Learning** y **Deep Learning** para la clasificación de **fenestración y dehiscencia**.

OE4: Evaluar el desempeño del sistema de **visión computacional** en el pre-diagnóstico por diente de **fenestración y dehiscencia** mediante el *Macro-F1* y métricas complementarias en una prueba retenida.

1.4. Justificación de la Investigación

1.4.1. Teórica

Esta investigación aporta evidencia sobre qué tipo de representación visual distingue mejor la **fenestración** de la **dehiscencia**: rasgos diseñados a mano, una red convolucional ajustada o un modelo fundacional. Asimismo, contrasta el aporte de la **fotografía intraoral** y de la **CBCT** por separado y combinadas, un aspecto que los trabajos previos no han evaluado en una tarea de tres clases (Liu et al., 2025; Xu et al., 2026).

1.4.2. Práctica

Al término de esta investigación se contará con un sistema que clasifica cada diente anterior como normal, con fenestración o con dehiscencia, y que puede servir al odontólogo como apoyo para decidir cuándo solicitar o revisar con mayor detalle una tomografía. Esto es relevante en ortodoncia, donde los defectos previos deben identificarse antes de mover los dientes (Guo et al., 2026).

1.4.3. Metodológica

La investigación aplica un protocolo de evaluación que evita la fuga de información: la partición es por paciente, la selección de modelos se realiza con validación cruzada anidada y la prueba retenida se usa una sola vez. Además, compara tres metodologías bajo las mismas condiciones y con intervalos de confianza por *bootstrap*, lo que permite replicar el procedimiento en otros problemas de imagen dental.

1.5. Delimitación del Estudio

1.5.1. Espacial

El presente trabajo de investigación se desarrolla en la Universidad ESAN, en Lima, Perú. Los datos provienen del dataset público **FDTooth**, recolectado en dos centros de la Facultad de Odontología de la Universidad de Hong Kong (Liu et al., 2025).

1.5.2. Temporal

La presente investigación se desarrolla durante el semestre académico 2026-2, entre agosto y diciembre de 2026. Los datos utilizados fueron recolectados entre enero de 2010 y enero de 2023 (Liu et al., 2025).

1.5.3. Conceptual

Esta investigación se centra en la clasificación de los 12 dientes anteriores de cada paciente en tres clases: normal, **fenestración** y **dehiscencia**. El sistema realiza un pre-diagnóstico de apoyo y no reemplaza el diagnóstico clínico ni la lectura de la tomografía por un especialista. No se aborda el tratamiento de los defectos ni el despliegue del sistema en un entorno clínico.

CAPÍTULO II: Marco Teórico

En el presente capítulo se presentan los antecedentes de la investigación, las bases teóricas de la variable independiente y de la variable dependiente, el marco conceptual y las hipótesis.

2.1. Antecedentes de la Investigación

A continuación, se presentan los antecedentes encontrados para entender cómo se ha tratado el tema de investigación, organizados según las tres metodologías que compara este trabajo.

2.1.1. Machine Learning con rasgos diseñados a mano

Los clasificadores de **Machine Learning** alimentados con rasgos cuantitativos de la imagen, como los radiómicos, de textura y de color, han sido ampliamente estudiados para el diagnóstico de **lesiones de los maxilares** en **CBCT**. Song et al. (2024) extrajeron 348 rasgos radiómicos de las **CBCT** de 326 pacientes para diferenciar **ameloblastoma y queratoquiste odontogénico** con seis algoritmos, y **XGBoost** alcanzó una exactitud de 0.843, un F1 de 0.841 y un AUC de 0.872, con un desempeño superior al de los radiólogos. Del mismo modo, Sha et al. (2025) integraron seis rasgos radiómicos de las **CBCT** de 300 pacientes en un clasificador por votación suave que combina **Random Forest, SVM y regresión logística**, y obtuvieron en el conjunto de prueba valores de AUC de 0.781 a 0.849 y una exactitud de 0.711 al distinguir tres tipos de **lesiones quísticas**. Asimismo, centrándose en pacientes con **periodontitis**, Zhang et al. (2026) emplearon 206 rasgos radiómicos de **CBCT**, y el modelo **Random Forest** logró un AUC de 0.710 para detectar aterosclerosis carotídea concomitante. Por otra parte, Rashid y Dudley (2026) transformaron mediciones de color **CIELAB** de 300 dientes extraídos en rasgos diseñados para clasificar la severidad de la **caries oclusal**, y observaron que los modelos basados en árboles rindieron por debajo de las redes neuronales, que alcanzaron una exactitud balanceada de 0.89. En conjunto, estos trabajos muestran que los rasgos diseñados a mano son interpretables y eficaces con muestras moderadas, pero ninguno los aplicó a la **fenestración y dehiscencia** ni a **fotografías intraorales**.

2.1.2. Deep Learning para la evaluación del hueso alveolar

Conscientes de las limitaciones de los rasgos diseñados a mano, trabajos recientes han aplicado **Deep Learning** a la evaluación del **soporte óseo periodontal**. Tichy et al. (2026) revisaron 29 estudios de **Deep Learning** para el diagnóstico de **periodontitis** y reportaron exactitudes de 81 a 99 % en radiografías panorámicas y de 78 % en **CBCT**, así como un AUROC de 0.93 en el cribado con **fotografías**, aunque advirtieron que la mayoría utilizó datos de un solo centro. Del mismo modo, Yang et al. (2026) entrenaron una **3D-ResNet** con 505 **CBCT** para clasificar la **pérdida ósea horizontal** de los primeros molares inferiores y alcanzaron una exactitud global de 0.829, comparable a la de los odontólogos (0.820). Asimismo, Palkovics

et al. (2026) utilizaron una **SegResNet** para segmentar en **CBCT** los **defectos periodontales infraóseos** mandibulares con mediciones confiables, mientras que Xu et al. (2026) entrenaron un **Swin UNETR** con 10 752 cortes sagitales de **CBCT** y detectaron la **fenestración y dehiscencia** con exactitudes de 0.82 a 0.95 a nivel de diente. Por otra parte, en el caso de las **fotografías intraorales**, Mao et al. (2025) analizaron 26 estudios de detección de **enfermedad periodontal** y hallaron exactitudes de clasificación de 0.46 a 1.00, con solo 9 estudios que usaron más de una vista. De igual manera, J. Li et al. (2026) compararon seis **redes convolucionales** entrenadas con **fotografías intraorales frontales** de 826 pacientes, usando como referencia mediciones derivadas de **CBCT**, y **ResNet-18** alcanzó una exactitud de 90.62 % en un conjunto de prueba externo para detectar la **deficiencia transversal maxilar**. Estos resultados confirman que un modelo basado en fotografías puede aprender de etiquetas obtenidas por **CBCT**, aunque el desempeño varía según la tarea y la vista utilizada.

2.1.3. Modelos fundacionales y fusión multimodal

Ante la escasez de datos etiquetados, los **modelos fundacionales** preentrenados de forma autosupervisada y la **fusión multimodal** se perfilan como alternativas al entrenamiento supervisado desde cero. Hu et al. (2025) adaptaron **DINOv2** mediante aprendizaje autosupervisado específico del dominio para segmentar **radiografías periapicales** con pocas anotaciones, y lograron un Dice de 74.77 % frente a 33.53–41.55 % de U-Net y DeepLabV3+. Del mismo modo, Y. Li et al. (2025) preentrenaron y ajustaron el modelo **HC-Net+** con 10 881 **ortopantomografías** para detectar **periodontitis** en estadios II a IV y superaron a los periodoncistas, con un AUROC de 94.2 % frente a 85.6 %. Asimismo, Feng et al. (2026) revisaron la **fusión de datos multimodales** en ortodoncia y concluyeron que integrar modalidades compensa las limitaciones de resolución y de especificidad tisular de cada una por separado. Sin embargo, el único trabajo que aborda la **fenestración y dehiscencia** con **fotografías intraorales** pareadas con **CBCT**, el de Liu et al. (2025), empleó un ensamble de **redes convolucionales** supervisadas solo sobre la fotografía y en una tarea binaria. Hasta donde se conoce, no se ha evaluado un **modelo fundacional** ni la **fusión** de ambas modalidades para distinguir por diente entre normal, **fenestración** y **dehiscencia**.

2.2. Bases Teóricas

2.2.1. Variable independiente: sistema de visión computacional

2.2.1.1. Definición

El aprendizaje automático o **Machine Learning** es un componente de la inteligencia artificial que usa algoritmos para que las computadoras aprendan patrones a partir de grandes cantidades de datos y hagan predicciones sobre datos nuevos sin una programación explícita. El aprendizaje profundo o **Deep Learning** es un subconjunto del Machine Learning que usa redes neuronales con muchas capas ocultas y permite tareas complejas como el análisis de imágenes médicas (Yuan et al., 2026). Dentro de este campo, el reconocimiento de imágenes es una tarea fundamental de la **visión computacional**, y en odontología resulta clave porque el cribado, el diagnóstico y la planificación del tratamiento de la mayoría de las enfermedades bucales dependen de la interpretación de fotografías clínicas, radiografías e imágenes histopatológicas (Yuan et al., 2026). En esta investigación, el sistema de visión computacional es el conjunto de fases que transforma las **fotografías intraorales y tomografías CBCT** de un paciente en una clase por diente.

2.2.1.2. Clasificación

Según la forma en que obtienen la representación de la imagen, los métodos que compara este trabajo se clasifican en tres grupos:

- **Rasgos diseñados a mano con Machine Learning.** Un experto define qué medir en la imagen, como la textura, el color o el grosor del hueso, y un clasificador como **SVM**, **Random Forest**, **Gradient Boosting** o **KNN** aprende a separar las clases a partir de esos valores (Sha et al., 2025; Song et al., 2024).

- **Ajuste fino de redes convolucionales.** Una red convolucional preentrenada aprende directamente de la imagen sus propias representaciones, y sus pesos se reajustan con los datos del problema. Las redes convolucionales son el marco predominante de Deep Learning para el análisis de imágenes dentales (Yuan et al., 2026), y **ConvNeXt V2** es una arquitectura reciente de este tipo (Woo et al., 2023).

- **Modelos fundacionales.** Son modelos entrenados mediante autosupervisión con conjuntos de datos grandes y diversos, que pueden reutilizarse en tareas distintas con pocos datos etiquetados (Moor et al., 2023). **DINOv2** es un modelo de este tipo cuyas representaciones pueden usarse sin reentrenar la red (Oquab et al., 2023), y ya se ha aplicado a imágenes dentales (Hu et al., 2025).

2.2.1.3. Primeras referencias

Las primeras aplicaciones de la visión computacional a estos defectos son recientes. Liu et al. (2025) publicaron **FDTooth**, el primer dataset público que combina fotografías intraorales y tomografías CBCT para su detección, junto con un modelo de referencia basado solo en fotografías. Del mismo modo, Xu et al. (2026) propusieron un modelo de Deep Learning que mide y detecta ambos defectos directamente en cortes de CBCT. Estos trabajos constituyen el punto de partida de la presente investigación.

2.2.2. Variable dependiente: pre-diagnóstico de fenestración y dehiscencia

2.2.2.1. Definición

La **fenestración** es un defecto localizado del hueso alveolar que expone la raíz del diente sin comprometer la cresta alveolar, mientras que la **dehiscencia** es la pérdida del hueso que cubre la superficie de la raíz y suele afectar al margen óseo (Liu et al., 2025). En esta investigación, el pre-diagnóstico es la clasificación automática de cada diente anterior como normal, con fenestración o con dehiscencia, que orienta pero no sustituye la evaluación del especialista.

2.2.2.2. Factores

Los defectos óseos alveolares tienen una etiología multifactorial que incluye anomalías craneofaciales congénitas, periodontitis crónica y alteraciones funcionales de la oclusión (Guo et al., 2026). Su frecuencia varía según el tipo de maloclusión: la dehiscencia es común en los dientes anteriores inferiores de pacientes con maloclusión esquelética Clase III de ángulo alto y en pacientes con biprotrusión, mientras que la fenestración predomina en los dientes anteriores superiores de pacientes con maloclusión esquelética Clase II (Guo et al., 2026). Asimismo,

un fenotipo periodontal delgado, una recesión gingival previa y un reborde alveolar estrecho aumentan el riesgo de que aparezcan o se agraven durante el tratamiento ortodóntico (Guo et al., 2026).

2.2.2.3. Etapas

Según el momento en que aparecen, los defectos pueden ser previos al tratamiento, cuando ya están presentes en la evaluación inicial, o adquiridos durante el tratamiento ortodóntico, en particular cuando el movimiento planificado excede los límites del hueso alveolar (Guo et al., 2026). Si no se detectan, la raíz expuesta favorece la acumulación de placa y la inflamación, y la enfermedad periodontal puede progresar hasta la pérdida del diente (Liu et al., 2025).

2.2.2.4. Características

En las fotografías intraorales, los dientes con estos defectos suelen mostrar signos indirectos como recesión gingival, alteraciones del contorno de la encía y raíces prominentes, aunque su identificación visual es subjetiva (Liu et al., 2025). En la tomografía, la lámina ósea vestibular de los dientes anterosuperiores presenta patrones morfológicos distintos, y su grosor y el grosor gingival son predictores clave de esa morfología (Domic et al., 2026).

2.2.2.5. Técnicas

Las radiografías bidimensionales, como las periapicales, no muestran con suficiente detalle los defectos vestibulares o linguales, por lo que la **CBCT** es la modalidad de imagen de elección para su diagnóstico (Liu et al., 2025). Las fotografías intraorales se proponen como un primer paso no invasivo para identificar los dientes en riesgo y orientar el uso de la CBCT (Liu et al., 2025), y los modelos de Deep Learning ya permiten detectar los defectos de forma automática en cortes tomográficos (Xu et al., 2026).

2.2.3. Otros temas: métricas de evaluación

Para un problema de clasificación en tres clases, cada métrica se calcula a partir de los verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN) de cada clase c. La precisión y la sensibilidad (*recall*) se definen en las Ecuaciones (1) y (2), y el F1 de cada clase

en la Ecuación (3):

$$\text{Precisión}_c = \frac{VP_c}{VP_c + FP_c} \tag{1}$$

$$\text{Recall}_c = \frac{VP_c}{VP_c + FN_c} \tag{2}$$

$$F1_c = \frac{2 \cdot \text{Precisión}_c \cdot \text{Recall}_c}{\text{Precisión}_c + \text{Recall}_c} \tag{3}$$

El *Macro-F1* es el promedio simple del F1 de las tres clases (Ecuación 4), por lo que cada clase pesa lo mismo sin importar cuántos dientes tenga. En cambio, el F1 ponderado pondera cada clase por su número de casos n_c sobre el total N (Ecuación 5), y la exactitud (*accuracy*) es la proporción de dientes bien clasificados (Ecuación 6):

$$\textit{Macro-F1} = \frac{1}{3} \sum_{c=1}^{3} F1_c \tag{4}$$

$$F1_{\text{pond}} = \sum_{c=1}^{3} \frac{n_c}{N} F1_c \tag{5}$$

$$\text{Exactitud} = \frac{\sum_{c=1}^{3} VP_c}{N} \tag{6}$$

Por último, el AUC-ROC mide la capacidad del modelo para ordenar los casos de una clase por encima de los demás a cualquier umbral, y se promedia entre las tres clases mediante el esquema uno contra el resto.

2.3. Marco Conceptual o Contexto de la Investigación

2.3.1. Fenestración ósea alveolar

Defecto localizado del hueso alveolar que deja expuesta la raíz sin comprometer la cresta alveolar (Liu et al., 2025).

2.3.2. Dehiscencia ósea alveolar

Pérdida del hueso que cubre la superficie de la raíz y que compromete el margen óseo (Liu et al., 2025).

2.3.3. Tomografía computarizada de haz cónico (CBCT)

Técnica de imagen tridimensional de alta resolución considerada la modalidad de elección para diagnosticar la fenestración y la dehiscencia (Liu et al., 2025).

2.3.4. Fotografía intraoral

Imagen clínica de los dientes y la encía que se toma de rutina en ortodoncia y que muestra signos indirectos de los defectos óseos, como la recesión gingival (Liu et al., 2025).

2.3.5. Visión computacional

Campo de la inteligencia artificial cuya tarea fundamental es el reconocimiento de imágenes, que en odontología apoya el cribado y el diagnóstico a partir de fotografías y radiografías (Yuan et al., 2026).

2.3.6. Modelo fundacional

Modelo entrenado mediante autosupervisión con grandes conjuntos de datos diversos, capaz de adaptarse a nuevas tareas con pocos o ningún dato etiquetado (Moor et al., 2023).

2.3.7. Ajuste fino

Reentrenamiento de los pesos de una red preentrenada con los datos de un problema específico para adaptar sus representaciones a ese problema.

2.4. Hipótesis

Para la identificación de la hipótesis general y de las hipótesis específicas se tomaron como base los problemas y objetivos identificados previamente.

2.4.1. Hipótesis general

Mediante el diseño de un sistema de **visión computacional** es posible pre-diagnosticar la **fenestración y dehiscencia ósea alveolar** a partir de **fotografías intraorales y tomografías CBCT** con un *Macro-F1* superior al obtenido usando solo la fotografía intraoral.

2.4.2. Hipótesis específicas

HE1: La verificación de integridad y de concordancia de las anotaciones permite construir a partir de **FDTooth** una cohorte sin archivos corruptos ni etiquetas discordantes.

HE2: El preprocesamiento de las **fotografías intraorales y tomografías CBCT** permite obtener una región de interés para al menos el 99 % de los dientes de la cohorte.

HE3: El ajuste fino de una red convolucional obtiene un *Macro-F1* significativamente mayor que los rasgos diseñados a mano y que el modelo fundacional congelado en la clasificación de **fenestración y dehiscencia**.

HE4: El sistema de **visión computacional** que incorpora la **CBCT** obtiene en la prueba retenida un *Macro-F1* mayor que el de los modelos que usan solo la **fotografía intraoral**.

CAPÍTULO III: Metodología

En el presente capítulo se define el diseño, el tipo y el enfoque de la investigación, y se describen la población y la muestra, la operacionalización de variables, la recolección de datos y la metodología de implementación de la solución.

3.1. Diseño de la investigación

3.1.1. Diseño

Según Hernández-Sampieri y Mendoza Torres (2018), en un diseño experimental se manipulan deliberadamente una o más variables independientes para analizar sus consecuencias sobre una o más variables dependientes en una situación de control. El diseño del presente trabajo de investigación es experimental, porque se manipula la variable independiente, el sistema de visión computacional, mediante tres metodologías y tres modalidades de entrada, y se observa su efecto sobre la variable dependiente, el desempeño del pre-diagnóstico, bajo las mismas particiones de datos.

3.1.2. Tipo

Para Hernández-Sampieri y Mendoza Torres (2018), la investigación aplicada busca resolver problemas prácticos. El presente trabajo de investigación es de tipo aplicado, porque busca ofrecer un apoyo al odontólogo para identificar los dientes con fenestración o dehiscencia sin depender solo de la inspección visual.

3.1.3. Enfoque

Según Hernández-Sampieri y Mendoza Torres (2018), el enfoque cuantitativo usa la recolección de datos y el análisis estadístico para probar hipótesis siguiendo un proceso secuencial. El enfoque de la presente investigación es cuantitativo, porque las imágenes se transforman en valores numéricos y el desempeño de los modelos se mide con métricas y con intervalos de confianza.

3.2. Población y Muestra

La Tabla 1 resume la población, la muestra y la unidad de análisis del estudio.

Tabla 1
Población, muestra y unidad de análisis

Dimensión	Estudio
Población	241 pacientes del dataset **FDTooth**, de 9 a 55 años, con una fotografía intraoral frontal y una tomografía CBCT cada uno, y 12 dientes anteriores etiquetados por paciente (Liu et al., 2025).
Muestra	Muestreo no probabilístico por conveniencia (Hernández-Sampieri & Mendoza Torres, 2018): 217 pacientes y 2604 dientes que cumplen los criterios de calidad. Se excluyeron 24 pacientes, 23 por discordancia entre las etiquetas del archivo CSV y del archivo JSON y uno por coordenadas de cajas incompatibles con la imagen.
Unidad de análisis	Un diente anterior, representado por su recorte de la fotografía intraoral y su región de interés de la tomografía CBCT.

Nota. Elaboración propia.

3.3. Operacionalización de Variables

La Tabla 2 presenta la operacionalización de la variable independiente y de la variable dependiente.

Tabla 2
Operacionalización de variables

Variable	Dimensión	Indicador	Medición
VI: Sistema de visión computacional	Metodología	M1 rasgos diseñados + ML; M2 ajuste fino de ConvNeXt V2 Tiny; M3 DINOv2 + ML	Nominal
	Modalidad de entrada	Fotografía, CBCT o fusión	Nominal
	Clasificador	SVM, RF, GB, KNN o regresión logística	Nominal
VD: Pre-diagnóstico de fenestración y dehiscencia	Desempeño global	*Macro-F1*, F1 ponderado, exactitud	Ecuaciones 4–6
	Desempeño por clase	Precisión, sensibilidad y F1 de N, F y D	Ecuaciones 1–3
	Discriminación	AUC-ROC uno contra el resto	Área bajo la curva
	Errores	Matriz de confusión	Conteo por clase

Nota. Elaboración propia.

3.4. Técnicas de Recolección de Datos

La recolección de datos se realiza de forma digital mediante la descarga del dataset **FDTooth** desde la plataforma PhysioNet, que lo distribuye con acceso acreditado. El dataset corresponde al trabajo de Liu et al. (2025) e incluye, para cada paciente, una fotografía intraoral en formato JPEG de 5760×3840 píxeles, una tomografía CBCT en formato DICOM con un tamaño de vóxel de 0.15 a 0.18 mm, un archivo CSV con la etiqueta de cada uno de los 12 dientes anteriores y las cajas delimitadoras de los dientes en la fotografía. Las etiquetas provienen de la lectura de la CBCT por dos odontólogos experimentados, con una concordancia $\kappa > 0.9$ (Liu et al., 2025). La Tabla 3 describe las clases y su distribución en el conjunto de desarrollo.

Tabla 3
Clases del estudio y distribución en el conjunto de desarrollo

Clase	Descripción	Dientes
N	Normal: hueso vestibular íntegro	938
F	**Fenestración**: raíz expuesta sin compromiso de la cresta	663
D	**Dehiscencia**: pérdida de hueso que compromete el margen óseo	487
Total	174 pacientes del conjunto de desarrollo	2088

Nota. Elaboración propia con base en Liu et al. (2025).

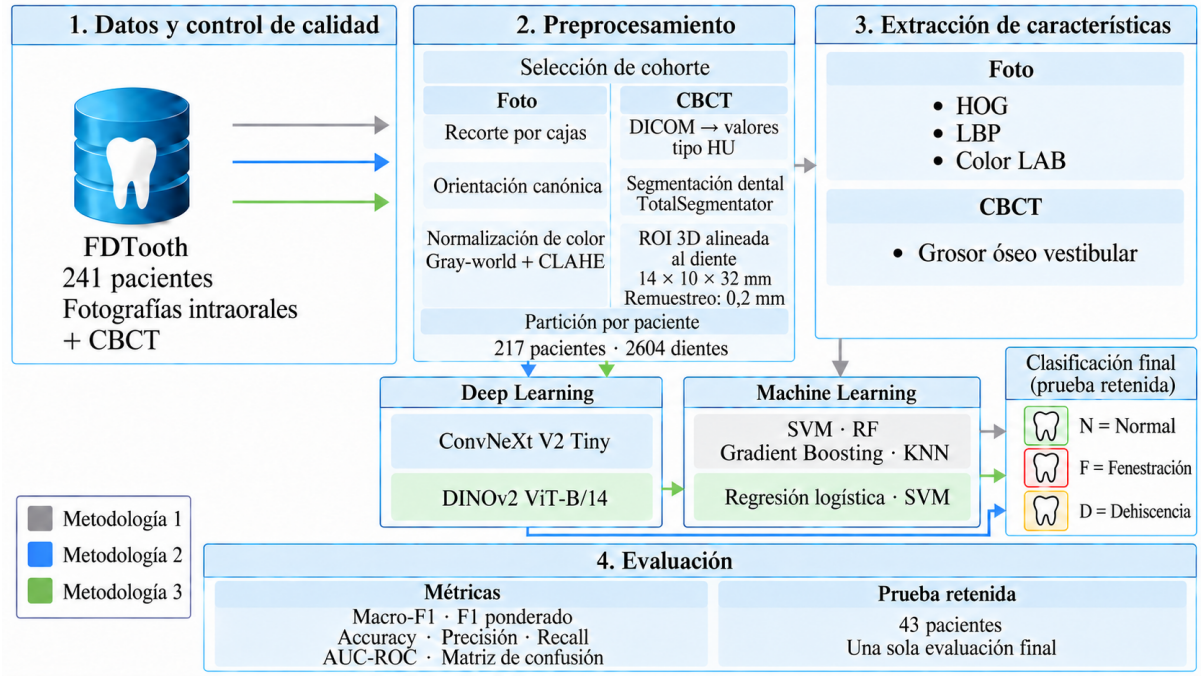
3.5. Metodología de la implementación de la solución

3.5.1. Selección de la metodología

La metodología seleccionada se basa en el flujo habitual de los sistemas de visión computacional en odontología, que transforma la imagen en una representación y luego la clasifica (Yuan et al., 2026). Sobre ese flujo se organizan cuatro fases y se comparan tres metodologías que difieren en cómo obtienen la representación: M1 con rasgos diseñados a mano, M2 con el ajuste fino de una red convolucional y M3 con un modelo fundacional congelado. La Figura 1 muestra la metodología propuesta.

Figura 1

Metodología propuesta



Nota. Elaboración propia.

3.5.2. Desarrollo de la metodología

3.5.2.1. Fase 1: Datos y control de calidad

En esta fase se verifica la integridad de los 487 archivos del dataset **FDTooth** mediante sumas SHA256 y se contrastan las etiquetas del archivo CSV con las del archivo JSON de anotaciones dentales. Se excluyen los pacientes con etiquetas discordantes o con coordenadas

de cajas incompatibles con la imagen, y se obtiene una cohorte de 217 pacientes y 2604 dientes. Esta fase responde al OE1.

3.5.2.2. Fase 2: Preprocesamiento

En la **fotografía intraoral**, cada diente se recorta a partir de su caja delimitadora, ampliada hacia la encía para incluir el margen gingival, se lleva a una orientación canónica y se redimensiona a 768 píxeles en su lado largo sin deformar la imagen. Luego se normaliza el color con el método **Gray-world**, que corrige el balance de blancos, y con **CLAHE**, que realza el contraste local. Asimismo, la **CBCT** se convierte de DICOM a valores tipo unidades Hounsfield y se segmenta con **TotalSegmentator** (Wasserthal et al., 2023), que identifica cada diente según la numeración FDI. A partir de cada segmentación se extrae una región de interés 3D de $14 \times 10 \times 32$ mm, alineada con el eje del diente y remuestreada a vóxeles de 0.2 mm. Por último, la cohorte se particiona por paciente en un conjunto de desarrollo de 174 pacientes (2088 dientes) y una prueba retenida de 43 pacientes (516 dientes). Esta fase responde al OE2.

3.5.2.3. Fase 3: Extracción de características y modelado

En la M1, cada diente se representa con rasgos diseñados a mano: el histograma de gradientes orientados (**HOG**) reducido con análisis de componentes principales, los patrones binarios locales uniformes (**LBP**) y estadísticas de color **LAB** del diente y la encía en la fotografía, y el perfil de **grosor óseo vestibular** en la CBCT, del que se derivan la altura de la cresta ósea y las zonas sin hueso. Estos rasgos alimentan a **SVM**, **Random Forest**, **Gradient Boosting** y **KNN**. En la M2, se realiza el ajuste fino de **ConvNeXt V2 Tiny** (Woo et al., 2023) con la fotografía, con una representación 2.5D de la CBCT y con la fusión de ambas en una arquitectura de dos ramas, usando aumento de datos y parada temprana. Por otra parte, en la M3 el modelo fundacional **DINOv2 ViT-B/14** (Oquab et al., 2023) se usa como extractor congelado, y sus representaciones se clasifican con **regresión logística** y **SVM**. Finalmente, se evalúa un ensamble de los mejores modelos. La salida de todas las metodologías es la clase de cada diente: N, F o D. Esta fase responde al OE3.

3.5.2.4. Fase 4: Evaluación

En el conjunto de desarrollo se aplica una validación cruzada de cinco particiones externas agrupadas por paciente, con una validación interna para seleccionar los hiperparámetros y predicciones fuera de partición para comparar las configuraciones. La mejor configuración de cada metodología se reentrena con todo el conjunto de desarrollo y se evalúa una sola vez en la prueba retenida. Esta fase responde al OE4.

3.5.3. Metodología para la medición de resultados

El análisis de los resultados de la implementación se realiza mediante la evaluación de las métricas definidas en las Ecuaciones 1 a 6, del AUC-ROC y de la matriz de confusión. La métrica principal es el *Macro-F1*, porque pondera por igual las tres clases y no premia a un modelo que solo acierta la clase mayoritaria. Los intervalos de confianza del 95 % y las diferencias entre modelos se estiman mediante *bootstrap* de pacientes con 1000 a 2000 remuestreos, y una diferencia se considera significativa cuando su intervalo no incluye el cero. Con estos criterios se contrastan las hipótesis: la HE3 compara el *Macro-F1* de las tres metodologías y la HE4 y la hipótesis general comparan los modelos con CBCT frente a los que usan solo la fotografía.

Referencias

Domic, D., Rodrigues, D. M., Couso-Queiruga, E., Barboza, E. P., Sanz, M., Ulm, C., & Avila-Ortiz, G. (2026). Morphological patterns of buccal bone plate in the maxillary esthetic zone: A cross-sectional study. *Journal of Periodontology*, *97*(7), 1503-1515. https://doi.org/10.1002/jper.70071

Feng, Y., Jia, Y., Lv, L., Wei, X., & Hu, M. (2026). Progress of Multimodal Imaging: Bridging Orthodontics to Comprehensive Oral Multidisciplinary Care. *International Dental Journal*, *76*(3), 109510. https://doi.org/10.1016/j.identj.2026.109510

GBD 2023 Latin America and Caribbean Oral Disorders Collaborators. (2026). The burden of oral disorders in Latin America and Caribbean countries from 1990 to 2023 and projections until 2050: a systematic analysis for the Global Burden of Disease Study 2023. *The Lancet Regional Health – Americas*, *60*, 101517. https://doi.org/10.1016/j.lana.2026.101517

Guo, R., Li, X., Hou, J., Huang, Y., Fang, B., He, H., Jin, Z., Yan, F., Wang, L., Bai, Y., Hu, W., Chen, L., Song, J., Han, X., Jin, F., Wang, J., & Hu, M. (2026). Expert consensus on orthodontic-associated alveolar ridge augmentation for adult patients. *International Journal of Oral Science*, *18*(1), 29. https://doi.org/10.1038/s41368-026-00430-x

Hernández-Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill Interamericana Editores.

Hu, M., Zhang, Q., Wei, Z., Jia, P., Yuan, M., Yu, H., Yin, X., & Peng, J. (2025). Self-supervised learning enhances periapical films segmentation with limited labeled data. *Journal of Dentistry*, *163*, 106150. https://doi.org/10.1016/j.jdent.2025.106150

Li, J., Wang, R., Yi, Z., Ni, J., Zuo, Z., & Wang, Y. (2026). Comparing Deep Learning Models for Identifying Maxillary Transverse Deficiency from Intraoral Photographs. *International Dental Journal*, *76*(4), 109689. https://doi.org/10.1016/j.identj.2026.109689

Li, Y., Cui, Z., Mei, L., Xie, Y., Marini, L., Pelekos, G., Gu, W., Yu, X., Wu, X., Wei, X., et al. (2025). A novel AI-powered radiographic analysis surpasses specialists in stage II–IV periodontitis detection: a multicenter diagnostic study. *npj Digital Medicine*, *8*(1), 691. https://doi.org/10.1038/s41746-025-02077-0

Liu, K., Elbatel, M., Chu, G., Shan, Z., Sum, F. H. K. M. H., Hung, K. F., Zhang, C., Li, X., & Yang, Y. (2025). FDTooth: Intraoral photographs and CBCT images for fenestration and dehiscence detection. *Scientific Data*, *12*, 1007. https://doi.org/10.1038/s41597-025-05348-3

Mao, K., Thu, K. M., Hung, K. F., Yu, O. Y., Hsung, R. T., & Lam, W. Y. (2025). Artificial Intelligence in Detecting Periodontal Disease From Intraoral Photographs: A Systematic Review. *International Dental Journal*, *75*(5), 100883. https://doi.org/10.1016/j.identj.2025.100883

Moor, M., Banerjee, O., Abad, Z. S. H., Krumholz, H. M., Leskovec, J., Topol, E. J., & Rajpurkar, P. (2023). Foundation models for generalist medical artificial intelligence. *Nature*, *616*(7956), 259-265. https://doi.org/10.1038/s41586-023-05881-4

Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., et al. (2023). DINOv2: Learning Robust Visual Features without Supervision.

Organización Mundial de la Salud. (2025, marzo). *Salud bucodental*. Consultado el 14 de octubre de 2026, desde https://www.who.int/news-room/fact-sheets/detail/oral-health

Palkovics, D., Molnar, B., Pinter, C., García-Mato, D., Diaz-Pinto, A., Tanacs, A., Dobos, A., Windisch, P., & Ramseier, C. A. (2026). Deep learning cone-beam computed tomography image segmentation for the 3D visualization of mandibular infraosseous periodontal defects. *Journal of Periodontology*, *97*(9), 1847-1859. https://doi.org/10.1002/jper.70058

Rashid, F., & Dudley, J. (2026). Classification of occlusal caries severity using spectrophotometric CIELAB measurements and machine learning algorithms. *Clinical Oral Investigations*, *30*(6), 233. https://doi.org/10.1007/s00784-026-06911-x

Sha, X., Wang, C., Sun, J., Qi, S., Yuan, X., Zhang, H., & Yang, J. (2025). CBCT radiomics features combine machine learning to diagnose cystic lesions in the jaw. *Dentomaxillofacial Radiology*, *54*(5), 381-388. https://doi.org/10.1093/dmfr/twaf024

Song, Y., Ma, S., Mao, B., Xu, K., Liu, Y., Ma, J., & Jia, J. (2024). Application of machine learning in the preoperative radiomic diagnosis of ameloblastoma and odontogenic keratocyst based on cone-beam CT. *Dentomaxillofacial Radiology*, *53*(5), 316-324. https://doi.org/10.1093/dmfr/twae016

Sun, L., Mu, C., Chen, L., Zhao, B., Pan, J., & Liu, Y. (2022). Dehiscence and fenestration of Class I individuals with normality patterns in the anterior region: a CBCT study. *Clinical Oral Investigations*, *26*(5), 4137-4145. https://doi.org/10.1007/s00784-022-04384-2

Tichy, A., Werner, N., Dujic, H., Wetzel, C., Pitchika, V., Bumm, C. V., Folwaczny, M., & Schwendicke, F. (2026). Artificial Intelligence in Periodontology: A Systematic Review. *Journal of Periodontal Research*, *61*(6), 639-661. https://doi.org/10.1111/jre.70107

Wasserthal, J., Breit, H.-C., Meyer, M. T., Pradella, M., Hinck, D., Sauter, A. W., Heye, T., Boll, D. T., Cyriac, J., Yang, S., Bach, M., & Segeroth, M. (2023). TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images. *Radiology: Artificial Intelligence*, *5*(5), e230024. https://doi.org/10.1148/ryai.230024

Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I. S., & Xie, S. (2023). ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 16133-16142. https://doi.org/10.1109/CVPR52729.2023.01548

Xu, A., Huang, H., Zhang, B., Dong, S., & Che, X. (2026). Using Swin UNETR deep model for automated detection of alveolar bone fenestration/dehiscence in CBCT. *Frontiers in*

Bioengineering and Biotechnology, *14*, 1752350. https://doi.org/10.3389/fbioe.2026.1752350

Yang, Y., Jin, E., Bian, Z., Chen, Y., Chen, X., Wu, Y., & Tan, J. (2026). The application of deep learning in intelligent assessment of horizontal bone loss in mandibular first molars. *Clinical Oral Investigations*, *30*(10), 470. https://doi.org/10.1007/s00784-026-07180-4

Yuan, Y., Zhou, H., Wang, B., Li, C., Gong, B., & Li, Z. (2026). Integrating AI into Dentistry: Technical Pathways and Clinical Applications in Oral Diseases-A Comprehensive Overview. *International Dental Journal*, *76*(2), 109336. https://doi.org/10.1016/j.identj.2025.109336

Zhang, M., Cai, J., Cao, Q., Chen, Z., Maimaitiaili, S., Yuan, S., Yang, T., Li, Z., Zhang, Z., Yang, Y., et al. (2026). Radiomic features and carotid stenosis in periodontitis a two stage bootstrap and multimodal machine learning study. *Scientific Reports*, *16*(1), 8177. https://doi.org/10.1038/s41598-026-38463-1

Anexos

Anexo 1: Matriz de Consistencia

Problemas	Objetivos	Hipótesis	Variables e indicadores	Metodología
PG: ¿En qué medida el diseño de un sistema de visión computacional permite el pre-diagnóstico de fenestración y dehiscencia ósea alveolar a partir de fotografías intraorales y tomografías CBCT?	**OG:** Diseñar un sistema de visión computacional para el pre-diagnóstico de fenestración y dehiscencia ósea alveolar a partir de fotografías intraorales y tomografías CBCT.	**HG:** El sistema de visión computacional permite el pre-diagnóstico con un Macro-F1 superior al obtenido usando solo la fotografía intraoral.	**VI:** Sistema de visión computacional. Dimensiones: metodología (M1, M2, M3), modalidad (foto, CBCT, fusión) y clasificador.	**Diseño:** experimental.
PE1: ¿Cómo asegurar la integridad y la consistencia de las imágenes de FDTooth?	**OE1:** Construir una cohorte verificada a partir de FDTooth.	**HE1:** La verificación permite una cohorte sin archivos corruptos ni etiquetas discordantes.	**VD:** Pre-diagnóstico de fenestración y dehiscencia.	**Tipo:** aplicada.
PE2: ¿Qué técnicas de preprocesamiento permiten obtener regiones de interés comparables por diente?	**OE2:** Implementar el preprocesamiento de las fotografías y tomografías.	**HE2:** El preprocesamiento obtiene una región de interés para al menos el 99 % de los dientes.	**Indicadores:** Macro-F1, F1 ponderado, exactitud, precisión, sensibilidad, AUC-ROC y matriz de confusión.	**Enfoque:** cuantitativo.
PE3: ¿Qué metodología de extracción de características y modelado obtiene el mejor desempeño?	**OE3:** Implementar y comparar tres metodologías de ML y DL.	**HE3:** El ajuste fino supera de forma significativa a los rasgos diseñados y al modelo fundacional congelado.		**Población:** 241 pacientes de FDTooth.
PE4: ¿Qué desempeño alcanza el sistema en una prueba retenida?	**OE4:** Evaluar el desempeño del sistema en una prueba retenida.	**HE4:** El sistema con CBCT obtiene un Macro-F1 mayor que los modelos con solo fotografía.		**Muestra:** 217 pacientes y 2604 dientes.