UNIVERSIDAD ESAN

FACULTAD DE INGENIERÍA

INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Modelo híbrido basado en Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de Seguridad Aeroportuaria

Trabajo de Tesis II

Cabello Espinoza Rodrigo Alejandro

Infantes Vargas Edgar Fernando

Asesor: Wilfredo Mamani Ticona

Lima, 21 junio de 2026

Tesis XRay - Cabello_Infantes Última Entrega (1) (1).docx

ORIGINALITY REPORT

4%	4%	2%	1%
SIMILARITY INDEX	INTERNET SOURCES	PUBLICATIONS	STUDENT PAPERS

PRIMARY SOURCES

1	repositorio.esan.edu.pe Internet Source	2%
2	repositorio.uncp.edu.pe Internet Source	2%
3	Songlin Zhang, Dingju Zhu, KaiLeung Yung, Andrew W. H. Ip. "Balanced X-ray Security Dataset and Enhanced YOLO for Contraband Detection", Scientific Data, 2025 Publication	1%

Exclude quotes	Off	Exclude matches	< 1%
Exclude bibliography	Off		

DEDICATORIA

Dedicamos este trabajo a nuestras familias,

por ser el apoyo principal en nuestra formación

y en cada etapa de nuestra carrera.

Índice

Resumen....1
Abstract....2
Introducción....3
Capítulo I: Planteamiento del Problema....6
1.1 Descripción de la Realidad Problemática....6
1.2 Formulación del Problema....13
1.2.1 Problema general....13
1.2.2 Problemas específicos....13
1.3 Objetivos de la Investigación....14
1.3.1 Objetivo general....14
1.3.2 Objetivos específicos....14
1.4 Justificación de la Investigación....14
1.4.1 Teórica....14
1.4.2 Práctica....15
1.4.3 Metodológica....15
1.5 Delimitación del Estudio....16
1.5.1 Espacial....16
1.5.2 Temporal....16
1.5.3 Conceptual....16
Capítulo II: Marco Teórico....17
2.1 Antecedentes de la Investigación....17
2.1.1 Resumen de artículos....17
2.2 Bases Teóricas....32
2.2.1 Inteligencia Artificial....32
2.2.2 Machine Learning....33
2.2.3 Deep Learning....35

2.2.4 Computer Vision....41
2.2.5 Objetos Prohibidos en el Contexto de la Seguridad Aeroportuaria....45
2.3 Marco Conceptual y Contexto de la Investigación....48
2.3.1 *Clutter* (Oclusión y desorden visual)....49
2.3.2 Embedding (Vector de Características)....49
2.3.3 Overfitting (Sobreajuste)....49
2.3.4 PCA (Análisis de Componentes Principales)....49
2.3.5 UMAP....49
2.3.6 K-Fold (Validación Cruzada Estratificada)....50
2.3.7 Early Stopping....50
2.3.8 ImageNet....50
2.3.9 Formato DICOM....50
2.3.10 API y FastAPI....50
2.3.11 Frame (Fotograma)....51
2.4 Hipótesis....51
2.4.1 Hipótesis general....51
2.4.2 Hipótesis específicas....51
Capítulo III: Metodología de la Investigación....53
3.1 Diseño de la investigación....53
3.1.1 Diseño....53
3.1.2 Tipo....53
3.1.3 Enfoque....54
3.2 Población y Muestra....54
3.3 Operacionalización de Variables....55
3.4 Técnicas de Recolección de Datos....56
3.5 Metodología de la implementación de la solución....58
3.5.1 Selección de la metodología....58

3.5.2 Obtención del dataset....59
3.5.3 Preprocesamiento....59
3.5.4 Feature Extraction....61
3.5.5 Machine Learning....64
3.5.6 Evaluación....66
3.5.7 Despliegue....67
3.6 Metodología para la Medición de los Resultados de la Implementación....74
3.6.1 Métricas para el modelo YOLOv8....74
3.6.2 Métricas para el modelo híbrido DL-ML....75
3.7 Cronograma de Actividades....78
3.8 Presupuesto....79
Capítulo IV: Desarrollo de la Solución....80
4.1 Determinación y evaluación de alternativas de solución....80
4.1.1 Alternativa 1: Enfoque basado en Machine Learning tradicional....80
4.1.2 Alternativa 2: Enfoque basado exclusivamente en Deep Learning....81
4.1.3 Alternativa 3: Enfoque híbrido basado en Deep Learning y Machine Learning....82
4.1.4 Comparación de alternativas....83
4.2 Propuesta de Solución....84
4.2.1 Planeamiento y Descripción de Actividades....84
4.2.2 Desarrollo de Actividades. Aplicación de Herramientas de solución. 87
4.3 Medición de la Solución....99
4.3.1 Análisis de indicadores cuantitativos y cualitativos (Fase 5: Evaluación)....100
4.3.2 Aplicación del software y visualización de resultados (Fase 6: Despliegue)....102
Capítulo V: Resultados y Análisis....111
Capítulo VI: Conclusiones y Recomendaciones....116
6.1 Conclusiones....116
6.2 Recomendaciones....118

REFERENCIAS BIBLIOGRÁFICAS.....120

ANEXOS 125

ÍNDICE DE FIGURAS

Figura 1. Estadísticas Mensuales de Sostenibilidad y Economía de la IATA. 6
Figura 2. Tráfico aéreo por principales mercados de América Latina y el Caribe, 2025 (en millones de pasajeros y crecimiento interanual). 10
Figura 3. Operativo conjunto de la PNP y Sucamec: incautación de armas de fuego y municiones de origen irregular. 11
Figura 4. Comparativa de la frecuencia de clases de objetos prohibidos antes y después de aplicación de CSAF y undersampling aleatorio. 18
Figura 5. Imágenes originales vs imágenes con data augmentation. 19
Figura 6. Muestras de las 5 categorías de “cutters”. 22
Figura 7. Resultados de visualización de la atención en imágenes de rayos X. 23
Figura 8. Comparación de los resultados de detección de los modelos YOLOv8s. (a) Modelo YOLOv8s original y (b) modelo YOLOv8s mejorado. 26
Figura 9. Muestras de las predicciones de los modelos. 29
Figura 10. Evolución histórica de la visión artificial. 31
Figura 11. Arquitectura AlexNet. 38
Figura 12. Ejemplo de proceso de detección de objetos mediante YOLO 44
Figura 13. Ejemplos de objetos prohibidos en imágenes de rayos X. 45
Figura 14. Metodología de la investigación. 58
Figura 15. Diagrama de la Arquitectura Lógica del Despliegue. 70
Figura 16. Diagrama de la Arquitectura de Inferencia. 71
Figura 17. Diagrama del Pipeline de Procesamiento de Video 73
Figura 18. Cronograma de Actividades. 78
Figura 19. Arquitectura general de un sistema basado en extracción manual de características y clasificación mediante Machine Learning. 81
Figura 20. Arquitectura general de una solución basada exclusivamente en Deep Learning. . 82
Figura 21. Arquitectura general del enfoque híbrido propuesto. 83
Figura 23. Estructura general del repositorio de las imágenes originales y su etiquetado. 88
Figura 24. Flujo de procesamiento para el recorte de objetos prohibidos y reorganización del dataset. 89
Figura 25. Resultado del proceso de recorte de regiones de interés: (a) Imagen de rayos X original y (b) Región de interés (Crop). 89
Figura 26. Flujo de procesamiento para redimensionamiento de las imágenes. 91

Figura 27. Flujo de procesamiento para la mejora de contraste de las imágenes. 92
Figura 28. Flujo de procesamiento para la localización y generación de bounding boxes mediante YOLOv8. 94
Figura 29. Flujo de procesamiento para la extracción profunda de características 97
Figura 30. Flujo de procesamiento para la clasificación final. 97
Figura 31. Estructura de directorios del proyecto. 104
Figura 32. Almacenamiento de modelos en Cloud Storage. 105
Figura 33. Interfaz de prueba de la API. 106
Figura 34. Arquitectura del pipeline CI/CD en GCP. 107
Figura 35. Registros de Docker. 108
Figura 36. Respuesta exitosa de la API en el navegador. 109
Figura 37. Interfaz inicial de la Aplicación X-Ray Security Portal. 110
Figura 38. Visualización de resultados y alerta de detección en tiempo real. 110
Figura 39. Matriz de Confusión del modelo híbrido con mejor rendimiento. 113
Figura 40. AUC ROC del mejor modelo. 114

ÍNDICE DE TABLAS

Tabla 1. Resultados del Mercado Global de Transporte Aéreo de Pasajeros (Abril 2026) 7
Tabla 2. Indicadores de tráfico aéreo en América Latina y el Caribe, 2025 9
Tabla 3. Comparación de modelos de detección en conjunto de datos balanceados 19
Tabla 4. Comparativa de rendimiento (mAP) entre el módulo DOAM y mecanismos de atención 23
Tabla 5. Resultados del estudio de ablación de los módulos MCA, PConv y Focaler-IoU sobre el rendimiento del modelo YOLOv8s 26
Tabla 6. Comparación con otros modelos en el dataset 28
Tabla 7. Listado de objetos prohibidos 47
Tabla 8. Población, muestra y unidad de análisis del estudio 54
Tabla 9. Operacionalización de Variables 55
Tabla 10. Descripción de las 12 clases de objetos prohibidos 57
Tabla 11. Actividades de Preprocesamiento 60
Tabla 12. Recursos del proyecto 79
Tabla 13. Comparación de Alternativas 83
Tabla 14. Distribución del dataset en los conjuntos de entrenamiento, validación y prueba 92
Tabla 15. Resultados comparativos de las arquitecturas híbridas evaluadas en el conjunto de prueba 111

Resumen

El incremento del tráfico aéreo en el Perú, con 25.5 millones de pasajeros movilizados por el Aeropuerto Internacional Jorge Chávez en 2025, ha aumentado la presión sobre los puntos de control de seguridad, donde la inspección de equipaje mediante rayos X depende de inspectores humanos expuestos a la fatiga visual, lo que incrementa el riesgo de omitir objetos peligrosos debido a la oclusión y el desorden visual generado por la superposición de artículos en el equipaje. El estudio tuvo como objetivo desarrollar un modelo híbrido basado en Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria, para lo cual se utilizó el dataset SIXray-PIDray, compuesto por 13,728 imágenes balanceadas en 12 categorías de objetos prohibidos en el contexto de seguridad aeroportuaria; las imágenes fueron preprocesadas mediante recorte de regiones de interés, redimensionamiento con relleno de bordes y mejora de contraste (CLAHE), y posteriormente procesadas con un detector YOLOv8 para la localización de los objetos. Las características visuales fueron extraídas evaluando ocho arquitecturas preentrenadas (EfficientNetV2-S, ConvNeXt-Tiny, Swin Transformer-Tiny, entre otras), y se entrenaron cinco algoritmos de Machine Learning (Regresión Logística, Linear SVM, RBF SVM, LightGBM y CatBoost) para la clasificación final, culminando en el despliegue del sistema como una API REST en Google Cloud Platform. Los resultados, evaluados mediante Accuracy, F1-macro y AUC, evidenciaron que el mejor clasificador fue la combinación de EfficientNetV2-S (fine-tuned) con Regresión Logística Multinomial, alcanzando 95.02% en Accuracy, 94.96% en F1-macro y 99.8% en AUC-macro, superando en 3.76% a la mejor alternativa basada en ConvNeXt-Tiny y confirmando que la arquitectura híbrida mejora significativamente la detección de objetos prohibidos frente a los enfoques tradicionales.

Palabras clave: Deep Learning, Machine Learning, detección de objetos, imágenes de rayos X, seguridad aeroportuaria, modelo híbrido.

Abstract

The growth of air traffic in Peru, with 25.5 million passengers handled by Jorge Chávez International Airport in 2025, has increased the pressure on airport security checkpoints, where baggage inspection through X-ray imaging relies on human inspectors exposed to visual fatigue, raising the risk of missing dangerous objects due to occlusion and visual clutter caused by overlapping items inside the baggage. The study aimed to develop a hybrid model based on Deep Learning and Machine Learning for the detection of prohibited items in X-ray images within the context of airport security, for which the SIXray-PIDray dataset was used, composed of 13,728 balanced images across 12 categories of prohibited items; the images were preprocessed through region-of-interest cropping, padding-based resizing, and contrast enhancement (CLAHE), and subsequently processed with a YOLOv8 detector for object localization. Visual features were extracted by evaluating eight pretrained architectures (EfficientNetV2-S, ConvNeXt-Tiny, Swin Transformer-Tiny, among others), and five Machine Learning algorithms (Logistic Regression, Linear SVM, RBF SVM, LightGBM, and CatBoost) were trained for the final classification, culminating in the deployment of the system as a REST API on Google Cloud Platform. The results, evaluated through Accuracy, F1-macro, and AUC, showed that the best classifier was the combination of fine-tuned EfficientNetV2-S with Multinomial Logistic Regression, achieving 95.02% Accuracy, 94.96% F1-macro, and 99.8% macro AUC, outperforming the best ConvNeXt-Tiny-based alternative by 3.76% and confirming that the hybrid architecture significantly improves prohibited item detection compared to traditional approaches.

Keywords: Deep Learning, Machine Learning, object detection, X-ray imaging, airport security, hybrid model.

Introducción

En la actualidad, el incremento del comercio global y el flujo constante de bienes a través de fronteras han intensificado la necesidad de sistemas de seguridad más efectivos. La revisión de equipajes y carga mediante rayos X es el núcleo de estos sistemas de seguridad; sin embargo, esta labor mayormente recae en inspectores humanos, quienes, como en cualquier otra actividad que requiere atención frecuente, pueden enfrentar fatiga visual al realizar las inspecciones durante largos periodos de tiempo, lo que podría generar limitaciones cognitivas y posiblemente omisiones. Según la Asociación Internacional de Transporte Aéreo (IATA, 2025), el tráfico global de pasajeros ha superado los niveles prepandemia, proyectando un crecimiento sostenido hacia el 2026, lo que aumenta la presión operativa en los puestos de control. En este escenario, el error humano sigue siendo el factor más riesgoso en la omisión de objetos peligrosos.

La trayectoria de la Inteligencia Artificial ha demostrado avances significativos frente a este tipo de limitaciones. No obstante, la detección automática de rayos X sigue siendo un problema debido al contraste, los fondos saturados y las oclusiones múltiples. A pesar de los avances en Deep Learning, los despliegues en el mundo real todavía presentan problemas de confusión de clases y variabilidad de dominio, lo que a menudo genera que modelos de una sola etapa tengan una alta tasa de falsos positivos (Talbi et al., 2025). Ante esto, organismos como la Organización de Aviación Civil Internacional (OACI) toman relevancia en integrar tecnologías avanzadas para cumplir con los estándares de seguridad.

A nivel latinoamericano, esta problemática tiene relevancia debido a que las exportaciones regionales crecieron un 6,4% en 2025 (Giordano y Michalczewsky, 2026), lo que ha sobrepasado la capacidad de inspección de muchos centros aduaneros. Según CEPAL (2025), aunque la región avanza en la adopción de la Inteligencia Artificial (IA), persiste una brecha tecnológica en la automatización de procesos críticos de seguridad. En este contexto, la

modernización de los sistemas de inspección es una prioridad para poder mitigar el error humano y enfrentar la creciente complejidad del comercio ilícito en puntos de control estratégicos de la región.

En el contexto peruano, esta problemática resulta especialmente relevante en los controles de seguridad aeroportuaria. El crecimiento de infraestructuras como el Aeropuerto Internacional Jorge Chávez ha provocado un aumento considerable en el número de imágenes de rayos X de equipajes que deben analizarse cada día. Ante este escenario, las autoridades de seguridad de la aviación deben afrontar desafíos como identificar no solo armas, sino también artículos prohibidos que intentan ser ingresados a las aeronaves. En este contexto, los procesos de inspección manual pueden convertirse en un cuello de botella y representar un posible riesgo para la seguridad nacional.

Con el objetivo de abordar esta problemática, el presente estudio plantea la implementación de un modelo híbrido aplicado al contexto de la seguridad aeroportuaria. Esta propuesta combina técnicas de detección y localización de objetos y extracción de características basadas en algoritmos Deep Learning con algoritmos de clasificación de Machine Learning, buscando mejorar la precisión en la identificación de objetos prohibidos durante los procesos de inspección de equipaje en terminales aéreos. Mediante esta estrategia, se busca disminuir significativamente los errores de detección y contribuir a la automatización de un proceso clave para el fortalecimiento de la seguridad aeroportuaria.

El presente trabajo de investigación está conformado por 6 capítulos. El primer capítulo se enfoca en el planteamiento del problema, el cual describe la realidad problemática y se establecen los objetivos. El segundo capítulo presenta la base teórica, detallando los fundamentos conceptuales relacionados con las arquitecturas híbridas, así como los principales antecedentes a nivel internacional. El capítulo 3, dedicado a la metodología, detalla el diseño de la investigación y las métricas empleadas para la evaluación del modelo. El Capítulo 4,

correspondiente al desarrollo de la solución, detalla el proceso de entrenamiento del modelo y los experimentos desarrollados. El Capítulo 5 se dedica a los resultados y análisis, espacio donde se contrastan cuantitativamente los resultados obtenidos frente a las métricas y la literatura científica. Finalmente, el Capítulo 6 presenta las conclusiones y recomendaciones, sintetizando los aportes más significativos del estudio y proponiendo futuras líneas de investigación.

Capítulo I: Planteamiento del Problema

1.1 Descripción de la Realidad Problemática

En el contexto mundial, la seguridad en puntos estratégicos de tránsito como aeropuertos y aduanas se enfrenta a problemas cada vez más complejos debido al crecimiento del comercio y el turismo global, lo que ha puesto en duda los métodos tradicionales de control en estos puntos. De acuerdo con los reportes macroeconómicos de la Asociación Internacional de Transporte Aéreo (IATA, 2026), el mercado global de pasajeros experimentó una ligera reducción interanual del 3.4% en los Pasajeros-Kilómetro Facturados o RPK (*Revenue Passenger Kilometers*, por sus siglas en inglés) en el mes de abril. Esta métrica, que representa el indicador estándar de la industria para medir la demanda real de tráfico aéreo mediante la multiplicación del número de pasajeros que pagaron un boleto por la distancia total en kilómetros que recorrieron, interrumpió la tendencia de crecimiento constante tras la recuperación post-pandemia debido a las interrupciones operativas por conflictos geopolíticos y el incremento en los precios del petróleo. Sin embargo, la presión sobre los puntos de control sigue siendo crítica, registrando un volumen masivo de 748 mil millones de RPK (IATA, 2026).

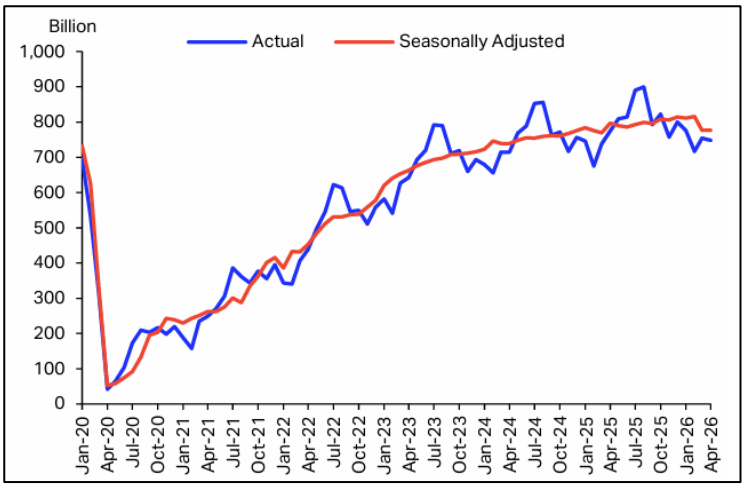


Figura 1. Estadísticas Mensuales de Sostenibilidad y Economía de la IATA.

Fuente: IATA (2026)

Por otro lado, se mantiene el factor de ocupación global o PLF (*Passenger Load Factor*, por sus siglas en inglés) del 83.1%. (IATA, 2026). Esta métrica evalúa la eficiencia operativa de las aerolíneas al calcular el porcentaje de capacidad de asientos disponibles que ha sido efectivamente ocupada por pasajeros que pagan de manera regular.

Tabla 1.
Resultados del Mercado Global de Transporte Aéreo de Pasajeros (Abril 2026)

	World	**April 2026 (year-on-year YoY, %)**				**April 2026 (year-to-date YtD, %)**			
Segmento	**share, %[1]**	**RPK**	**ASK**	**PLF (%-pt)**	**PLF (level)**	**RPK**	**ASK**	**PLF (%-pt)**	**PLF (level)**
TOTAL MARKET	**100.0**	**-3.4**	**-2.9**	**-0.4**	**83.1**	**2.1**	**1.0**	**0.9**	**82.6**
International	62.8	-5.3	-5.1	-0.2	83.9	1.5	-0.1	1.3	82.8
Domestic	37.2	0.0	0.8	-0.7	81.9	3.1	2.8	0.2	82.3

Nota. YoY: Variación Interanual; YtD: Variación Acumulada del Año a la Fecha. [1]% de la industria RPK.

Fuente: Adaptado de IATA (2026)

Como se puede apreciar en la Tabla 1, la reducción interanual del 3.4% en el mercado global está determinada por el segmento internacional, el cual concentra el 62.8% del total de la industria y sufrió una caída del 5.3% en su demanda (IATA, 2026). Ante esto, las aerolíneas redujeron los Asientos-Kilómetro Disponibles o ASK (*Available Seat Kilometers*, por sus siglas en inglés) en un 5.1% (IATA, 2026). Esta métrica representa el indicador estándar para medir la oferta total de la industria, calculada multiplicando la cantidad de asientos disponibles para la venta por la distancia en kilómetros de los vuelos. Sin embargo, a pesar de este ajuste en la oferta, el factor de ocupación global se mantuvo en un nivel crítico del 83.9% (IATA, 2026).

El presente comportamiento estadístico demuestra que, aunque la frecuencia de vuelos disminuyó por la coyuntura geopolítica, los aviones que operan lo hacen casi al límite de su capacidad física (IATA, 2026). En la perspectiva aduanera, que los vuelos internacionales viajen al 84% de su capacidad física significa que existe una acumulación temporal de maletas. Esta acumulación sobrecarga las líneas de inspección por rayos X, exigiendo que los operadores humanos analicen imágenes sin descanso, lo que eleva el estrés visual y los errores de omisión. El escenario de alta ocupación global, que indica que los vuelos comerciales operan casi al límite de su capacidad física, exige que los sistemas de inspección mediante rayos X operen con máxima eficiencia y precisión, reduciendo los tiempos muertos. En este sentido, investigaciones en factores humanos señalan que la detección efectiva de amenazas de alto riesgo (como armas o artefactos) sigue dependiendo en gran parte de la capacidad cognitiva, la agudeza visual y el nivel de alerta del operador humano frente al monitor de inspección, factores que se ven afectados por la duración del turno y la frecuencia de aparición de las amenazas (Meuter y Lacherez, 2016).

No obstante, las pautas de salud ocupacional publicadas en la plataforma oficial de la Organización Mundial de la Salud (OMS, 2023) advierten que la efectividad en tareas que exigen un monitoreo visual crítico decae significativamente debido al síndrome de fatiga visual y el agotamiento de la atención sostenida. De acuerdo con los criterios de medicina del trabajo de la organización, la exposición continua a pantallas que requieren alta demanda cognitiva genera un desgaste visual que exige pausas alternas cada 20 o 30 minutos para evitar micro-errores de omisión. En el entorno aeroportuario, este estrés visual es más propenso a estos micro-errores por la complejidad geométrica del equipaje, conocida en la visión computacional como *clutter* u oclusión (Goodfellow et al., 2016), donde la superposición de objetos inofensivos obliga al sistema visual humano a realizar un sobreesfuerzo de acomodación, incrementando el riesgo de dejar pasar desapercibidos patrones de amenazas en los objetos.

Al pasar este contexto al ámbito latinoamericano, la presión sobre los sistemas de inspección aeroportuaria adquiere una dimensión especialmente crítica debido al crecimiento sostenido y acelerado del tráfico aéreo regional. Según el informe anual de la Asociación Latinoamericana y del Caribe de Transporte Aéreo (ALTA), el tráfico aéreo total en la región alcanzó 477,3 millones de pasajeros en 2025, representando un crecimiento interanual del 3,8% equivalente a 17,5 millones de viajeros adicionales, con el 84% de la expansión concentrada en el segmento intrarregional (ALTA, 2026). En términos operativos, la oferta total de vuelos aumentó un 2% interanual y la capacidad medida en asientos creció un 3,1%, con un promedio de 160 asientos por vuelo en 2025 frente a 158 en 2024; al mismo tiempo, la capacidad en ASK creció un 4,6%, la demanda en RPK un 4,5%, y el factor de ocupación promedio se situó en 83,7% (ALTA, 2026). El segmento internacional intrarregional fue el de mayor expansión, registrando un crecimiento en demanda (RPK) del 10,6% y en capacidad (ASK) del 11,2%, lo que subraya la creciente interdependencia aérea dentro de la región (ALTA, 2026).

Tabla 2.
Indicadores de tráfico aéreo en América Latina y el Caribe, 2025

	diciembre			ACUMULADO		
	2025	2024	Crecimiento	2025	2024	Crecimiento
Pasajeros	**44,290,314**	**42,005,769**	**5.4%**	**477,316,163**	**459,799,344**	**3.8%**
Doméstico	24,020,752	22,449,301	7.0%	264,554,616	254,651,854	3.9%
Internacional Intrarregional	4,951,792	4,623,522	7.1%	56,222,361	51,454,657	9.3%
Internacional Extrarregional	15,317,769	14,932,946	2.6%	156,539,184	153,692,832	1.9%
RPK (millones)	**96,943**	**91,833**	**5.6%**	**1,016,769**	**972,551**	**4.5%**
Doméstico	23,120	21,487	7.6%	250,113	238,128	5.0%
Internacional Intrarregional	10,539	9,695	8.7%	117,546	106,290	10.6%
Internacional Extrarregional	63,284	60,650	4.3%	649,110	628,134	3.3%
ASK (millones)	**116,349**	**109,735**	**6.0%**	**1,214,756**	**1,160,899**	**4.6%**
Doméstico	27,108	25,335	7.0%	295,877	285,631	3.6%
Internacional Intrarregional	13,325	12,339	8.0%	149,226	134,203	11.2%
Internacional Extrarregional	75,915	72,061	5.3%	769,653	741,065	3.9%
Factor de Ocupación	**83.3%**	**83.7%**	**-0,4pp**	**83.7%**	**83.8%**	**-0,1pp**
Doméstico	85.3%	84.8%	0,5pp	84.5%	83.4%	+1,1pp
Internacional Intrarregional	79.1%	78.6%	0,5pp	78.8%	79.2%	-0,4pp
Internacional Extrarregional	83.4%	84.2%	-0,8pp	84.3%	84.8%	-0,5pp

Fuente: ALTA (2026)

Este crecimiento no se distribuye de manera homogénea entre los mercados. Brasil se consolidó como el mayor mercado aéreo de la región, registrando 129,6 millones de pasajeros con un crecimiento interanual del 9,4% y superando por primera vez los 100 millones de pasajeros domésticos, mientras que su tráfico internacional alcanzó un máximo histórico de 28,4 millones de pasajeros (ALTA, 2026). Argentina registró el mayor crecimiento porcentual de la región, con 33,3 millones de pasajeros y un incremento interanual del 13,2%, impulsado principalmente por la apertura de nuevas rutas internacionales (ALTA, 2026). En el caso específico de Perú, el tráfico aéreo total alcanzó 28,5 millones de pasajeros en 2025, con un crecimiento del 5,9% interanual (superior al promedio regional), con el tráfico doméstico creciendo un 4,7% y el internacional un 7,6%, en un contexto de ampliación de la infraestructura aeroportuaria del país (ALTA, 2026). A nivel del principal punto de control del país, el Aeropuerto Internacional Jorge Chávez movilizó 25,5 millones de pasajeros durante 2025, con un crecimiento del 4,1% respecto al año anterior, destacando el segmento de transferencia internacional con más de 1,6 millones de pasajeros y un crecimiento superior al 21%, lo que refuerza su rol como centro estratégico de conexiones a nivel regional (Lima Airport Partners [LAP], 2026).

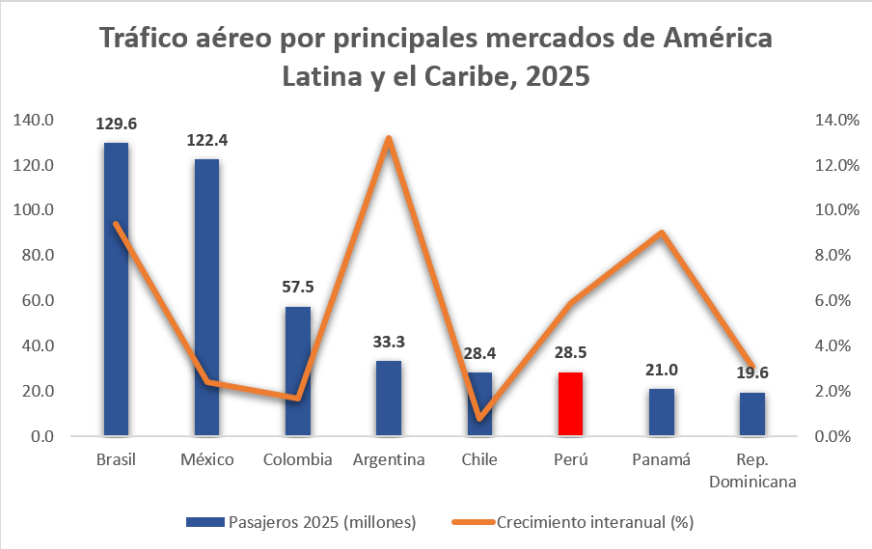


Figura 2. Tráfico aéreo por principales mercados de América Latina y el Caribe, 2025 (en millones de pasajeros y crecimiento interanual).

Fuente: Elaboración propia con datos de ALTA (2026)

Este incremento en el flujo de pasajeros no solo implica mayores volúmenes de equipaje a inspeccionar, sino que también amplía la exposición a amenazas de seguridad. En el Aeropuerto Internacional Jorge Chávez y en los principales terminales del país, los controles de rayos X representan la principal barrera contra el ingreso de objetos peligrosos que atentan contra la aviación civil. La circulación y el tráfico de estos elementos prohibidos representan un riesgo crítico a nivel nacional, según las cifras oficiales de la Superintendencia Nacional de Control de Servicios de Seguridad, Armas, Municiones y Explosivos de Uso Civil (Sucamec) se reportó la destrucción de más de 600 toneladas de explosivos decomisados entre 2024 y 2025, junto con la incautación de cientos de armas de fuego y miles de municiones de origen irregular. De igual manera, durante el primer semestre de 2024 se reportó la destrucción de más de 347 armas, manteniendo un alto nivel de incautaciones durante 2025. Este volumen de elementos peligrosos en circulación evidencia la constante amenaza que enfrentan los operadores de inspección diariamente, quienes tienen la responsabilidad de evitar que armas y objetos punzocortantes vulneren los controles de seguridad.



Figura 3. Operativo conjunto de la PNP y Sucamec: incautación de armas de fuego y municiones de origen irregular.

Fuente: Diario Oficial El Peruano (2025).

Frente a este escenario, la modernización de los sistemas de inspección cobra una relevancia estratégica. El Ministerio de Transportes y Comunicaciones del Perú (MTC) informó que el nuevo Aeropuerto Internacional Jorge Chávez sería el primero en la región en incorporar tecnología de tomografía computarizada 3D para el control de equipajes, con 27 tomógrafos Rapiscan 920CT para equipaje de mano con capacidad de procesar 291 equipajes por hora, y cuatro tomógrafos Rapiscan RTT 110 para equipaje de bodega capaces de inspeccionar más de 2.700 equipajes por hora (MTC, 2025). Este sistema emplea rayos X de alta resolución para producir imágenes tridimensionales de los objetos contenidos en las maletas, permitiendo a los inspectores identificar electrónicamente dispositivos, líquidos o sustancias sospechosas sin necesidad de abrir el equipaje (MTC, 2025). La capacidad total de inspección de equipaje de bodega se elevaría a 4.000 equipajes por hora (MTC, 2025).

Sin embargo, la incorporación de equipamiento avanzado no elimina por sí sola la brecha de seguridad. Si bien las imágenes tridimensionales de los tomógrafos 920CT representan una mejora sustantiva frente a los sistemas de rayos X convencionales de proyección bidimensional, el sistema sigue requiriendo que inspectores humanos visualicen e interpreten cada imagen para identificar con precisión los objetos transportados (LAP, 2026). Con un aumento de hasta 4.000 equipajes por hora proyectada para el sistema completo, el volumen de imágenes que un operador debe procesar de forma continua supera la capacidad de atención sostenida que una persona puede mantener, según lo documentado en estudios de factores humanos en seguridad aeroportuaria (Meuter y Lacherez, 2016).

Por lo tanto, debido a las limitaciones naturales del ser humano para mantener la concentración frente al gran volumen de equipajes, resulta necesario complementar los nuevos equipos de rayos X con herramientas tecnológicas de apoyo. En este sentido, el desarrollo de un sistema basado en Inteligencia Artificial se presenta como una solución viable. En particular, la implementación de un modelo híbrido que combine técnicas de Deep Learning y

Machine Learning permitiría analizar las imágenes de forma automática y en tiempo real. Esta herramienta actuaría como un asistente directo para el operador de seguridad, ayudando a reducir los errores causados por el cansancio visual y la superposición de objetos ocultos, garantizando así inspecciones más eficientes y seguras en los terminales aéreos.

1.2 Formulación del Problema

1.2.1 Problema general

PG: ¿De qué manera el desarrollo de un modelo híbrido basado en Deep Learning y Machine Learning mejora la precisión en la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria?

1.2.2 Problemas específicos

PE1: ¿Cuáles son las características que deben cumplir los datasets públicos de imágenes de rayos X para el entrenamiento de modelos de detección de objetos prohibidos en el contexto de la seguridad aeroportuaria?

PE2: ¿Qué técnicas de procesamiento de imágenes son más efectivas para mejorar la calidad de las imágenes de rayos X destinadas a la detección de objetos prohibidos en el contexto de la seguridad aeroportuaria?

PE3: ¿Qué algoritmos de Deep Learning y Machine Learning, integrados en una arquitectura híbrida, ofrecen mayor eficiencia y robustez para la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria?

PE4: ¿Qué métricas de evaluación son las más adecuadas para validar el desempeño de los modelos de detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria?

1.3 Objetivos de la Investigación

1.3.1 Objetivo general

OG: Desarrollar un modelo híbrido basado en Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de seguridad aeroportuaria.

1.3.2 Objetivos específicos

OE1: Obtener un dataset público de imágenes de rayos X que reúna las características necesarias para el entrenamiento de modelos de detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.

OE2: Implementar técnicas de procesamiento de imágenes que permitan mejorar la calidad de las imágenes de rayos X para la detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.

OE3: Implementar una arquitectura híbrida basada en algoritmos de Deep Learning y Machine Learning para lograr una detección eficiente y robusta de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria.

OE4: Implementar métricas de evaluación adecuadas para validar el desempeño de los modelos de detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria.

1.4 Justificación de la Investigación

1.4.1 Teórica

Esta investigación busca proponer un nuevo enfoque orientado a mejorar los sistemas de seguridad aeroportuaria mediante la implementación de un modelo híbrido. La relevancia de esta propuesta se enfoca en evidenciar que la combinación de métodos de localización de objetos mediante Deep Learning junto con métodos de clasificación utilizando Machine

Learning permite abordar de manera más efectiva las limitaciones presentes en los modelos tradicionales de una sola etapa.

Desde un enfoque teórico, el estudio se orienta a analizar sistemáticamente distintas arquitecturas modernas empleadas para la extracción de características semánticas en imágenes de rayos X.

1.4.2 Práctica

El presente estudio aborda un problema crítico en la seguridad aeroportuaria: la filtración de objetos peligrosos en los equipajes. La constante revisión manual mediante monitores de rayos X genera una severa fatiga en los inspectores de seguridad, lo cual incrementa el riesgo de errores humanos y vulnera la integridad de las instalaciones. Es por ello que, gracias a esta investigación, los operadores contarán con una herramienta tecnológica que alertará automáticamente sobre estas amenazas en tiempo real, agilizando el proceso de inspección y previniendo fallos originados por el cansancio visual.

1.4.3 Metodológica

El aporte metodológico de esta investigación se basa en proponer un enfoque de análisis visual dividido en dos etapas, ya que los métodos tradicionales suelen evaluar las radiografías de manera general y con menor precisión. Para este estudio, se plantea una primera fase encargada de localizar automáticamente las áreas sospechosas dentro del equipaje para luego aplicar un análisis profundo exclusivamente sobre esas regiones detectadas. Asimismo, la metodología establece un protocolo de evaluación continuo que servirá para garantizar que el sistema propuesto no solo sea altamente preciso, sino también lo suficientemente ágil para operar en las computadoras de un entorno de seguridad real.

1.5 Delimitación del Estudio

1.5.1 Espacial

Este estudio se sitúa bajo el contexto de la modernización de la infraestructura aeroportuaria en el Perú. Se utiliza el *X-ray Contraband Detection Dataset*, el cual contiene imágenes de equipaje acompañadas de etiquetas correspondientes a 12 categorías de objetos prohibidos en el contexto de seguridad aeroportuaria, simulando escenarios reales de inspección en terminales de transporte.

1.5.2 Temporal

La investigación toma en cuenta el periodo entre 2024 y 2026, etapa caracterizada por el proceso de expansión operativa y modernización tecnológica del sector aeroportuario. Este intervalo temporal se relaciona con las proyecciones de recuperación del tráfico aéreo postpandemia de la Asociación Internacional de Transporte Aéreo (IATA), y la reciente ampliación de la capacidad operativa del principal aeropuerto aéreo del Perú.

1.5.3 Conceptual

El presente proyecto tiene como alcance el diseño y validación de una arquitectura de software de tipo híbrido orientada a la detección, extracción de características y clasificación de objetos prohibidos en imágenes de rayos X en el contexto de seguridad aeroportuaria. Dentro de este enfoque se incluyen procesos de preprocesamiento de imágenes, utilizados para mejorar el contraste local, el entrenamiento de redes neuronales y la optimización de clasificadores supervisados.

Capítulo II: Marco Teórico

Este capítulo abordará los antecedentes, bases teóricas, y conceptos clave necesarios para comprender con mayor precisión el problema de investigación. Se revisarán estudios previos y resultados de las investigaciones de los autores con el fin de poner en contexto el tema y proporcionar una base para el desarrollo de esta investigación.

2.1 Antecedentes de la Investigación

2.1.1 Resumen de artículos

A. Zhang, S., Zhu, D., Yung, K. L., & Ip, A. W. H. (2025). Balanced X-ray Security Dataset and Enhanced YOLO for Contraband Detection. *Scientific Data*.

- **Resumen:**

  La investigación aborda problemáticas clave sobre la detección de contrabando mediante imágenes de rayos X, dando énfasis al desbalance de las clases, la limitada cantidad de datos de alta calidad y la poca adaptabilidad que tienen los modelos ante escenarios más complejos. Se destaca que estos factores suelen afectar negativamente el desempeño global de los modelos, ya que favorecen el aprendizaje de aquellas clases con mayor representación en el dataset. El principal objetivo de este estudio es desarrollar modelos ligeros de alta precisión para la detección de objetos prohibidos, capaces de ser implementados en dispositivos periféricos de recursos computacionales limitados.

- **Base de Datos:**

  Se construyó un conjunto de datos balanceados derivados de los repositorios SIXray y PIDray, conformado por 13, 728 imágenes que cubren en total 12 categorías de contrabando. Para resolver el desbalance de clases se aplicó Class-Specific Augmentation Framework (CSAF), complementado con técnicas de undersampling

aleatorio asegurando aproximadamente 1500 muestras por categoría para obtener una distribución uniforme de clases.

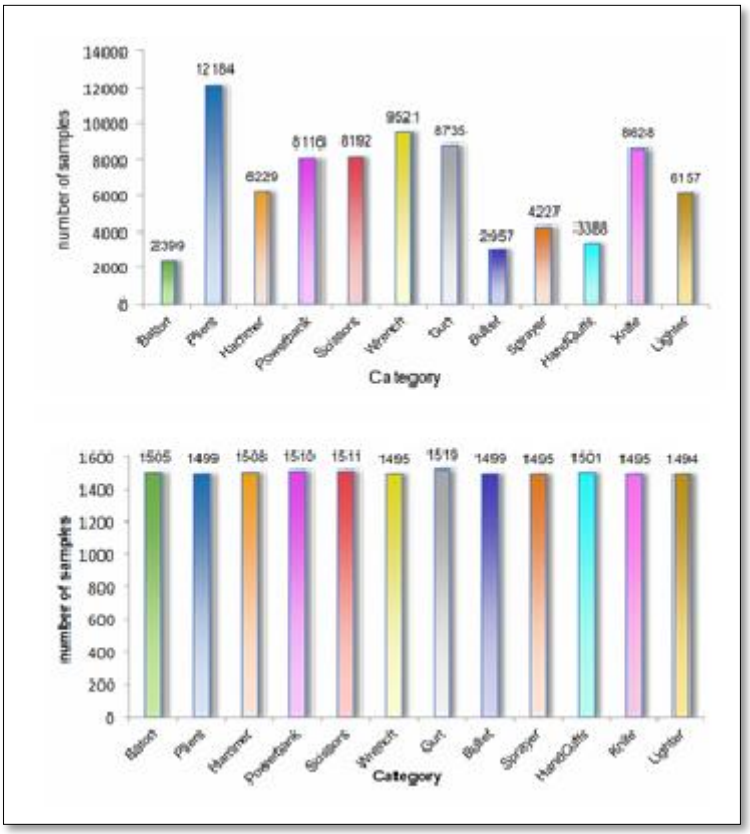


Figura 4. Comparativa de la frecuencia de clases de objetos prohibidos antes y después de aplicación de CSAF y undersampling aleatorio.

Fuente: Zhang et al. (2025).

- **Metodología:**
  - **Balanceo y data augmentation (CSAF):** Se utilizó el *Class-Specific Augmentation Framework* para aplicar transformaciones físicas (giro horizontal, rotación aleatoria, ajuste de brillo/contraste y desenfoque gaussiano) solamente a las clases minoritarias, preservando la validez de las etiquetas.
  - **Arquitectura de red:** Se rediseñó el modelo YOLOv11s reemplazando su backbone original por EfficientNet-B0 para lograr una extracción de características más eficiente y ligera.

- **Mecanismo de atención:** Se integró el módulo SEAMHead en el cabezal de detección con detección mejorada.

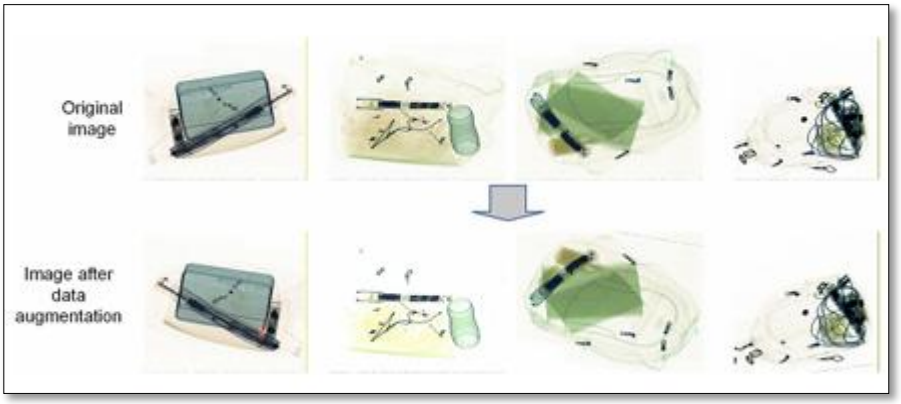


Figura 5. Imágenes originales vs imágenes con data augmentation.

Fuente: Zhang et al. (2025).

➢ **Resultados:**

En los resultados se mostró que el uso del dataset balanceado permitió que la precisión promedio aumentara al 95.78% y el mAP@50 global se elevara a 93.55% demostrando que la eliminación del sesgo hacia las clases mayoritarias mejora significativamente la efectividad del modelo. Se observaron mejoras en categorías difíciles por oclusión, logrando una precisión del 98.43% en la detección de esposas e incrementos hasta el 6% en herramientas complejas como llaves en comparación con modelos entrenados con data desbalanceada. El modelo ASEA-Net superó a YOLOv11s base reduciendo los parámetros en un 13.37%, mientras que CSEC-Net logró una reducción del 39.91% en parámetros y del 40.38% en FLOPs, manteniendo una exactitud del 95.56%. Por último, el estudio concluye que el balance de los datos junto con los backbones eficientes y módulos de atención permite un despliegue robusto en sistemas de seguridad.

Tabla 3.

Comparación de modelos de detección en conjunto de datos balanceados

Models	P/%	R/%	mAP @50/ %	mAP @50:9 5/%	Param eters/ M	FLOPs/ G	FPS
YOLOv3-tiny	90.66	79.74	87.50	65.82	9.53	14.3	364
YOLOv5s	94.84	85.16	91.91	74.78	7.82	18.8	247
YOLOv6s	91.96	83.01	89.55	72.70	15.98	42.8	245
YOLOv8n	92.37	84.54	90.22	72.94	2.69	6.8	**387**
YOLOv8s	95.03	85.15	91.97	76.54	9.83	23.4	243
YOLOv10s	92.81	84.52	91.49	75.42	7.22	21.4	248
YOLOv11n	91.76	82.59	89.85	71.54	**2.58**	**6.3**	339
YOLOv11s (baseline)	94.32	86.44	92.18	75.92	9.42	21.3	234
YOLOv11m	**96.20**	86.27	93.20	**79.01**	20.04	67.7	118
RT-DETR-L	93.19	**88.77**	92.13	78.66	28.47	100.7	59
RT-DETR-ResNet50	93.18	84.19	89.02	67.40	41.96	125.7	52
CSEC-Net (ours)	95.56	87.58	93.05	75.35	5.66	12.7	130
ASEA-Net (ours)	95.78	88.17	93.55	**78.30**	8.16	15.4	128

Fuente: Zhang et al. (2025).

- **Conclusión y relevancia para la presente investigación:**

Este estudio resulta fundamental para la presente investigación, ya que valida la eficacia de utilizar conjuntos de datos balanceados derivados de SIXray y PIDray para mejorar la precisión en la detección de objetos prohibidos. La implementación de mecanismos de atención y el uso de backbones eficientes como EfficientNet proporcionan un sustento técnico directo para nuestro modelo híbrido, permitiéndonos adoptar estrategias probadas para mitigar el error por oclusión y desbalance de clases. Asimismo, los resultados obtenidos por Zhang et al. establecen un punto de referencia de alto rendimiento (macro-AUC de 0.998) contra el cual se puede contrastar la robustez de nuestra arquitectura híbrida en entornos de seguridad aeroportuaria.

B. Wei, Y., Tao, R., Wu, Z., Ma, Y., Zhang, L., & Liu, X. (2020). Occluded Prohibited Items Detection: An X-ray Security Inspection Benchmark and De-occlusion Attention Module.

- **Resumen:**

Este trabajo de investigación expone el bajo rendimiento de los sistemas de inspección de seguridad cuando los objetos en el equipaje están superpuestos, lo que degrada la efectividad de la detección de artículos prohibidos. El estudio resalta que, a pesar de la importancia de este problema, existen pocas investigaciones y datasets que han abordado este tema. El objetivo principal fue desarrollar el primer benchmark de alta calidad enfocado en la oclusión y proponer un módulo de atención para la desoclusión (DOAM) "plug-and-play" capaz de mejorar a los detectores populares, mejorando así su rendimiento. A pesar de la fuerte oclusión en las imágenes de rayos X, la apariencia de la forma de los objetos se conserva bien, y también, los diferentes materiales se muestran visualmente con distintos colores y texturas.

- **Base de datos:**

El estudio presentó el dataset OPIXray, el primer benchmark de detección de objetos de alta calidad para inspección de seguridad enfocado en el artículo prohibido más frecuente, el “cutter”. Contiene 8885 imágenes de rayos X etiquetadas manualmente por inspectores profesionales de aeropuertos internacionales. El conjunto de prueba se divide en 3 niveles de oclusión para comprender mejor el rendimiento de los detectores.

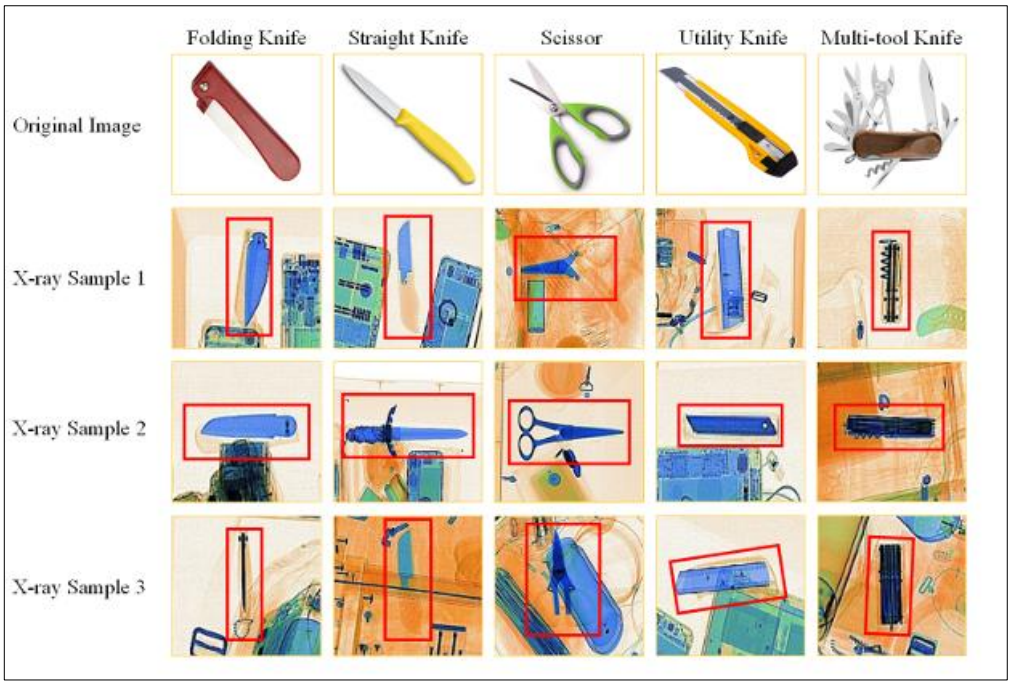


Figura 6. Muestras de las 5 categorías de "cutters".

Fuente: Wei et al. (2020).

- **Metodología:**
  - **Módulo de Atención de Desoclusión (DOAM):** Se propuso el *De-occlusion Attention Module,* que puede insertarse fácilmente en los detectores más populares como SSD, YOLOv3 o FCOS.
  - **Aprovechamiento de Apariencia Multimodal:** El DOAM aprovecha simultáneamente la información de apariencia de los artículos prohibidos (basada en colores y texturas específicos de la imagen de rayos X) para generar el mapa de atención.
  - **Refinamiento de características:** Estos mapas de atención ayudan a refinar los mapas de características de los detectores generales, permitiendo que la red neuronal ignore el ruido de la superposición y se concentre en los rasgos distintivos de los objetos prohibidos.
- **Resultados:**

La evaluación exhaustiva del módulo DOAM en el dataset OPIXray demostró que el módulo puede mejorar de forma consistente el rendimiento de los métodos de detección de vanguardia como SSD, FCOS, etc., y supera significativamente a varios mecanismos de atención ampliamente utilizados. Los resultados indicaron que las ventajas del módulo propuesto en la investigación son aún más resaltantes en escenarios con niveles más altos de oclusión, lo que demuestra su potencial de implementación en inspecciones del mundo real donde el desorden en el equipaje es cotidiano.

Tabla 4.
Comparativa de rendimiento (mAP) entre el módulo DOAM y mecanismos de atención

Method	OL 1	OL 2	OL 3
SSD [10]	75.45	69.54	66.30
SSD+SE [7]	76.02	70.11	67.53
SSD+Non-local [23]	75.99	70.17	65.87
SSD+DA [4]	77.41	69.68	66.93
SSD+DOAM(ours)	**77.87**	**72.45**	**70.78**

Fuente: Wei et al. (2020).

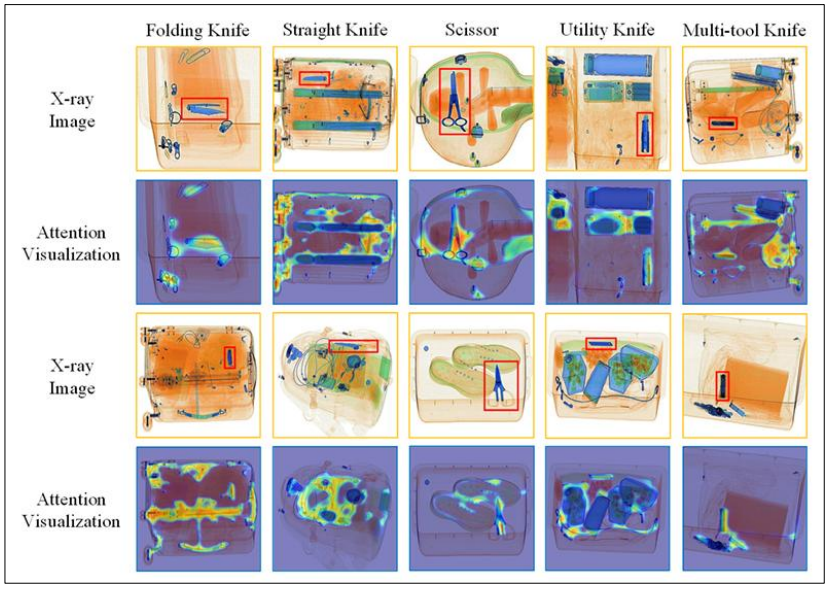


Figura 7. Resultados de visualización de la atención en imágenes de rayos X. Fuente: Wei et al. (2020).

- **Conclusión y relevancia para la presente investigación:**

La relevancia de este estudio está en su capacidad para demostrar que los mecanismos de atención especializados son superiores a los métodos convencionales ante niveles altos de oclusión. Para nuestra investigación, este hallazgo es importante, ya que refuerza la necesidad de tratar la localización y la clasificación para reducir errores por superposición. Los resultados obtenidos por el módulo DOAM, al centrarse en la identificación de bordes y materiales, indican que la implementación de una arquitectura híbrida es una estrategia adecuada para abordar los problemas de oclusión presentes en los sistemas aeroportuarios.

C. Chen, J., Hao, J., & Liu, X. (2025). An X-Ray Contraband Detection Method Based on Improved YOLOv8.

- **Resumen:**

Esta investigación aborda el desafío de la detección de contrabando en entornos de seguridad donde existen problemas como los fondos saturados y los objetos superpuestos en las imágenes de rayos X que dificultan la identificación de los objetos prohibidos. El estudio propone un enfoque de detección avanzado basado en la arquitectura YOLOv8, integrando mejoras orientadas a reducir la influencia de características irrelevantes en escenarios complejos de rayos X. El objetivo principal consiste en desarrollar un modelo que logre una alta precisión para la detección de contrabando y eficiencia computacional, de modo que pueda operar rápidamente y ser implementado en sistemas de detección en tiempo real.

- **Base de datos:**

El conjunto de datos experimentales se seleccionó del conjunto de datos PIDray, diseñado específicamente para la detección de contrabando mediante rayos X y la inspección de seguridad automática por parte del Instituto de Tecnología Informática

de la Academia China de Ciencias. Aproximadamente el 60 % del conjunto de datos, compuesto por 29 457 imágenes de inspección de seguridad, se seleccionó aleatoriamente utilizando una semilla de aleatorización. Posteriormente, estas imágenes se distribuyeron en conjuntos de entrenamiento, validación y prueba en una proporción de 8:1:1. Los conjuntos de entrenamiento y validación se utilizaron para ajustar los parámetros del modelo, mientras que el conjunto de prueba se empleó para evaluar el rendimiento del modelo en situaciones prácticas.

- **Metodología:**
  - **Multi-scale cross-axis attention (MCA):** Se integró este mecanismo para capturar dependencias globales a través de la colaboración de atención horizontal y vertical, filtrando el ruido visual de los fondos complejos.
  - **Partial Convolution (PConv):** Se implementó una arquitectura de cuello de botella ligera mediante PConv, la cual permite reducir significativamente las operaciones de punto flotante sin perder la sensibilidad posicional del modelo.
  - **Focaler-IoU:** Se empleó esta función de pérdida para ponderar dinámicamente las muestras difíciles durante el entrenamiento, mejorando la precisión en la regresión de los cuadros delimitadores y el ajuste del modelo.
- **Resultados:**

Los resultados experimentales demostraron que el modelo propuesto logró un mAP@0.5 de 97.3%, superando al YOLOv8s. En cuanto a la eficiencia, el uso de PConv redujo los FLOPs en un 31%, mientras que la función Focaler-IoU incrementó la precisión en un 0.9% y el *recall* en un 2.4%. Asimismo, el sistema alcanzó un

rendimiento destacado de 121 FPS, logrando superar en precisión a modelos más recientes como YOLOv10-S (96.5%) y YOLOv12-S (96.8%).

Tabla 5.
Resultados del estudio de ablación de los módulos MCA, PConv y Focaler-IoU sobre el rendimiento del modelo YOLOv8s

Model	mAP@0.5 (%)	FPS (f/s)	FLOPs (G)
Faster R-CNN	82.5	25	218.4
SSD	79.7	38	26.3
YOLOv3	89.4	95	14.8
YOLOv5s	92.1	99	16.4
YOLOv8s	96.1	101	28.7
YOLOv8s + MobileNetv3	94.7	115	24.5
YOLOv8s + CTAM	96.3	110	29.1
YOLOv8s + GAM	96.6	106	33.9
YOLOv8s + CBAM	96.4	103	29.7
YOLOv10-S	96.5	118	21.6
YOLOv12n	95.1	**135**	**8.5**
YOLOv12s	96.8	120	21.4
Improved YOLOv8s(Ours)	**97.3**	121	20.5

Fuente: Chen et al. (2025).

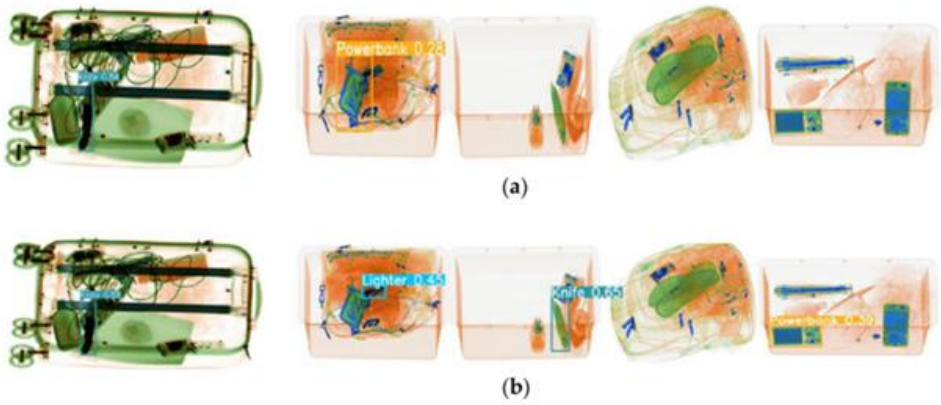


Figura 8. Comparación de los resultados de detección de los modelos YOLOv8s. (a) Modelo YOLOv8s original y (b) modelo YOLOv8s mejorado.

Fuente: Chen et al. (2025)

- **Conclusión y relevancia para la presente investigación:**

La presente investigación es relevante para la propuesta, ya que aporta sustento científico sobre el impacto de la optimización de funciones de pérdida (Focaler-IoU) y

la aplicación de convoluciones parciales (PConv) en la mejora del desempeño de los modelos de detección, sin comprometer la velocidad de procesamiento. Asimismo, la incorporación de mecanismos de atención de eje cruzado se relaciona con la necesidad de filtrar información irrelevante durante la etapa inicial de localización dentro del modelo híbrido que se propuso. De igual manera, al analizar la eficiencia de los resultados obtenidos, se evidencia la viabilidad de implementar soluciones basadas en Deep Learning.

D. Haq, A., Suciati, N., & Bui, N. D. (2025). ESI-YOLO: Enhancing YOLOv8 with Efficient Multi-Scale Attention and Wise-IoU for X-Ray Security Inspection.

- **Resumen:**

Este antecedente propone el modelo ESI-YOLO, el cual es una arquitectura mejorada en basada en YOLOv8 diseñada específicamente para la detección de objetos prohibidos en inspecciones de seguridad por rayos X. El estudio aborda el problema de interpretar estas imágenes debido a la complejidad y diversidad de objetos prohibidos, así como la presencia de desorden visual. El objetivo principal fue optimizar la representación de características multiescala y la precisión de la detección en escenarios de equipaje cerrado, manteniendo la eficiencia computacional para sistemas de inspección.

- **Base de datos:**

Para entrenar y validar el modelo, se utilizaron dos conjuntos de datos de rayos X del mundo real: *CLCXray* (enfocado en cortadores y contenedores de líquidos, con 9,059 imágenes) y *PIDray* (uno de los más grandes en este campo, con 124,486 imágenes y un subconjunto específico de objetos ocultos).

- **Metodología:**

- **Multi-Scale Attention (EMA):** Se integró el mecanismo EMA tanto en el backbone como en el neck del modelo para mejorar la representación de características evitando una complejidad computacional significativa.
- **Función de Pérdida Wise-IoU (WIoU):** Se implementó WIoU para mejorar la regresión de los cuadros delimitadores, siendo específicamente efectiva en escenarios donde los objetos están altamente superpuestos y desordenados.
- **Exploración sistemática:** Se realizó un análisis para determinar la ubicación óptima de los módulos EMA, concluyendo que la integración entre backbone y neck resulta ser más efectiva.

➢ **Resultados:**

La evaluación comparativa del modelo propuesto demuestra una superioridad en la precisión de detección frente a variantes de la arquitectura YOLOv8 y otros modelos. El ESI-YOLO logra un equilibrio óptimo entre precisión y complejidad computacional.

Tabla 6.
Comparación con otros modelos en el dataset

Model	mAP50	mAP	#Param	GFLOPs
Faster R-CNN [64]	80.2	64.5	43.3M	173.3
RetinaNet [65]	76.7	59.3	36.6M	146.3
YOLOv5n [59]	81.4	68.1	2.5M	7.2
YOLOv6n [66]	80.8	68.9	4.2M	11.9
YOLOv8n [58]	81.6	69.5	3M	8.2
YOLO11n [67]	81.4	69.1	2.6M	6.5
ESI-YOLO (n)	**82.5**	**70.1**	**3M**	**8.4**
YOLOv5s [59]	82.8	70.7	9.1M	24.1
YOLOv8s [58]	82.5	71.5	11.1M	28.7
YOLO11s [67]	82.4	71.4	9.4M	21.6
ESI-YOLO (s)	**83.3**	**71.8**	**11.1M**	**29.2**

Fuente: Haq et al. (2025).

El modelo ESI-YOLO superó a la versión estándar de YOLOv8. En el conjunto CLCXray, alcanzó una precisión media (mAP@0.5) del 82.5%. Su desempeño fue especialmente notable en el subconjunto de objetos ocultos (*hidden subset*) de PIDray, donde logró un 60.1% de precisión. Todo esto se logró manteniendo una alta eficiencia computacional, exigiendo únicamente 8.4 GFLOPs en su versión más ligera (nano).

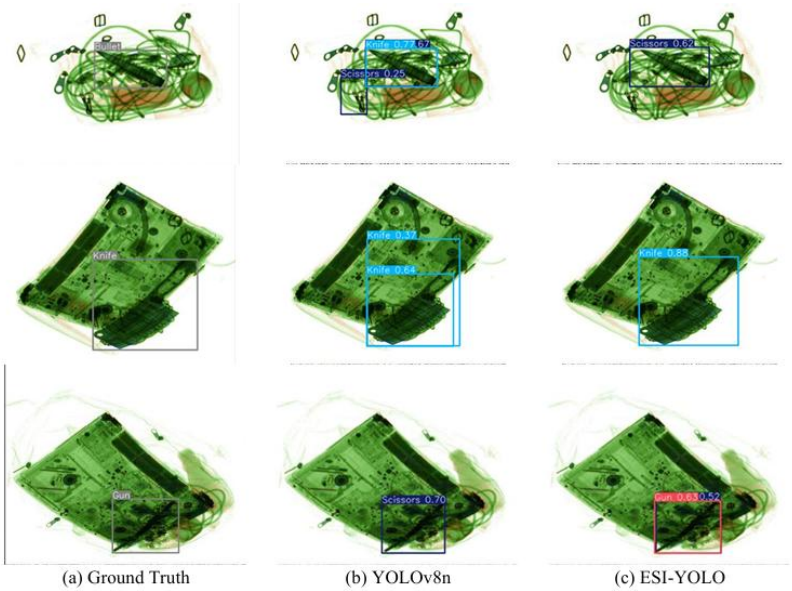


Figura 9. Muestras de las predicciones de los modelos.

Fuente: Haq et al. (2025)

- **Conclusión y relevancia para la presente investigación:**

  El estudio concluye que la integración de mecanismos de atención y funciones de pérdida dinámicas mejora significativamente la detección de amenazas ocultas o superpuestas sin sacrificar la velocidad de procesamiento. Este antecedente es fundamental para el desarrollo de la metodología híbrida para la detección de contrabando en imágenes de seguridad por rayos X, ya que demuestra cómo optimizar arquitecturas YOLO para resolver el problema específico de la oclusión, justificando el uso de enfoques de aprendizaje profundo (Deep Learning, DL) eficientes para entornos aeroportuarios o de aduanas.

E. Talbi, H., Ben-Hafsa, I. B., Alshorman, A., & El-Sappagh, S. (2025). An Overview on Computer Vision Analysis in the Airport Environment: Challenges, Trends, and Future Directions. *Applied Sciences*.

- **Resumen:**

Esta investigación presenta un análisis exhaustivo del panorama actual de *Computer Vision* aplicada a entornos aeroportuarios. El estudio explora diversas técnicas de reconocimiento y seguimiento de objetos, evaluando su desempeño en condiciones del mundo real como baja visibilidad, oclusión y preocupaciones de privacidad de datos. El propósito principal consiste en identificar y sistematizar las soluciones basadas en Inteligencia Artificial que contribuyen a mejorar la eficiencia operativa y los niveles de seguridad, destacando el papel importante de los modelos de Deep Learning en el desarrollo de sistemas de seguridad aeroportuarios.

- **Base de datos:**

Para evaluar los modelos, el antecedente hace referencia a conjuntos de datos estándar (como PASCAL VOC, COCO e ImageNet) y bases de datos especializadas en entornos aeroportuarios, como ASS-BD. Específicamente para la detección de amenazas, los investigadores utilizaron imágenes de rayos X reales y conjuntos de datos sintéticos generados mediante redes neuronales (arquitecturas GAN como PGGAN) para simular diferentes vistas de objetos peligrosos.

- **Metodología:**

La investigación compara métodos tradicionales de extracción de características (como HOG y SVM) con arquitecturas modernas de aprendizaje profundo, incluyendo detectores de una etapa (YOLO, SSD) y de dos etapas (Faster R-CNN). En el ámbito de la inspección de equipaje, el estudio evalúa metodologías basadas en imágenes de

rayos X 2D y tomografía computarizada (CT) 3D, empleando modelos de detección capaces de aprovechar las diferencias de atenuación presentes en los materiales para identificar objetos prohibidos y mejorar la precisión de la inspección automatizada.

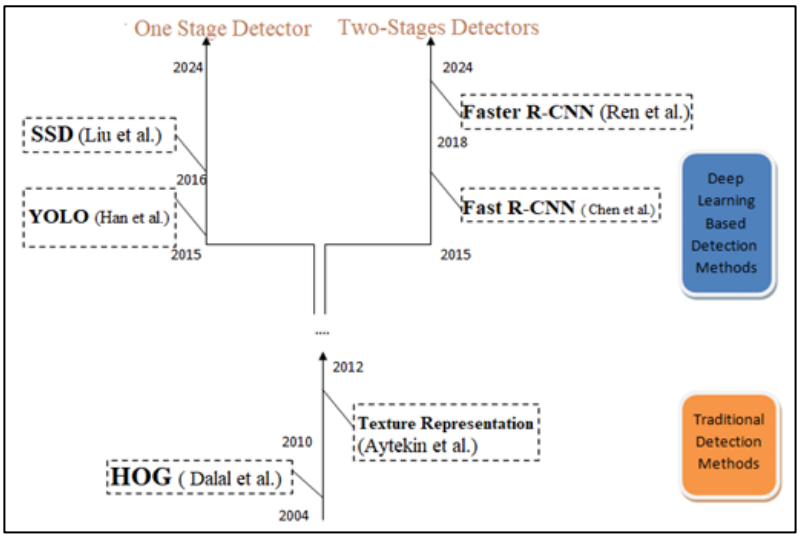


Figura 10. Evolución histórica de la visión artificial.

Fuente: Talbi et al. (2025)

- **Resultados:**

La aplicación de la visión artificial en la seguridad aeroportuaria ha demostrado que los modelos de aprendizaje profundo superan significativamente a los métodos tradicionales en la inspección de equipaje. Específicamente, la integración de imágenes de rayos X 2D y tomografía computarizada (CT) 3D permite analizar la densidad y la estructura atómica de los objetos para diferenciar eficazmente materiales inofensivos de explosivos y armamento de baja o alta densidad. En este ámbito, enfoques innovadores que combinan redes generativas adversarias (PGGAN) para la simulación de datos con detectores de objetos como YOLO, SSD y RetinaNet han optimizado notablemente la identificación de contrabando; por ejemplo, el uso de la arquitectura YOLOv3 sobre imágenes de rayos X alcanzó una Precisión Media Promedio (mAP) global del 80.0% en la detección de amenazas, destacando una alta eficacia en la ubicación de armas de fuego (96.3%) frente a objetos punzocortantes más pequeños,

como cuchillos (76.2%), que requieren resoluciones de imagen superiores. Asimismo, la implementación de Redes Neuronales Convolucionales (CNN) y técnicas de aprendizaje autosupervisado en el manejo y seguimiento automatizado de equipaje ha logrado niveles de precisión de entre el 73.1% y el 89%, consolidando a estas arquitecturas de extracción de características multiescala como soluciones robustas para el procesamiento en tiempo real y la superación de desafíos como la oclusión de objetos superpuestos en los escáneres de seguridad.

- **Conclusión y relevancia para la presente investigación:**

El estudio concluye que *Computer Vision* es un pilar esencial para la automatización de la seguridad y el procesamiento ágil de datos visuales. Este antecedente es de gran relevancia para la presente investigación enfocada en la construcción de una metodología híbrida para la detección de contrabando en imágenes de rayos X, ya que valida la efectividad de utilizar modelos como YOLO para la detección y localización de objetos prohibidos en controles de seguridad. Asimismo, al exponer las limitaciones actuales que tienen los modelos individuales frente a los objetos ocluidos o superpuestos, justifica y respalda la necesidad de plantear una estrategia híbrida que logre mayor precisión en la clasificación de imágenes complejas.

2.2 Bases Teóricas

2.2.1 Inteligencia Artificial

La Inteligencia Artificial (IA) se define formalmente como el estudio de agentes que reciben percepciones provenientes de su entorno y, en función de estas, ejecutan acciones (Russell y Norvig, 2020). Técnicamente, cada agente implementa una función que mapea las secuencias de información percibida hacia una acción específica. Las maneras de representar estas funciones son muy variadas, abarcando desde agentes reactivos básicos hasta sistemas

avanzados de aprendizaje profundo. Asimismo, el aprendizaje tiene un rol fundamental, ya que no solo se utiliza como un método para desarrollar sistemas competentes, sino que también representa la vía principal para que estos agentes puedan operar y adaptarse en entornos desconocidos (Russell y Norvig, 2020).

2.2.2 Machine Learning

2.2.2.1 Definición

Según Mitchell (1997), el Aprendizaje Automático o Machine Learning puede definirse ampliamente como cualquier programa informático que mejora su rendimiento en alguna tarea a través de la experiencia, concepto que el autor formaliza matemáticamente de la siguiente manera: "Se dice que un programa informático aprende de la experiencia E con respecto a alguna clase de tareas T y medida de rendimiento P, si su desempeño en las tareas de T, medido por P, mejora con la experiencia E". Donde cada componente se define así:

- **T (Task / Tarea):** La clase de tareas que el programa debe aprender a realizar.
- **P (Performance measure / Medida de rendimiento):** El criterio con el que se evalúa qué tan bien el programa ejecuta la tarea.
- **E (Experience / Experiencia):** Los datos o situaciones a partir de los cuales el programa aprende.

Esta base teórica ha evolucionado con el tiempo hacia enfoques más aplicados. El MIT Sloan School of Management (2021) describe el Machine Learning como una subdisciplina de la Inteligencia Artificial que otorga a las computadoras la capacidad de aprender sin ser programadas explícitamente, mientras que IBM (2021) lo precisa como el subconjunto de la IA centrado en algoritmos capaces de aprender los patrones

presentes en datos de entrenamiento para realizar predicciones precisas sobre datos nuevos.

2.2.2.2 Tipos de Aprendizaje

Desde el punto de vista algorítmico, las técnicas de aprendizaje automático (ML) se clasifican en tres tipos, estructurados según la disponibilidad de datos etiquetados durante su fase de entrenamiento (Russell y Norvig, 2020):

- **Aprendizaje Supervisado:** El algoritmo es entrenado con un conjunto de datos emparejados $D = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$, donde cada vector de entrada tiene asociada una etiqueta o salida esperada conocida como *ground truth*. Su objetivo metodológico es inferir una función de mapeo que relacione las entradas con las salidas, ajustando sus parámetros internos para minimizar una función de pérdida o error (Bishop, 2006). Este enfoque se subdivide en clasificación (cuando pertenece a un conjunto discreto de categorías) y regresión (cuando es un valor continuo). Este es el enfoque fundamental para el desarrollo de sistemas predictivos con clases previamente tipificadas. En cuanto a sus ámbitos de aplicación, es el estándar industrial para el reconocimiento de patrones visuales (como la detección de amenazas radiográficas en aeropuertos), el diagnóstico médico asistido, la clasificación de lenguaje natural y el pronóstico de series temporales.
- **Aprendizaje No Supervisado:** El modelo recibe un conjunto de datos $D = \{x_1, x_2, \ldots, x_n\}$ que carece por completo de *targets* o etiquetas *y*. El objetivo algorítmico es inferir la distribución de probabilidad para descubrir correlaciones ocultas, jerarquías o estructuras intrínsecas en los datos (Goodfellow et al., 2016). Teóricamente, sus técnicas más representativas

incluyen el agrupamiento o *clustering* (para agrupar datos por similitud de características) y la reducción de dimensionalidad (para proyectar espacios vectoriales complejos en representaciones más compactas y eficientes) (Bishop, 2006). Sus aplicaciones principales destacan en escenarios exploratorios, tales como la segmentación de perfiles de usuarios en bases de datos, la detección de anomalías en ciberseguridad o fraudes bancarios, los sistemas de recomendación y el preprocesamiento de información genética.

- **Aprendizaje por Refuerzo:** Este enfoque modela el aprendizaje como un Proceso de Decisión de Markov (MDP). Un agente computacional interactúa continuamente con un entorno dinámico; en cada paso de tiempo discreto, el agente debe descubrir, mediante prueba y error, una política que maximice la recompensa acumulada a largo plazo (Russell y Norvig, 2020). El modelo no recibe instrucciones sobre qué acciones tomar, sino que debe descubrir, mediante prueba y error, una política de actuación que maximice la recompensa acumulada a largo plazo. Debido a su naturaleza interactiva, sus aplicaciones abarcan la robótica autónoma, los vehículos autónomos y el desarrollo de agentes capaces de superar a expertos humanos en entornos de simulación.

2.2.3 Deep Learning

2.2.3.1 Definición

Deep Learning (Aprendizaje Profundo) es una rama especializada del Machine Learning cuya arquitectura se basa en redes neuronales artificiales con múltiples capas ocultas. La idea central detrás de esta disciplina es lo que se conoce como aprendizaje de representaciones (LeCun et al., 2015; Goodfellow et al., 2016). En el aprendizaje

automático clásico, un experto humano debe diseñar y extraer manualmente las características relevantes de los datos, un proceso conocido como feature engineering. Deep Learning supera esta limitación al procesar los datos crudos y aprender por sí misma a identificar jerarquías. Esto ocurre mediante una serie de transformaciones no lineales sucesivas: las primeras capas detectan patrones simples y de bajo nivel (bordes o contrastes), mientras que las capas más profundas combinan esos elementos básicos para construir representaciones cada vez más abstractas y complejas, sin que sea necesaria ninguna intervención humana en el proceso (LeCun et al., 2015).

Este aprendizaje jerárquico es posible gracias al algoritmo de retropropagación del error (*backpropagation*). Junto con métodos de optimización como el descenso de gradiente, este mecanismo permite ajustar de forma iterativa los pesos y parámetros internos de la red, con el objetivo de minimizar el error del modelo (Rumelhart et al., 1986; Goodfellow et al., 2016). Es precisamente esta combinación (múltiples capas no lineales junto con la capacidad de procesar enormes volúmenes de datos) lo que permite al Deep Learning modelar funciones extremadamente complejas y alcanzar resultados de vanguardia en tareas como la visión computacional.

2.2.3.2 Redes Neuronales

La arquitectura base de cualquier modelo de aprendizaje profundo se estructura matemáticamente mediante grafos computacionales organizados en múltiples niveles o capas (Goodfellow et al., 2016). El flujo de la información a través de esta estructura define el proceso de inferencia de la red, la cual se compone de los siguientes elementos fundamentales:

- **Capa de Entrada (*Input Layer*):** Constituye el punto de recepción inicial donde el modelo ingiere los datos crudos sin procesamiento analítico previo (LeCun et al.,

2015). En el contexto de la visión computacional, esta capa recibe tensores multidimensionales que representan las intensidades numéricas de los píxeles de una imagen radiográfica, adaptando sus dimensiones a la topología y arquitectura requerida por la red (Goodfellow et al., 2016).

- **Capas Ocultas (*Hidden Layers*):** Son las capas intermedias ubicadas entre la entrada y la salida, responsables de realizar el procesamiento profundo y la extracción de características de la red (LeCun et al., 2015). Cada neurona en estas capas realiza una transformación afín sobre el vector de entrada *x*, multiplicándolo por una matriz de pesos W y sumando un sesgo o bias b, representado como $z = Wx + b$ (Goodfellow et al., 2016). A medida que la información avanza a través de sucesivas capas, la red extrae niveles de abstracción cada vez más complejos.
- **Funciones de Activación:** Son operaciones matemáticas aplicadas a la salida lineal de cada neurona $a = f(z)$ (Goodfellow et al., 2016). Su propósito algorítmico es introducir la no linealidad en el modelo, una propiedad crítica que permite a la red aprender fronteras de decisión altamente complejas que un modelo puramente lineal no podría resolver (LeCun et al., 2015). Ejemplos estándar incluyen la función sigmoide, la tangente hiperbólica y la unidad lineal rectificada (ReLU).
- **Capa de Salida (*Output Layer*):** Es la capa final encargada de emitir la predicción del modelo. Dependiendo del diseño de la arquitectura, puede aplicar una función *Softmax* para generar una distribución de probabilidades entre diversas clases (Goodfellow et al., 2016). Sin embargo, en arquitecturas híbridas orientadas a la extracción de características, esta capa suele omitirse para que la red retorne el vector numérico denso (*embedding*) generado por la última capa oculta, el cual será procesado por clasificadores estadísticos independientes (Bishop, 2006).

2.2.3.3 Principales Arquitecturas de Deep Learning

El campo de Deep Learning comprende una extensa variedad de estructuras de redes neuronales diseñadas para ingerir múltiples tipos de datos estructurados y secuenciales (Goodfellow et al., 2016). No obstante, para abordar los problemas de visión computacional, los modelos matemáticos deben estar estrictamente optimizados para procesar arreglos espaciales en forma de matrices bidimensionales y extraer características morfológicas sin perder la jerarquía visual (LeCun et al., 2015). En la actualidad, la literatura especializada destaca dos enfoques principales para el procesamiento de imágenes mediante redes profundas (Liu et al., 2022):

A) **Redes Neuronales Convolucionales (CNN):** Están diseñadas para recibir datos en forma de cuadrícula (como los píxeles), utilizando capas de filtros de convolución que comparten pesos para detectar patrones locales y operaciones de submuestreo (*pooling*) que otorgan invarianza a la traslación (Krizhevsky et al., 2012). Modelos recientes como EfficientNetV2 (Tan y Le, 2021) y ConvNeXt (Liu et al., 2022) mejoran esta base integrando bloques residuales, lo que permite maximizar la extracción de características reduciendo el consumo computacional.

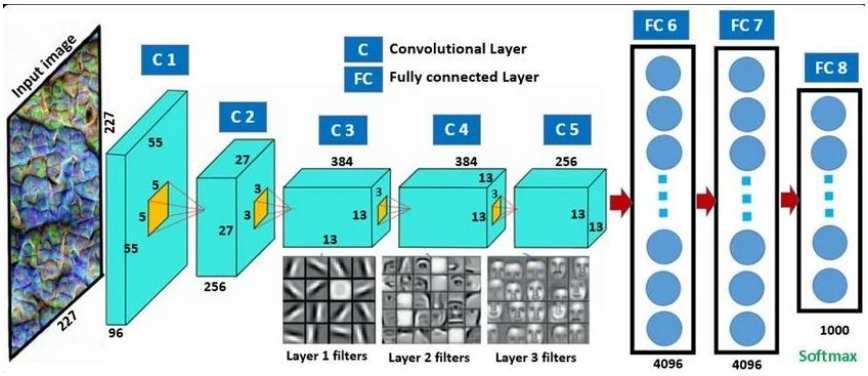


Figura 11. Arquitectura AlexNet.

Fuente: Adaptado de la arquitectura AlexNet propuesta por Krizhevsky et al. (2012)

B) Vision Transformers (ViT): Son arquitecturas más actuales que procesan la imagen dividiéndola en secciones o parches, aplicando mecanismos de auto-atención (*self-attention*) para relacionar la información de toda la imagen desde las primeras capas (Touvron et al., 2021). Modelos como Swin Transformer (Liu et al., 2021) adaptan este mecanismo utilizando ventanas de atención que se desplazan, combinando las ventajas de análisis espacial de las CNN con la capacidad global de los *Transformers*.

2.2.3.4 Transfer Learning

La mayoría de los algoritmos tradicionales de Machine Learning parten de una premisa importante: que los datos de entrenamiento y los datos futuros deben pertenecer al mismo espacio de características y seguir la misma distribución (Pan & Yang, 2009).

El *Transfer Learning* (Aprendizaje por Transferencia) surge como un marco de aprendizaje que aborda esta limitación, permitiendo que los dominios, tareas y distribuciones usados en entrenamiento y prueba sean diferentes entre sí (Pan & Yang, 2009). La idea parte de una intuición humana: así como una persona que aprende a reconocer manzanas puede transferir ese conocimiento para reconocer peras, o quien aprende a tocar el órgano puede aprender piano con mayor facilidad, los sistemas de aprendizaje automático pueden reutilizar conocimiento adquirido previamente para resolver problemas nuevos de forma más rápida o efectiva (Pan & Yang, 2009).

En otras palabras, el objetivo del Transfer Learning es extraer el conocimiento de una o más tareas fuente y aplicarlo a una tarea objetivo (Pan & Yang, 2009). A diferencia del aprendizaje tradicional, donde cada tarea se aprende desde cero, el Transfer Learning transfiere conocimiento de tareas previas hacia la tarea objetivo, más

aún cuando esta última cuenta con datos de entrenamiento limitados o de menor calidad (Pan & Yang, 2009).

2.2.3.4.1 Backbone

Es la porción base de una red neuronal profunda preentrenada, generalmente compuesta por sus capas convolucionales o de atención, encargada de extraer las representaciones o características visuales de una imagen, excluyendo su capa final de clasificación (Bolager et al., 2023). En el contexto del Transfer Learning, el backbone constituye el componente que se reutiliza de una tarea fuente, ya sea congelando sus pesos o reentrenándolos parcialmente, según la estrategia empleada a continuación.

2.2.3.4.2 Estrategias de Transfer Learning

A) **Feature Extraction:** Es una estrategia de Transfer Learning en la que no es necesario reentrenar el modelo preentrenado, ya que este ha capturado previamente la representación o características esenciales de una tarea similar; basta con añadir un nuevo clasificador y ajustar solamente sus parámetros, manteniendo congelados los pesos del modelo base (Bolager et al., 2023). En la práctica, esto se traduce en congelar los pesos del backbone preentrenado y añadir una o más capas totalmente conectadas al final de la red, las cuales son las únicas que se entrenan con los nuevos datos (Bolager et al., 2023).

B) **Fine-tuning:** Es una estrategia de Transfer Learning en la que se reentrenan algunos o todos los parámetros del modelo preentrenado utilizando una tasa de aprendizaje menor, mediante algoritmos típicos de optimización basados en gradiente (Bolager et al., 2023). A diferencia de Feature Extraction, los pesos originalmente aprendidos en la tarea fuente se ajustan gradualmente para adaptarse a las particularidades del nuevo dominio, en lugar de mantenerse fijos (Bolager et al., 2023).

2.2.4 Computer Vision

2.2.4.1 Definición

La Visión Computacional es un subcampo de las ciencias de la computación que se ocupa del procesamiento de imágenes capturadas por cámaras, y que busca generar "visión" en las computadoras dotándolas de una percepción similar a la humana (Talbi et al., 2025).

Por un largo tiempo, el avance de métodos que permiten a las computadoras reconocer y comprender entradas visuales ha sido una importante área de investigación, proceso que comenzó en 1959 y se desarrolló progresivamente con tecnologías como el reconocimiento óptico de caracteres y las redes neuronales convolucionales (Talbi et al., 2025). Hoy en día, gracias al Deep Learning, la Visión Computacional ha avanzado considerablemente, aumentando en gran medida la precisión del reconocimiento de imágenes, y sus tecnologías se están expandiendo al ritmo más rápido en términos de uso industrial y tamaño de mercado (Talbi et al., 2025).

2.2.4.2 Preprocesamiento de Imágenes

Dentro de la Visión Computacional clásica, previa a la incorporación del Deep Learning, existen técnicas de mejora visual orientadas a optimizar la calidad de la imagen antes de su análisis.

- **Desnormalización de Bounding Boxes:** Es el proceso de convertir las coordenadas relativas (normalizadas en un rango de 0 a 1) que delimitan un bounding box hacia un espacio de píxeles absolutos, multiplicando dichos valores por las dimensiones reales de ancho y alto (W, H) de la imagen (Gonzalez y Woods, 2018). Este formato normalizado es habitual en las anotaciones generadas por los modelos de detección de objetos, ya que permite mantener la independencia respecto a la resolución original de la imagen (Redmon et al., 2016).

- **Recorte de Regiones de Interés (Cropping):** Es el proceso de extraer físicamente la sección de una imagen delimitada por una bounding box, a partir de sus coordenadas absolutas en píxeles. Esta técnica permite aislar las regiones discriminativas de un objeto de interés, eliminando el ruido de fondo circundante y mejorando la eficiencia del aprendizaje de representaciones en las arquitecturas de extracción de características (Redmon et al., 2016; Wei et al., 2020).
- **Redimensionamiento:** Es el proceso de ajustar las dimensiones espaciales (ancho y alto) de una imagen a un tamaño fijo y estandarizado, requisito necesario para que las arquitecturas de redes neuronales profundas, tanto convolucionales como basadas en Transformers, puedan procesar los datos en forma de matrices de tamaño constante (Goodfellow et al., 2016). Una de las técnicas empleadas para este fin es el escalado proporcional combinado con relleno de bordes (padding), la cual permite ajustar la imagen al tamaño objetivo sin alterar la estructura ni las proporciones originales del contenido visual (Tan y Le, 2021).
- **Mejora de contraste (CLAHE):** Es una técnica de mejora de contraste local aplicada en imágenes que presentan distribuciones de intensidad superpuestas o bajo contraste global. CLAHE divide la imagen en regiones contextuales y redistribuye las intensidades, resaltando de manera óptima los bordes y los patrones de textura o densidad presentes, sin amplificar excesivamente el ruido visual de fondo (Haq et al., 2025).
- **Image Rescaling:** Es un procedimiento de normalización numérica que transforma los valores de intensidad de los píxeles (originalmente en escala de 8 bits [0, 255]) hacia un intervalo continuo estandarizado, típicamente [0, 1] o [-1, 1], sin alterar las dimensiones espaciales de la imagen. Esta operación es indispensable para

homogeneizar la distribución de los datos de entrada y acelerar la convergencia matemática durante el entrenamiento (Goodfellow et al., 2016).

- **Normalización Específica del Backbone:** Es el proceso de ajuste estadístico aplicado a los canales de una imagen, mediante el cual se alinean sus valores numéricos con la media y desviación estándar esperadas por un modelo preentrenado. De acuerdo con los principios de diseño de Krizhevsky et al. (2012) y Tan y Le (2021), esta estandarización de los datos de entrada previene la saturación de las funciones de activación y estabiliza la extracción de los embeddings, asegurando que las características aprendidas originalmente por la red sean consistentes con los nuevos datos de entrada.

2.2.4.3 Detección de Objetos

- **Bounding Box:** Es una caja delimitadora rectangular que circunscribe espacialmente un objeto de interés dentro de una imagen, definida matemáticamente mediante un conjunto de coordenadas, ya sea el centro del objeto junto con su ancho y alto, o alternativamente las esquinas superior izquierda e inferior derecha (Redmon et al., 2016). En el contexto de la detección de objetos, esta representación constituye la unidad fundamental de salida que modelos como YOLO generan para cada objeto identificado, permitiendo localizar con precisión su posición dentro de la escena antes de cualquier procesamiento posterior.
- **YOLO (You Only Look Once):** Es un nuevo enfoque para la detección de objetos que reformula el problema como una regresión hacia cajas delimitadoras (*bounding boxes*) espacialmente separadas y probabilidades de clase asociadas. Una única red neuronal predice directamente las cajas delimitadoras y las probabilidades de clase a partir de imágenes completas en una sola evaluación (Redmon et al., 2016). A diferencia de métodos anteriores que reutilizaban clasificadores para realizar la

detección en múltiples etapas, la arquitectura de YOLO es extremadamente rápida: el modelo base procesa imágenes en tiempo real a 45 fotogramas por segundo, mientras que una versión más pequeña denominada Fast YOLO alcanza los 155 fotogramas por segundo, logrando el doble del rendimiento de otros detectores en tiempo real (Redmon et al., 2016).

- **Mecanismos de atención multiescala:** Técnica que permite al modelo priorizar las características más relevantes del objeto prohibido, ignorando elementos irrelevantes del entorno que podrían generar confusión en la faja de inspección (Haq et al., 2025).
- **Optimización por funciones de pérdida dinámicas:** Procedimiento que ajusta el aprendizaje del modelo para dar mayor peso a los objetos prohibidos que presentan mayor dificultad de reconocimiento u oclusión debida a la densidad del equipaje (Haq et al., 2025).

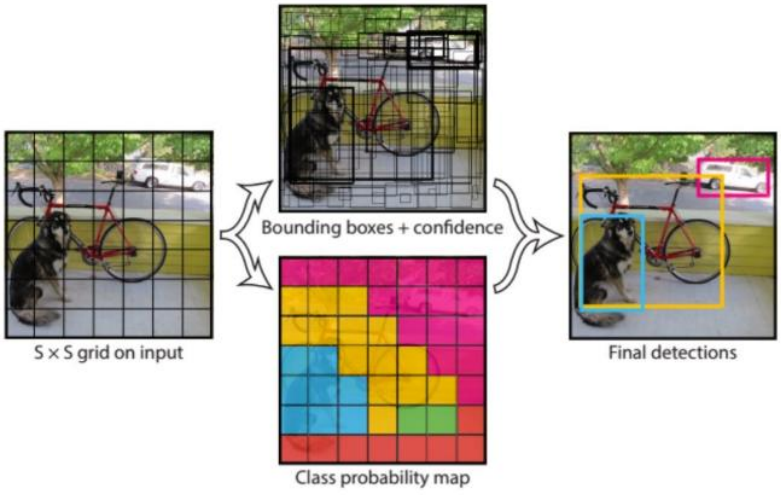


Figura 12. Ejemplo de proceso de detección de objetos mediante YOLO

Fuente: Redmon et al. (2016)

2.2.5 Objetos Prohibidos en el Contexto de la Seguridad Aeroportuaria

2.2.5.1 Definición

Los objetos prohibidos en el contexto de la seguridad aeroportuaria se definen como artículos que, por su naturaleza, representan una amenaza directa para la integridad de los pasajeros y la continuidad de las operaciones de vuelo (Talbi et al., 2025). Según la Organización de Aviación Civil Internacional (OACI, 2021), estos elementos comprenden armas de fuego, armas blancas, sustancias explosivas y herramientas industriales con capacidad de daño severo. Físicamente, estos objetos poseen una densidad material y un número atómico (Z) propio, característica que determina cómo se ven y qué color presentan en una imagen de rayos X, permitiendo diferenciar entre materiales orgánicos, inorgánicos y metálicos.

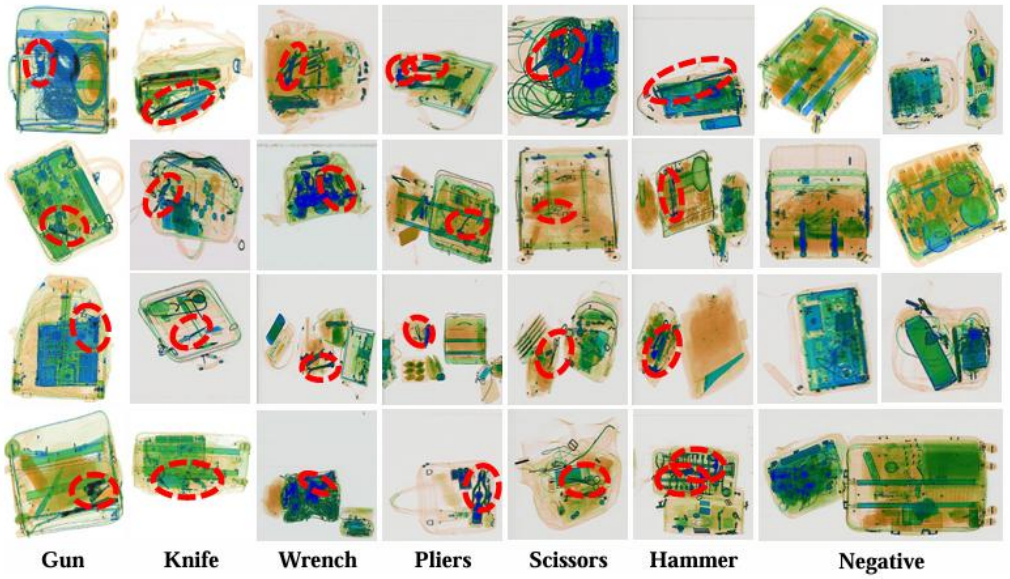


Figura 13. Ejemplos de objetos prohibidos en imágenes de rayos X.

Fuente: Miao et al. (2019)

2.2.5.2 Factores

La identificación de los objetos prohibidos se ve afectada por diversos factores relacionados con su propia naturaleza. De acuerdo con Wei et al. (2020) y Talbi et al. (2025), estos factores se agrupan en tres categorías:

- **Factores estructurales y composicionales:** Son las propiedades físicas propias del objeto, como su densidad, su forma y su número atómico (Z). Estas características permiten diferenciar, por ejemplo, entre un metal inofensivo y la estructura de un arma de fuego (Miao et al., 2019).
- **Factores de disposición espacial:** Tienen que ver con la ubicación y orientación del objeto dentro del equipaje. La presencia de otros elementos a su alrededor puede generar oclusión y desorden visual, ocultando rasgos importantes del objeto (Zhang et al., 2025).
- **Factores de frecuencia y variabilidad:** Se refieren a que estos objetos aparecen con poca frecuencia (son escasos) y pueden presentar muchas formas distintas dentro de una misma categoría de amenaza (Haq et al., 2025).

2.2.5.3 Clasificación

Además de su definición general, los objetos prohibidos se organizan en categorías según su naturaleza y nivel de amenaza. De acuerdo con Park et al. (2025), estos elementos se clasifican siguiendo los estándares de la Organización de Aviación Civil Internacional (OACI) y la legislación de cada país, agrupándose en categorías como objetos punzocortantes, armas y materiales peligrosos. Esta clasificación no es arbitraria: responde al tipo de daño que cada objeto puede causar, lo cual también se relaciona con su densidad y forma características en la imagen de rayos X, tal como se

muestra en la Tabla 7 del presente estudio, adaptada de los criterios de la Dirección General de Aeronáutica Civil (DGAC, 2022).

Tabla 7.
Listado de objetos prohibidos

Categoría	Objetos Prohibidos
Armas de fuego y proyectiles	Pistolas, revólveres, fusiles, escopetas
	Armas de juguete, réplicas e imitaciones de armas de fuego
	Piezas de armas de fuego (excepto miras telescópicas)
	Armas de aire comprimido (balines, perdigones, CO2)
	Pistolas de bengala y de largada
	Arpones y lanzas
	Hondas, tirachinas y catapultas
Artefactos de aturdimiento	Dispositivos de descarga eléctrica
	Máquinas para aturdir animales
	Gas pimienta o ají, gases lacrimógenos
	Aerosoles ácidos y repelentes para animales
Objetos punzocortantes	Hachas, hachuelas, cuchillas
	Hachas y garfios para hielo
	Navajas
	Cuchillos
	Tijeras con hojas mayores a 6 cm
	Equipos de artes marciales con filo o punta
	Espadas y sables
Herramientas de trabajo	Palancas de hierro
	Taladros y barrenas (incluidos eléctricos)
	Destornilladores u otras herramientas > 6 cm
	Sierras (incluidas eléctricas)
	Sopletes
	Llaves/aprietatuercas y pistolas neumáticas

Objetos contundentes	Bates de béisbol o softball
	Porras, cachiporras, palos
	Equipos de artes marciales
Explosivos e inflamables	Municiones
	Fulminantes
	Detonadores y mechas
	Réplicas de explosivos
	Minas, granadas y explosivos militares
	Fuegos artificiales
	Cartuchos fumígenos
	Dinamita, pólvora, explosivos plásticos

Fuente: Adaptado de la Dirección General de Aeronáutica Civil (DGAC, 2022)

2.2.5.4 Marco Normativo Internacional

La regulación de los objetos prohibidos en el transporte aéreo se basa en estándares internacionales. El Anexo 17 de la Organización de Aviación Civil Internacional (OACI, 2021) establece que el proceso de inspección consiste en aplicar medios técnicos para identificar armas u otros dispositivos peligrosos que puedan usarse para cometer un acto de interferencia ilícita. Esta normativa también exige que cada país mantenga revisión constante sobre el nivel de amenaza dentro de su territorio, ajustando sus políticas según una evaluación de riesgo. A nivel nacional, esto se traduce en listados específicos que especifican qué artículos no pueden ingresar a una aeronave.

2.3 Marco Conceptual y Contexto de la Investigación

El siguiente marco conceptual delimita las terminologías y fundamentos tecnológicos que sustentan el modelo híbrido propuesto, estableciendo la relación entre la inteligencia computacional y la seguridad aeroportuaria.

2.3.1 *Clutter* (Oclusión y desorden visual)

En el contexto de la inspección, hace referencia a la obstrucción causada por la superposición de objetos comunes sobre un objeto prohibido. Esto altera la identificación de la amenaza y representa el principal desafío para la robustez de los algoritmos de detección (Wei et al., 2020).

2.3.2 Embedding (Vector de Características)

Es la representación numérica de una imagen en forma de vector, generada por la última capa de una red neuronal profunda antes de su clasificación final. Este vector resume de forma compacta los patrones visuales más relevantes del objeto, permitiendo que modelos de Machine Learning lo procesen posteriormente (Goodfellow et al., 2016).

2.3.3 Overfitting (Sobreajuste)

Ocurre cuando un modelo aprende excesivamente los detalles y el ruido específicos del conjunto de entrenamiento, perdiendo su capacidad de generalizar correctamente ante datos nuevos. Esto se refleja en un buen desempeño durante el entrenamiento, pero un rendimiento bajo durante la validación o prueba (Goodfellow et al., 2016).

2.3.4 PCA (Análisis de Componentes Principales)

Es una técnica estadística que reduce la dimensionalidad de un conjunto de datos, transformando las variables originales en un nuevo conjunto de componentes no correlacionados que conservan la mayor parte de la variabilidad de los datos. En este estudio se utiliza para visualizar e inspeccionar la separación entre clases en el espacio de los embeddings (Bishop, 2006).

2.3.5 UMAP

Es una técnica de reducción de dimensionalidad orientada a la visualización de datos de alta dimensión, que preserva tanto la estructura local como gran parte de la estructura global

del conjunto de datos original, siendo una alternativa eficiente a métodos como PCA o t-SNE (McInnes et al., 2018).

2.3.6 K-Fold (Validación Cruzada Estratificada)

Es una técnica de evaluación de modelos que divide el conjunto de datos en partes (folds) de forma proporcional según la distribución de clases, asegurando que cada partición mantenga la misma representación de categorías que el conjunto original. Esto permite obtener una estimación más confiable del rendimiento del modelo (Kohavi, 1995).

2.3.7 Early Stopping

Es una técnica de regularización que detiene el entrenamiento de un modelo de forma anticipada cuando su rendimiento en el conjunto de validación deja de mejorar, evitando así que continúe ajustándose en exceso a los datos de entrenamiento (Goodfellow et al., 2016).

2.3.8 ImageNet

Es una base de datos de imágenes a gran escala, organizada jerárquicamente, ampliamente utilizada para el preentrenamiento de modelos de Deep Learning. Las arquitecturas evaluadas en este estudio fueron preentrenadas sobre este conjunto de datos antes de ser adaptadas al dominio de rayos X (Deng et al., 2009).

2.3.9 Formato DICOM

Es un estándar internacional para el almacenamiento, formato y transmisión de imágenes médicas y su información asociada, desarrollado por la Asociación Nacional de Fabricantes Eléctricos (NEMA). En este estudio, las imágenes de rayos X procesadas pueden recibirse bajo este formato como entrada del sistema (NEMA, 2024).

2.3.10 API y FastAPI

Una interfaz de programación de aplicaciones (API) es un componente de software que otorga a una aplicación acceso a las funcionalidades de otra cuando es invocada (Sommerville, 2016). FastAPI es un framework de Python utilizado para construir este tipo de interfaces,

reconocido por su alto rendimiento y su capacidad de generar documentación interactiva de forma automática (Ramírez, 2018).

2.3.11 Frame (Fotograma)

Es cada una de las imágenes individuales que componen un flujo de video. En sistemas de inspección en tiempo real, el análisis se realiza procesando frames específicos extraídos del flujo continuo de la cámara, en lugar de analizar el video completo de forma simultánea (Gonzalez y Woods, 2018).

2.4 Hipótesis

2.4.1 Hipótesis general

El desarrollo de un modelo híbrido basado en algoritmos de Deep Learning y Machine Learning mejora significativamente la precisión en la detección de objetos prohibidos en imágenes de rayos X en comparación a métodos convencionales en el contexto de la seguridad aeroportuaria.

2.4.2 Hipótesis específicas

HE1: La selección de un dataset público de imágenes de rayos X que contenga objetos prohibidos y cumpla con criterios de calidad, diversidad y etiquetado adecuado favorece el entrenamiento efectivo de modelos de detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.

HE2: La aplicación de técnicas de procesamiento de imágenes mejora significativamente la calidad visual y la nitidez de las imágenes de rayos X, favoreciendo la detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.

HE3: La implementación de una arquitectura híbrida basada en algoritmos de Deep Learning y Machine Learning permite alcanzar una detección precisa, eficiente y robusta de objetos prohibidos en imágenes de rayos X dentro del contexto de la seguridad aeroportuaria.

HE4: La utilización de métricas de evaluación adecuadas permite medir con precisión el desempeño de los modelos híbridos basados en algoritmos de Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria.

Capítulo III: Metodología de la Investigación

3.1 Diseño de la investigación

3.1.1 Diseño

Según Hernández-Sampieri y Mendoza (2018), en un diseño experimental se manipulan deliberadamente una o más variables independientes (supuestas causas antecedentes) para analizar las consecuencias que la manipulación tiene sobre una o más variables dependientes (supuestos efectos) en una situación de control. Este diseño se utiliza cuando se busca establecer el efecto de una causa que se manipula.

En el presente estudio se utilizará un diseño experimental, debido a que se manipularán las variables independientes (Deep Learning y Machine Learning) mediante diversos experimentos a fin de obtener la mayor cantidad de resultados posibles y observar los efectos sobre la variable dependiente (detección de objetos prohibidos). Estos resultados serán comparados bajo las mismas condiciones de control para seleccionar el modelo de clasificación óptimo.

3.1.2 Tipo

Para Hernández-Sampieri y Mendoza (2018), la investigación aplicada se centra en la resolución de problemas prácticos y la generación de conocimiento orientado a transformar una realidad específica.

Bajo este concepto, el estudio es una investigación aplicada, ya que busca dar solución a la problemática de seguridad en los puntos de control del país, mitigando las limitaciones del ojo humano y la fatiga del inspector mediante la automatización del reconocimiento de objetos prohibidos.

3.1.3 Enfoque

Según Hernández-Sampieri y Mendoza (2018), un enfoque cuantitativo hace uso de datos numéricos, aplica la estadística y realiza pruebas de hipótesis; asimismo, es un proceso secuencial y riguroso donde no es posible omitir etapas.

El enfoque del estudio es cuantitativo, debido a que es necesario trabajar con datos numéricos procedentes de los píxeles y densidades de las imágenes de rayos X. Mediante técnicas de extracción de características se convertirá la información visual en vectores numéricos (embeddings) con los que se entrenará al modelo. Además, la secuencialidad de la metodología implica seguir estrictamente fases de preprocesamiento, localización y clasificación.

3.2 Población y Muestra

Tabla 8.

Población, muestra y unidad de análisis del estudio

Dimensión	Definición	Estudio
Población	Según Hernández-Sampieri y Mendoza (2018), la población es el conjunto de todos los casos que concuerdan con una serie de especificaciones.	Se define como todas las imágenes de inspección por rayos X generadas en terminales de transporte y aduanas.
Muestra	Según Hernández-Sampieri y Mendoza (2018), el muestreo por conveniencia se realiza cuando se tiene acceso a casos disponibles y representativos para el investigador.	Se llevó a cabo un muestreo por conveniencia utilizando el X-ray Contraband Detection Dataset, el cual cuenta con imágenes validadas que cubren 12 categorías de objetos prohibidos.

Unidad de análisis	Según Hernández-Sampieri y Mendoza (2018), se refiere al segmento o caso individual de la población del cual se extraen los datos.	La unidad de análisis es una imagen de rayos X individual.

Fuente: Elaboración propia

3.3 Operacionalización de Variables

Tabla 9.
Operacionalización de Variables

Variable	Definición	Medición	Fórmula
Independientes:			
Deep Learning	Modelos para la extracción de descriptores y representaciones numéricas (embeddings) a partir de datos visuales (Wei et al., 2020).	mAP	$mAP = \frac{1}{C}\sum_{c=1}^{C} AP_c$ (1)
Machine Learning	Algoritmos para la clasificación supervisada de los rasgos extraídos (Talbi et al., 2025).	Accuracy	$Acc = \frac{TP + TN}{TP + FP + FN + TN}$ (2)
		F1-macro	$F1_{macro} = \frac{1}{C}\sum_{i=1}^{C} F1_i$ (3)
		ROC AUC	

$$AUC_{macro} = \frac{1}{C}\sum_{k=1}^{C} AUC_k \quad (4)$$

Dependiente: **Objetos Prohibidos en el contexto de seguridad aeroportuaria**	Artículos que, por su naturaleza, representan una amenaza para la seguridad de los pasajeros y las operaciones de vuelo. Físicamente, poseen una densidad material y un número atómico (Z) propio, características que determinan su apariencia en una imagen de rayos X (Talbi et al., 2025).	Tasa de detección de amenazas por equipaje inspeccionado	$T = \left(\frac{n_d}{N}\right) \times 100$ (5) Donde: *T* = Tasa de detección; *n_d* = equipajes con amenaza detectada; *N* = total de equipajes inspeccionados.

Fuente: Elaboración propia

3.4 Técnicas de Recolección de Datos

La recolección de datos para la presente investigación se realizó de forma digital mediante la descarga del X-ray Contraband Detection Dataset desde la plataforma Kaggle. Este

conjunto de datos es la versión pública del trabajo de Zhang et al. (2025), quienes consolidaron y equilibraron imágenes de seguridad para mejorar la detección de amenazas.

El dataset recolectado contiene 13,728 imágenes que provienen originalmente de bases de datos internacionales reconocidas como SIXray y PIDray. Lo más resaltante de esta técnica de recolección es que los datos ya están organizados en 12 categorías de objetos prohibidos y tienen archivos de anotación en formato YOLO. Esto permitió consolidar una base sólida y validada científicamente para entrenar el modelo híbrido propuesto.

Tabla 10.
Descripción de las 12 clases de objetos prohibidos

Clase Original (Inglés)	Traducción
Gun	Arma de fuego
Bullet	Munición / Bala
Knife	Cuchillo / Arma blanca
Scissors	Tijeras
Baton	Bastón
Hammer	Martillo
Wrench	Llave inglesa
Pliers	Alicates
Powerbank	Batería externa (Litio)
Lighter	Encendedor / Mechero
Sprayer	Aerosol
HandCuffs	Esposas

Fuente: Elaboración propia

3.5 Metodología de la implementación de la solución

3.5.1 Selección de la metodología

La metodología seleccionada para este estudio se basa en una propuesta de modelo híbrido que combina lo mejor del aprendizaje profundo (Deep Learning) y el aprendizaje automático (Machine Learning). Esta decisión se tomó al integrar dos enfoques de investigación previos: el de Wei et al. (2020), que establece las fases para procesar imágenes con redes neuronales mediante un módulo de de-oclusión y atención. Esta combinación permite aprovechar la potencia del Deep Learning para extracción de características y la precisión de Machine Learning para la clasificación final.

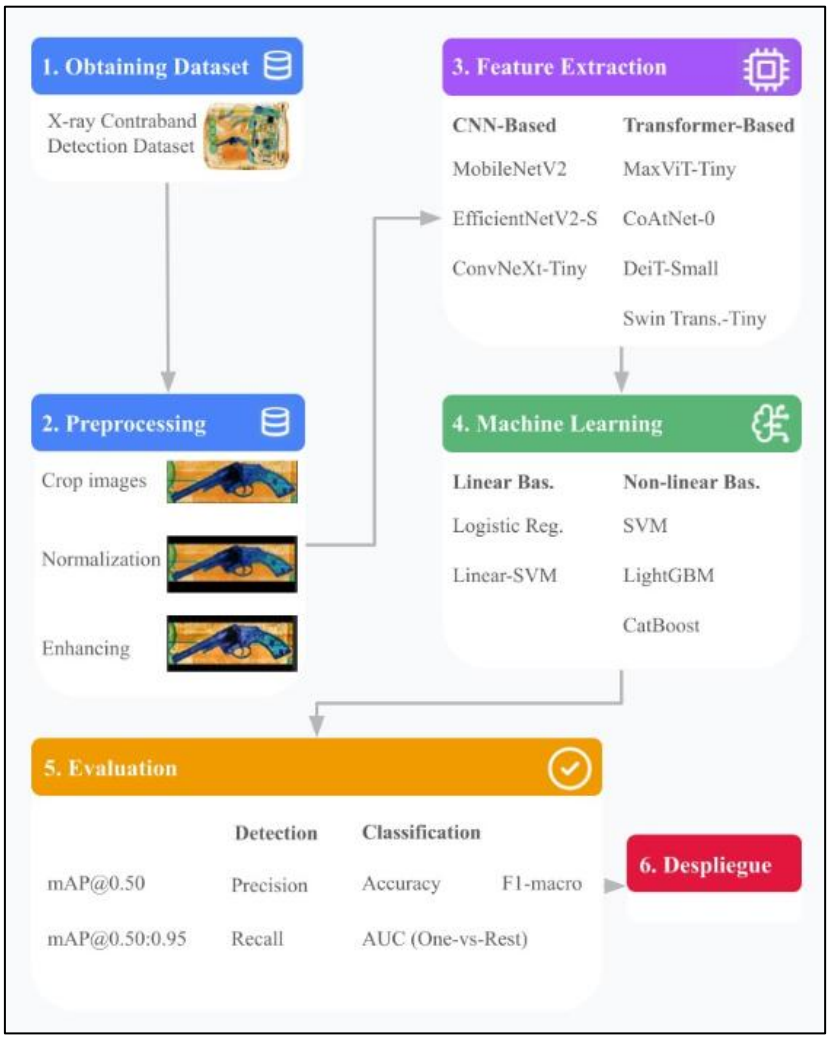


Figura 14. Metodología de la investigación.

Fuente: Elaboración propia

3.5.2 Obtención del dataset

Para este estudio, la recolección de datos fue un proceso digital. Se trata de un conjunto de datos con validez científica.

- **Origen de los datos:** Se descargó el X-ray Contraband Detection Dataset desde la plataforma Kaggle mediante la siguiente URL: https://www.kaggle.com/datasets/nikitamanaenkov/x-ray-contraband-detection-dataset/data, el cual corresponde a la versión pública del estudio de Zhang et al. (2025). El repositorio viene organizado de forma general bajo la estructura estándar exigida por los modelos de detección de objetos, donde la carpeta principal data/ se divide internamente en el directorio images/, que almacena las capturas originales de los escaneos de equipaje, y el directorio labels/. Asimismo, la raíz del folder incluye los archivos de configuración data.yaml y SPXray.yaml, los cuales contienen los metadatos y los nombres de las clases necesarios para que el algoritmo reconozca y mapee correctamente las etiquetas durante el entrenamiento.
- **Composición de la muestra:** El dataset está consolidado por 13,728 imágenes de alta calidad que provienen de dos fuentes reconocidas: SIXray (Miao et al., 2019) y PIDray (Wei et al., 2020).
- **Categorización:** La recolección incluyó etiquetas para 12 tipos de objetos prohibidos. Al descargar esta base de datos, se verificó que cada imagen contara con su respectivo archivo de anotación en formato YOLO. Esto permite al modelo identificar con precisión qué objetos constituyen una amenaza y cuáles no.

3.5.3 Preprocesamiento

La segunda fase de la metodología se trata de transformar las imágenes crudas que obtuvimos en la recolección del dataset en inputs estandarizados para los modelos. A continuación, se presentarán las actividades del preprocesamiento y tareas:

Tabla 11.
Actividades de Preprocesamiento

Actividad	Descripción	Tareas
Recorte de Imágenes y Reorganización del Dataset	Conversión de coordenadas YOLO a espacio de píxeles, extracción de regiones de interés y organización en directorios por clase (Wei et al., 2020; Goodfellow et al., 2016).	Parsear etiquetas .txt. / Calcular coordenadas en píxeles. / Recortar por objeto. / Guardar recortes en carpetas split/clase (0–11).
Redimensionamiento con Aspecto	Estandarización a un tamaño de entrada fijo (224x224 px) (Tan & Le, 2021).	Escalar usando el factor mínimo. / Aplicar zero-padding.
Mejora de Contraste (CLAHE)	Ecualización adaptativa de histogramas para resaltar estructuras y densidades (Zhang et al., 2025).	Aplicar CLAHE al canal de luminancia.

Fuente: Elaboración propia

- **Recorte y Reorganización del Dataset:** Las anotaciones en formato YOLO vienen normalizadas en valores entre 0 y 1, por lo que deben convertirse a coordenadas de píxeles para poder extraer el objeto de la imagen. Como explican Wei et al. (2020), este paso es fundamental en imágenes de seguridad por rayos X para aislar las regiones de interés y reducir el ruido de fondo provocado por el equipaje circundante, lo que mejora la eficiencia en el aprendizaje del modelo. Una vez recortadas, las imágenes se organizan de forma automática en subcarpetas separadas

por cada clase para asegurar la compatibilidad con el pipeline de entrenamiento; de acuerdo con los principios de estructuración de Goodfellow et al. (2016), mantener una organización limpia en el repositorio favorece una optimización estable y sin errores durante esta etapa.

- **Redimensionamiento:** Para evitar distorsiones en la geometría original de los objetos prohibidos, no se realiza un estiramiento o ajuste directo al tamaño de cuadrado fijo de 224x224 píxeles. En su lugar, siguiendo la metodología propuesta por Tan & Le (2021), el reajuste se calcula mediante el factor mínimo entre las dimensiones objetivo y las originales, aplicando posteriormente padding para completar el lienzo sin alterar la morfología real del artículo.
- **Mejora de Contraste (CLAHE):** Las imágenes de rayos X aeroportuarios suelen presentar un bajo contraste global debido a la superposición de múltiples objetos en la maleta. Como señalan Zhang et al. (2025) en sus experimentos de mejora visual para contrabando, la técnica CLAHE divide la imagen en pequeñas regiones locales y redistribuye sus intensidades, lo que mejora significativamente la visibilidad de los bordes delgados y los patrones de densidad de las amenazas ocultas.

3.5.4 Feature Extraction

En esta etapa, se realiza la extracción de características profundas utilizando diversas arquitecturas convolucionales y basadas en *transformers*, todas preentrenadas en el conjunto de datos ImageNet. En lugar de utilizar las salidas directas del modelo, se eliminan las capas de clasificación finales (heads) para obtener vectores de características de alto nivel llamados embeddings. Estos sirven como representaciones discriminativas para los clasificadores de Machine Learning que se aplicarán en la etapa posterior. Las arquitecturas evaluadas son las siguientes:

- **ConvNeXt-Tiny:** Esta arquitectura moderniza las redes convolucionales al incorporar principios de diseño de los Vision Transformers, como el uso de kernels de gran tamaño y cuellos de botella invertidos. De esta forma, mantiene el sesgo inductivo convolucional alcanzando un rendimiento al nivel de los transformadores (Liu et al., 2022).

$$z = \text{GlobalAvgPool}\big(F_L(x)\big) \tag{6}$$

Donde:
- $F_L(.)$: Salida de la última etapa convolucional
- GlobalAvgPool: Operador de agregación espacial

- **Swin Transformer-Tiny:** Introduce un aprendizaje de representación jerárquica mediante el uso de atención de ventana desplazada (shifted window attention), lo que permite reducir la complejidad computacional preservando la capacidad de modelado global (Liu et al., 2021).

$$z = \text{MLP}\big(\text{W-MSA}(x)\big) \tag{7}$$

Donde:
- W-MSA: Auto-atención de múltiples cabezas basada en ventanas
- MLP: Proyección de avance

- **EfficientNetV2-S:** Propone un aprendizaje progresivo y bloques MBConv fusionados, lo cual optimiza tanto la eficiencia durante el entrenamiento como el escalado de los parámetros del modelo (Tan y Le, 2021).

$$z = \phi\big(\text{MBConv}(x)\big) \tag{8}$$

Donde:
- MBConv: Convolución de cuello de botella invertida móvil
- ϕ: Activación no lineal

- **DeiT-Small:** Los transformadores de imagen eficientes en datos (Data-efficient Image Transformers) aprovechan la destilación de conocimiento para mejorar la eficiencia del entrenamiento sin requerir bases de datos masivas (Touvron et al., 2021).

$$z = \text{TransformerEncoder}\left(x_{patch}\right) \tag{9}$$

Donde:
- x_{patch}: Entrada tokenizada por parches

- **MaxViT-Tiny:** Combina mecanismos convolucionales y de atención global para capturar de manera efectiva las dependencias en múltiples escalas dentro de la imagen de seguridad (Tu et al., 2022).

$$z = \text{Block}_{conv}(x) + \text{Block}_{attn}(x) \tag{10}$$

Donde:
- Block_{conv}: Bloque convolucional
- Block_{attn}: Bloque de atención

- **CoAtNet-0:** Logra integrar la convolución y la atención mediante un apilamiento vertical para equilibrar la capacidad de generalización y el sesgo inductivo (Dai et al., 2021).

$$z = \text{Attention}\left(\text{Conv}(x)\right) \tag{11}$$

Donde:
- $\text{Conv}(x)$: Operación de convolución aplicada a la entrada
- Attention: Mecanismo de atención aplicado secuencialmente

- **MobileViT-S y MobileViTv2-100:** Estas arquitecturas integran convoluciones ligeras con bloques de transformadores para crear modelos de visión eficientes y aptos para dispositivos móviles (Mehta y Rastegari, 2022).

$$z = \text{MobileBlock}(x) + \text{TransformerBlock}(x) \tag{12}$$

Donde:
- MobileBlock: Bloque de convolución ligera
- TransformerBlock: Bloque de transformador integrado

3.5.5 Machine Learning

En esta fase, se entrenaron clasificadores de Machine Learning (ML) utilizando los embeddings que son outputs (salidas) de los backbones de la etapa previa. Esta estrategia híbrida permite combinar la capacidad de representación de las redes neuronales con las propiedades de generalización de los clasificadores tradicionales.

Para identificar la configuración óptima, se realizó una evaluación sistemática de combinaciones cruzadas entre cada backbone y cada clasificador de ML. Durante este proceso, se descartaron los modelos que mostraron un F1-macro y un Accuracy inferiores en el conjunto de validación, de esta manera solo las mejores combinaciones entrarían a la evaluación final. A continuación, se describen los algoritmos evaluados en esta investigación:

- **Regresión Logística Multinomial:** Este modelo proyecta probabilidades posteriores mediante la función softmax, estableciendo una frontera de decisión lineal en el espacio de los embeddings. Se basa en los principios de reconocimiento de patrones propuestos por Bishop (2006):

$$P(y = k \mid z) = \frac{\exp(w_k^T z + b_k)}{\sum_{j=1}^{C} \exp\left(w_j^T z + b_j\right)} \tag{13}$$

Donde:
- $z \in R^d$: Vector de embedding
- C: Número de clases
- w_k: Vector de pesos para la clase k
- b_k: Término de sesgo

- **Linear Support Vector Machine (Linear SVM):** El objetivo de este clasificador es maximizar el margen de separación entre las clases dentro del espacio de características, siguiendo el enfoque de Cortes y Vapnik (1995):

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{N} \xi_i \tag{14}$$

Sujeto a: $y_i(w^T z_i + b) \geq 1 - \xi_i$
Donde:
- C: Parámetro de regularización
- ξ_i:Variables de holgura
- N: Número de muestras

- **SVM con Kernel RBF:** Este modelo introduce no linealidad al mapear los embeddings a un espacio de mayor dimensión mediante el uso del kernel de Función de Base Radial (RBF). Al igual que la versión lineal, se fundamenta en el trabajo de Cortes y Vapnik (1995):

$$K(z_i, z_j) = \exp\left(-\gamma\left\|z_i - z_j\right\|^2\right) \tag{15}$$

Donde:
- γ: Coeficiente del kernel

- **LightGBM:** Es un marco de trabajo de gradient boosting basado en árboles de decisión, optimizado mediante la división por histogramas y el crecimiento por hojas (leaf-wise). Se basa en la investigación de Ke et al. (2017):

$$F_m(z) = F_{m-1}(z) + \eta h_m(z) \tag{16}$$

Donde:
- F_m: Modelo de ensamble en la iteración m
- h_m: Aprendiz de árbol de decisión
- η: Tasa de aprendizaje

- **CatBoost:** Este algoritmo implementa un gradient boosting avanzado con árboles simétricos y una técnica de ordered boosting para mitigar el sobreajuste y el desplazamiento de las predicciones, siguiendo lo propuesto por Prokhorenkova et al. (2018):

$$F_m(z) = F_{m-1}(z) + \eta T_m(z) \tag{17}$$

Donde:
- T_m: Árbol de decisión simétrico

3.5.6 Evaluación

Esta etapa del desarrollo de la metodología explica cómo se diseñó el proceso para probar, comparar y elegir los mejores componentes de todo el sistema. Para que la elección sea justa y transparente, los modelos se evaluaron usando únicamente el conjunto de validación, asegurando que solo las combinaciones con mejor rendimiento pasen a la evaluación final. El proceso de evaluación se dividió en tres niveles según las etapas de la solución:

- **Evaluación del localizador (YOLOv8):** En esta evaluación se midió qué tan bien el modelo YOLOv8 logra ubicar y encerrar los objetos prohibidos dentro de la maleta completa. Para esto, se utilizaron las métricas estándar de detección llamadas mAP@0.5 y mAP@0.5:0.95, las cuales miden la precisión del cuadro delimitador.
- **Evaluación y descarte de modelos de Deep Learning:** En esta parte se puso a prueba la calidad de los vectores (*embeddings*) que genera cada modelo de Deep Learning. Se evaluaron y compararon un total de 8 arquitecturas diferentes: ConvNeXt-Tiny, Swin Transformer-Tiny, EfficientNetV2-S, DeiT-Small, MaxViT-Tiny, CoAtNet-0, MobileViT-S y MobileViTv2-100. Para ver qué tan bien se

agrupaban y separaban las clases, se utilizaron técnicas de reducción de datos como PCA y UMAP. La regla impuesta fue descartar por completo los modelos que confundían los objetos o daban resultados bajos en la validación, lo que permitió eliminar arquitecturas como DeiT o MobileViT y quedarnos solo con las mejores.

- **Evaluación y ajuste de los modelos de Machine Learning:** Los vectores de las mejores arquitecturas sirvieron como entrada en varios clasificadores tradicionales para que compitan entre sí: Regresión Logística Multinomial, Linear SVM, RBF Kernel SVM, LightGBM y CatBoost. Para entrenarlos y mover sus parámetros de forma segura, se utilizó una validación cruzada de 5 *folds*. El rendimiento final de la clasificación se midió con las métricas de Accuracy, Precision, Recall, el Área Bajo la Curva ROC (AUC) y, como filtro principal de elección, el F1-Score Macro.
- **Evaluación y Selección de las Métricas Finales:** Durante los experimentos se calcularon varias métricas tradicionales como Accuracy, Precision y Recall. Sin embargo, se determinó que métricas como el Accuracy debían dejarse en segundo plano o descartarse como criterio principal, ya que en problemas de seguridad con datos desbalanceados pueden ocultar el mal rendimiento en las clases con menos imágenes. Por esta razón, se eliminaron las demás métricas como criterios de decisión final y se seleccionó el F1-Score Macro como la métrica principal, ya que evalúa a todas las amenazas con el mismo nivel de exigencia.

3.5.7 Despliegue

Esta sección describe el proceso de implementación y despliegue de una solución de inteligencia artificial para la detección automática de objetos peligrosos en imágenes de rayos X aplicadas al contexto de seguridad aeroportuaria.

La solución desarrollada integra técnicas de Deep Learning y Machine Learning mediante una arquitectura híbrida compuesta por:

- Un modelo de detección de objetos basado en la arquitectura YOLO para la localización espacial de las regiones de interés.
- Un extractor profundo de características (*feature extractor*) basado en la red convolucional EfficientNetV2 para el aislamiento de descriptores.
- Un clasificador de Regresión Logística Multinomial (*Multinomial Logistic Regression*) a cargo la clasificación final de la amenaza.
- Una *REST API* desplegada en una plataforma de infraestructura en la nube (*Google Cloud Platform*).
- Una aplicación cliente de escritorio diseñada específicamente para la interacción directa y la toma de decisiones por parte de los operadores de seguridad aeroportuaria.

El objetivo principal fue dar disponibilidad al modelo desarrollado localmente como un servicio escalable y accesible desde diferentes plataformas, manteniendo una arquitectura desacoplada y orientada a servicios.

1. Arquitectura Lógica

La arquitectura lógica propuesta para el sistema de seguridad opera bajo un enfoque cliente-servidor distribuido en la nube, el cual permite separar las responsabilidades para que la estación local no asuma los altos costos computacionales. El flujo inicia directamente con el Operador Aeroportuario, quien actúa como el usuario final del sistema interactuando directamente en la estación de inspección con la Aplicación Desktop. Esta interfaz local se encarga de capturar las matrices visuales de los equipajes a partir de los escaneos de rayos X o flujos de video, empaquetar las solicitudes y prepararlas para su transmisión segura hacia los servicios en la nube.

La conectividad y orquestación del sistema se centralizan en una API REST desarrollada sobre el Framework FastAPI y desplegada mediante contenedores en Cloud Run. Este componente actúa como puente de entrada al entorno Cloud, recibiendo la carga útil enviada por el cliente y derivándola inmediatamente hacia el Pipeline de Inferencia operado en Vertex AI. Esta capa de orquestación se encarga de sincronizar el ciclo de vida de los datos y de realizar las llamadas optimizadas hacia los tres modelos predictivos del sistema. En este punto, el modelo YOLO localiza espacialmente los objetos sospechosos, el extractor profundo EfficientNetV2 procesa los recortes para generar los embeddings vectoriales de alta densidad y, finalmente, el clasificador de regresión logística en BigQuery ML clasifica la categoría de riesgo.

Finalmente, el pipeline consolida los tres resultados individuales en un Resultado Final (Predicción consolidada). Esta respuesta final es devuelta en sentido inverso a través de la API en Cloud Run hacia la aplicación de escritorio, la cual activa de forma instantánea las alertas sonoras y visuales correspondientes en la pantalla de Operador, tal como se muestra en la Figura 15.

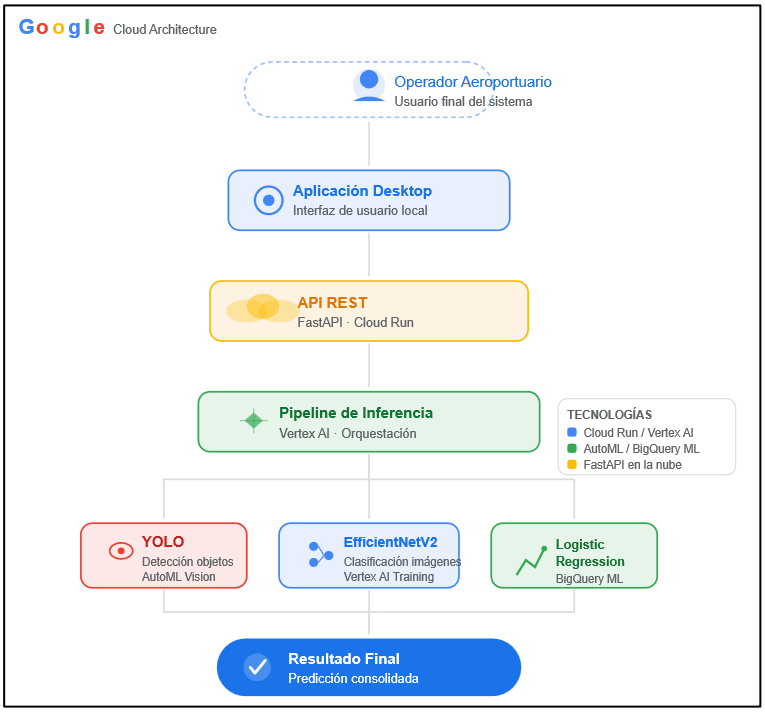


Figura 15. Diagrama de la Arquitectura Lógica del Despliegue.

Fuente: Elaboración propia

2. Arquitectura de Inferencia

El sistema implementa una estrategia híbrida de clasificación estructurada en un pipeline secuencial de procesamiento de datos, diseñado para optimizar tanto la localización como la clasificación de los objetos prohibidos. El ciclo de inferencia comienza con la recepción de la imagen de rayos X en formato raw (DICOM o PNG) almacenada en Cloud Storage, la cual sirve como la entrada principal del sistema. Inmediatamente, el detector YOLO procesa la imagen completa de rayos X y genera cajas delimitadoras (*bounding boxes*) que aíslan las coordenadas exactas de los objetos sospechosos detectados.

Una vez localizadas estas regiones de interés, cada región detectada se recorta dinámicamente y se somete al pipeline de normalización dimensional previamente

parametrizado. El extractor profundo EfficientNetV2 procesa los recortes normalizados de forma independiente, removiendo su capa de salida para mapear los patrones visuales y transformarlos en vectores de características de alta densidad (*embeddings*).

En la etapa final del flujo, los descriptores vectoriales se envían a un repositorio centralizado de características (*Feature Store*) en Vertex AI para asegurar la consistencia de los datos normalizados. Finalmente, estos vectores limpios alimentan directamente al clasificador de regresión logística desarrollado en BigQuery ML, el cual computa las probabilidades posteriores mediante la función *softmax* para asignar la etiqueta definitiva de la clase prohibida, consolidando el comportamiento del pipeline tal como se detalla en la Figura 16.



Figura 16. Diagrama de la Arquitectura de Inferencia.

Fuente: Elaboración propia

3. Especificación Funcional de la Aplicación

La aplicación de escritorio constituye el último paso del sistema de despliegue, actuando como la interfaz encargada de traducir los resultados del pipeline en acciones operativas entendibles para el operador. El sistema está diseñado para realizar las siguientes funcionalidades:

- La carga de imágenes estáticas de rayos X.
- Gestionar la ingesta continua de secuencias multimedia a través de un módulo especializado en el procesamiento de videos.
- Comunicación con la API Cloud para enviar las muestras y recibir las predicciones.
- Visualización de detecciones.
- Generación de alertas.
- Reproducción de sonido ante amenazas detectadas.

El análisis de flujos de video opera de manera específica mediante un algoritmo de muestreo periódico de *frames*, lo cual balancea eficientemente el consumo de ancho de banda y la velocidad de respuesta. Ante el escenario crítico en que el pipeline cloud retorne la presencia confirmada de un objeto prohibido dentro de un *frame* evaluado, la aplicación interrumpe la secuencia regular para ejecutar un protocolo inmediato de contención y respuesta, la cual se detalla de la siguiente manera:

- La reproducción del video se pausa de forma instantánea para congelar el *frame* sospechoso.
- El sistema genera una alerta visual sobre las coordenadas de la amenaza.
- Se reproduce una alerta sonora para capturar la atención inmediata del operador.

- Se da un control absoluto al operador bajo un enfoque de supervisión humana, quedando a la espera del operador para decidir formalmente si descarta el peligro y continúa con la secuencia, o si detiene de manera definitiva la inspección física para proceder con un registro manual del equipaje.

Este pipeline opera mediante la recepción del flujo crudo en el módulo de Video, el cual descompone la señal en un *stream de frames*. Posteriormente, el componente Cada N Frames aplica un muestreo periódico configurable para aislar únicamente el *frame* seleccionado y enviarlo hacia la API Cloud en Cloud Run. Una vez ejecutada la inferencia, el servidor retorna una predicción JSON hacia el entorno local, donde la aplicación de escritorio decodifica el mensaje para consolidar el resultado final en la estación de trabajo, desplegando instantáneamente la clase del objeto, el nivel de confianza y la alerta en pantalla. El flujo se detalla en la Figura 17.

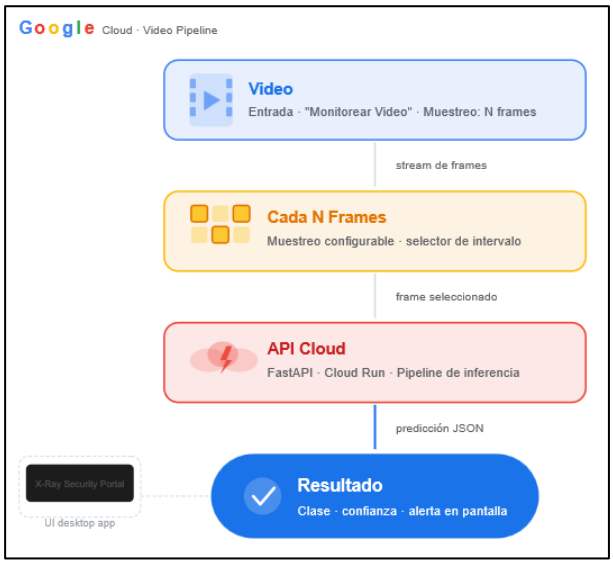


Figura 17. Diagrama del Pipeline de Procesamiento de Video

Fuente: Elaboración propia

3.6 Metodología para la Medición de los Resultados de la Implementación

La evaluación del desempeño se refiere a la medición integral de cada una de las fases que componen la arquitectura propuesta. Dado que el objetivo principal es la localización e identificación precisa de objetos prohibidos en imágenes de rayos X, se han seleccionado métricas y técnicas de análisis que permitan medir la robustez de todo el sistema. A continuación, se detallan los criterios utilizados en cada etapa y sus expresiones matemáticas:

3.6.1 Métricas para el modelo YOLOv8

- **Intersección sobre Unión (IoU):** De acuerdo con Redmon et al. (2016), mide el grado de superposición entre la caja que predice el modelo (A) y la caja real anotada a mano (B). Sirve para determinar matemáticamente la precisión del encuadre geométrico:

$$IoU = \frac{|A \cap B|}{|A \cup B|} \tag{18}$$

  Donde:
  - A:Área de la caja delimitadora predicha
  - B:Área de la caja delimitadora real (ground truth)
  - $\cap$:Operador de intersección geométrica
  - $\cup$:Operador de unión de superficies

- **Mean Average Precision (mAP@0.5):** Representa el promedio de la precisión de todas las clases evaluadas bajo un umbral fijo donde el IoU debe ser de al menos el 50%. Como describen Redmon et al. (2016), esta métrica permite medir la sensibilidad general del detector para encontrar los objetos.

$$mAP_{0.50} = \frac{1}{C}\sum_{c=1}^{C} AP_c \tag{19}$$

  Donde:
  - C: Número total de clases
  - c: Índice numérico de cada clase
  - AP_c: Precisión promedio para la clase c
  - Umbral de $IoU = 0.50$

- **Mean Average Precision (mAP@0.5:0.95):** Es la métrica más exigente en la detección de objetos. Según Redmon et al. (2016), esta métrica calcula el promedio del mAP variando el umbral de IoU desde el 50% hasta el 95% con pasos constantes de 5%, lo que sirve para evaluar la calidad y exactitud milimétrica de las cajas generadas frente a escenarios de superposición.

$$mAP_{0.50:0.95} = \frac{1}{10C} \sum_{t=0.50}^{0.95} \sum_{c=1}^{C} AP_c^{(t)} \tag{20}$$

Donde:
- t: Umbrales de IoU desde 0.50 a 0.95 con pasos de 0.05
- $AP_c^{(t)}$: AP para la clase c en el umbral t

3.6.2 Métricas para el modelo híbrido DL-ML

a) Accuracy: Representa la fracción total de predicciones correctas realizadas por el modelo sobre el total de casos evaluados. De acuerdo con los fundamentos de selección métrica de Bishop (2006), este indicador es útil para evaluar la exactitud global del sistema, pero pierde representatividad y no destaca como un criterio principal cuando se trabaja con conjuntos de datos desbalanceados.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{21}$$

Donde:
- TP: Verdaderos Positivos
- TN: Verdaderos Negativos
- FP: Falsos Positivos
- FN:Falsos Negativos

b) Precision: Mide la calidad de las predicciones positivas; es decir, bajo los criterios de evaluación probabilística de Goodfellow et al. (2016), determina qué tan confiable es el modelo híbrido cuando indica que una región recortada de la imagen

pertenece a una de las 12 clases de amenaza, minimizando la ocurrencia de falsas alarmas.

$$\text{Precision}_{macro} = \frac{1}{C}\sum_{i=1}^{C}\frac{TP_i}{TP_i + FP_i} \tag{22}$$

Donde:
- C:Número total de clases (12)
- TP_i:Verdaderos Positivos de la clase i
- FP_i:Falsos Positivos de la clase i

c) Recall: Evalúa la capacidad del modelo para detectar todas las amenazas realmente presentes en el dataset. Como señala Bishop (2006), es una métrica crítica y prioritaria en entornos de seguridad aeroportuaria, ya que un valor de *Recall* bajo implica dejar pasar objetos peligrosos hacia la cabina del avión (generando Falsos Negativos).

$$\text{Recall}_{macro} = \frac{1}{C}\sum_{i=1}^{C}\frac{TP_i}{TP_i + FN_i} \tag{23}$$

Donde:
- FN_i:Falsos Negativos de la clase i

d) F1-Score (Macro-Averaged): Proporciona un equilibrio directo entre la precisión y la sensibilidad mediante su cálculo basado en la media armónica. Según Goodfellow et al. (2016) para problemas multiclase, se utiliza la versión *Macro* para asegurar que todas las clases de amenazas tengan exactamente el mismo peso en la evaluación final, independientemente de si cuentan con una frecuencia alta o baja de imágenes.

$$F1_{macro} = 2 \times \frac{\text{Precision}_{macro} \times \text{Recall}_{macro}}{\text{Precision}_{macro} + \text{Recall}_{macro}} \tag{24}$$

e) Multiclass AUC (One-vs-Rest): Esta métrica se calcula de forma independiente para cada una de las C clases basándose en las teorías de distribución de Bishop (2006), evaluando de manera continua la relación entre la tasa de verdaderos

positivos y la tasa de falsos positivos a lo largo de diferentes umbrales, lo que mide la capacidad del clasificador para separar limpiamente las categorías de contrabando.

$$AUC_{macro} = \frac{1}{C}\sum_{k=1}^{C} AUC_k \tag{25}$$

Donde:

- C: Número total de clases
- AUC_k: Área bajo la curva para la clase k

3.7 Cronograma de Actividades

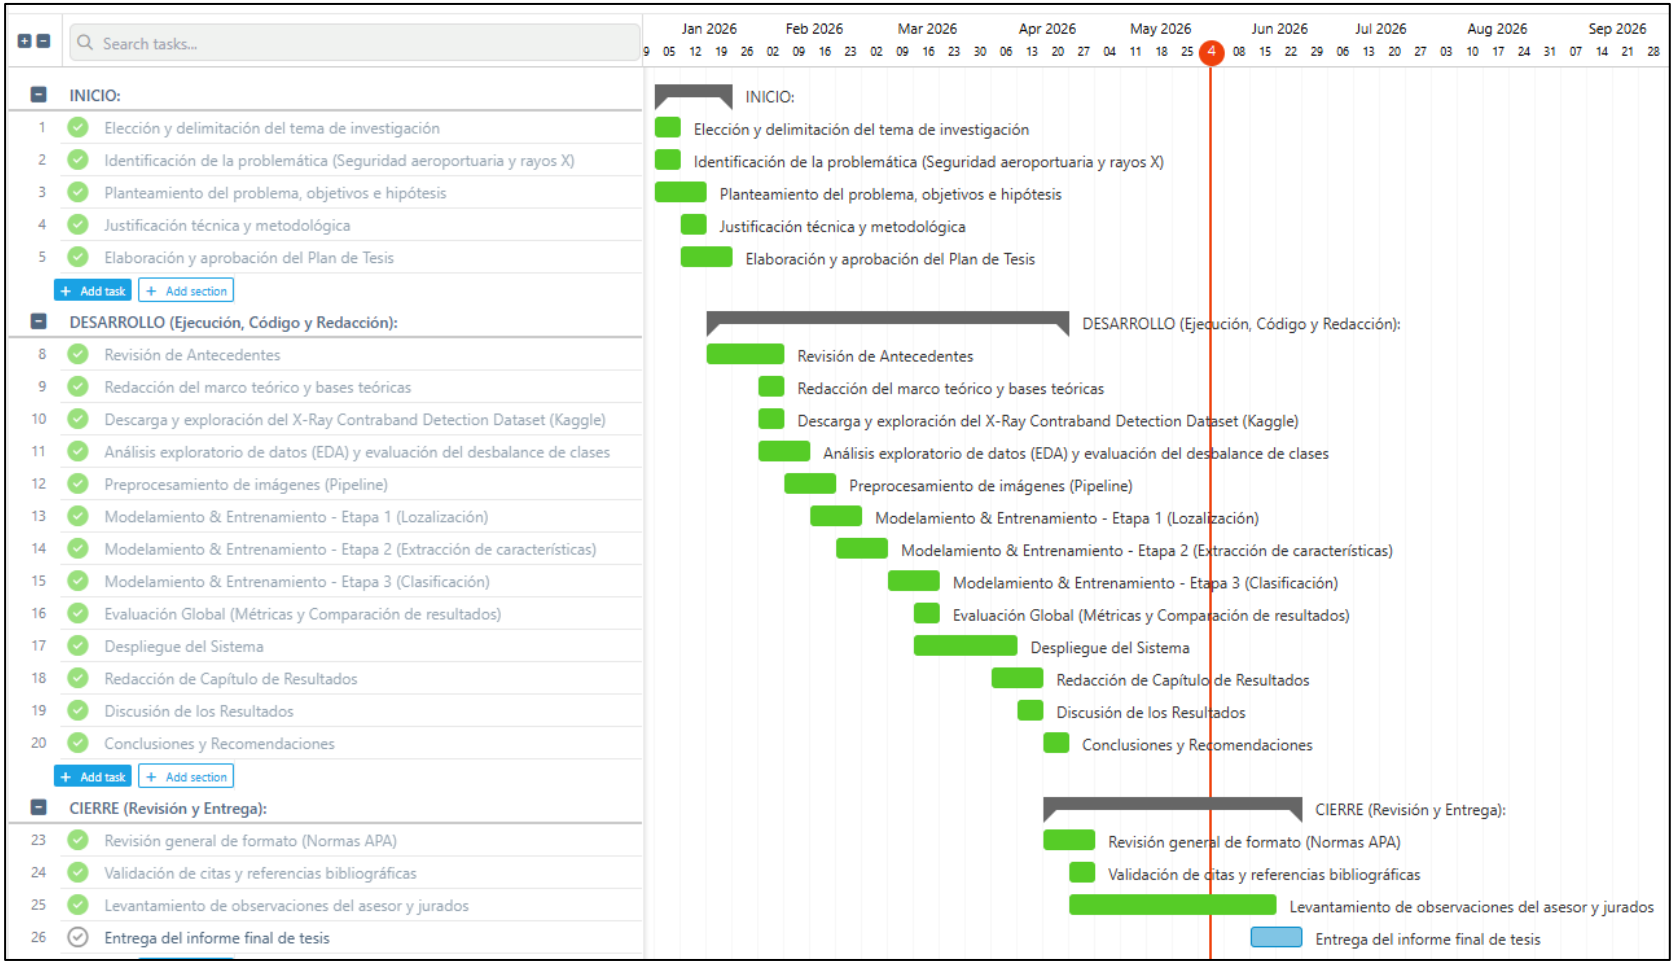


Figura 18. Cronograma de Actividades.

Fuente: Elaboración propia

3.8 Presupuesto

Tabla 12.
Recursos del proyecto

Categoría	Descripción	Cantidad / Tiempo	Costo Aproximado
Equipos	Lenovo Yoga Slim 7 Series	1 unidad / 6 meses	S/ 562.50
	ASUS TUF Gaming A15	1 unidad / 6 meses	S/ 450.00
Cloud	Google Platform Cloud	Prueba Gratuita	S/ -
	Suscripción Google Colab Pro	2 consumos	S/ 86.07
	Almacenamiento en Google Drive (Dataset y Pesos)	Licencia Gratuita	S/ -
Software	Entorno de desarrollo (Instagantt, Microsoft Office, otros.)	Licencia Gratuita	S/ -
Otros gastos estimados	Servicio de Internet y energía eléctrica	6 meses	S/ 700.00
TOTAL			**S/ 1,798.57**

Fuente: Elaboración propia

Capítulo IV: Desarrollo de la Solución

4.1 Determinación y evaluación de alternativas de solución

Con el objetivo de desarrollar un sistema capaz de detectar objetos prohibidos en imágenes de rayos X de manera precisa y robusta, se analizaron diferentes alternativas tecnológicas utilizadas en problemas de visión por computadora. La evaluación consideró criterios como capacidad de detección, robustez ante oclusiones y superposición de objetos, complejidad de implementación, requerimientos computacionales y desempeño reportado en investigaciones previas. A partir de este análisis se identificaron tres enfoques principales que podrían ser aplicados al problema planteado.

4.1.1 Alternativa 1: Enfoque basado en Machine Learning tradicional

Esta alternativa consiste en utilizar técnicas tradicionales de visión por computadora para extraer características manualmente a partir de las imágenes de rayos X. Posteriormente, dichas características son utilizadas por algoritmos de clasificación supervisada como Support Vector Machine (SVM), Random Forest o Regresión Logística.

Entre los descriptores más utilizados se encuentran Histogram of Oriented Gradients (HOG), Local Binary Patterns (LBP) y otros métodos de extracción de texturas y bordes. La principal ventaja de este enfoque radica en sus bajos requerimientos computacionales y en la facilidad de interpretación de los resultados. Sin embargo, presenta limitaciones importantes para representar escenas complejas con objetos superpuestos y variaciones significativas de forma, orientación y escala.

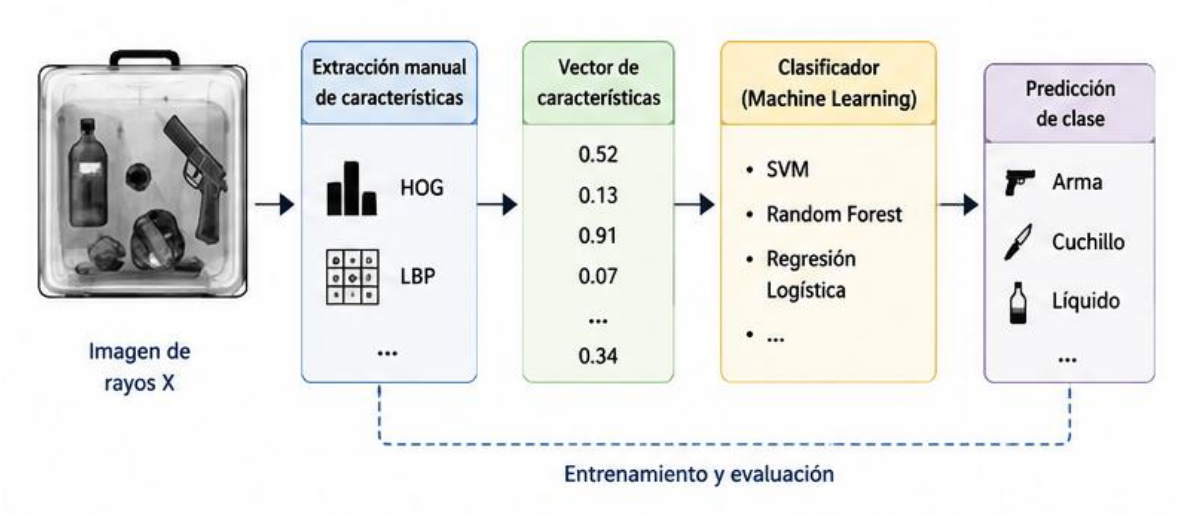


Figura 19. Arquitectura general de un sistema basado en extracción manual de características y clasificación mediante Machine Learning.

Fuente: Elaboración propia

4.1.2 Alternativa 2: Enfoque basado exclusivamente en Deep Learning

La segunda alternativa consiste en utilizar arquitecturas de Deep Learning capaces de aprender automáticamente representaciones visuales a partir de grandes volúmenes de datos. Modelos como YOLO, EfficientNet, ConvNeXt y Swin Transformer han demostrado resultados sobresalientes en tareas de clasificación y detección de objetos.

La principal ventaja de este enfoque es su elevada capacidad para modelar patrones complejos presentes en imágenes de rayos X, especialmente en escenarios donde existen oclusiones o superposición de objetos. No obstante, estos modelos requieren mayores recursos computacionales, tiempos de entrenamiento prolongados y una optimización más compleja de hiperparámetros.

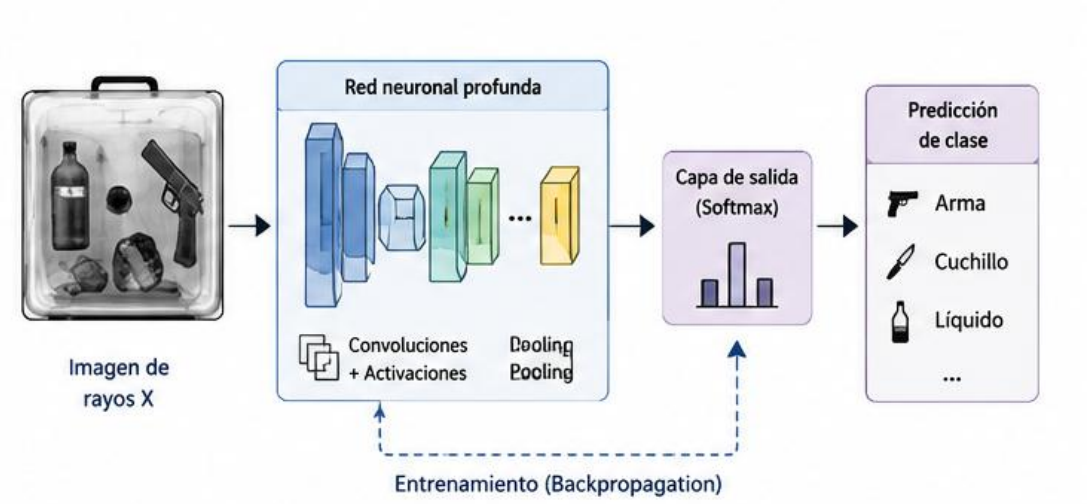


Figura 20. Arquitectura general de una solución basada exclusivamente en Deep Learning. Fuente: Elaboración propia

4.1.3 Alternativa 3: Enfoque híbrido basado en Deep Learning y Machine Learning

La tercera alternativa combina las ventajas de los enfoques anteriores mediante una arquitectura híbrida. En esta estrategia, modelos de Deep Learning preentrenados son utilizados para extraer características visuales de alto nivel, mientras que algoritmos de Machine Learning realizan la clasificación final.

Este enfoque permite aprovechar la capacidad de representación de las redes neuronales profundas sin depender completamente de ellas para la toma de decisiones. Además, facilita la evaluación de diferentes clasificadores utilizando un mismo conjunto de características, permitiendo identificar configuraciones con mejor capacidad de generalización.

Debido a estas ventajas, esta alternativa fue seleccionada como base para el desarrollo de la presente investigación.

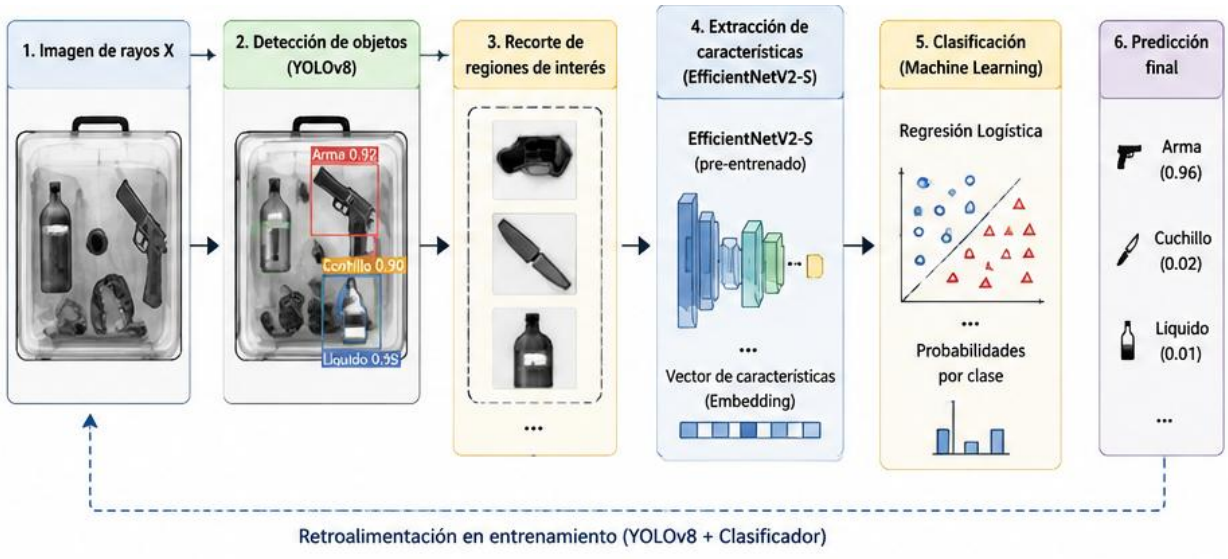


Figura 21. Arquitectura general del enfoque híbrido propuesto.

Fuente: Elaboración propia

4.1.4 Comparación de alternativas

Con el propósito de seleccionar la alternativa más adecuada para el problema de detección de objetos prohibidos en imágenes de rayos X, se realizó una comparación considerando criterios técnicos y operativos relevantes para el contexto aeroportuario.

Tabla 13.
Comparación de Alternativas

Criterio	Machine Learning	Deep Learning	Arquitectura Híbrida
Extracción automática de características	No	Si	Si
Robustez ante oclusiones	Baja	Alta	Alta
Precisión esperada	Media	Alta	Alta
Complejidad de entrenamiento	Baja	Alta	Media
Requerimientos computacionales	Bajos	Altos	Medios
Capacidad de generalización	Media	Alta	Alta
Facilidad de optimización	Alta	Media	Alta
Adaptabilidad a nuevas clases	Baja	Alta	Alta
Adecuación al problema planteado	Media	Alta	Muy Alta

Fuente: Elaboración propia

A partir de la comparación realizada, se determinó que la arquitectura híbrida representa la alternativa más adecuada para el contexto de la investigación, ya que combina la capacidad de aprendizaje profundo para la extracción de características con la eficiencia y flexibilidad de los algoritmos de Machine Learning durante la clasificación. Esta combinación permite obtener un equilibrio entre desempeño, complejidad computacional y capacidad de generalización, aspectos fundamentales para sistemas de apoyo a la inspección aeroportuaria.

4.2 Propuesta de Solución

Una vez seleccionada la arquitectura híbrida como alternativa de solución para la detección de objetos prohibidos en imágenes de rayos X, fue necesario definir una estrategia de implementación que permitiera desarrollar, entrenar y evaluar el sistema de manera estructurada. Para ello se estableció un conjunto de actividades organizadas secuencialmente, orientadas a transformar los datos de entrada en un modelo capaz de identificar amenazas dentro del equipaje inspeccionado.

La propuesta de solución se diseñó siguiendo un enfoque incremental, donde cada actividad aporta los elementos necesarios para la siguiente etapa del proceso. De esta manera, se garantiza la trazabilidad desde la preparación de los datos hasta la evaluación final del desempeño del modelo.

4.2.1 Planeamiento y Descripción de Actividades

Con el propósito de implementar la solución propuesta de manera estructurada, se definió un conjunto de actividades secuenciales que permitieran transformar imágenes de rayos X en predicciones automáticas de objetos prohibidos. La planificación se diseñó considerando el flujo completo de procesamiento de datos, desde la adquisición de las imágenes hasta la evaluación del desempeño del sistema. Cada actividad fue concebida para proporcionar los

insumos necesarios para la siguiente etapa, garantizando la integridad del proceso y la correcta integración de los componentes de la arquitectura híbrida.

El flujo general de actividades consideradas durante el desarrollo de la solución propuesta se puede visualizar en el diseño de la metodología de la implementación de la solución (Ver Figura. 14).

Actividad 1. Identificación y Descarga del Dataset

La primera actividad consistió en planificar la obtención de un conjunto de datos adecuado para el entrenamiento y evaluación de los modelos. Para ello se contempló la búsqueda de datasets públicos especializados en inspección de equipajes mediante rayos X, priorizando aquellos que incluyeran imágenes etiquetadas de objetos prohibidos y que hubieran sido utilizados previamente en investigaciones científicas.

Asimismo, se planteó realizar un análisis de la cantidad de imágenes disponibles, la distribución de las categorías, la calidad de las anotaciones y la diversidad de escenarios presentes en los datos. Como resultado esperado de esta actividad, se buscó disponer de un conjunto de imágenes representativo que permitiera entrenar modelos capaces de generalizar correctamente ante diferentes configuraciones de equipaje y distintos tipos de amenazas.

Actividad 2. Preprocesamiento

La segunda actividad estuvo orientada a la preparación de las imágenes antes de su utilización en los modelos de aprendizaje automático. Se planificó aplicar técnicas de procesamiento de imágenes que permitieran mejorar la visibilidad de los objetos y reducir la influencia de elementos irrelevantes presentes en las radiografías.

Entre las acciones previstas se consideró la identificación de regiones de interés, el recorte de objetos detectados, la normalización de tamaños y la aplicación de técnicas de mejora de contraste. Estas operaciones tuvieron como finalidad resaltar características visuales

importantes como bordes, contornos y patrones de densidad, facilitando posteriormente el proceso de extracción de características realizado por los modelos de Deep Learning.

Actividad 3. Entrenamiento

La tercera actividad correspondió al desarrollo del núcleo de la solución propuesta. Se planificó implementar una arquitectura híbrida compuesta por una etapa de detección de objetos, una etapa de extracción de características y una etapa de clasificación.

Inicialmente se contempló utilizar un modelo de detección para localizar automáticamente las regiones donde se encontrarán posibles objetos prohibidos dentro de las imágenes de rayos X. Posteriormente, dichas regiones serían procesadas mediante arquitecturas de Deep Learning preentrenadas con el objetivo de generar representaciones numéricas de alto nivel. Finalmente, estas características servirían como entrada para diferentes algoritmos de Machine Learning, permitiendo comparar distintas configuraciones y seleccionar aquella que ofreciera el mejor desempeño.

Actividad 4. Evaluación

La cuarta actividad estuvo orientada a la validación del sistema desarrollado. Para ello se planificó utilizar métricas ampliamente empleadas en problemas de clasificación multiclase, permitiendo medir de manera objetiva la capacidad del modelo para identificar correctamente las diferentes categorías de objetos prohibidos.

Asimismo, se consideró la comparación de diversas combinaciones de extractores de características y clasificadores, con el fin de determinar la configuración más adecuada para el problema estudiado. Como parte de esta actividad también se contempló el análisis de errores mediante herramientas de visualización, tales como matrices de confusión y curvas ROC, permitiendo identificar fortalezas y limitaciones del sistema antes de su despliegue final.

4.2.2 Desarrollo de Actividades. Aplicación de Herramientas de solución.

4.2.2.1 Fase 1: Obtención del Dataset

Actividad 1. Identificación y Descarga del Dataset

La robustez de un modelo híbrido para la detección y clasificación de objetos prohibidos depende principalmente de la calidad y variabilidad de los datos de entrenamiento. Para este estudio, se utilizó un dataset consolidado de 13,728 imágenes de alta calidad, provenientes de dos de los repositorios académicos más reconocidos en el ámbito de la seguridad aeroportuaria: SIXray (Miao et al., 2019) y PIDray (Wei et al., 2020).

La integración de ambas fuentes dio un total de 12 clases de objetos prohibidos, abarcando desde armas de fuego y armas blancas hasta herramientas contundentes. Las distintas clases son de mucha importancia para enseñar al modelo a reconocer amenazas bajo distintos niveles de oclusión y en escenarios de clutter extremo (aglomeración de objetos). La información se estructuró en una carpeta principal con las imágenes originales y sus anotaciones:

data/: Contiene las imágenes originales junto con sus archivos de etiquetas (labels/ e images/) y los archivos de configuración .yaml (data.yaml, SPXray.yaml y data_ultra.yaml) necesarios para indicarle al modelo la ubicación de las rutas y los nombres de las clases.



Figura 23. Estructura general del repositorio de las imágenes originales y su etiquetado.

Fuente: Elaboración propia

4.2.2.2 Fase 2: Preprocesamiento

La etapa de preprocesamiento transforma las imágenes originales de los escáneres y sus anotaciones en entradas estandarizadas y óptimas para el extractor de características profundas. Esta fase es importante para corregir las variaciones de resolución, iluminación y escala inherentes a las capturas de rayos X. A continuación, se detalla los pasos del preprocesamiento realizados en Python:

Actividad 1. Recorte de imágenes (Cropping) y Reorganización del dataset

Las anotaciones originales del dataset consolidado están almacenadas en archivos de texto .txt bajo el formato estándar de YOLO. Cada línea de estos archivos representa un objeto prohibido mediante cinco variables: el índice de la clase y las coordenadas del cuadro delimitador, las cuales vienen normalizadas de forma relativa en un rango de 0 a 1. Para poder extraer los embeddings, el script desarrollado carga primero las imágenes originales utilizando la librería PIL (Pillow) y extrae sus dimensiones reales en píxeles (ancho y alto total). Mediante un bucle automatizado, el código multiplica estas dimensiones por las coordenadas de YOLO, transformando los valores relativos en píxeles absolutos para hallar los bordes exactos del cuadro. Inmediatamente después, el script ejecuta el método de recorte (img.crop) para aislar la región donde se encuentra la amenaza, eliminando todo el ruido de fondo de la maleta. Para evitar que los archivos se sobrescriban cuando hay múltiples objetos dentro de un mismo equipaje, cada recorte se exporta con un identificador único bajo el formato {nombre_imagen}-{i}.jpg. Finalmente, los fragmentos se guardan de forma automatizada en el directorio data_crops/, ordenados en subcarpetas del 0 al 11 para cada una de las clases de contrabando. El flujo secuencial de esta actividad se detalla de forma sistemática en la Figura 24.

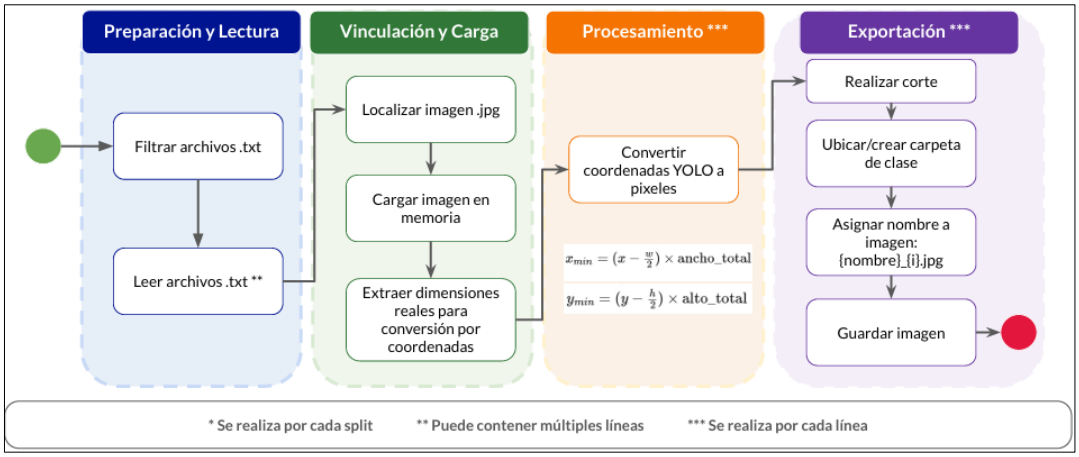


Figura 24. Flujo de procesamiento para el recorte de objetos prohibidos y reorganización del dataset.

Fuente: Elaboración propia

Por otro lado, el impacto visual de esta transformación sobre las imágenes de inspección reales se ejemplifica en la Figura 25, donde se contrasta la captura completa de la maleta frente al objeto prohibido.

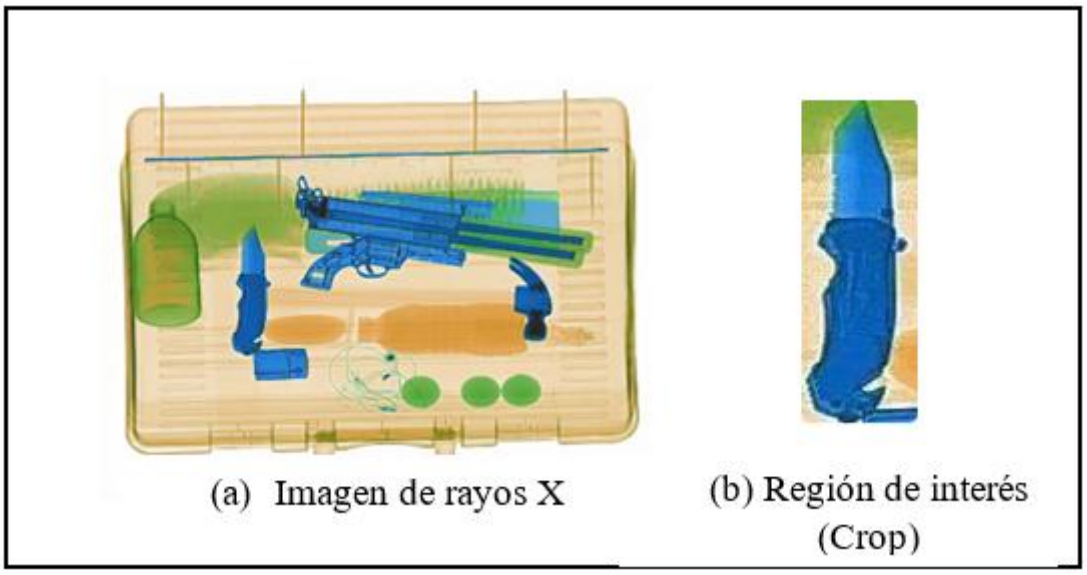


Figura 25. Resultado del proceso de recorte de regiones de interés: (a) Imagen de rayos X original y (b) Región de interés (Crop).

Fuente: Elaboración propia

Actividad 2. Normalización

El extractor de características profundas seleccionado (EfficientNetV2-S) exige que las imágenes de entrada tengan un tamaño cuadrado fijo de 224x224 píxeles. Sin embargo, realizar un reajuste directo deformaría la geometría de los objetos prohibidos, alterando su morfología y afectando el aprendizaje del clasificador. Para solucionar esto, se programó una función de redimensionamiento utilizando OpenCV. El algoritmo evalúa las dimensiones originales del objeto recortado y calcula un factor de escala mínimo para ajustarlo al tamaño objetivo sin perder sus proporciones reales, cuyo cálculo es la siguiente relación matemática:

$$scale = \frac{S}{\max(W, H)} \tag{26}$$

Donde:
- $scale$:Factor de escala adaptativo.
- S:Tamaño objetivo del lienzo fijo (224 píxeles).
- W:Ancho original del recorte (crop).
- H:Alto original del recorte (crop).
- $\max(W, H)$:Mayor dimensión entre el ancho y el alto original.

A partir de este factor, las nuevas dimensiones proporcionales del objeto se determinan como se ve en la fórmula:

$$W' = W \times scale \quad ; \quad H' = H \times scale \tag{27}$$

Donde:
- W':Nuevo ancho escalado del objeto.
- H': Nuevo alto escalado del objeto.

El reajuste se ejecuta mediante una interpolación de área (cv2.INTER_AREA), la cual es ideal para reducir tamaños manteniendo la nitidez de los bordes delgados. Una vez escalado el objeto, el script genera un lienzo completamente negro de 224x224 píxeles mediante la función np.zeros. Luego, calcula los desplazamientos espaciales necesarios para colocar el

recorte exactamente en el centro de este lienzo (zero-padding), aplicando las ecuaciones de compensación que se muestran a continuación:

$$x_{offset} = \frac{S - W'}{2} \quad ; \quad y_{offset} = \frac{S - H'}{2} \tag{28}$$

Donde:

- x_{offset}: Desplazamiento horizontal para el centrado.
- y_{offset}: Desplazamiento vertical para el centrado.

Esto asegura que el 100% de las entradas tengan un tamaño uniforme sin distorsionar la estructura física del artículo. Las imágenes normalizadas resultantes se guardan en la ruta Dataset_Normalized/.

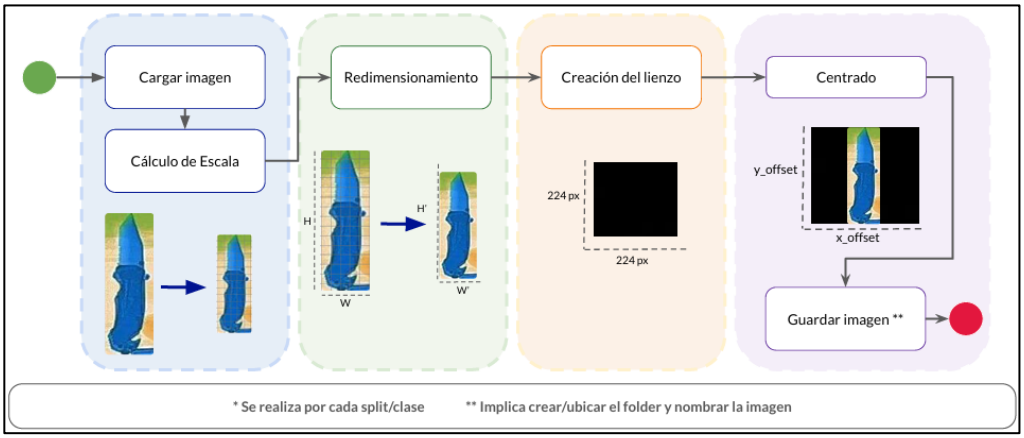


Figura 26. Flujo de procesamiento para redimensionamiento de las imágenes.

Fuente: Elaboración propia

Actividad 3. Mejora de Contraste Local CLAHE (Enhancing)

Las imágenes de rayos X suelen presentar distribuciones de intensidad muy compactas y objetos encimados de densidades similares. Con el fin de resaltar los contornos críticos y las firmas materiales de las amenazas ocultas, el script ejecuta una última etapa de optimización visual basada en el algoritmo CLAHE. Si este filtro se aplica directamente sobre los canales de color RGB convencionales, alteran los colores representativos del material de rayos X. Para evitar esta distorsión, la función apply_clahe_rgb convierte primero la imagen al espacio de color LAB, el cual tiene la ventaja de separar por completo la información de luminosidad

(canal L) de los componentes de color (canales A y B). Una vez aislado el canal de luminosidad, se instancia el objeto CLAHE configurando los parámetros óptimos definidos en tu código: un límite de contraste (clipLimit=2.0) para evitar que el ruido del fondo se sobreamplifique en las regiones más densas, y una división zonal en cuadrículas locales (tileGridSize=(8,8)) de 8x8 píxeles para ecualizar el histograma por áreas pequeñas. Finalmente, los canales se vuelven a fusionar y la imagen se reconvierte al formato original, logrando resaltar de forma nítida los bordes metálicos y las texturas de los contrabandos. El producto final se exporta de manera automatizada hacia la ruta Dataset_Enhanced/, quedando listo para la extracción de *embeddings*.

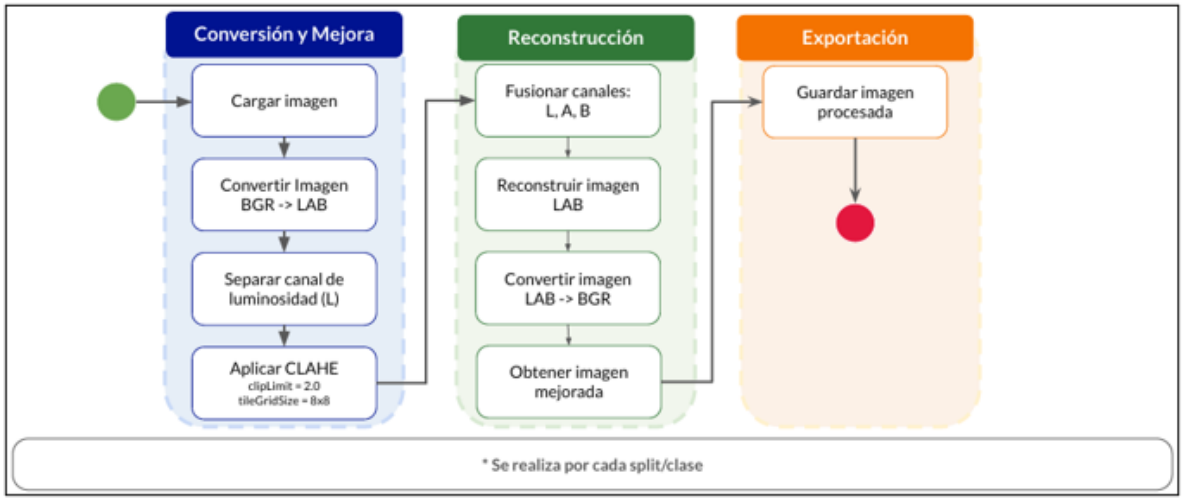


Figura 27. Flujo de procesamiento para la mejora de contraste de las imágenes.

Fuente: Elaboración propia

A partir de esta estructura, el dataset final de 18 014 imágenes se distribuyó como se muestra en la Tabla 14.

Tabla 14.
Distribución del dataset en los conjuntos de entrenamiento, validación y prueba

Subconjunto	**Imágenes**	**% del total**
Entrenamiento (Train)	14,413	80.01%
Validación (Val)	1,794	9.96%
Prueba (Test)	1,807	10.03%
Total	**18,014**	**100%**

Fuente: Elaboración propia

El conjunto de datos se distribuyó siguiendo una proporción aproximada de 80/10/10, manteniendo un balance similar entre clases en cada subconjunto. Esta partición garantiza que el conjunto de prueba permanezca completamente aislado durante el entrenamiento y la validación, permitiendo una evaluación imparcial del desempeño final del modelo.

4.2.2.3 Fase 3: Feature Extraction

Al tratarse de un modelo híbrido, el sistema primero delimita la ubicación de la amenaza para mitigar falsos positivos y confusiones entre objetos visualmente similares.

Actividad 1. Localización de Regiones de Interés (Modelo YOLO v8)

La primera etapa de la arquitectura tiene como objetivo principal poder localizar automáticamente las regiones de interés mediante cuadros delimitadores, también conocidos como *bounding boxes*, permitiendo aislar los objetos prohibidos de resto del equipaje para posteriormente analizarlo en el modelo híbrido.

El entrenamiento del detector se configuró bajo un conjunto de hiperparámetros controlados para evitar problemas de sobreajuste (*overfitting*):

- **Resolución de entrada:** Las imágenes de entrada se procesaron a un tamaño de 224x224 píxeles.
- **Volumen de entrenamiento:** Se estableció un límite de 50 épocas de aprendizaje para el modelo.
- **Tamaño de lote (Batch Size):** Configurado a 32 imágenes por iteración.
- **Criterio de regularización:** Se activó la función de parada temprana (early stopping), la cual monitorea la pérdida en el subconjunto de validación y detiene el entrenamiento de forma automática si el modelo deja de registrar mejoras.

Como entregables principales de esta subfase, se genera el detector de objetos entrenado, los archivos de pesos optimizados del modelo, las métricas de desempeño sobre el conjunto de prueba y el sistema de inferencia para la detección automática.

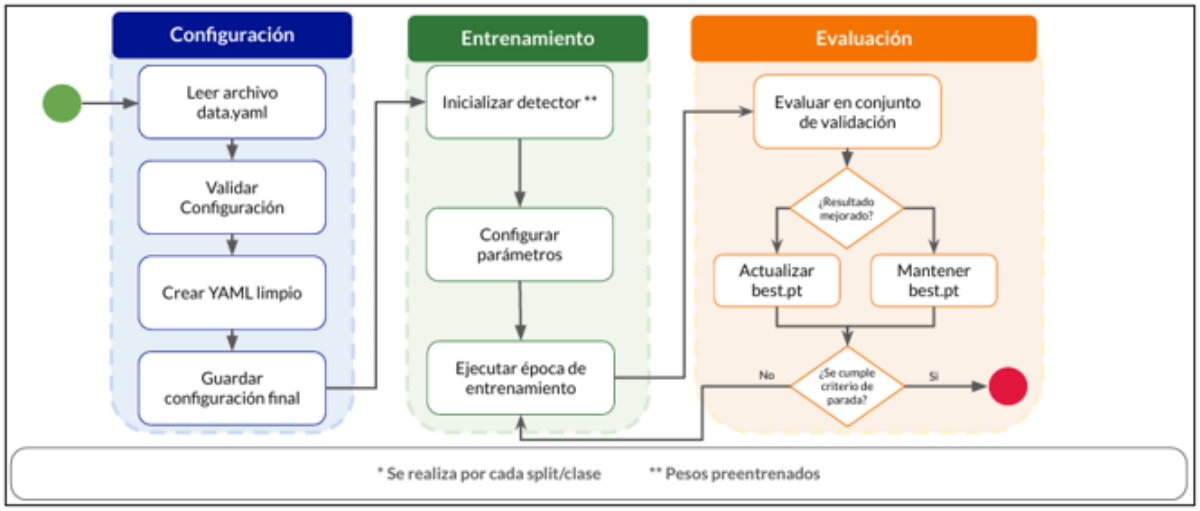


Figura 28. Flujo de procesamiento para la localización y generación de bounding boxes mediante YOLOv8.

Fuente: Elaboración propia

Actividad 2. Generación de Embeddings con Backbones Preentrenados)

Una vez que las regiones de interés fueron localizadas por el detector y pasaron por el pipeline de normalización visual, se procedió con la etapa de extracción profunda de características. El modelo de Deep Learning fue utilizado como extractor profundo de características sobre los objetos detectados en el paso anterior, aislando descriptores visuales. El objetivo principal de esta etapa es transformar cada objeto de interés en un vector de características discriminativas capaz de representar patrones complejos, permitiendo posteriormente su procesamiento mediante algoritmos de Machine Learning. Para encontrar la representación semántica con más valor, se evaluaron e implementaron múltiples arquitecturas preentrenadas basadas en redes convolucionales y *Vision Transformers*. El proceso de selección técnica se guio por las siguientes características operativas:

- **Fine-Tuning:** Los *backbones* pasaron por una estrategia de *fine-tuning* para optimizar y especializar sus pesos.
- **Criterio de regularización:** Se programó un criterio de parada temprana (*early stopping*), deteniendo el entrenamiento si la pérdida de validación dejaba de disminuir.
- **Validación cruzada y comparación sistemática:** Todos los modelos pasaron por una evaluación cruzada sistemática configurado por métricas para descartar las configuraciones de bajo rendimiento.

Las arquitecturas de Deep Learning evaluadas como extractores de características (*Feature Extractors*) se detallan a contonuación:

- **ConvNeXt-Tiny:** Se implementó en el *test* logrando generar *embeddings* estables de 768 dimensiones. Durante las evaluaciones del pipeline demostró un rendimiento inicial robusto; sin embargo, debido a que su capacidad discriminativa relativa fue menor frente a la arquitectura ganadora, se terminó descartando durante la selección final de despliegue.
- **Swin Transformer-Tiny:** Se evaluó en el entorno experimental registrando una reducción efectiva en la complejidad computacional del modelado global de los objetos. A pesar de generar *embeddings* competitivos, el rendimiento general del pipeline tuvo ineficientes resultados frente a las pruebas basadas en ConvNeXt, procediendo a su descarte de la arquitectura final.
- **EfficientNetV2-S:** Se configuró aplicando una estrategia de aprendizaje progresivo en el balance de sus parámetros. Este extractor generó vectores de características robustos de 1,792 dimensiones y consolidó los valores métricos de validación F1-macro más altos y estables de toda la experimentación, siendo seleccionada de forma definitiva como la arquitectura base (*backbone*) de la solución final con *fine-tuning*.

- **DeiT-Small:** Se introdujo en los experimentos con el fin de evaluar vectores de características compactos, produciendo *embeddings* de 384 dimensiones. No obstante, durante las pruebas de validación, la métrica F1-macro decayó consistentemente por debajo de los resultados requeridos para la solución, provocando su eliminación del conjunto de candidatos finales.
- **MaxViT-Tiny:** Se integró para capturar dependencias a múltiples escalas espaciales en las imágenes normalizadas. Registró un rendimiento balanceado de rango medio (*mid-range performance*) en las pruebas, pero fue descartado para el despliegue final al no superar las métricas de validación obtenidas por las opciones previamente evaluadas.
- **CoAtNet-0:** Se evaluó con el propósito de balancear la capacidad de generalización en el testeo de los objetos. Aunque demostró ser un extractor estructuralmente estable en el procesamiento de datos, sus *embeddings* vectoriales no lograron superar los límites de F1-macro alcanzados por ConvNeXt y EfficientNetV2, quedando descartado del pipeline definitivo.
- **MobileViT-S y MobileViTv2-100:** Se incorporaron en la fase experimental como alternativas ligeras orientadas a optimizar los tiempos de ejecución. Pese a que demostraron una alta eficiencia computacional en las pruebas de velocidad, arrojaron métricas de validación comparativamente deficientes frente al resto, siendo removidos por completo de los experimentos subsecuentes.

El flujo y las especificaciones de esta actividad de extracción se describen en la Figura 29.

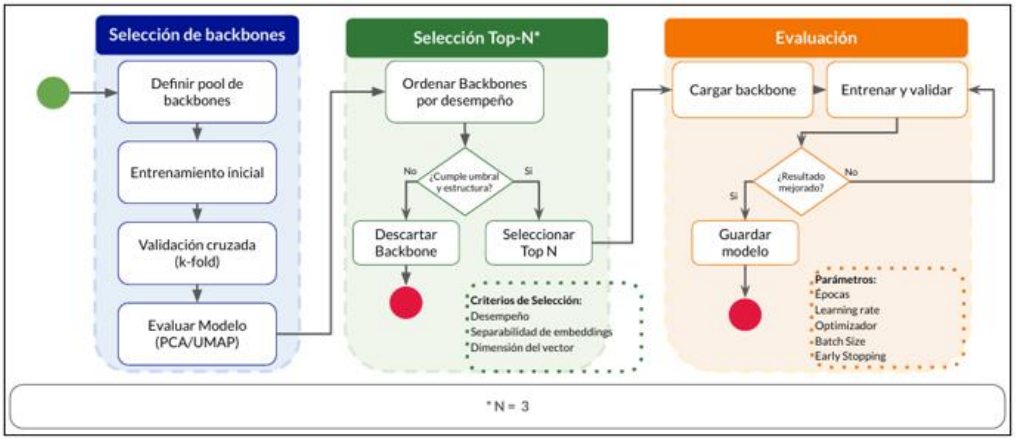


Figura 29. Flujo de procesamiento para la extracción profunda de características.

Fuente: Elaboración propia

4.2.2.4 Fase 4: Machine Learning

Los vectores de 1,792 dimensiones extraídos óptimamente por EfficientNetV2-S se utilizaron como la matriz de entrada directa para alimentar a los clasificadores supervisados de Machine Learning. El modelo de Machine Learning fue utilizado para realizar la clasificación final a partir de los embeddings generados por el extractor Deep Learning. El objetivo principal de esta etapa es identificar automáticamente la clase del objeto utilizando representaciones profundas discriminativas, optimizando el desempeño mediante clasificadores lineales y no lineales. Este proceso se ejecuta secuencialmente en tres etapas principales, tal como se muestra en la Figura 30.

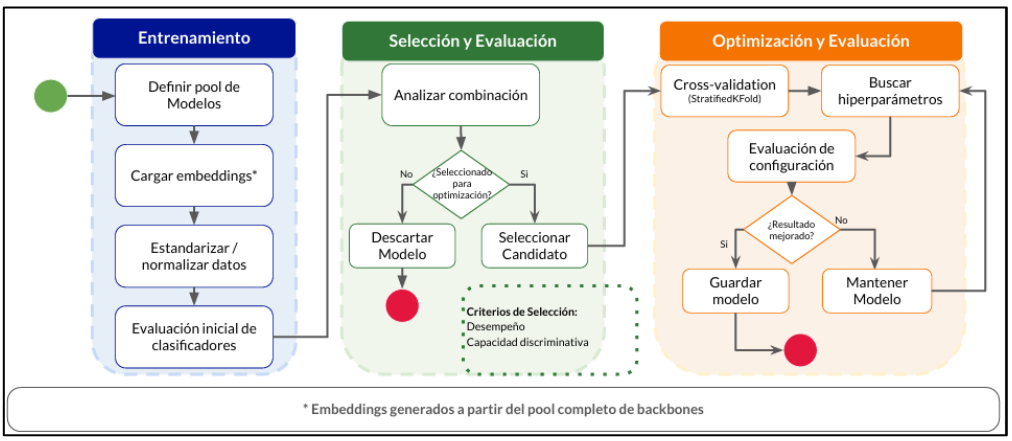


Figura 30. Flujo de procesamiento para la clasificación final.

Fuente: Elaboración propia

Actividad 1. Entrenamiento

En esta primera etapa, se define el pool de modelos, se cargan los embeddings generados por el backbone, se normalizan los datos y se realiza una evaluación inicial de los clasificadores. Los clasificadores evaluados se configuraron bajo las siguientes especificaciones lógicas:

- **Regresión Logística Multinomial:** Configurada mediante la función softmax multinomial para modelar probabilidades posteriores en un espacio lineal estable, optimizada con el solucionador lbfgs y regularización. Aunque inicialmente se consideró como una línea base simple, tras el fine-tuning del backbone se convirtió en la combinación óptima del sistema.
- **Support Vector Machine (LinearSVM, L2_LinearSVM y RBF_SVM):** Se evaluaron tres variantes del clasificador SVM. La variante lineal estándar (LinearSVM) busca un hiperplano de separación óptimo directamente sobre los embeddings escalados, mientras que su variante con normalización L2 (L2_LinearSVM) proyecta primero los vectores sobre una hiperesfera unitaria antes del entrenamiento, favoreciendo la estabilidad del margen en espacios de alta dimensionalidad. Por su parte, la variante con Kernel de Función de Base Radial (RBF_SVM) proyecta los embeddings a dimensiones superiores para maximizar los márgenes geométricos interclase en problemas no separables linealmente.
- **Algoritmos de Gradient Boosting (LightGBM y CatBoost):** Se configuraron mediante la construcción secuencial de árboles de decisión optimizados por histogramas y simetría estructural para blindar las fronteras contra el desbalance de datos.

Actividad 2. Selección y Evaluación

En esta segunda etapa, se analiza cada combinación bajo criterios de desempeño y capacidad discriminativa; las configuraciones insuficientes se descartan y el mejor modelo es

seleccionado como candidato. Para calibrar las fronteras de decisión entre las 12 categorías de objetos prohibidos, este protocolo se caracterizó por las siguientes propiedades operativas:

- **Basado en vectores de características:** El procesamiento prescinde de las imágenes crudas, operando directamente sobre matrices numéricas compactas de alta dimensionalidad.
- **Integración DL-ML:** Combina la generalización espacial de las redes neuronales con la robustez matemática de los modelos clásicos.
- **Selección basada en F1-macro:** Respetando las exigencias en la seguridad aeroportuaria, el criterio de descarte priorizó el F1-Score Macro para penalizar cualquier descuido sobre clases minoritarias.

Actividad 3. Optimización y Evaluación

Finalmente, el candidato seleccionado se somete a una validación cruzada (Stratified K-Fold) y a una búsqueda de hiperparámetros mediante Grid Search, respaldada por una validación cruzada de 5 folds, para sintonizar los parámetros de regularización sin comprometer el conjunto de prueba. Si la nueva configuración mejora el resultado, el modelo final se guarda; caso contrario, se mantiene el modelo base. Los entregables finales de esta subfase constituyeron el clasificador multiclasificado entrenado, el modelo híbrido DL-ML optimizado, las métricas finales de clasificación y el pipeline consolidado listo para despliegue en entornos de alta velocidad aeroportuaria.

4.3 Medición de la Solución

La medición de la solución tuvo como finalidad determinar el nivel de desempeño alcanzado por la arquitectura híbrida propuesta en la detección y clasificación de objetos prohibidos en imágenes de rayos X. Para ello, se estableció un proceso de evaluación orientado a cuantificar la capacidad predictiva del modelo y analizar su comportamiento frente a las

diferentes condiciones presentes en las imágenes de inspección, tales como la superposición de objetos, las variaciones de escala y las diferencias entre categorías.

Con el propósito de obtener una evaluación integral, se emplearon indicadores cuantitativos que permitieron analizar tanto el rendimiento estadístico del sistema como la calidad de las predicciones generadas. Estos criterios de evaluación se describen a continuación.

4.3.1 Análisis de indicadores cuantitativos y cualitativos (Fase 5: Evaluación)

La evaluación de la solución se ejecutó de manera integral abarcando de forma unificada las etapas de detección, extracción profunda de características y clasificación final, con el objetivo de analizar el desempeño individual y conjunto del modelo híbrido. El análisis se fundamentó en métricas cuantitativas que permitieron validar la capacidad de generalización y la robustez del pipeline sobre las complejas estructuras visuales de las imágenes de rayos X. Para asegurar un diseño experimental riguroso, el proceso no se limitó a un reporte ciego de resultados, sino que implementó una estrategia de eliminación y selección jerárquica basada estrictamente en el conjunto de validación. Este protocolo impidió la optimización posterior o sesgos optimistas sobre el conjunto de prueba independiente, descartando progresivamente las configuraciones que mostraron un desempeño estadísticamente inferior en cada nivel de la arquitectura. Las dimensiones evaluadas y sus respectivos criterios de descarte se estructuraron bajo los siguientes tres ejes lógicos:

Actividad 1. Evaluación del modelo YOLOv8

En la primera etapa del pipeline híbrido, se evaluó matemáticamente la capacidad del modelo YOLOv8 para localizar correctamente los objetos de interés dentro de la maleta completa. La evaluación de la localización y la precisión de las cajas delimitadoras se rigió por dos métricas fundamentales del estado del arte:

- **mAP@0.5:** Precisión media promedio calculada bajo un umbral estricto de Intersección sobre Unión (*IoU*) fijado en el 50%, permitiendo validar la sensibilidad base del localizador para capturar candidatos de interés.
- **mAP@0.5:0.95:** Una métrica de tolerancia significativamente más rigurosa que promedia el desempeño a través de múltiples umbrales de IoU (desde 50% hasta 95% con pasos constantes de 5%), evaluando la precisión milimétrica del encuadre geométrico frente a la superposición de objetos.

Actividad 2. Evaluación de los modelos Deep Learning

Para el componente de Deep Learning, el protocolo se enfocó en evaluar la calidad de los embeddings de alta dimensionalidad extraídos por los backbones evaluados, determinando su capacidad para representar patrones discriminativos. En esta subfase, se ejecutaron análisis de reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA) y Mapeo y Proyección Uniforme de Variedades (UMAP) para inspeccionar visualmente la separabilidad y el agrupamiento de los vectores en el espacio latente.

- **Criterio de Eliminación Directa:** Aquellos backbones que exhibieron de manera consistente puntuaciones bajas de separabilidad espacial o un desvanecimiento en el poder discriminativo de sus capas durante la validación cruzada congelada fueron descartados de inmediato. Arquitecturas como DeiT-Small, MobileViT-S y MobileViTv2-100 fueron eliminadas del flujo de procesamiento en esta fase al demostrar un bajo rendimiento de representación frente al potencial modelo EfficientNetV2-S.

Actividad 3. Evaluación de los modelos Machine Learning

La última fase del protocolo evaluó el desempeño específico de los clasificadores tradicionales entrenados utilizando exclusivamente los embeddings profundos inyectados. Para

responder a la naturaleza crítica de la seguridad aeroportuaria y mitigar los efectos del desbalance entre clases, se estructuró un orden jerárquico de decisión basado en tres métricas clave:

- **F1-Macro:** Utilizada como el filtro rendimiento, debido a que promedia el desempeño de cada clase de forma independiente a su volumen de muestras, garantizando que los objetos peligrosos minoritarios reciban la misma rigurosidad de detección.
- **Accuracy:** Evalúa la exactitud global del sistema midiendo la tasa general de predicciones correctas sobre el total del dataset.
- **AUC One-vs-Rest:** El Área Bajo la Curva ROC multiclase que mide la capacidad probabilística del clasificador para separar de forma limpia cada amenaza frente al resto de categorías, operando de manera independiente al umbral de decisión discreto.

Al cruzar todas las combinaciones en la matriz de validación, se ejecutó la eliminación de todos los pares que mostraron un decaimiento en el F1-Score. Este filtro condujo a la selección definitiva de la arquitectura compuesta por el extractor EfficientNetV2-S (fine-tuned) y el clasificador de Regresión Logística Multinomial (tuned), la cual avanzó hacia la evaluación final sobre el conjunto de prueba independiente.

4.3.2 Aplicación del software y visualización de resultados (Fase 6: Despliegue)

Una vez validado el desempeño de la arquitectura híbrida mediante los indicadores de evaluación establecidos, se procedió a la fase de despliegue con el objetivo de implementar una solución funcional capaz de ejecutar inferencias sobre nuevas imágenes de rayos X. Esta etapa permitió trasladar el modelo desde un entorno experimental hacia una arquitectura de software orientada a su utilización práctica, integrando los componentes de detección, extracción de

características y clasificación en un flujo de procesamiento unificado. Asimismo, se desarrollaron mecanismos para la gestión de los modelos entrenados, el procesamiento de solicitudes y la visualización de resultados, permitiendo demostrar el funcionamiento integral de la solución propuesta en un escenario similar al de una operación real de inspección aeroportuaria.

Actividad 1. Estructura Backend y Gestión de Artefactos

La aplicación fue desarrollada siguiendo los principios de programación orientada a objetos y la separación de responsabilidades. El código base del proyecto se organizó en módulos lógicos delimitados, tal como se evidencia en el árbol de directorios de la Figura 31. Se implementó un módulo “api” encargado de gestionar los controladores HTTP y expone los endpoints REST, un módulo “services” para la coordinación de la lógica de negocio, y un módulo “core” destinado a la administración de las variables de entorno y parámetros globales de ejecución.

El núcleo del sistema se encapsuló en el módulo “ml”, donde se integraron de manera secuencial los artefactos predictivos resultantes de las fases de entrenamiento. En esta capa se referenciaron los tres modelos fundamentales del pipeline híbrido: el detector espacial YOLO (detector/best.pt), la red convolucional EfficientNetV2 RW-S ajustada mediante *fine-tuning* para la extracción de características (featureExtractor/effnetv2_rw_s_best.pt), y el modelo de Regresión Logística encargado de la clasificación final (classifier/LogReg_tuned.joblib).

Alineado con las buenas prácticas de operaciones de Machine Learning (*MLOps*), los archivos de pesos entrenados no se almacenaron en el repositorio de código fuente (GitHub) debido a sus restricciones de tamaño y a la necesidad de mantener la separación entre el código y los artefactos de IA. En su lugar, los modelos fueron exportados y alojados de forma segura dentro de un *bucket* dedicado en el servicio Cloud Storage de Google Cloud Platform (GCP),

estableciendo una jerarquía de carpetas idéntica a la del entorno local, como se ilustra en la Figura 32.

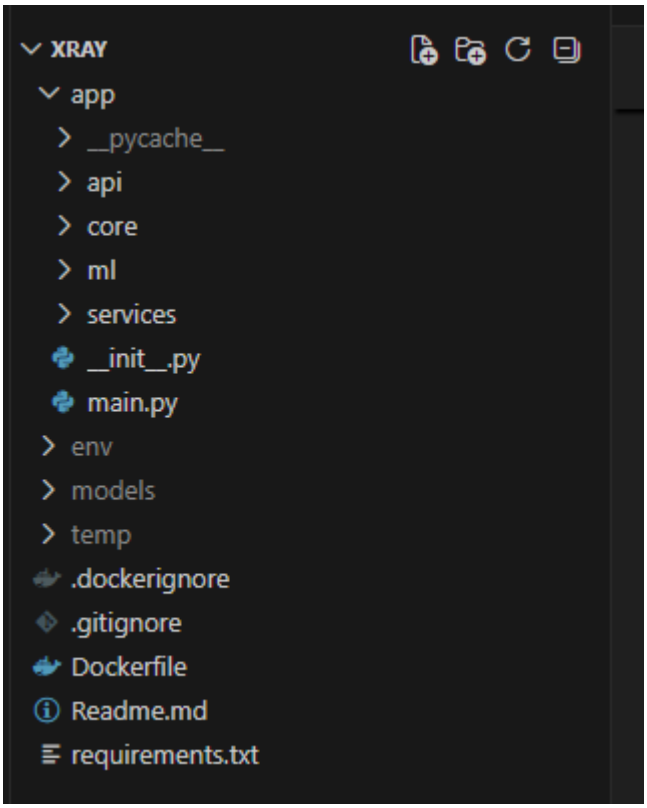


Figura 31. Estructura de directorios del proyecto.

Fuente: Elaboración propia

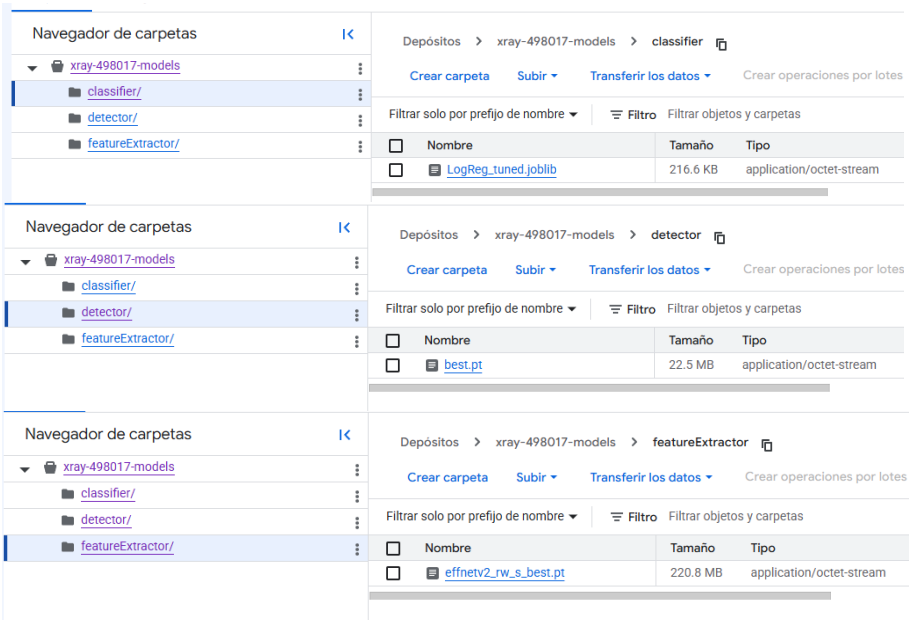


Figura 32. Almacenamiento de modelos en Cloud Storage.

Fuente: Elaboración propia

Actividad 2. Construcción de la API REST y Contenerización

Para disponibilizar la lógica de inferencia, se construyó una interfaz de programación de aplicaciones (*REST API*) utilizando el framework de alto rendimiento FastAPI. Esta herramienta fue seleccionada por su velocidad de ejecución, su compatibilidad nativa con arquitecturas de contenedores y su capacidad para generar documentación interactiva de forma automática. El servicio expone el endpoint principal **POST / predict**, el cual fue parametrizado para recibir las imágenes de rayos X codificadas, ejecutar el pipeline bajo demanda y retornar un objeto JSON con las coordenadas espaciales, el nombre de la clase y los niveles de confianza de la amenaza detectada, funcionalidad que se validó mediante Swagger (Figura 33).

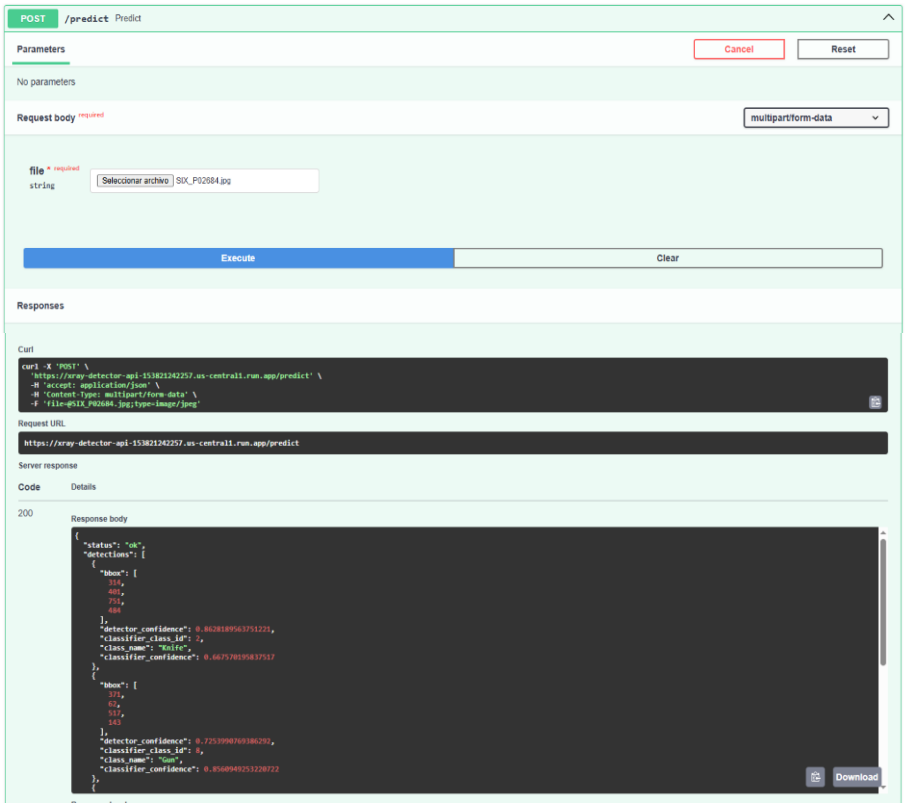


Figura 33. Interfaz de prueba de la API.

Fuente: Elaboración propia

Para garantizar la reproducibilidad del entorno, la escalabilidad y la consistencia absoluta entre los ambientes de desarrollo y producción, la aplicación completa fue empaquetada utilizando la tecnología de contenerización *Docker*. Esta estrategia permitió aislar las dependencias del sistema operativo base, facilitando el despliegue en la nube.

Actividad 3. Infraestructura en GCP (Google Cloud Platform)

El sistema de producción fue desplegado sobre la infraestructura de Google Cloud Platform (GCP), aprovechando sus capacidades de escalamiento elástico y disponibilidad global. La topología de integración y entrega continua (*CI/CD*) se diseñó para automatizar el ciclo de vida del software, cuyo flujo se detalla en la Figura 34.

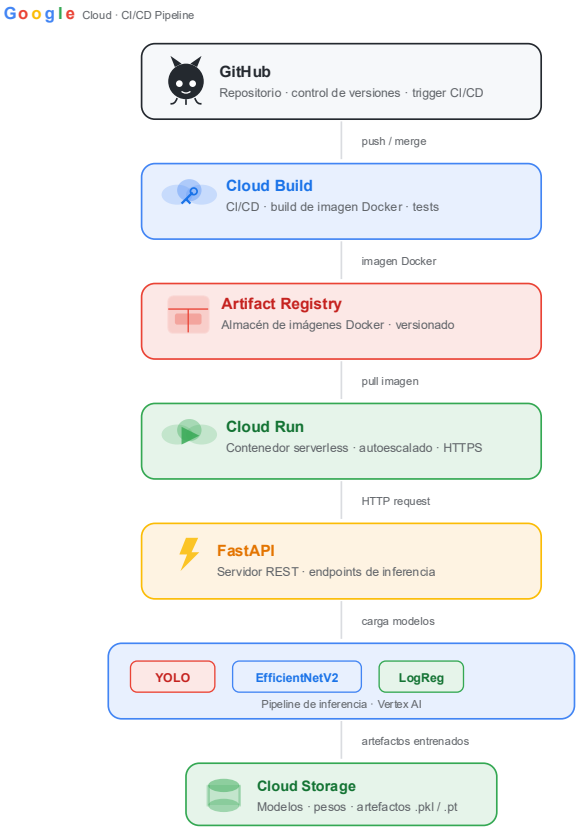


Figura 34. Arquitectura del pipeline CI/CD en GCP.

Fuente: Elaboración propia

Cada actualización en el repositorio de código activaba automáticamente un disparador (*trigger*) en Cloud Build, el cual se encargaba de compilar la imagen de Docker y ejecutar las pruebas correspondientes, como se evidencia en los registros de compilación exitosa de las Figura 35. Posteriormente, la imagen certificada era almacenada y versionada en Artifact Registry, quedando lista para su consumo.

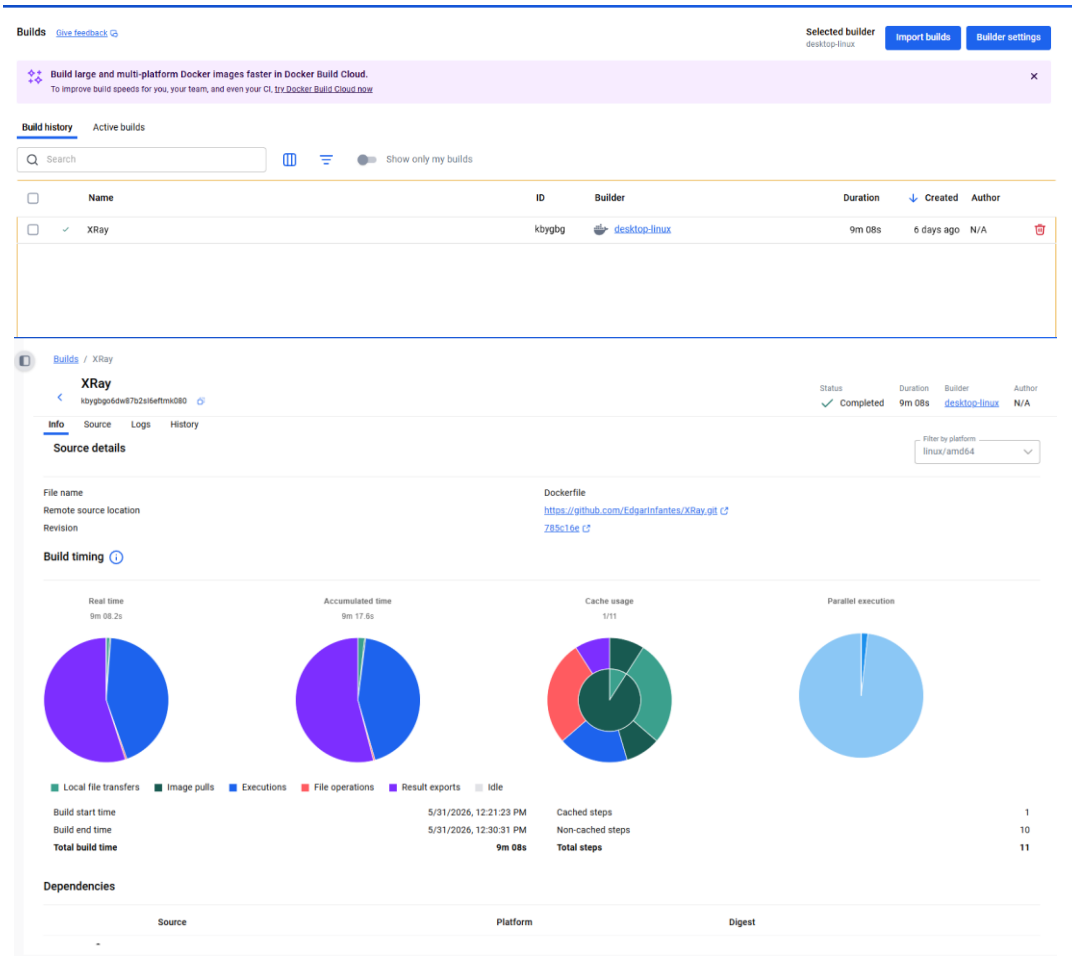


Figura 35. Registros de Docker.
Fuente: Elaboración propia

Finalmente, el contenedor fue instanciado utilizando Cloud Run, un servicio *serverless* que otorgó a la API de un escalado automático, alta disponibilidad concurrente y exposición segura mediante el protocolo HTTPS. El servicio quedó operativo y accesible públicamente, verificando su estado de conexión mediante respuestas HTTP 200, como se muestra en la Figura 36. El *endpoint* base del servicio en producción fue habilitado en la siguiente URL: https://xray-detector-api-153821242257.us-central1.run.app/

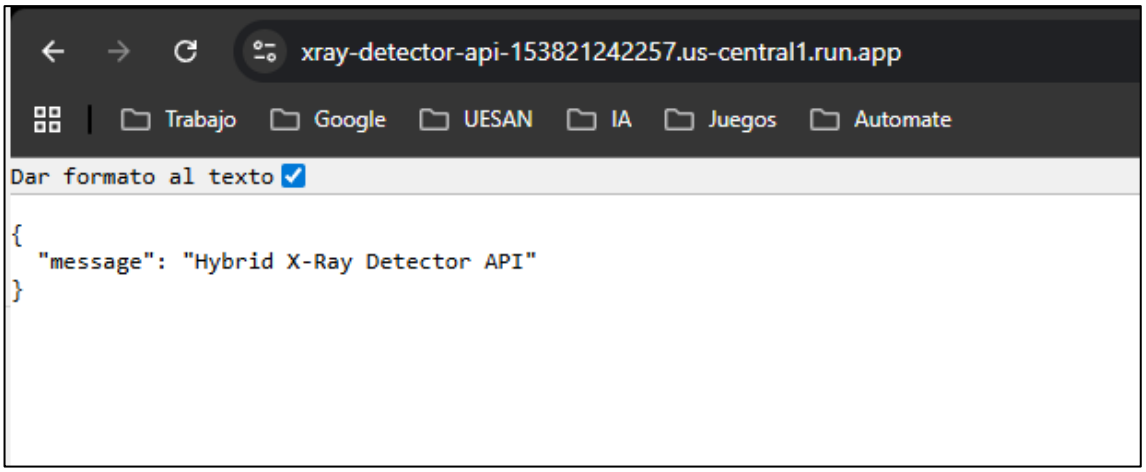


Figura 36. Respuesta exitosa de la API en el navegador.

Fuente: Elaboración propia

Actividad 4. Resultados de la Implementación

La ejecución técnica de esta arquitectura logró transformar los modelos de inteligencia artificial entrenados en un entorno local aislado en un servicio de inferencia centralizado y accesible vía Internet. El uso orquestado de Docker, Cloud Storage, Artifact Registry y Cloud Run permitió construir una infraestructura robusta y escalable que desacopla el alto costo computacional del Machine Learning respecto de la capa de presentación. Como resultado directo, el backend quedó completamente optimizado y listo para ser consumido en tiempo real por la aplicación Desktop, habilitando el procesamiento ininterrumpido de imágenes y flujos de video en el demandante escenario de la seguridad aeroportuaria. La visualización final de esta integración operativa, tanto en su estado inicial como durante el despliegue de una alerta predictiva, se presenta en las Figuras 37 y 38.

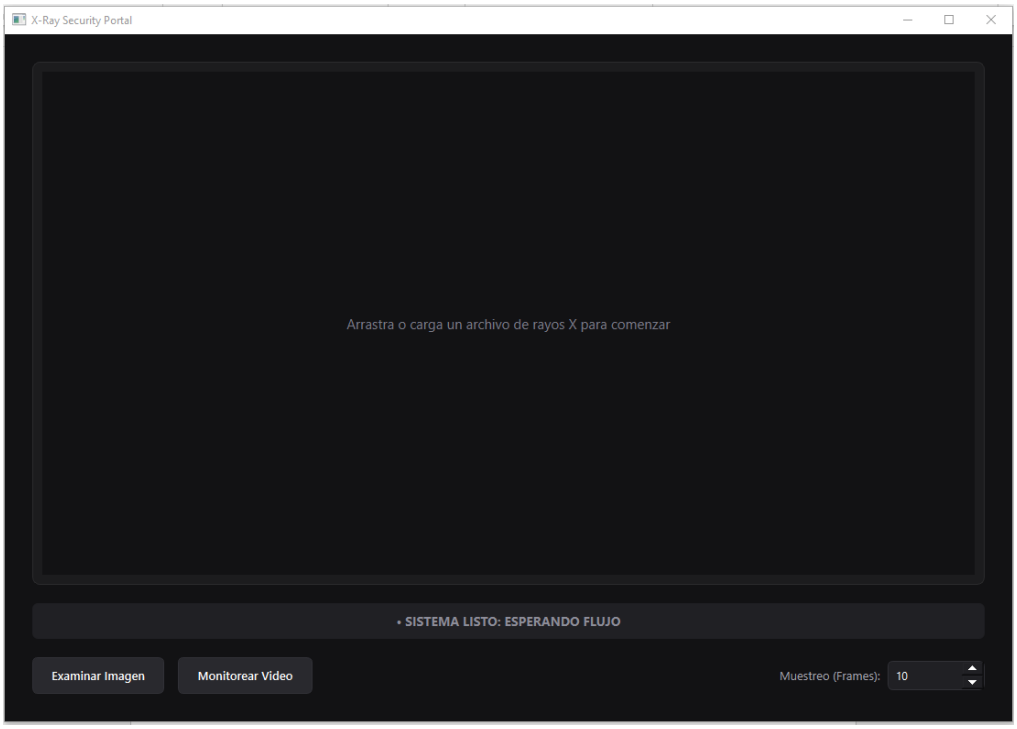


Figura 37. Interfaz inicial de la Aplicación X-Ray Security Portal.

Fuente: Elaboración propia



Figura 38. Visualización de resultados y alerta de detección en tiempo real.

Fuente: Elaboración propia

Capítulo V: Resultados y Análisis

En el presente capítulo se detallan los resultados experimentales obtenidos tras la implementación del marco metodológico híbrido. El proceso de selección del modelo óptimo se realizó de manera exclusiva sobre el conjunto de validación, estableciendo la métrica F1-macro como criterio principal de evaluación, respaldada por la Exactitud (Accuracy) y el Área Bajo la Curva (AUC) como indicadores secundarios. El conjunto de prueba (test set) se reservó estrictamente para la evaluación final imparcial de la configuración con mejor rendimiento.

Para determinar la arquitectura más eficiente, se evaluaron las 18 combinaciones posibles entre los 3 backbones finalistas de la Fase 3 (EfficientNetV2-S, ConvNeXt-Tiny y Swin Transformer-Tiny) y los 6 clasificadores de Machine Learning evaluados (Regresión Logística, Linear SVM, L2 LinearSVM, RBF SVM, LightGBM y CatBoost). Como se observa en la Tabla 15, la configuración híbrida conformada por EfficientNetV2-S (fine-tuned) acoplada a una Regresión Logística Multinomial (tuned) alcanzó el rendimiento superior entre todas las combinaciones evaluadas, registrando un Accuracy de 0.9502 y un F1-macro de 0.9496 en el conjunto de prueba. Los resultados reportados a continuación se evaluaron sobre el conjunto de prueba, compuesto por 1 807 imágenes (10.03 % del dataset total), el cual permaneció aislado del proceso de entrenamiento y ajuste de hiperparámetros para garantizar una medición imparcial del desempeño.

Tabla 15.
Resultados comparativos de las arquitecturas híbridas evaluadas en el conjunto de prueba

Backbone_FT	ML_Model	Accuracy	F1_macro
effnetv2_rw_s	**LogReg**	**0.9502**	**0.9496**
effnetv2_rw_s	RBF_SVM	0.9491	0.9484
effnetv2_rw_s	LinearSVM	0.9463	0.9454
effnetv2_rw_s	L2_LinearSVM	0.9402	0.9394
effnetv2_rw_s	CatBoost	0.9286	0.9273
effnetv2_rw_s	LightGBM	0.9259	0.9248
convnext_tiny	RBF_SVM	0.9126	0.9113

swin_tiny	RBF_SVM	0.9081	0.9065
convnext_tiny	L2_LinearSVM	0.9059	0.9041
convnext_tiny	LogReg	0.9032	0.9018
swin_tiny	L2_LinearSVM	0.9007	0.8989
convnext_tiny	LinearSVM	0.8996	0.8982
swin_tiny	LogReg	0.8965	0.8946
swin_tiny	LinearSVM	0.8910	0.8892
convnext_tiny	CatBoost	0.8871	0.8850
convnext_tiny	LightGBM	0.8838	0.8815
swin_tiny	CatBoost	0.8796	0.8771
swin_tiny	LightGBM	0.8752	0.8728

Fuente: Elaboración propia

Los resultados evidencian una superioridad consistente de la arquitectura EfficientNetV2-S frente a ConvNeXt-Tiny y Swin Transformer-Tiny en esta tarea específica de extracción visual: incluso su peor combinación (LightGBM, Accuracy 0.9259) supera a la mejor combinación obtenida con cualquiera de los otros dos backbones (ConvNeXt-Tiny + RBF SVM, Accuracy 0.9126), una brecha de 3.76% que confirma que el rendimiento superior se debe principalmente a la calidad de los embeddings extraídos, y no a la elección del clasificador final. Asimismo, se observa que el clasificador RBF SVM se posiciona consistentemente como la segunda mejor opción para los tres backbones, mientras que los algoritmos de Gradient Boosting (CatBoost y LightGBM) obtuvieron sistemáticamente los resultados más bajos en los tres casos, lo que sugiere que estos modelos basados en árboles de decisión no logran explotar tan eficientemente la estructura continua del espacio de embeddings como sí lo hacen los clasificadores lineales y de margen máximo.

Para evaluar el rendimiento detallado por categoría de la configuración óptima, se analizó la matriz de confusión correspondiente a las predicciones sobre el conjunto de prueba (Figura 39).

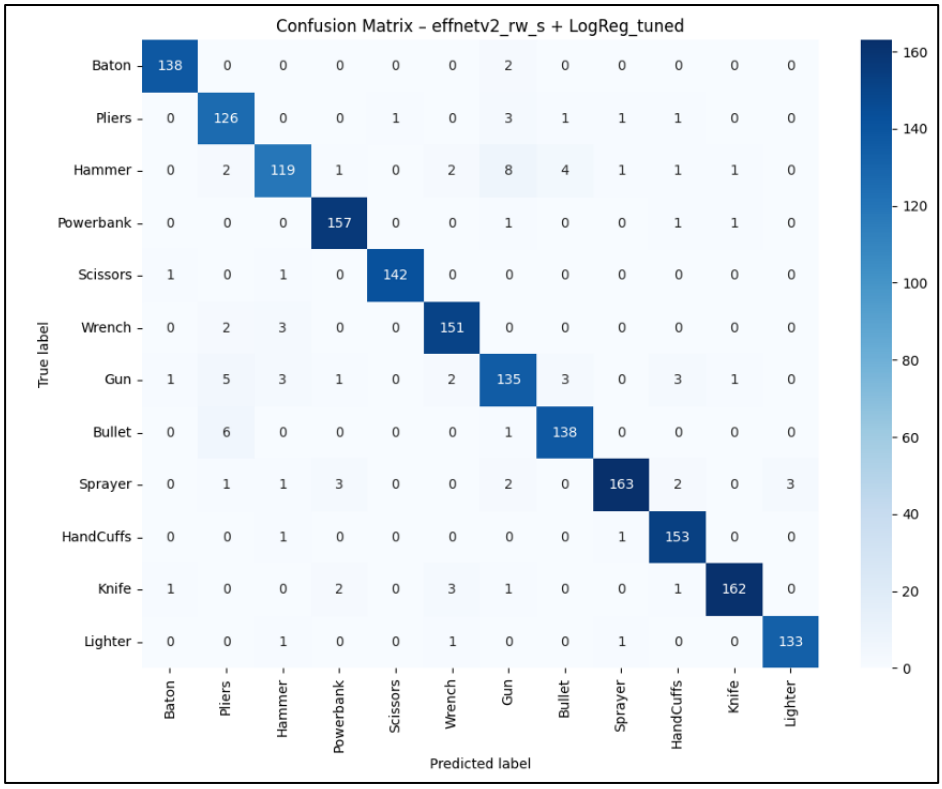


Figura 39. Matriz de Confusión del modelo híbrido con mejor rendimiento.

Fuente: Elaboración propia

La matriz se muestra dominante en la diagonal principal, lo que indica un alto nivel de sensibilidad (recall) por clase y una contaminación cruzada limitada. La mayor confusión individual registrada en todo el sistema ocurre entre Hammer y Gun, con 8 instancias clasificadas erróneamente, seguida de Bullet confundido con Pliers (6 casos) y Gun confundido con Pliers (5 casos). Estas confusiones se concentran casi en su totalidad entre objetos metálicos de geometría compacta (martillos, armas de fuego, alicates, llaves y municiones), cuya similitud en densidad y número atómico genera una apariencia radiográfica visualmente parecida. En contraste, categorías con geometrías más distintivas, como Powerbank, HandCuffs y Knife, presentan una separabilidad casi perfecta, con menos de 4 errores de clasificación en total. Es importante destacar que ninguna clase demuestra un colapso sistemático hacia otra categoría específica, lo cual confirma que el espacio de características (embedding space) aprendido

preserva una excelente separabilidad interclase y respalda la robustez de la etapa de clasificación.

Para complementar el análisis y medir la capacidad del modelo de distinguir con probabilidades entre las diferentes clases de amenazas, se evaluó la Curva de Características Operativas del Receptor (ROC) y su respectiva Área Bajo la Curva (AUC).

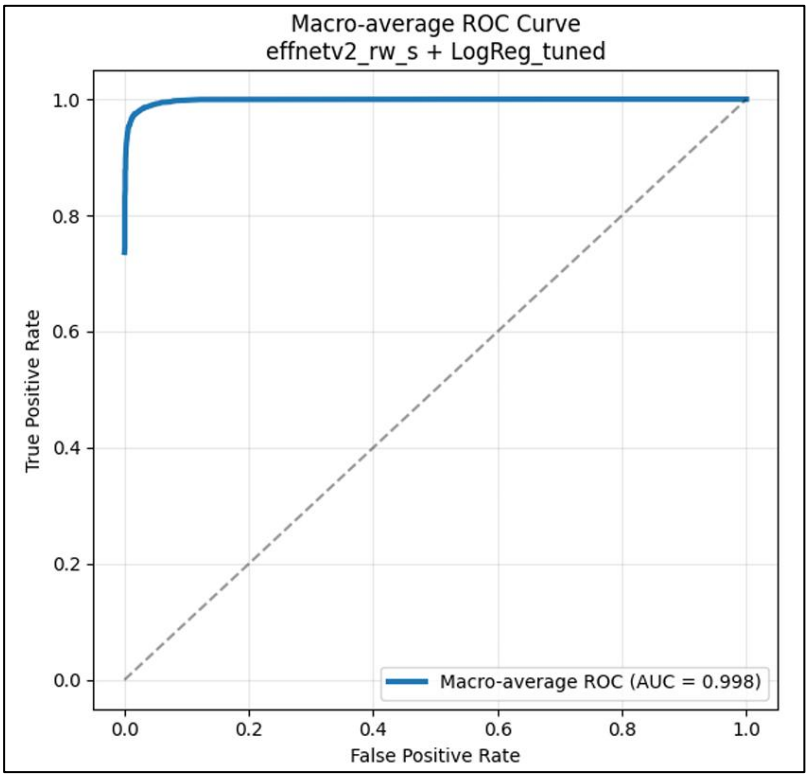


Figura 40. AUC ROC del mejor modelo.

Fuente: Elaboración propia

Como se muestra en la Figura 40, la curva se aproxima rápidamente a la esquina superior izquierda del espacio, alcanzando un valor de AUC-macro = 0.998. Esta separabilidad casi perfecta indica que el clasificador mantiene una alta sensibilidad incluso cuando se imponen tasas muy bajas de falsos positivos. La coherencia entre el alto valor del AUC-macro y el F1-macro obtenido confirma que la separabilidad probabilística lograda por el modelo se traduce efectivamente en predicciones discretas precisas.

En conjunto, estos resultados confirman que la arquitectura híbrida propuesta funciona correctamente. Por un lado, el backbone ajustado logra extraer características útiles y representativas a partir de las imágenes originales. Por otro lado, el clasificador logra separar de manera estable las distintas clases de objetos a partir de esas características. Este enfoque también le da flexibilidad al sistema, ya que permite obtener un buen rendimiento sin perder la capacidad de adaptarse a escenarios reales de despliegue como lo es el sector Aeroportuario, donde se necesita tanto rapidez de procesamiento como la posibilidad de incorporar nuevas amenazas en el futuro.

Capítulo VI: Conclusiones y Recomendaciones

6.1 Conclusiones

El incremento sostenido del tráfico aéreo y la creciente complejidad de los procesos de inspección de equipajes han convertido la detección de objetos prohibidos en un desafío crítico para la seguridad aeroportuaria. En este contexto, la presente investigación se enfocó en desarrollar una solución basada en Inteligencia Artificial capaz de complementar el trabajo de los operadores de seguridad, reduciendo las limitaciones asociadas a la fatiga visual y a la interpretación manual de imágenes de rayos X. Los resultados obtenidos demuestran que la integración de técnicas de Deep Learning y Machine Learning constituye una alternativa viable para mejorar la precisión y confiabilidad de los sistemas de inspección, aportando evidencia empírica sobre el potencial de las arquitecturas híbridas en entornos de seguridad aeroportuaria.

El objetivo general de la investigación consistió en desarrollar un modelo híbrido basado en Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de seguridad aeroportuaria. Para cumplir este objetivo se diseñó una arquitectura de dos etapas compuesta por un detector de objetos, un extractor de características y un clasificador supervisado. Como resultado, el modelo alcanzó un F1-macro de 0.9496 y un AUC-macro de 0.998 en el conjunto de prueba, demostrando una elevada capacidad para identificar y diferenciar objetos prohibidos en escenarios complejos de inspección. Estos resultados validan la efectividad del enfoque híbrido propuesto y evidencian su potencial aplicación como herramienta de apoyo en los controles de seguridad aeroportuaria.

El primer objetivo específico consistió en obtener un dataset público de imágenes de rayos X que reuniera las características necesarias para el entrenamiento de modelos de detección de objetos prohibidos. Para cumplir este objetivo se seleccionó un conjunto de datos derivado de los repositorios SIXray y PIDray, conformado por 13,728 imágenes balanceadas distribuidas en 12 categorías de objetos prohibidos. Como resultado, se dispuso de una base de

datos adecuada para el entrenamiento, validación y evaluación del sistema propuesto, reduciendo el impacto del desbalance de clases reportado en investigaciones previas.

El segundo objetivo específico consistió en implementar técnicas de procesamiento de imágenes que permitieran mejorar la calidad de las imágenes de rayos X. Para ello se aplicaron procedimientos de recorte de regiones de interés, redimensionamiento con conservación de proporciones mediante relleno de bordes y mejora de contraste utilizando CLAHE. Como resultado, se logró resaltar las características visuales relevantes de los objetos prohibidos, disminuyendo la influencia del ruido visual generado por el resto del equipaje y facilitando el aprendizaje de los modelos posteriores.

El tercer objetivo específico consistió en implementar una arquitectura híbrida basada en algoritmos de Deep Learning y Machine Learning para lograr una detección eficiente y robusta de objetos prohibidos. Para cumplir este objetivo se evaluaron diversas combinaciones de extractores de características y clasificadores supervisados. Como resultado, la arquitectura conformada por YOLOv8, EfficientNetV2-S y Regresión Logística obtuvo el mejor desempeño, alcanzando una exactitud de 95.02% y un F1-macro de 94.96%, superando a las demás configuraciones evaluadas. Estos resultados demuestran que la extracción profunda de características combinada con clasificadores tradicionales constituye una estrategia eficaz para la clasificación de amenazas en imágenes de rayos X.

El cuarto objetivo específico consistió en implementar métricas de evaluación adecuadas para validar el desempeño del modelo. Para cumplir este objetivo se utilizaron Accuracy, F1-macro y AUC-macro como indicadores de rendimiento. Como resultado, se comprobó que el modelo mantiene un comportamiento consistente entre las diferentes categorías evaluadas, alcanzando un AUC-macro de 0.998, lo que evidencia una elevada

capacidad de discriminación entre clases y una evaluación equilibrada del desempeño del sistema.

Los resultados obtenidos confirman los hallazgos reportados en la literatura especializada respecto a que la oclusión y la superposición de objetos representan los principales desafíos en la inspección de equipajes mediante rayos X. Aunque los errores residuales se concentraron principalmente entre objetos metálicos con características visuales similares, el elevado desempeño alcanzado demuestra que la arquitectura propuesta es capaz de diferenciar correctamente la gran mayoría de amenazas presentes en escenarios reales, constituyéndose como una alternativa tecnológica prometedora para fortalecer los procesos de seguridad aeroportuaria.

6.2 Recomendaciones

Se recomienda ampliar el dataset utilizado con imágenes reales tomadas directamente en los puntos de control del Aeropuerto Internacional Jorge Chávez, en coordinación con las autoridades aeroportuarias correspondientes, ya que esto permitiría probar el modelo bajo las condiciones reales de iluminación, ángulo y calidad de imagen del entorno donde finalmente operaría.

Se recomienda medir el tiempo real que tarda el sistema completo en dar una respuesta, desde que recibe la imagen hasta que entrega la predicción final, ya que este dato es clave para confirmar si el sistema puede operar en tiempo real dentro de un aeropuerto con un volumen alto de pasajeros, como el que se proyecta tras la modernización del nuevo Jorge Chávez señalada en el Capítulo I.

Se recomienda incluir más categorías de objetos prohibidos en futuras versiones del modelo, ya que el dataset actual solo cubre 12 clases y existen otros artículos regulados por la

normativa de la OACI y el listado de la DGAC, como líquidos o sustancias químicas, que no fueron considerados en este estudio.

Dado que la principal fuente de error del modelo fue la confusión entre objetos metálicos de apariencia similar, se recomienda para futuras investigaciones explorar el uso de módulos de atención adicionales o de información complementaria, como el color del material en la imagen de rayos X, que podría ayudar a diferenciar mejor estos casos límite.

Se recomienda también poner a prueba el modelo con imágenes que presenten niveles más altos de oclusión, similares a los datasets especializados como OPIXray con el fin de medir qué tan bien se sostiene el rendimiento del sistema en escenarios más exigentes que los del conjunto de prueba actual.

Por último, se recomienda realizar una prueba piloto del sistema desplegado en un entorno controlado junto a operadores de seguridad reales, con el fin de evaluar la facilidad de uso de la aplicación de escritorio y recoger su retroalimentación antes de considerar un despliegue a mayor escala en los puntos de control del país.

REFERENCIAS BIBLIOGRÁFICAS

Asociación Internacional de Transporte Aéreo (IATA). (2025). *Global air passenger demand reaches record high in 2024*. IATA. https://www.iata.org/en/pressroom/2025-releases/2025-01-30-01/

Asociación Internacional de Transporte Aéreo (IATA). (2026). *Air Passenger Market Analysis – April 2026*. IATA. https://www.iata.org/en/iata-repository/publications/economic-reports/air-passenger-market-analysis-april-2026/

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. https://www.microsoft.com/en-us/research/uploads/prod/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf

Bolager, E. L., Burak, I., Datar, C., Sun, Q., y Dietrich, F. (2023). Sampling weights of deep neural networks. *arXiv*. https://arxiv.org/pdf/2306.16830

Chen, J., Hao, J., y Liu, X. (2025). *An X-Ray Contraband Detection Method Based on Improved YOLOv8*. ResearchGate. An X-Ray Contraband Detection Method Based on Improved YOLOv8

Comisión Económica para América Latina y el Caribe (CEPAL). (2025). *Índice Latinoamericano de Inteligencia Artificial (ILIA) 2025*. ILIA Latam. https://indicelatam.cl/

Cortes, C., y Vapnik, V. (1995). *Support-vector networks*. Machine Learning. https://link.springer.com/article/10.1007/BF00994018

Dai, Z., Liu, H., Le, Q. V., y Tan, M. (2021). *CoAtNet: Marrying Convolution and Attention for All Data Sizes*. arXiv. https://arxiv.org/pdf/2106.04803

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., y Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*. https://doi.org/10.1109/CVPR.2009.5206848

Dirección General de Aeronáutica Civil (DGAC, 2022). *Listado de artículos prohibidos para ser transportados por pasajeros en la cabina de la aeronave o en el equipaje de mano*. Ministerio de Transportes y Comunicaciones. https://www.dgac.gob.cl/los-objetos-prohibidos-mas-comunes-en-equipaje-de-mano-2/

Giordano, P., & Michalczewsky, K. (2026). *Estimaciones de las tendencias comerciales: América Latina y el Caribe*. Edición 2026. Banco Interamericano de Desarrollo. https://doi.org/10.18235/0013901

Gonzalez, R. C., y Woods, R. E. (2018). *Digital Image Processing* (4.ª ed.). Pearson Education.

Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep Learning*. MIT Press. https://aikosh.indiaai.gov.in/static/Deep+Learning+Ian+Goodfellow.pdf

Haq, A., Suciati, N., y Bui, N. D. (2025). *ESI-YOLO: Enhancing YOLOv8 with Efficient Multi-Scale Attention and Wise-IoU for X-Ray Security Inspection*. Expert Systems with Applications. https://www.researchgate.net/publication/396821704_ESI-YOLO_Enhancing_YOLOv8_with_Efficient_Multi-Scale_Attention_and_Wise-IoU_for_X-Ray_Security_Inspection

Hernández-Sampieri, R., y Mendoza, C. P. (2018). *Metodología de la investigación: las rutas cuantitativa, cualitativa y mixta*. UPN. https://bellasartes.upn.edu.co/wp-content/uploads/2024/11/METODOLOGIA-DE-LA-INVESTIGACION-Sampieri-Mendoza-2018.pdf

IBM (2021). *What is Machine Learning?* IBM Cloud Education. https://www.ibm.com/think/topics/machine-learning

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... y Liu, T. Y. (2017). *LightGBM: A highly efficient gradient boosting decision tree*. NeurIPS. https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence, 2*, 1137-1143.

Krizhevsky, A., Sutskever, I., y Hinton, G. E. (2012). *ImageNet classification with deep convolutional neural networks*. Communications of the ACM. https://dl.acm.org/doi/10.1145/3065386

Lima Airport Partners. (15 de enero de 2026). *El aeropuerto de Lima movilizó 25,5 millones de pasajeros en 2025*. Aviacionline. https://www.aviacionline.com/espanol/infraestructura/aeropuertos-de-latinoamerica-y-

el-caribe/aeropuertos-de-peru/el-aeropuerto-de-lima-movilizo-25-5-millones-de-pasajeros-en-2025_a69699f280e48856db2540ee3

LeCun, Y., Bengio, Y., y Hinton, G. (2015). *Deep learning*. Nature. https://www.nature.com/articles/nature14539

LeCun, Y., Bottou, L., Bengio, Y., y Haffner, P. (1998). *Gradient-based learning applied to document recognition*. Proceedings of the IEEE. http://yann.lecun.com/exdb/publis/pdf/lecun-01a.pdf

Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., ... y Guo, B. (2021). *Swin Transformer: Hierarchical vision transformer using shifted windows*. ICCV. https://arxiv.org/pdf/2103.14030

Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., y Xie, S. (2022). *A ConvNet for the 2020s*. CVPR. https://arxiv.org/pdf/2201.03545

McInnes, L., Healy, J., y Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv preprint*. https://arxiv.org/abs/1802.03426

Mehta, S., y Rastegari, M. (2022). *MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer*. ICLR. https://arxiv.org/abs/2110.02178

Meuter, R. F., y Lacherez, P. F. (2016). When and why threats go undetected: Impacts of event rate and shift length on threat detection accuracy during airport baggage screening. *Human Factors*. https://doi.org/10.1177/0018720815616306

Miao, C., Xie, L., Wan, F., Su, C., Liu, H., Jiao, J., y Ye, Q. (2019). *SIXray: A Large-scale Security Inspection X-ray Benchmark for Prohibited Item Discovery*. CVPR. https://arxiv.org/abs/1901.00303

Ministerio de Transportes y Comunicaciones (MTC, 2025). *Plan Estratégico de Infraestructura Aeroportuaria 2025-2030*. Gob.pe. MTC: Nuevo aeropuerto Jorge Chávez contará con moderno sistema de seguridad para control de equipajes - Noticias - Ministerio de Transportes y Comunicaciones - Plataforma del Estado Peruano

Minsky, M., y Papert, S. (1969). *Perceptrons: An Introduction to Computational Geometry*. MIT Press. https://rodsmith.nz/wp-content/uploads/Minsky-and-Papert-Perceptrons.pdf

MIT Sloan School of Management (2021). *Machine Learning Explained*. MIT Sloan Ideas Made to Matter. https://mitsloan.mit.edu/ideas-made-to-matter/machine-learning-explained

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill. https://www.cs.cmu.edu/~tom/files/MachineLearningTomMitchell.pdf

National Electrical Manufacturers Association. (2024). *DICOM PS3.1: Introduction and overview* (2024e ed.). https://dicom.nema.org/medical/dicom/current/output/html/part01.html

Organización de Aviación Civil Internacional. (2021). *Anexo 17: Seguridad – Protección de la aviación civil internacional*. https://www.bazl.admin.ch/dam/en/sd-web/TCrMIRQLbTlK/icao_annex_17_security.pdf

Organización Mundial de la Salud. (2023). Salud ocupacional: Riesgos físicos y cognitivos en el uso de pantallas de visualización de datos. https://www.who.int/es/news-room/fact-sheets/detail/occupational-health-digital-environments e

Pan, S. J., y Yang, Q. (2009). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering, 22*(10), 1345-1359. https://www.cse.ust.hk/~qyang/Docs/2009/tkde_transfer_learning.pdf

Park, J., An, G., Lee, B.-N., y Seo, H. (2025). Real-Time CNN-Based Object Detection of Prohibited Items for X-Ray Security Screening. *Radiation Physics and Chemistry*. https://doi.org/10.1016/j.radphyschem.2025.112681

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., y Gulin, A. (2018). *Catboost: unbiased boosting with categorical features*. NeurIPS. https://arxiv.org/pdf/1706.09516

Ramírez, S. (2018). *FastAPI* [Software]. https://fastapi.tiangolo.com/

Redmon, J., Divvala, S., Girshick, R., y Farhadi, A. (2016). *You Only Look Once: Unified, Real-Time Object Detection*. CVPR. https://arxiv.org/pdf/1506.02640

Rosenblatt, F. (1957). *The Perceptron: A Perceiving and Recognizing Automaton*. Cornell Aeronautical Laboratory. https://bpb-us-e2.wpmucdn.com/websites.umass.edu/dist/a/27637/files/2016/03/rosenblatt-1957.pdf

Rumelhart, D. E., Hinton, G. E., y Williams, R. J. (1986). *Learning representations by back-propagating errors*. Nature. https://www.nature.com/articles/323533a0

Russell, S. J., y Norvig, P. (2020). *Artificial Intelligence: A Modern Approach*. Pearson. https://aima.cs.berkeley.edu/newchap00.pdf

Samuel, A. L. (1959). *Some studies in machine learning using the game of checkers*. IBM Journal of Research and Development. https://ieeexplore.ieee.org/document/5392560

Sommerville, I. (2016). *Software Engineering* (10.ª ed.). Pearson Education.

Talbi, H., Ben-Hafsa, I. B., Alshorman, A., y El-Sappagh, S. (2025). *An Overview on Computer Vision Analysis in the Airport Environment: Challenges, Trends, and Future Directions*. ResearchGate. (PDF) An Overview on Computer Vision Analysis in the Airport Applications

Tan, M., y Le, Q. V. (2021). *EfficientNetV2: Smaller models and faster training*. ICML. EfficientNetV2: Smaller Models and Faster Training

Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., y Jégou, H. (2021). *Training data-efficient image transformers & distillation through attention*. ICML. https://arxiv.org/pdf/2012.12877

Tu, Z., Talebi, H., Zhang, H., Pang, F., Vasu, V., y Milanfar, P. (2022). *MaxViT: Multi-axis Vision Transformer*. ECCV. https://arxiv.org/pdf/2204.01697

Turing, A. M. (1950). *Computing machinery and intelligence*. Mind. https://courses.cs.umbc.edu/471/papers/turing.pdf

Wei, Y., Tao, R., Wu, Z., Ma, Y., Zhang, L., y Liu, X. (2020). *Occluded Prohibited Items Detection: An X-ray Security Inspection Benchmark and De-occlusion Attention Module*. ICCV. https://arxiv.org/pdf/2004.08656

Zhang, S., Zhu, D., Yung, K. L., y Ip, A. W. H. (2025). *Balanced X-ray Security Dataset and Enhanced YOLO for Contraband Detection*. Scientific Data. https://www.nature.com/articles/s41597-025-06322-9.pdf

ANEXOS

Anexo 1: Matriz de Consistencia

Modelo híbrido basado en Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X			
PROBLEMA GENERAL	**OBJETIVO GENERAL**	**HIPÓSTESIS GENERAL**	**VARIABLES**
¿De qué manera el desarrollo de un modelo híbrido basado en Deep Learning y Machine Learning mejora la precisión en la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria?	Desarrollar un modelo híbrido basado en Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de seguridad aeroportuaria.	El desarrollo de un modelo híbrido basado en algoritmos de Deep Learning y Machine Learning mejora significativamente la precisión en la detección de objetos prohibidos en imágenes de rayos X en comparación a métodos convencionales en el contexto de la seguridad aeroportuaria.	**Variable Independiente:** **Deep Learning** Se emplea como una rama avanzada que utiliza redes neuronales profundas para modelar presentaciones jerárquicas y extraer características de alto nivel directamente de las imágenes (IBM, 2021).

			Machine Learning Permite a los algoritmos identificar patrones complejos y mejorar su rendimiento de forma autónoma a partir de los datos expuestos (MIT Sloan, 2021).
PROBLEMAS ESPECÍFICOS	**OBJETIVOS ESPECÍFICOS**	**HIPÓTESIS ESPECÍFICAS**	
¿Cuáles son las características que deben cumplir los datasets públicos de imágenes de rayos X para el entrenamiento de modelos de detección de objetos prohibidos en el contexto de la seguridad aeroportuaria?	Obtener un dataset público de imágenes de rayos X que reúna las características necesarias para el entrenamiento de modelos de detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.	La selección de un dataset público de imágenes de rayos X que contenga objetos prohibidos y cumpla con criterios de calidad, diversidad y etiquetado adecuado favorece el entrenamiento efectivo de modelos de detección de objetos prohibidos	**Variable Dependiente:** **Objetos prohibidos en el contexto de seguridad aeroportuaria** Capacidad del sistema para identificar y categorizar

		en el contexto de la seguridad aeroportuaria.	elementos que representan una amenaza mediante el análisis de su densidad material y su número atómico (*Z*), los cuales determinan su apariencia visual en el monitor de inspección (Miao et al., 2019).
¿Qué técnicas de procesamiento de imágenes son más efectivas para mejorar la calidad de las imágenes de rayos X destinadas a la detección de objetos prohibidos en el contexto de la seguridad aeroportuaria?	Implementar técnicas de procesamiento de imágenes que permitan mejorar la calidad de las imágenes de rayos X para la detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.	La aplicación de técnicas de procesamiento de imágenes mejora significativamente la calidad visual y la nitidez de las imágenes de rayos X, favoreciendo la detección de objetos prohibidos en el contexto de la seguridad aeroportuaria.	
¿Qué algoritmos de Deep Learning y Machine Learning, integrados en una arquitectura híbrida, ofrecen mayor eficiencia y robustez para la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria?	Implementar una arquitectura híbrida basada en algoritmos de Deep Learning y Machine Learning para lograr una detección eficiente y robusta de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria.	La implementación de una arquitectura híbrida basada en algoritmos de Deep Learning y Machine Learning permite alcanzar una detección precisa, eficiente y robusta de objetos prohibidos en imágenes de rayos X dentro del	

		contexto de la seguridad aeroportuaria.
¿Qué métricas de evaluación son las más adecuadas para validar el desempeño de los modelos de detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria?	Implementar métricas de evaluación adecuadas para validar el desempeño de los modelos de detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria.	La utilización de métricas de evaluación adecuadas permite medir con precisión el desempeño de los modelos híbridos basados en algoritmos de Deep Learning y Machine Learning para la detección de objetos prohibidos en imágenes de rayos X en el contexto de la seguridad aeroportuaria.